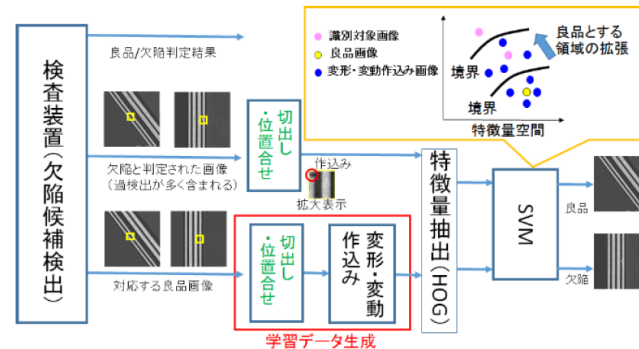


2020年10月15日

HOG特徴量を電子部品検査に適用した場合の課題検討

検査対象：電子部品等に使われるプリント基板

検出方法：検査装置による不良品の過検出を、対応する良品画像と比較することで減らし、最終的にOCSVMで欠陥を識別。SVMが判別する特徴量には、HOG特徴量を用いる。



検査対象とする画像の切り出し位置の決定および比較する画像缶での位置合わせを、HOG特徴量の類似度二より行う。

- 画像の類似度算出には、以下のアルゴリズムを用いる。
 - HI (Histogram Intersection)
 - KLD (Kullback Leibler Divergence)

Kernel-SVMを用いたワイヤロープ健全性への 連続ウェーブレット変換による特徴量の算出

検査対象：ワイヤロープ

磁気センサを用いた漏洩磁束探傷法では、ワイヤロープの主な損傷要因である素線破断の外部素線破断と内部素線破断を区別することが難しい。

そのため、磁気センサと光学式センサを組み合わせた複合センシングによる外部と内部の素線破断の損傷判別を行う。

センサデータから、連続ウェーブレット変換(CWT: Continuius Wavlet Transform) と 主成分分析(PCA: Principal Component Analysis) を行うことで、特徴量を抽出し、カーネルサポートベクタマシン(K-SVM: Kernel Suppoet Vector Machine) によって分類することで、ワイヤロープの異常を検知。

- CWTの特徴：距離 (時間) 成分を残しつつ周波数成分の解析を行うことができる。
- PCAの特徴：次元削減

2020年10月15日

One Class SVMによる道路振動データを用いた路面のひび割れ検知

検査対象：道路の路面

従来法

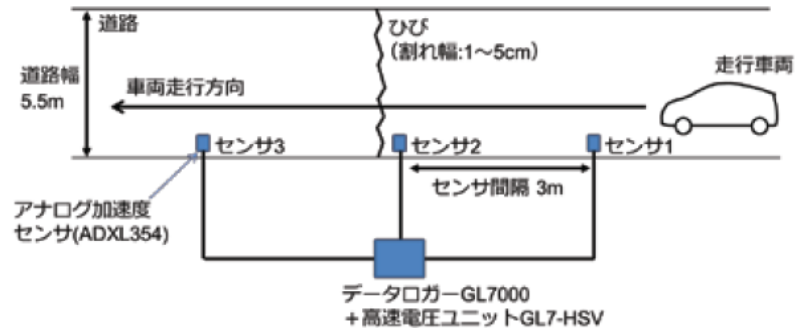
- FWD (Falling Weight Deflectometer)
 - 路面に対して錘を落とし、その時に発生したたわみ量から道路の健全性を評価する方法。
 - 計測に時間がかかることが課題。
- RWD (Rolling Weight Deflectometer)
- MWD (Moving Weight Deflectometer)
 - 測定車の台数に限りがある。

目標

道路に振動センサを設置し、車両が走行したときの振動を用いることで、道路の異常を検知することを目指す。

2020年10月15日

以下に、実験で使用された道路振動測定系を示す。



データ

測定開始時点からある時点まで（例えば、数か月）は、道路に異常が発生しないものと仮定して、この時に得られた振動データを全て正常とみなす。

結果

実験結果を以下に示す。Outlier とは、道路の正常値において適用する OCSVM データに含まれる異常の割合の想定値のこと。

表 1 道路のひびの有無の正答率

Outlier(%)	1	0.1	0.01	0.001
正答率(%)	75.00	89.06	76.56	68.75

2020年10月15日

画像を用いた自動外観検査技術

製品外観の良否判定を、画像を用いた外観検査により自動化したいニーズがある。

外観検査

- 判定方法
 - 画像から製品外観の良否判定
 - 製品外観の欠陥検出
- 判定基準
 - 人が決める (ルールベース)
 - 機械学習により判定基準を獲得

2020年10月15日

外観検査アルゴリズムコンテスト

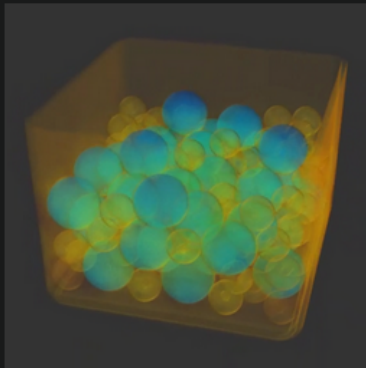
主催：精密工学会 画像応用技術専門委員会

共催：国立研究開発法人 理化学研究所 ボクセル情報処理システム研究チーム

WEBページ: [外観検査アルゴリズムコンテスト2020](#)

外観 アルコン

目指せ！実画像処理技術の日本一！



金属部品の中をみる！

詳細発表：2020年6月26日(金)
エントリー：2020年8月7日(金)
作品の提出〆切：2020年9月25日(金)

2020年10月15日

半教師あり学習

SURF特徴のOrientation と特徴点の x 座標と y 座標の3次元を特徴量として、OCSVM により分類。

良品学習

良品学習とは、検査画像の画素ごとに次式で求められる $Z - score$ と呼ばれる値を用いて良否判定や欠陥検出を行うものである。

$$Z - score(i, j) = \frac{v(i, j) - m(i, j)}{std(i, j)}$$

ここで、 i, j は画素位置であり、 v は輝度値、 m は学習用の良品画像から求めた輝度値の平均値、 std は輝度値の標準偏差を表す。

$Z - score$ は平均値からの差を標準偏差で割ったものなので、 $Z - score$ の絶対値が大きいほど良品から外れていることを意味する。

そのため、 $Z - score$ の絶対値の総和から良否判定を行う。または、閾値以上の $Z - score$ を持つ画素が密集した領域を欠陥領域と判定することにより外観検査や欠陥検出が可能。

機械学習の溶着不良品判別への適用

本研究では、打音検査に有用な機械学習法を開発することを目的とする。

予備実験

学習には、以下のモデルを用いた。

- 3種類の決定木
- 2種類の判別分析
- ロジスティクス回帰
- 6種類のSVM
- 6種類の KNN (k-nearest neighbor algorithm)
- 5種類のアンサンブル

表 1(a) A タイプ品を学習した場合

分類器	正解率		
	A タイプ品	判断不明瞭品	B タイプ品
決定木	99.3%	93.3%	18.6%
判別分析	99.9%	100.0%	81.3%
ロジスティック回帰	94.4%	70.0%	18.6%
SVM	99.9%	100.0%	81.3%
KNN	99.8%	100.0%	81.3%
アンサンブル	99.9%	100.0%	18.6%

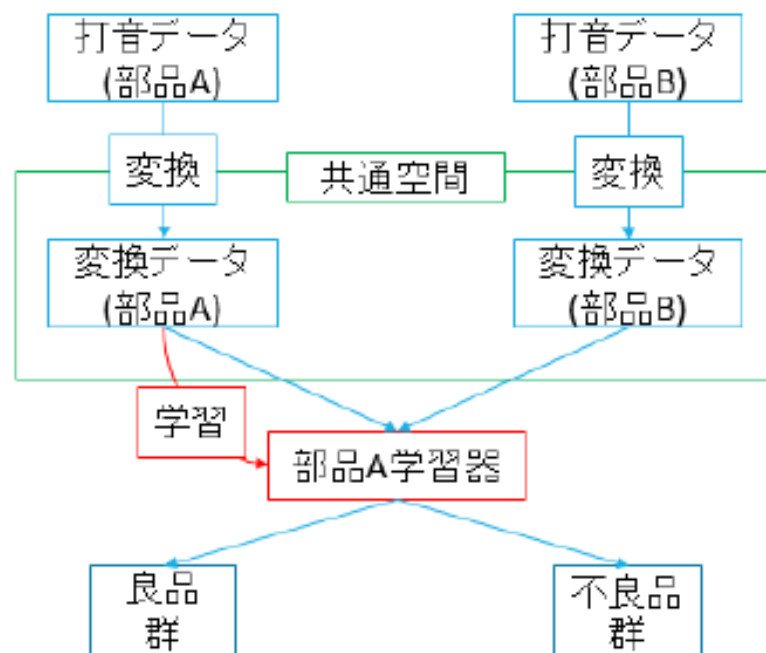
表 1(b) B タイプ品を学習した場合

分類器	正解率	
	B タイプ品	A タイプ品
決定木	93.0%	73.7%
判別分析	100.0%	22.9%
ロジスティック回帰	97.7%	28.9%
SVM	100.0%	22.9%
KNN	100.0%	22.9%
アンサンブル	100.0%	20.7%

学習データ

- Aタイプ品
 - 良品: 618 検体
 - 不良品: 184 検体
 - 判断不明瞭品: 30 検体
- Bタイプ品
 - 良品: 35 検体
 - 不良品: 8 検体

実験方法を左図に示す。



実験方法

1. 周波数特性のグラフの総面積が 1 になるようにゲインを調節
2. 良品データのみを対象に、打音データの各周波数についてゲインの大きさの平均をとり、ゲインが大きい物から順に周波数に番号を付ける。
3. 学習に用いる部品のみから主成分係数を求め、それを共通空間にある全部品の重み係数とする。

表 2 提案手法を用いた際の判別結果

分類器	正解率	
	B タイプ品	A タイプ品
決定木	97.7%	98.6%
判別分析	100.0%	98.8%
ロジスティック回帰	100.0%	98.8%
SVM	100.0%	99.1%
KNN	100.0%	84.3%
アンサンブル	100.0%	97.5%


実験結果

実験結果を右の表に示す。

製品検査における1クラス SVM のパラメータ調整手法

ガウスカーネルパラメータ σ

- σ が十分に大きい場合、サポートは単一クラスタとなる。
- σ が小さすぎる場合、複数クラスタに分割される可能性がある。



σ の選択基準

- 汎化誤差の最小化を意図した「SV 数最小化基準」
- 提案する基準はサポート形状に着目したものであり、学習サンプル中心へ至る線分が識別面と交差する MSV (CO-MSV: Crossover MSV) の数が 0 となる最小の σ を選択する。