

機械学習の溶着不良品判別への適用

東京大学 ○山下 遥介, 吉田 和憲, 木下 裕介, 梅田 靖

Application of machine learning to discrimination of brazing defects

The University of Tokyo, Yosuke Yamashita, Kazunori Yoshida, Yusuke Kishita, Yasushi Umeda

This research aims at constructing a system that can discriminate brazing defects by hit sounds of hammering test. It is desirable that this system is applicable to multiple kinds of parts. For this purpose, this paper proposes a machine learning based method. For making the method applicable to multiple kinds of parts, this paper proposes a common space of hit sounds among different parts. This paper also confirmed its effectiveness by using actual data.

1. 序論

品質検査を行うことは品質を保証するために不可欠である。部品の全数検査を行う場合、非破壊で検査を行う必要がある。非破壊検査の代表的なものに、渦電流探傷試験、超音波探傷試験、打音検査などが挙げられる[1]。渦電流探傷試験は表面付近の欠陥を検出することはできるが、深くにある欠陥を検知することは難しい。超音波探傷試験は装置が高価であり、検査に時間がかかる。打音検査はコストや時間がかからないといった利点があり、広く用いられている。しかし、人の耳で判別することが難しい場合があるといった問題点も抱えている。

本研究の目的は打音検査に有用な機械学習法を開発することである。このために、まず企業から提供された溶着部品の打音検査結果を対象に機械学習を用いた判別を行い、機械学習が打音検査に対して有用であるということを示す。

次に機械学習を用いた打音検査の問題点の解決を試みる。問題点として、部品ごとに学習を行わなければならない点や不良品の数が少ないため、用意することが難しい点が挙げられる。

本研究では、1 種類の部品に対して学習した学習器を用いて異なる複数の部品を判別するための手法の構築を試みる。

2. 予備実験

2.1. 分析対象

分析対象として、企業より提供された 2 部品を接合された部品のサイズ違い（Aタイプ、Bタイプ 2 種類）を用いる。これらの部品は、2 部品を接着剤の役割を果たす部材にて接合され、製作されている。接合の際に、接合材がうまく広がらず、接合不良が起きることがある。現場では、それぞれの柱を打撃し、作業者の耳で接合不良の有無を判断している。この打音データを計測することにより、0~40kHzの周波数領域のゲインデータが得られる。これを分析対象とする。

企業から提供された部品データはAタイプ品の良品 618 検体、不良品 184 検体、判断不明瞭品 30 検体、Bタイプ品の良品 35 検体、不良品 8 検体のデータであった。判断不明瞭品とは実際は不良品であるにもかかわらず人間が良品と判別してしまった部品のことである。

2.2. 学習方法

学習器として試みに MATLAB を使用した。学習に用いる分類器は MATLAB に実装されているすべてとした。3 種類の決定木、2 種類の判別分析、ロジスティック回帰、6 種類の SVM(support vector machine)、6 種類の KNN(k-nearest neighbor algorithm)、5 種類のアンサンブルを用いた[2]。

交差検定を行い、学習の効果を検定する。交差検定により、過学習の危険性を小さくできる。今回は一般的によく用いられている五分割交差検定を用いる[3]。データをランダムに五分割し、その 4 つを用いて学習し、残りの 1 つでテストする。テストデータを変えながらこれ

を 5 回行い、その正解した割合の平均値を「正解率」とする。

2.3. 学習結果

各部品の正解率を表 1 に表す。表 1(a)では、A タイプ品の良品と不良品を用いて学習を行い、表 1(b)では、B タイプ品の良品、不良品を用いて学習を行った。各分類器のうち学習に用いた部品を最も高い正解率で判別したアルゴリズムの正解率を表す。学習に用いていない部品（判断不明瞭品、および、B タイプ品）を判別する際にはそれらのアルゴリズムのみを用いた。学習に用いた部品は高い正解率で判別できた。判断不明瞭品は学習に用いていないが、正しく判別できた。ただし、部品の種類が異なる場合は正しく判別することができなかった。

表 1(a) A タイプ品を学習した場合

分類器	正解率		
	A タイプ品	判断不明瞭品	B タイプ品
決定木	99.3%	93.3%	18.6%
判別分析	99.9%	100.0%	81.3%
ロジスティック回帰	94.4%	70.0%	18.6%
SVM	99.9%	100.0%	81.3%
KNN	99.8%	100.0%	81.3%
アンサンブル	99.9%	100.0%	18.6%

表 1(b) B タイプ品を学習した場合

分類器	正解率	
	B タイプ品	A タイプ品
決定木	93.0%	73.7%
判別分析	100.0%	22.9%
ロジスティック回帰	97.7%	28.9%
SVM	100.0%	22.9%
KNN	100.0%	22.9%
アンサンブル	100.0%	20.7%

2.4 課題

部品ごとに学習を行う場合、部品の種類数が増えるほど、学習にかかる作業量が大きくなる。さらに、不良品は良品に比べて数が少ないため、学習のために用意することが難しい。これらの点が課題である。

3. 複数部品に適用可能な機械学習法の提案

3.1 アプローチ

部品の構造や打音データの取得方法が部品によって異なるため、ゲインの大きさや固有振動数などは部品ごとに傾向が異なる。そこで、本研究では学習を行う前にゲインの強さを揃える操作と周波数特性の違いを吸収する操作を行う。これらの操作により各部品に共通な打音の周波数特性を得ることができる。これを共通空間と呼ぶ。本

研究で行うアプローチを図1に表す。

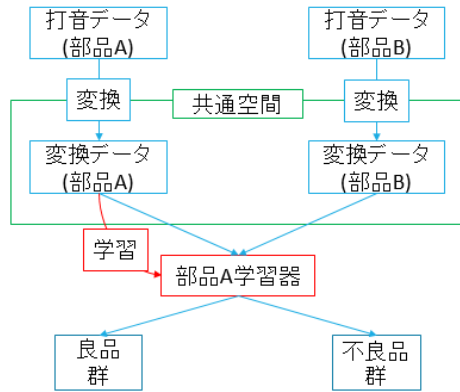


図1 本研究のアプローチ

3.2 本研究の手順

初めに学習と判別に用いるデータをすべて変換し、共通空間上に移す。その後、共通空間上の1種類の部品のデータを用いて学習を行う。学習には、2章の予備実験で正解率の高かったアルゴリズムと五分割交差検定を用いる。学習の後、共通空間上にある学習に用いていない部品の判別を行う。

3.3 共通空間への変換方法

まず、周波数ごとのゲインの大きさに関する部品間の違いを吸収するために、周波数特性のグラフの総面積が1になるようにゲインを調節する。

データを分析すると、部品ごとに良品の固有振動数は揃っており、不良品の固有振動数は良品のそれとは異なることを見つけた。そこで、良品の固有振動数近傍の特徴を抽出することを考え、部品ごとに以下の操作を行う。良品データのみを対象に、打音データの各周波数についてゲインの大きさの平均をとり、ゲインが大きいものから順に周波数に番号を付ける。その後、番号順になるように良品、不良品のデータを並べ替える。この操作により、異なる部品種類間の固有振動数の違いはなくなり、良品のゲインの大きい順に周波数特性データが並ぶことになる。この操作の例を図2に表す。上記の良品の固有振動数が揃っており、不良品の固有振動数は良品のそれとは違うという事実から、小さな番号の周波数では良品のゲインは大きく、不良品のゲインは小さいはずであり、判定に重要な情報になっているはずである。逆に、大きな番号の周波数の重要度は低い。従って、番号の小さなものにより重みをもたせることを考える。各部品を対象にした主成分分析[4]では、どの部品でも良品の固有振動数の係数が最も大きくなっていた。本研究では、学習に用いる部品のみから主成分係数を求め、それを共通空間にある全部品の重み係数とする。なお、主成分分析の説明分散は95%とする。

3.4 実行結果

Aタイプ品で学習を行った学習器によるBタイプ品の判別結果(表2の2列目)と、Bタイプ品で学習を行った学習器によるAタイプ品の判別結果(表2の3列目)を表す。変換により、学習に用いていない部品の高い正解率で判別できることが示された。

4. 考察

本研究のアプローチを用いることで、学習に用いていない部品の高い正解率で判別できることを示せた。ただし、学習させる部品によって正解率に差がある。これは、学習させる部品の数によるものであると考えられる。そこでAタイプ品を対象にBタイプ品の学習に用いたのと同じ数である良品35本、不良品8本を用いて線形判別で学習を行うと、学習に用いていないAタイプ品の正解率が99.3%、Bタイプ品の正解率が100%となった。今後、判別に用いるBタイプ品が

増えた場合に正解率がどう変化するか調べる必要がある。さらに、実用化するためには、学習に用いた部品と同程度の正解率が必要になると考えられる。




図2 並べ替えの例

表2 提案手法を用いた際の判別結果

分類器	正解率	
	Bタイプ品	Aタイプ品
決定木	97.7%	98.6%
判別分析	100.0%	98.8%
ロジスティック回帰	100.0%	98.8%
SVM	100.0%	99.1%
KNN	100.0%	84.3%
アンサンブル	100.0%	97.5%

5. 結論

打音検査において、一種類の部品から学習された学習器を用いて、特性の異なる別の種類の部品の判別する手法の構築を試みた。実行例として特性の異なる2つの部品を用いて手法の有用性を示した。

今後の課題としては、実用化に向けて正解率を高めることや、他の部品を用いて追加検証することなどが挙げられる。

参考文献

- [1] Adams R.D., et al., "A review of defect types and nondestructive testing techniques for composites and bonded joints", NDT International, Vol 21, No. 4, pp. 208-222, 1988.
- [2] MATLAB 公式 HP(最終閲覧日 2018 年 1 月 15 日)
<https://jp.mathworks.com/help/stats/choose-a-classifier.html#bunt0rb-1>
- [3] Refaeilzadeh P., Tang L., Liu H. (2009) Cross-Validation. In: LIU L., ÖZSU M.T. (eds) Encyclopedia of Database Systems. Springer, Boston, MA.
- [4] Hervé A., et al., "Principal component analysis", Wiley Interdisciplinary Reviews: Computational Statistics, Vol 2, No. 4, pp. 433-459, 2010.