

# 深層学習を用いたトンネル覆工面のひび割れ検出手法の開発

鵜飼 正人\*

Tunnel Lining Crack Detection Method by Means of Deep Learning

Masato UKAI

Existing image processing programs for detecting structural damage such as cracks have required the fine-tuning of numerous parameters and experience-based expertise. We have developed a method of distinguish cracks from others using tunnel lining images with a deep learning applied. A classifier was created after learning from a large volume of images in two groups - either “presence of a crack” or “absence of a crack”. It recognizes the presence or absence of the crack successfully at a rate of more than 90%. Using a color-coded pixelated image to show the position of probable cracks, we proposed a hybrid detection method for analyzing cracks with a focus on there locations and the directions in which they progress.

キーワード：トンネル、ひび割れ検出、機械学習、深層学習、画像処理


## 1. はじめに

鉄道構造物の保守点検業務では、「目視」による検査が基本となっているため、作業効率や検査精度などが課題となっている。これらの問題解決に向けて、目視検査の代替として画像処理技術への期待は大きく、保守点検業務での早期の実用が望まれている。

鉄道総研では、これまでに、画像の濃淡や輪郭を基にひび割れなどの変状を検出する手法<sup>1)</sup>（以下、従来手法）を提案したが、経験を基に、最適なアルゴリズムを試行錯誤的に見つけ出すというアプローチで開発したものであった。そこで、ひび割れの抽出に、近年注目されている深層学習の適用を検討し、これまでに開発した画像解析技術と組み合わせることによって、人間の判断に近い検出結果が得られる手法<sup>2)</sup>を開発した。本稿では、適用した深層学習の概要について述べたのち、検出結果の例を報告する。

## 2. 従来手法によるひび割れ検出

従来手法によるひび割れ検出では、多くの画像処理パラメータを調整しなければならない上、画像が変わるとこれらのパラメータを再調整する必要があり、大きな労力を要した。図1に示すように、トンネル覆工面を撮影した画像には、ひび割れと共にケーブル、目地、汚れなども一緒に映っている場合が多い。従来手法を適用した場合、濃淡や輪郭が似ているひび割れとこれらのノイズも変状として抽出されることから、ノイズの除去に難しさがあった。



(a) 撮影元画像 (b) 従来手法 (c) 望ましい抽出結果

図1 従来手法によるひび割れ検出

## 3. 深層学習によるひび割れ領域の抽出

### 3.1 深層学習の概要

深層学習は、人間の脳の神経回路をモデルにしたニューラルネットワークという手法をベースにしており、図2に示すように入力層と出力層にはさまれた隠れ層を何層にも重ねた構造となっている。そのプロセスは、




図2 深層ニューラルネットワークの構造

\* 信号・情報技術研究部 画像・IT研究室

## 特集：信号通信技術

大きく「学習」と「推論」に分けられる。学習プロセスでは、ラベル付けされた大量の画像を反復的に学習することで、規則性やパターンなどの特徴を見つけ出し、識別モデルを生成する。推論プロセスでは、学習済みの識別モデルに未知の画像を与えると、推論結果として各ラベルの確率スコアが返される。人間が明示的にプログラムしなくても、コンピュータが自動的に特徴量を獲得し、自律的にデータを分析できるようになる。

## 3.2 学習の考え方と訓練用データセット

本節では、学習に用いた訓練データについて述べる。画像サイズが大きい場合、目地やケーブルが混在する可能性が高くなるので特徴の分類が不明瞭になる。さらに、画像中のひび割れの位置を特定する処理が後で必要になる。また、画像の各ピクセルが入力層の1入力に相当するため、サイズが大きいとその分入力次元が大きくなり、計算量が増加する。一方、画像サイズを小さくし過ぎると、それがひび割れなのか、ノイズなのか判別できなくなるので、誰が見ても間違いなく「ひび割れ」と判断できる大きさを検討した。その結果、トンネルのスパン画像（打継目で分割される単位）に対して、128mm 四方の領域を2mm/画素の解像度で圧縮した画像（サイズは64画素×64画素）を用意した。

今回は、「ひび割れ有り（Crack）」と「ひび割れ無し（None）」の2クラス分類とした。データセットはひび割れ有り約8万枚とひび割れ無し約25万枚からなるデータセットA、および、異なるトンネルにおける幅0.5mm程度以上の主要なひび割れに絞った、ひび割れ有り約4万枚とひび割れ無し約12万枚からなるデータセットBを用意した。なお、検証用のデータは、訓練用データとは異なるスパン画像から選んだ。ひび割れ有りの訓練データの例を図3に示す。

なお、ひび割れ有りの訓練データを増やすために画像の加工による増殖を検討した。回転、反転、拡大縮小、明暗補正などを試した結果、学習性能向上に効果のあった回転と反転を適用して、16倍に増殖させることで十分なデータを用意した。




図3 訓練データ（ひび割れ有り）の例

## 3.3 深層学習のモデル作成


深層学習のフレームワークは画像認識でよく使われるCaffeを利用した。表1に作成したモデルを示す。ニューラルネットワークはGoogLeNetを、誤差関数を最小化する勾配降下法の最適化アルゴリズムにはNAG（Nesterov Accelerated Gradient）を用いた。また、GPU（Graphics Processing Unit）を利用して学習と認識処理の高速化を図った。

表1 作成した深層学習のモデル

モデル番号	Type00	Type01	Type02
訓練データセット (A/B)	Crack A	8万枚	—
		—	4万枚
	None B	25万枚	—
		—	12万枚
学習済識別モデルの利用	—	—	有 Type00
学習率 (パラメータ更新の大きさ)	0.01 ~ 0.0025	0.01 ~ 0.0025	0.001
ニューラルネットワーク	GoogLeNet	GoogLeNet	GoogLeNet
勾配降下法 (重み更新の最適化手法)	NAG	NAG	NAG
Epochs (繰返学習回数)	30	30	30
学習時間	11h	6h	17h

## 3.4 識別モデルによる推論結果

識別モデルは0～1.0に正規化されたひび割れ確率を出力する。出力結果を確認したところ、ひび割れ確率70%以上とすれば、抽出したいひび割れがほぼ含まれていることがわかった。図4にモデルのタイプ00およびタイプ01の推論結果を示す。ひび割れ確率の高いセルほど濃く描いているので、ひび割れに対する反応度合いを一目で把握することができる。従来手法では抽出されていた付帯物やケーブルを、正しく背景として認識していることがわかる。



(a) Type00による認識結果 (b) Type01による認識結果

図4 識別モデルによるひび割れの推論結果

### 3.5 推論の高速化

GPU を利用した並列計算により推論処理の高速化を検討した。並列化のバッチサイズに対する処理時間をプロットしたグラフを図5に示す。同図において Forward time は並列化できた部分の処理時間を、Total time は全体の処理時間を示す。セル画像を1枚ずつ処理した場合は、1スパン全体の推論に約15秒程度かかっていたが、画像処理プログラムを並列化し、バッチサイズを30並列程度に設定することで、約10秒に短縮することができた。Forward time と Total time との差が、確率値の出力など、並列化できない部分の処理である。また、並列数を30以上に増やしても時間短縮は頭打ちとなることがわかった。

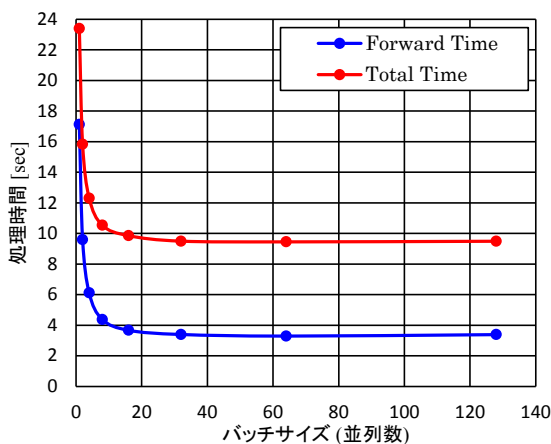


図5 並列化と認識処理時間

### 3.6 識別モデルの性能評価

機械学習で識別モデルの評価によく用いられるものにROC(Receiver Operating Characteristic)曲線<sup>3)</sup>がある。実際にひび割れがあり、予測もひび割れであるデータの数我真陽性(以下、TP(True Positive))、実際はひび割れのない背景で予測も背景であるデータの数我真陰性(以下、TN(True Negative))、実際はひび割れがないのにひび割れと予測したデータの数偽陽性(以下、FP(False Positive))、実際はひび割れなのに背景と予測したデータの数偽陰性(以下、FN(False Negative))と呼ぶ時、横軸に偽陽性率=FP/(FP+TN)(以下、FPR(False Positive Rate))、縦軸に真陽性率=TP/(TP+FN)(以下、TPR(True Positive Rate))をとってプロットしたものがROC曲線である。

正解率=(TP+TN)/(TP+TN+FP+FN)を評価指標として用いるのが直感的には良さそうであるが、今回のように、クラス間のデータ数に偏りがあると、データ数が少ないひび割れ有りの正解率が低くても、データ数が多いひび割れ無しの正解率が高ければ全体の正解率が高くなってしまい、適切な評価にならない。それに対し、ROC曲線はクラス間のデータ数の偏りによる影響を受

けないという特徴がある。モデルのタイプ00及びタイプ01の識別結果のROC曲線を、図6及び図7に示す。

このROC曲線に基づくAUC(Area Under the Curve)が識別モデルの評価尺度となる。0から1までの値を取り、完全な識別ができた時は面積が1になる。つまり、この面積が大きいほど、良い予測ができていとされる。AUCの一般的な評価として0.7～0.9は中程度の精度、0.9以上は高精度と言われているので、いずれの識別モデルも良好な結果が得られている。ただし、Type00では、微細なひび割れまでラベル付けしようとしたため、汚れなどを間違って仕分けした可能性もあり、学習時とは異なるトンネルデータセットBの認識においてAUCの低下が見られた。それに対してType01では、ラベル付けが正確に行われたようで、同様に異なるデータセットAの認識においても高いAUCが観測された。またType02では、学習済みの認識モデルを用いて両データを再学習したが、0.95を超える高いAUCを維持していたことから、追加学習の有効性が示された。

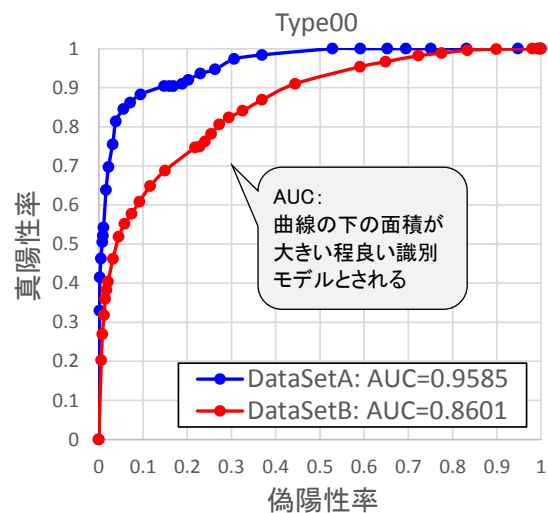


図6 モデル Type00 の ROC 曲線

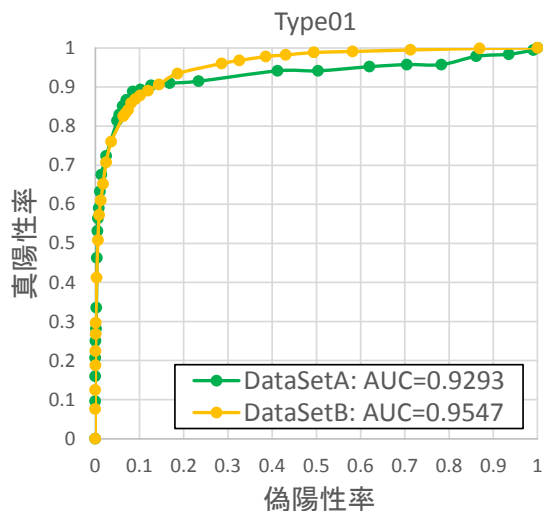


図7 モデル Type01 の ROC 曲線



#### 4. 推論結果に対する考察

深層学習は高い精度が出せる反面、なぜ精度が良いのか、何を根拠に判断しているかよくわからないという弱点がある。「精度が高いならそれでよい」という議論もあるが、判断を納得した上で利用するにはその根拠を提示することが重要であり、様々な研究が行われている。

その一つに、深層学習が画像中のどこを見て判断しているかを、入力に対する出力確率変化の大きさをヒートマップで可視化する、Grad-CAM<sup>4)</sup>という手法がある。ひび割れ画像全体に微小変化を加えた時に、確率スコアに生じる変化の大きさを表す係数を取り出して評価する。クラス判定に与える影響が大きい画像箇所は、確率スコアの微分係数も大きくなることに着目した手法である。

今回、Grad-CAM によるヒートマップ出力プログラムを作成し、評価実験を行った。まず、Crack クラスの画像の中でも、ひび割れだけが映っている比較的綺麗な画像を処理した。可視化結果を図8に示す。上が入力画像、下が Grad-CAM による可視化結果である。赤く色づいている部分が、スコアに強く影響を与えている領域である。識別結果も Crack 確率 98% 以上と判別されたものである。背景と輝度差があるひび割れの中心とそのエッジ部分、さらにその周辺にも着目していることがわかる。

次に、Crack クラスの画像の中から、ひび割れ以外の物も映っている画像を処理した。可視化結果を図9に示す。ケーブルや汚れなどのノイズには反応せず、ひび割れの箇所を見ていることがわかる。識別結果も Crack 確率 70 ~ 90% 程度と良好な結果が得られている。




図8 Crack クラスの Grad-CAM 1





図9 Crack クラスの Grad-CAM 2

一方、ひび割れを背景と判定した偽陰性の画像を処理した結果を図10に示す。確認のために Crack と None の両方のヒートマップを示すが、背景と判定したとおり、Crack のヒートマップでは、赤枠部分のひび割れ箇所は全く色づいていないのに対し、None のそれでは、汚れやケーブルなどのひび割れ以外の部位が色づいている。画像中のケーブルや黒っぽい汚れに着目して、“背景”と判断したようである。確かに元画像には太いひび割れが映っているものの、最終的な判定は識別モデルが行うので、どちらともとれるラベル付けは認識性能を低下させることがわかった。これへの対策として、

- ・ ひび割れとそれ以外の物なるべく混在しないように、訓練データのサイズをもう一回り小さくする。
  - ・ どちらともとれる「保留」クラスを追加する。このクラスと判定された画像については、後述の詳細画像解析で周囲のクラスの様子をもとに再度仕分けをする。
- などが考えられ、今後検討する。

Grad-CAM をはじめとする可視化技術により、「なぜそこを見ているのかまではわからないものの、この箇所を見て AI が判断した」という根拠は検証できた。識別根拠の場所を確認できるようになったので、より高いひび割れ抽出性能が得られる訓練データの作成や、学習方法などの検討に活かせると考える。



元画像 Crackのヒートマップ Noneのヒートマップ

図10 偽陰性画像の Grad-CAM 結果

#### 5. 推論結果を補う詳細画像解析

##### 5.1 ひび割れの骨格線検出

誤った推論結果を調べてみると、一つながりのひび割れが部分的に検出できていなかったり、黒っぽい汚れに反応したりといったケースが多かった。実用性の高いひび割れ検出を行うためには、途切れたひび割れの接合や、孤立点除去などの後処理が重要である。そこで、ひび割れ確率を画素値とみなした濃淡画像に対して、詳細解析を行うハイブリッド型のひび割れ検出手法を提案した。

確率値 0 ~ 1.0 を 0 ~ 255 にリニアスケールで変換し

たビットマップ画像を生成し、位置や方向性に着目した画像解析を行う。ひび割れは主軸方向につながっている傾向があるので、膨張処理した後、近接する線成分を連結した上で、一定長さ以下の線分を除去する。さらに残った領域を収縮し、平滑化、骨格線抽出を行って、最終的なひび割れとして検出する手法を開発した。提案手法によるひび割れの検出結果を図 11 に示す。図 12 から分かるように、ケーブルや付帯物の背後のひび割れを正しく検出できている。




図 11 詳細処理によるひび割れ検出結果




図 12 付帯物の背後のひび割れ検出状況

手書きの変状展開図の同一箇所を、提案手法で検出した結果を並べて図 13 に示すが、人間の判断に近い、実用的な検出結果が得られていることがわかる。

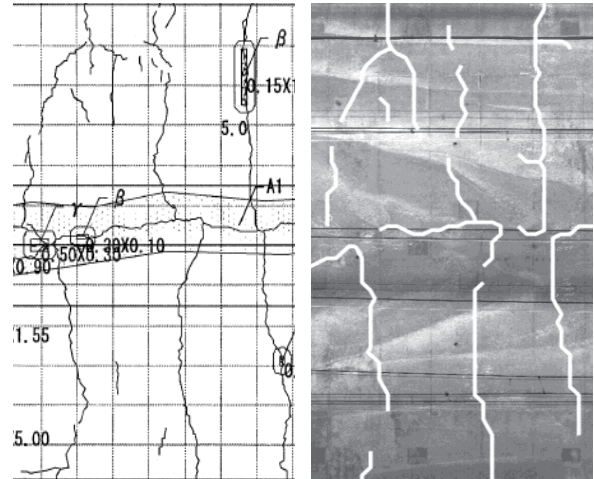


図 13 人間が作成した変状展開図との比較

## 5.2 ひび割れの詳細検出

前節で述べた手法は、ひび割れが含まれるセル領域の骨格線をもってひび割れの検出としているが、ひび割れを正確にトレースした検出結果も欲しいという要求がある。そこで、識別モデルの推論結果のセルに対応する元画像を切り出し、そのブロック単位で検出を行うモードも用意した。この方法で処理すれば、処理時間は幾分増えるが、ブロック毎に異なる明るさの違いを吸収して最適なコントラストの画像に補正できるので、ひび割れを忠実にトレースした結果を得ることができる。詳細検出の結果を図 14 に示す。

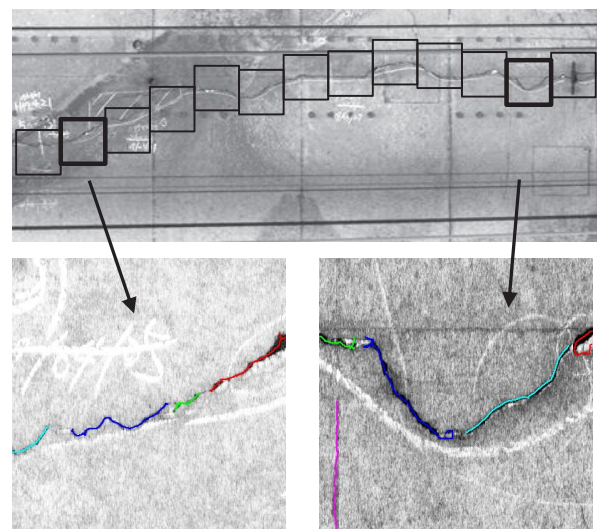


図 14 ブロック単位の詳細ひび割れ検出結果

### 5.3 サブピクセル精度のひび割れ計測

これまでに開発したひび割れ検出アルゴリズム<sup>5)</sup>に改良を加え、ノイズの過剰抽出を抑えて、重要な太いひび割れを確実に抽出できるようにした。まず、元画像を平滑化した後、動的閾値処理により画像を分割する。一定面積以下の粒子を除去した後膨張させ、ひび割れ探索領域を絞り込む。図15に示すように、ひび割れの輪郭部分は、領域の外側から内側に向けて暗くなる所なので、画像の微分値（デジタル画像の場合、微分は輝度値の差分となる）の高い部分を抽出するフィルタを当該探索領域に作用させ、図16に示すようにひび割れの輪郭を抽出する。なお、処理はサブピクセル処理により撮影解像度の10倍程度の精度で計測することができる。輪郭線に囲まれるひび割れ領域の最大幅を計測した例を図17に示す。

このフィルタで使用する三つのパラメータ（平滑化係数、微分値の上限及び下限閾値）は検出性能を左右する重要な値であるが、これまでは試行錯誤的に設定しており、安定した検出を実現する上で課題となっていた。本手法では、抽出したい最大ひび割れ幅と、画像の明暗のコントラスト値から内部計算するようにした。これによ

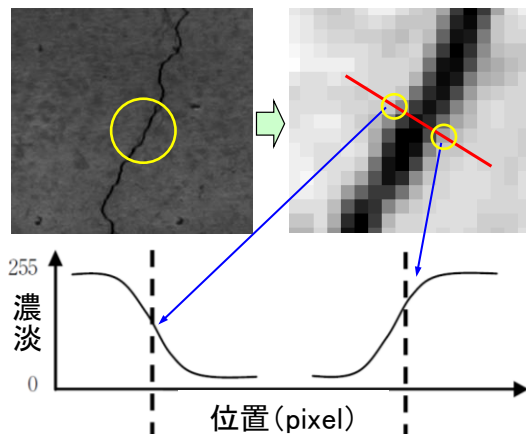


図15 エッジ検出フィルタによる輪郭の抽出




図16 サブピクセル精度のひび割れ検出処理

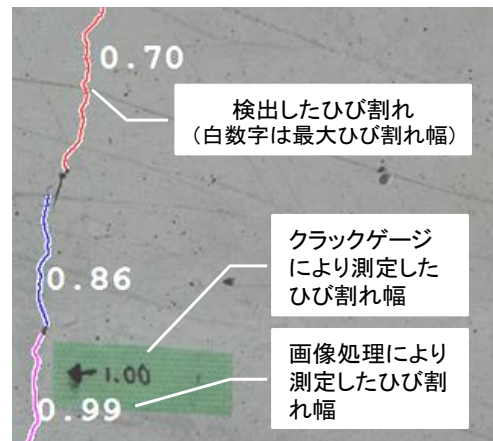


図17 最大ひび割れ幅の検出結果

りパラメータチューニングの自動化を図ることができ、実用性が向上した。最後に、終点が隣接するひび割れ候補を連結し、一定の長さ以下の成分を除去して、最終的なひび割れとして検出した。

## 6. おわりに

深層学習を用いてひび割れの存在領域を抽出する識別モデルを作成し、得られた抽出結果を基に位置や方向性に着目した画像解析を行う、ハイブリッド型のひび割れ検出手法を提案した。人間の判断に近い検出結果が得られており、今後は、変状展開図の自動作成の要素技術として、ひび割れ検出性能の更なる向上と、漏水など他の変状への対応を進める予定である。

## 文 献

- 1) 鵜飼正人, 長峯望, 御崎哲一, 坂本保彦: トンネル変状抽出のための高精度画像処理手法の開発, 会誌サイバネティクス, Vol.17, No.2, 2012
- 2) 鵜飼正人, 御崎哲一, 安田光範, 菅原章博, 田中斗志貴: 機械学習を用いたひび割れ検出手法の開発, 会誌サイバネティクス, Vol.22, No.2, 2017
- 3) Richard Szeliski: コンピュータビジョン—アルゴリズムと応用—, 共立出版, 2013
- 4) Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, Dhruv Batra. "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization, ArXiv e-prints, Mar 2017.
- 5) 鵜飼正人, 長峯望: 画像処理技術による構造物検査手法の高精度化, 鉄道総研報告, Vol.28, No.11, 2016