

第 2015-16 号

# インタラクティブ・ロボティックス による橋梁診断スキームの構築

関西大学総合情報学部

古田 均

平成 29 年 8 月

## 助成申請者

古田 均

関西大学総合情報学部・教授

## 共同研究者

林 勲

関西大学総合情報学部・教授

広兼 道幸

関西大学総合情報学部・教授

荻野 正樹

関西大学総合情報学部・教授

# 目 次

|                           |    |
|---------------------------|----|
| 第1章 はじめに                  | 1  |
| 1.1 研究の背景                 | 1  |
| 1.2 研究の目的                 | 1  |
| 1.3 本報告書の構成               | 2  |
| 第2章 橋梁維持管理について            | 3  |
| 2.1 橋梁維持管理とは              | 3  |
| 2.2 橋梁点検の種類               | 3  |
| 2.3 高力ボルトの軸力検査            | 4  |
| 2.3.1 高力ボルトの軸力検査方法        | 5  |
| 2.3.2 軸力検査の今後の課題          | 6  |
| 2.4 点検の方法と問題点             | 6  |
| 第3章 橋梁点検データの収集            | 8  |
| 第4章 ドローンを用いた橋梁点検データ収集システム | 17 |
| 4.1 提案の概要                 | 17 |
| 4.2 従来手法との違いと有用性          | 17 |
| 4.3 ドローンについて              | 19 |
| 4.3.1 ドローンの安全対策           | 19 |
| 4.3.2 ドローンの改良             | 22 |
| 4.3.3 プロトタイプ1代目           | 23 |
| 4.3.4 プロトタイプ2代目           | 25 |
| 4.3.5 考察                  | 31 |
| 4.4 ドローンに搭載するカメラについて      | 31 |
| 第5章 3次元モデルの構築スキーム         | 33 |
| 5.1 図面が残されていない橋梁          | 33 |
| 5.2 3次元モデルの作成             | 33 |
| 5.3 実験内容                  | 36 |
| 5.3.1 屋内の椅子               | 36 |
| 5.3.2 乗用車                 | 36 |
| 5.3.3 建物                  | 37 |
| 5.4 考察                    | 39 |
| 第6章 パターン認識                | 41 |
| 6.1 パターン認識とは              | 41 |
| 6.1.1 パターン認識の過程           | 42 |

|                                    |    |
|------------------------------------|----|
| 6.1.2 学習の必要性                       | 43 |
| 6.1.3 パターン認識の問題点                   | 43 |
| 6.2 決定木                            | 44 |
| 6.3 ランダムフォレスト                      | 46 |
| 6.4 サポートベクタマシン (SVM)               | 47 |
| 6.4.1 学習の定式化                       | 47 |
| 6.4.2 SVM の多クラス識別問題への拡張            | 49 |
| 6.5 ニューラルネットワーク (NN)               | 50 |
| 6.5.1 誤差逆伝搬法 (BP 法)                | 50 |
| 6.5.2 中間層ユニットと出力層ユニットの結合定数の修正量の導出  | 51 |
| 6.5.3 入力層ユニットと中間層ユニットの結合係数の修正量の導出  | 52 |
| 6.5.4 出力層ユニットと中間層ユニットのオフセットの修正量の導出 | 52 |
| 6.6 深層学習 (Deep Learning)           | 53 |
| 6.6.1 畳み込みニューラルネット                 | 53 |
| 6.6.2 畳み込み層                        | 54 |
| 6.6.3 プーリング層                       | 56 |
| 6.6.4 ドロップアウト                      | 57 |
| 第7章 撮影画像データによる損傷度診断スキーム            | 59 |
| 7.1 診断スキームの検証データ                   | 59 |
| 7.2 前処理部                           | 60 |
| 7.2.1 処理の流れ                        | 60 |
| 7.2.2 画像の正規化                       | 61 |
| 7.2.3 2値化処理によるひび割れの抽出              | 63 |
| 7.2.4 ノイズの除去                       | 66 |
| 7.2.5 4-連結細線化処理                    | 66 |
| 7.2.6 特徴点に基づく画像の修正                 | 68 |
| 7.3 特徴量の抽出                         | 69 |
| 7.3.1 ひび割れ画像からの特徴抽出                | 69 |
| 7.3.2 ひび割れ画素の周辺分布ヒストグラム            | 69 |
| 7.3.3 ひび割れによって囲まれた領域の周辺分布ヒストグラム    | 70 |
| 7.3.4 ひび割れ線図形における特徴点               | 72 |
| 7.4 識別実験                           | 74 |
| 7.4.1 学習ベクトル量子化による識別実験             | 75 |
| 7.4.2 線形サポートベクトルマシンによる識別実験         | 76 |
| 7.4.3 非線形サポートベクトルマシンによる識別実験        | 78 |

|                                      |     |
|--------------------------------------|-----|
| 第 8 章 打音点検データによる軸力診断スキーム             | 82  |
| 8.1 診断スキームの検証データ                     | 82  |
| 8.2 フーリエ変換                           | 83  |
| 8.2.1 離散フーリエ変換                       | 83  |
| 8.2.2 高速フーリエ変換                       | 84  |
| 8.3 正規化                              | 85  |
| 8.4 特徴量の抽出                           | 88  |
| 8.4.1 周波数特徴量とレスポンス特徴量の抽出             | 88  |
| 8.4.2 移動平均法                          | 89  |
| 8.4.3 移動平均法を適用した減衰率特徴量の抽出            | 90  |
| 8.5 特徴量を用いた診断スキームの識別実験               | 92  |
| 8.5.1 実験の概要                          | 92  |
| 8.5.2 識別実験（周波数・レスポンス特徴量を用いた識別）       | 94  |
| 8.5.3 識別実験 2（減衰率特徴量を用いた識別）           | 102 |
| 8.5.4 識別実験 3（周波数・レスポンス・減衰率特徴量を用いた識別） | 117 |
| 8.5.5 特徴量を用いた識別実験を通しての考察             | 118 |
| 8.6 深層学習による識別実験                      | 119 |
| 8.6.1 実験の概要                          | 119 |
| 8.6.2 畳み込みニューラルネットワークによる識別実験         | 120 |
| 8.6.3 ドロップアウトを適用した畳み込みネットによる識別実験     | 121 |
| 第 9 章 おわりに                           | 124 |
| 参考文献                                 | 126 |
| 謝 辞                                  | 128 |
| 参考資料（JACIC 研究打ち合わせ実績一覧）              | 129 |
| 参考資料（JACIC 初回研究打ち合わせメモ）              | 132 |
| 参考資料（JACIC 中間研究打ち合わせメモ）              | 133 |
| 参考資料（JACIC 最終研究打ち合わせメモ）              | 134 |
| 参考資料（その他研究打ち合わせメモ）                   | 135 |
| 参考資料（発表実績一覧）                         | 137 |

## 第1章 はじめに

### 1.1 研究の背景

近年、高度成長期に建設された橋梁の多くは、適切な維持管理を必要としている。現在、橋梁の点検は技術者による目視点検が主となっている。しかしながら、地方公共団体の現状として、町の約5割、村の約7割で橋梁保全業務に携わっている土木技術者数が0人となっている。そのような地域では遠望目視による点検も多く（約8割）[1]、点検の質に課題がある。また、わが国では熟練技術者の多くが団塊の世代であるため、若手技術者が圧倒的に不足している。技術者は育成に時間がかかるため、今後、技術者不足は更に深刻になると予想される。さらに、国土交通省は2014年7月1日から、トンネルや2メートル以上の道路橋などを、5年に1度の頻度で近接目視による点検を行うことを義務付けるとした。2メートル以上の橋梁は約70万橋が存在している[2][3]。罰則等は設けられてはいないが、予算や技術者確保等の面で苦しむ自治体が多く出ていると考えられる。高度経済成長期に集中して建設された橋梁は適切に点検を行なっていかなければ、多くの橋梁が同時期に落橋等の重大な事故を引き起こすことになりかねない。さらに今後、一斉に補修などの対策が必要になる状態になった場合、予算が不足することが予想されている。しかしながら、高所などの人が立ち入りづらい場所の点検では、安全性を確保するために点検コストが高くなるなどの問題点がある。その結果、点検の頻度が下がってしまい、損傷の発見が遅れる可能性がある。また、建設年度が不明となっている橋梁が全体66万橋のうち、約30万橋と全橋梁の約半数も存在する。さらに図面を保存・管理できていない自治体も多く存在している。全国の都道府県と政令指定都市にアンケートが行われた結果によると、地方自治体の87%で詳細な図面が残っていないことがわかっている。橋梁の詳細が示された図面がなければ、橋梁の補修工事を行うことができない。そのため、もう一度、その橋梁の図面を作り直す必要が発生する[4][5]。図面の作り直しには、多くの時間とコストが必要になる。

既往研究[6]では、高精度、かつ容易にデータを収集するために、無線センサーネットワークを用いたモニタリングが有効と考えられている。しかしながら、電源供給のための設備を構築しなければならず、多額の費用がかかってしまう問題があるため、近年の経済下で構築することは容易ではない。そのため、経済性、効率性、安全性に着目した新たな点検法の開発が望まれているのが現状である。

### 1.2 研究の目的

本研究の目的は、橋梁の維持管理の効率化、省力化のための新たなヘルスマニタリングシステムの開発を最終的な達成目的として、

- ・ロボットに画像カメラや打音装置等を実装し、認知ロボットの自律走行を実現する。ただし、ロボットは飛行機器も含む。

- ・橋梁のコンクリートの壁の模擬を実験室に装備する。
- ・橋梁のコンクリート壁画像の写真と打音の分析からコンクリート壁内部の状態を推定する検査モデルを構築する。
- ・ロボットが自動撮影しながら自律走行して、模擬コンクリート壁の診断マップを作製する実験の評価を行う。

等の研究課題を研究計画としてあげた。これらの計画を初回の打ち合わせ（2015 年 9 月 24 日実施，参考資料「初回研究打ち合わせ」参照）において，2 年間での実現可能も含めて議論して，具体的な研究計画を議論した。具体的な研究の進め方は，1) ロボットによるデータ収集（検査ロボットの制御），2) 画像と打音による健全度の評価（収集データの評価），3) 実装実験（供試体による評価と実橋による評価），の 3 つの課題について個別に進めていくこととした。上記 1)～3)の具体的な内容を以下に示す。

- 1) ロボットによるデータ収集（検査ロボットの制御）
  - ・ロボットによるひび割れ画像の撮影（複数画像からの 3D モデルの作成）
  - ・ロボットによる打音の収集
  - ・ドローンを使って上記のデータ収集を検討（優先順位は，画像→打音）
  - ・様々なロボットの利活用に関する調査（吸着型ロボットなど）
- 2) 画像と打音による健全度の評価（収集データの評価）
  - ・ひび割れ画像データ（視覚情報）による健全度の評価
  - ・打音データ（聴覚情報）による健全度の評価
  - ・加速度データ（触覚情報）による健全度の評価を追加で検討
- 3) 実装実験（供試体による評価と実橋による評価）
  - ・小型の供試体を作り，実際にデータを収集して，健全度の評価実験を実施
  - ・実際の橋梁での収集データによる健全度の評価実験を実施

### 1.3 本報告書の構成

本論文では，第 1 章は，本研究の背景と目的について述べた。第 2 章では，橋梁維持管理の現状と問題点について述べる。第 3 章では，(1)の課題である，様々なロボットの利活用に関する調査結果をまとめた。第 4 章では，(1)の課題であるドローンを用いた橋梁点検データの収集方法の検討結果をまとめ，第 5 章では，(1)の課題である複数画像からの 3D モデルの作成方法およびその結果についてまとめた。第 6 章では，第 7 章と第 8 章でまとめる視覚情報と触覚情報に基づく健全度・軸力診断スキームで用いたパターン認識手法の基礎についてまとめた。第 7 章では(2)の課題である，視覚情報に基づくコンクリート床版の健全度診断スキームの評価実験結果についてまとめ，第 8 章では(2)の課題である，触覚情報（加速度データ）による高力ボルトの軸力診断スキームの評価実験結果についてまとめた。最後に第 9 章で結論と今後の課題についてまとめる。

## 第2章 橋梁維持管理について

### 2.1 橋梁維持管理とは

橋梁点検とは、「橋梁に求められる、安全性などの性能や機能を保持するために劣化、不良箇所を致命的な損傷になる前に発見すること」[7]である。橋梁などのインフラストラクチャと呼ばれる構造物の建設には多額の税金が投入されていること、建設時や解体時には大量の二酸化炭素や廃棄物が発生し、環境への負担が大きいため、可能な限り有効に使い続けることが要求される。構造物は完成後から時間の経過とともに劣化、老朽化していくため、定期的に点検を行い、損傷箇所を発見、修復していかなければならない。しかしながら、点検、修復をしていかなければ、構造物を安全な状態で長持ちさせることが出来ず、長期的に使用していくことが難しくなる。そのため、構造物を安全に長期的に、そして快適に使用するには、定期的な点検を行い、損傷の早期発見をしていくことが極めて重要である。

### 2.2 橋梁点検の種類

橋梁の点検は、橋梁を管理する機関(国、都道府県、市町村、道路会社など)や民間の調査会社などの多くの技術者によって点検される。点検には目的に応じて種類があり、主に目視、または簡易的な非破壊試験により橋梁の部材の状態を把握する。これらの点検の結果から橋梁の性能や損傷を評価することが出来ない場合や詳細なデータが必要となった場合には、別の非破壊試験などを用いて、さらに調査を行うこととなる。表 2.1 に橋梁点検の種類を示す。

現在、国が管理する道路橋では、日常点検として、毎日、道路パトロールカーから橋梁の路面の状態を走行しながら確認する巡回作業と、1年に1回、橋梁の下面から双眼鏡などを用いて遠望目視にて点検を行っている。また、定期点検として、5年に1回の頻度で点検を行い、緊急対応や補修などが必要かどうか、必要であれば、その時期を判定できるシステムを構築している。本報告書の6章以降では、診断スキームの一例として打音検査で得られた加速度波形データをもとに高力ボルトのゆるみを診断するための人工知能を応用したスキームを提案している。そのため、表 2.1 に示した定期点検や臨時点検などで実施される非破壊検査手法の1つで鋼橋の高力ボルトのゆるみを診断するための方法について、次節で詳しく述べる。



表 2.1 点検の種類 [7]

| 種類   | 目的   | 方法  |
|------|--|---|
| 初期点検 | 構造物の初期状態を把握する  | 使用開始にあたって最初に行われ、それ以降の劣化評価の原点になる。主に目視観察などの簡易な調査を実施する         |
| 日常点検 | 早期に構造物の変状を把握する   | 数日から数週間に1回程度の頻度で実施する点検で、主に目視観察などの簡易な調査を実施する                 |
| 定期点検 | 日常点検では確認できない部位の状態を把握する   | 数年に1回程度の頻度で実施する定期的な点検。通常は近接目視による点検を行うが、場合によっては簡易な非破壊試験を実施する |
| 臨時点検 | 偶発荷重(発生時期が予想できない地震などにより生じる荷重)が与えた損傷(地震などにより発生し、その後は大きく変化しないもの)の状態を把握する | 大規模な地震などによる偶発荷重や車両や船舶の衝突などの偶発荷重が作用したあとに目視観察に寄って実施する         |
| 緊急点検 | 構造物に影響の大きい事故や損傷が生じた場合に、同様の構造物において、同様のことが起こっていないかを臨時に把握する               | 目視または非破壊試験装置を用いて実施する  |

## 2.3 高力ボルトの軸力検査

鋼橋の添接部に使用されている高力ボルトにとって軸力は極めて重要であるが、高力ボルトの軸力は経年変化や腐食により低下してしまうため、定期的な点検が必要不可欠である[8]。従来、高力ボルトの点検は熟練者による打音法で行われてきた。打音法は点検箇所をハンマーで打撃し、その時に発生する振動や音から軸力の異常の有無を検査する簡便な検査方法である[9]。しかし、打音法は熟練者の勘や感覚に依存しているので、非熟練者の場合、診断の信頼性が疑わしいといった問題点がある。そのため、打音法に代わる軸力検査の方法として、様々な検査技術が開発されてきた。

### 2.3.1 高力ボルトの軸力検査方法

#### (1) ひずみゲージ

ひずみゲージは高力ボルトに貼り付けて使用する。図2.1(a)は高力ボルトにひずみゲージを貼り付けた時の図である。高力ボルトに軸力が加わると、その軸力の大きさに比例した長さのひずみがボルトに発生する。ボルトに発生したひずみによって、ひずみゲージ内の抵抗体も伸縮し、抵抗値が増減する。この抵抗値の変化によって、ひずみゲージは軸力を測定する。ひずみゲージは精度・信頼性ともに高い特徴があるが、ひずみゲージの貼り付け位置の検討が必要である[10]。また、図2.1(b)のようにボルトに貼り付けるための加工や、軸力とひずみの関係をキャリブレーションする必要もあるため、非常に効率が悪い。このことより、膨大な数のボルトを検査しなければならない場合、ひずみゲージを用いた軸力検査は不適當である。




図 2.1 ひずみゲージの貼り付け・埋め込み方

#### (2) 戻しトルクチェック

戻しトルクチェックは図2.2に示すようなトルクレンチでボルトを弛める際に、ボルトが回りだす瞬間のトルク値から軸力を推定する方法である[11]。この方法では、トルク係数値も不明であり、トルク係数値を推定したうえで戻しトルクから換算して軸力を推定することになり精度は期待できない。また、高力ボルトを残置して使用する場合は、弛んでしまう可能性が高く、増し締めしても機能確保に問題が残る。



図 2.2 トルクレンチ

#### (3) 超音波軸力計

超音波軸力計は超音波を軸力が作用する方向に伝播させ、ボルト締め付け前後の伝播時間の差からボルト長の変化を測定し、軸力に換算する[12]。図2.3は超音波軸力計を用いた測定方法の例である。図2.3においては、ボルトの頭部に超音波軸力計の探触子を当て、超音波を発生することによって軸力の測定を行う。初期のボルトの長




図 2.3 超音波軸力計を用いた測定方法例

さが既知である場合は高い精度で測定可能な特徴がある[12]。しかし、温度変化の影響を受けることや、ボルトの塗膜を除去し頭部とねじ部先端を平滑に仕上げる必要があるため、非常に手間がかかる検査である。

#### (4) 磁気軸力計

磁気軸力計は鋼材材料に応力が加わると逆磁歪効果によりその磁気異方性が変化するという現象を利用した応力センサである[13]。磁気軸力計を用いた軸力の測定を行う時においても、超音波軸力計と同様に探触子をボルトに当て、軸力を測定する。磁気軸力計の利点として、ボルトを抜かずに測定可能なことが挙げられる。しかし、ボルトの塗膜や温度変化などが測定値に影響し、精度に難があることや、ボルトの材質によっては測定できないものがあるなどの問題点が存在する。

### 2.3.2 軸力検査の今後の課題

従来の高力ボルト軸力点検・検査法の問題点として下記のようなことが挙げられる。

- i) 測定精度が必ずしも期待通りではない
- ii) 一度ボルトを抜く、ボルトに加工が必要であるなど、時間やコストがかかる
- iii) 熟練技術者の減少と診断対象の増大により人員不足が予想される

前節でも述べたように、目視点検や従来の打音法といった検査手法は、熟練の専門家の知識や直感に頼りすぎている面がある。今後、我が国では少子高齢化がさらに進み、建設分野等の技術者も減少していくものと予測される。今までは建設分野への就業者数は約 10%であったが、維持管理部門への就業者割合はその 1/10 にも満たない。もしこの傾向が継続すると考えると、これからの維持管理部門への就業者数を大幅に増大させる政策等がとられない場合は、検査、判定などが行える技術者の人材不足が大きな問題になってくる。よって、早急に熟練技術者の経験に基づくノウハウを取得し、そのノウハウを利用することにより非熟練技術者でも高い精度で大量のボルトを診断可能な検査手法の確立が必要不可欠である。

### 2.4 点検の方法と問題点

橋梁点検では、上部構造から下部構造まで土中、水中にある箇所を除いて、目視できる箇所はすべて点検を行う。点検は対象橋梁の立地条件から、徒歩、梯子、リフト車、橋梁点検車、船舶などの方法によって実施される。橋上は徒歩によって路面から点検を行うことを基本とし、橋下は梯子によって目視が可能であれば、梯子を、橋梁の下に河川などが存在する場合には橋梁点検車（図 2.4）を用いるなど、状況に応じて高所作業車（図 2.5）や梯子（図 2.6）などの機材を用いて点検を行う。

しかしながら、現状では、これらの橋下の定期点検には、高所などの人が立ち入りにくい箇所での作業であるため、風などの影響を受けながら、目視点検を行っている。そのた

め、安全性の確保のために仮設足場を組み、作業を行うなどの膨大な費用がかかる。また、点検時には道路の車線制限などを行わなければならない場合があり、道路交通、第三者に大きな影響を与えてしまう現状もある。このような現状から、容易に点検作業を行うことが難しく、また、我が国の予算が不足していることもあるため、1つ1つの橋梁の点検の質が下がってしまう恐れがある。その結果、橋梁に生じた損傷の発見が遅れてしまう可能性があるという問題が発生している。



図 2.4 橋梁点検車を用いた点検[7]



図 2.5 高所作業車を用いた点検[7]



図 2.6 梯子を用いた点検[7]

### 第3章 橋梁点検データの収集

インフラ維持管理・更新・マネジメントにおける研究課題の中で最も重要なテーマである「アセットマネジメント技術の研究開発」では、膨大なインフラに対して、限られた財源と人材で効率的に維持管理を行うことが求められ、ライフサイクルコストの最小化を目指すインフラ構造物のアセットマネジメント技術に関する様々な研究が実施されている。

内閣府のもとに戦略的イノベーション創造プログラム（SIP：Cross-ministerial Strategic Innovation Promotion Program）では11ある研究課題の1つに「インフラ維持管理・更新・マネジメント技術」に関する研究課題が設けられ、この研究課題のプログラムディレクターである藤野陽三教授（横浜国立大学・先端科学高等研究院・上席特別教授）を中心に様々な研究が実施されている。

これらの研究プロジェクトでは、インフラの効率的な維持管理に関する研究が実施され、

- 1) インフラ構造物の点検・モニタリング・診断技術の研究開発
- 2) 構造材料・劣化機構・補修・補強技術の研究開発
- 3) 情報・通信技術の研究開発
- 4) ロボット技術の研究開発
- 5) アセットマネジメント技術の研究開発

など、様々な研究が実施され、使える技術として公開されているところである。

そこで、本研究での参考とするため、SIPでの研究において、効率的なインフラの診断のための情報を収集するためのロボット技術を含んだ数多く提案されているスキームを、表3.1（[http://www.jst.go.jp/sip/k07\\_kadai\\_dl.html](http://www.jst.go.jp/sip/k07_kadai_dl.html)）にまとめた。表3.1における、No.1～No.34は「1) インフラ構造物の点検・モニタリング・診断技術の研究開発」、No.35～No.38は「2) 構造材料・劣化機構・補修・補強技術の研究開発」、No.39～No.43は「3) 情報・通信技術の研究開発」、No.44～No.56は「4) ロボット技術の研究開発」、No.57～No.60は「5) アセットマネジメント技術の研究開発」に関する課題となっている。

「4) ロボット技術の研究開発」において開発されているロボット技術はドローン（マルチコプター）を利用したものが多く、カメラやポール打検機・打撃ローラーなどを搭載して、近接目視や打音検査を代替するロボット技術も提案されてる。さらにロボットの制御では熟練者のモデルを構築し、そのモデルに従ったロボット制御の仕組みも提案されている。さらに、「1) インフラ構造物の点検・モニタリング・診断技術の研究開発」の中でも多くのモニタリングのための装置が開発されており、これらの装置をロボットに実装することにより、維持管理業務のさらなる効率化が図れるものと期待できる。

表 3.1 SIP 開発技術の概要

| No. | 研究課題  | 研究責任者                | 目的              | 備考                                   |
|-----|---|----------------------|-----------------|--------------------------------------|
| 1   | 異分野融合によるイノベティブメンテナンス技術の開発                   | 石田雅博<br>土木研究所        | コンクリート橋の診断技術    | 可搬型高出力 X 線源・小型中性子源による高精度投下撮影装置       |
| 2   | レーザー超音波可視化探傷技術を利用した鋼橋の劣化                    | 高坪純治<br>つくばテクノロジー    | 鋼橋の診断技術         | 小型レーザー超音波検査装置                        |
| 3   | インフラ劣化評価と保全計画のための高感度磁気非破壊検査                 | 塚田啓二<br>岡山大学         | 鋼板の非破壊検査        | 鉄鋼構造物を対象とした磁気センサを用いたポータブル検査装置        |
| 4   | レーザーを活用した高性能・非破壊劣化インフラ診断技術の開発               | 緑川克美<br>理化学研究所       | コンクリートの非破壊検査    | コンクリート内部結果の検出のためのレーザーによる欠陥検査装置       |
| 5   | 舗装と盛土構造の点検・診断自動化技術の開発                       | 八嶋厚<br>岐阜大学          | 舗装の健全性・盛土の安定性評価 | 2次元表面波探査装置を全自動化した自動計測装置              |
| 6   | コンクリート内部の鉄筋腐食検査装置の開発                        | 生嶋健司<br>東京農工大学       | コンクリートの非破壊検査技術  | 超音波誘起される交流磁場検出方法による非破壊鉄筋磁性評価技術       |
| 7   | コンクリート内部を可視化する後方散乱 X 線装置の開発                 | 豊川弘之<br>産業技術総合研究所    | コンクリートの内部の劣化診断  | 後方散乱 X 線を用いたコンクリート内部の非破壊検査装置         |
| 8   | インフラモニタリングのための振動可視化レーダーの開発                  | 能美仁<br>アルウェットテクノロジー  | インフラの振動計測・解析技術  | 振動可視化レーダーを用いた橋梁・高架橋等の振動計測・解析装置       |
| 9   | 高速走行型非接触レーダーによるトンネル覆工の内部欠陥点検技術と統合型診断システムの開発 | 安田亨<br>パシフィックコンサルタンツ | トンネル覆工の内部欠陥点検技術 | 非接触型アンテナを搭載した走行型計測車両の開発と可視化診断システムの開発 |
| 10  | 高感度近赤外分光を用いたインフラの遠隔診断技術の研究開発                | 津野和宏<br>首都高技術        | コンクリート劣化因子の測定技術 | 近赤外分光による高精度化学分析技術を用いた劣化因子の計測装置       |

|    |   |                         |                    |   |
|----|---|-------------------------|--------------------|---|
| 11 | 学習型打音解析技術の開発                                    | 村川正宏<br>産業技術総合研究所       | 打音検査結果の定量化と可視化技術   | 台車型・高所打音装置の開発と機械学習に基づく打音解析技術                |
| 12 | ラジコンボートを用いた港湾構造物の点検・診断システムの開発                   | 小笠原哲也<br>五洋建設           | 港湾構造物の劣化モニタリング技術   | ラジコンボートによる撮影画像の解析による劣化診断技術                  |
| 13 | 空洞及び裏込沈下調査におけるチャープレーダー等特殊 GPR 装置の研究開発           | 山田茂治<br>川崎地質            | 岸壁の空洞・空洞化危険箇所の発見技術 | 車両牽引式深層用空洞調査 GPR・鉄筋コンクリート対応型マルチチャンネル GPR 装置 |
| 14 | 衛星及びソナーを利用した港湾施設のモニタリングシステムの構築                  | 西畑剛<br>五洋建設             | 港湾施設のモニタリングシステム    | 衛星画像を用いた広域モニタリング技術・4Dソナーシステムによる計測技術         |
| 15 | 地上設置型合成開口レーダーおよびアレイ型イメージングレーダを用いたモニタリング         | 佐藤源之<br>東北大学            | 空港滑走路等の舗装体の異常検知技術  | 地上設置型合成開口レーダー装置（広域計測）・アレイ型イメージングレーダ装置（内部計測） |
| 16 | 高解像度画像からのクラック自動抽出技術による空港の舗装巡回点検用モニタリングシステムの研究開発 | 原徹<br>アルファ・プロダクト        | 空港滑走路のモニタリングシステム   | 高解像度画像による滑走路表面のクラック自動抽出・CAD データ生成装置         |
| 17 | 3 次元カメラと全方位型ロボットによる滑走路のクラック検知システムの研究開発          | 木村康郎<br>NTT アドバンステクノロジー | 空港滑走路のモニタリングシステム   | 全方位型ロボットによる滑走路の 3 次元画像の自動収集・解析装置            |
| 18 | 空港管理車両を活用した簡易舗装点検システムの研究開発                      | 石川雄章<br>東京大学            | 空港舗装路面の簡易計測システム    | 光学カメラ・赤外線センサーによる舗装路面の簡易計測・記録・可視化装置          |

|    |  |                           |                         |   |
|----|--|---------------------------|-------------------------|---|
| 19 | 衛星 SAR による地盤および構造物の変状を広域かつ早期に検知する変位モニタリング手法の開発 | 金銅将史<br>国土技術政策総合研究所       | 地盤や構造物の変位モニタリングシステム     | 衛星 SAR データを用いた地盤や構造物の広域的な変位モニタリング技術               |
| 20 | ALB（航空レーザー測深機）による洗掘状況の把握                       | 坂下裕明<br>パスコ               | 橋梁の洗掘状況モニタリングシステム       | 航空レーザー測深機を用いた橋梁の洗掘状況モニタリング技術                      |
| 21 | 振動モード解析に基づく橋梁の性能評価システムの開発                      | 川合忠雄<br>大阪市立大学            | 橋梁の性能評価のためのモニタリングシステム   | 橋脚に設置したセンサで取得した振動から振動モード解析による橋梁の性能評価技術            |
| 22 | 橋梁点検ロボットカメラ等機器を用いたモニタリングシステムの創生                | 藤原保久<br>三井住友建設            | 橋梁の定期監視型モニタリングシステム      | 橋梁点検ロボットカメラ、デジタルカメラ、レーザースキャナを用いた定期監視型モニタリング技術     |
| 23 | 画像解析技術を用いた遠方からの床版ひび割れ定量評価システムの構築               | 堀口賢一<br>大成建設              | 床版劣化の定量評価のための画像解析処理技術   | 床版のひび割れ・遊離石灰の定量的評価のためのデジタル画像撮影技術と画像解析技術           |
| 24 | 省電力化を図ったワイアレスセンサによる橋梁の継続的遠隔モニタリングシステムの現場実証     | 西田秀志<br>オムロンソーシャルソリューションズ | 継続的遠隔モニタリングシステム         | 加速度・ひずみ・ACM型腐食センサなどによる省電力ワイアレスセンサによる継続的遠隔モニタリング技術 |
| 25 | 高精度かつ高効率で人工構造物の経年変位をモニタリングする技術                 | 村田稔<br>日本電気               | 人工構造物の経年変位モニタリングシステム    | SAR 画像を用いた広範囲の人工構造物の異常を検知するための経年変位モニタリング技術        |
| 26 | 傾斜センサ付き打込み式水位計による表層崩壊の予測・検知方法の実証実験             | 荘田泰敬<br>応用地質              | 表層崩壊の発生予測のためのモニタリングシステム | 雨量・傾斜センサ・打込み式水位計を用いたデータ収集技術と表層崩壊の予測技術             |



|    |                                    |                          |                              |   |
|----|------------------------------------|--------------------------|------------------------------|---|
| 27 | 多点傾斜変位と土壌水分の常時監視による斜面崩壊早期警報システム    | 王林<br>中央開発               | 斜面崩壊の予兆現象のモニタリングシステム         | 傾斜センサと土壌水分計を用いた斜面崩壊前の予兆現象を把握するための技術                           |
| 28 | 大型除草機械によるモグラ（小動物）穴の面的検出システム        | 鈴木清<br>朝日航洋              | 河川堤防の変状把握の計測システム             | 大型除草機械にレーザーキャナやデジタルカメラなどの計測機器を取り付け、変状を計測するための技術               |
| 29 | 比抵抗による堤体内滞水状態モニタリング                | 斎藤秀樹<br>応用地質             | 堤体内の状態変化に着目したモニタリングシステム      | 物理探査による危険箇所抽出技術と比抵抗モニタリングシステムによる堤体内部変状の監視技術                   |
| 30 | 河川堤防の変状検知等モニタリングシステムの技術研究開発        | 佐古俊介<br>国土技術研究センター       | 河川堤防変状のモニタリングシステム            | 光ファイバセンサと侵食センサを用いた河川堤防の浸透・侵食に対するリアルタイムモニタリング技術                |
| 31 | 衛星観測を活用した河川堤防モニタリングの効率化            | 片山毅<br>国際建設技術協会          | 河川堤防変状のモニタリングシステム            | ALOS 衛星観測による解析結果と測量結果の比較による経年的な堤防高の変位計測技術                     |
| 32 | 物理探査と地下水観測技術を活用した堤防内部状態のモニタリングシステム | 新清晃<br>応用地質              | 堤防内部状態のモニタリングシステム            | 物理探査を非出水期と出水期に実施して、比抵抗や S 波速度の変化量をもとに堤体内部の湿潤状態等の変化が大きい箇所の抽出技術 |
| 33 | モニタリング技術の活用による維持管理業務の高度化・効率化       | 本間淳史<br>モニタリングシステム技術研究組合 | 社会インフラのモニタリングシステムの基準化・標準化の提案 | 橋梁構造物を中心に、すべてのインフラ管理者を対象として、モニタリング技術を活用するためのガイドライン案を作成        |

|    |  |                      |                             |  |
|----|--|----------------------|-----------------------------|--|
| 34 | IT 等を活用した社会資本の維持管理（点検・診断）                          | 国土交通省                | 様々な IT を活用した社会インフラの点検・診断技術  | 様々な IT を活用した社会インフラの点検・診断技術                         |
| 35 | インフラ構造材料研究拠点の構築による構造物劣化機構の解明と効率的維持管理技術の開発          | 土谷浩一<br>物質・材料研究機構    | 省力・低コストかつ計画的な維持管理を可能とする診断技術 | 土木工学と材料工学の異分野融合や産学官連携研究と人材育成のためのインフラ構造材料に関する研究拠点構築 |
| 36 | 構造物の状態を高度可視化するハイブリッド応力発光材料の研究開発                    | 徐超男<br>産業技術総合研究所     | 構造物の劣化を検出・可視化する高感度応力発光材料    | 高感度応力発光材料を用いた構造物の劣化を検出・可視および損傷レベルの判定技術             |
| 37 | 鋼構造物の腐食による劣化損傷の新溶射材による補修技術の開発                      | 東健司<br>大阪府立大学        | 鋼構造物の金属溶射合金による補修技術          | 防食耐久性に優れた新溶射合金による容易な補修技術の開発                        |
| 38 | 超耐久性コンクリートを用いたプレキャスト部材の製品化のための研究開発                 | 綾野克紀<br>岡山大学         | 高炉スラグを砂として用いる超耐久性コンクリートの製品化 | 交通規制の短縮，確実な施工，改修による耐久性向上を実現するプレキャスト製品の開発           |
| 39 | インフラ予防保全のための大規模センサ情報統合に基づく路面・橋梁スクリーニング技術の研究開発と社会実装 | 家入正隆<br>JIP テクノサイエンス | 道路ネットワークの状態を把握するモニタリングシステム  | 無線センサネットワークによる道路・橋梁群の大規模一括長期モニタリング技術               |
| 40 | 社会インフラ（地下構造物）のセンシングデータ収集・伝送技術及び処理技術の研究開発           | 吉野修一<br>日本電信電話       | 地下構造物を対象としたモニタリングシステム       | 上水管などの地下構造物のお夏データの収集・伝送技術および機械学習による漏水箇所の推定技術       |
| 41 | インフラセンシングデータの統合的データマネジメント基盤の研究開発                   | 安達淳<br>国立情報学研究所      | 目視・打音・非破壊検査による構造物の変状判定技術    | 様々なセンサによる計測データを比較分析するためのマルチセンシング技術                 |

|    |  |                 |                              |  |
|----|--|-----------------|------------------------------|--|
| 42 | 高度なインフラ・マネジメントを実現する多種多様なデータの処理・蓄積・解析・応用技術の開発 | 上田功<br>東日本高速道路  | 高度なインフラ・マネジメントのためのデータ管理技術    | 点検・診断データのDB化および統合的な分析・評価の実施によるインフラ管理を支援する仕組みの提案              |
| 43 | インフラ維持管理・更新に関する多種多様なデータの蓄積・管理・活用技術の研究開発      | 鯨井敏宏<br>日立製作所   | 平成 27 年度終了                   |  |
| 44 | 柔軟静電吸着装置を搭載した半自動飛行マルチコプターによるインフラ構造物点検システムの開発 | 長谷川忠大<br>芝浦工業大学 | インフラ構造物の壁面検査のための半自立飛行マルチコプター | 静電吸着方式により壁面に柔軟に吸着して、構造物の壁面検査を実施するためのマルチコプターの開発               |
| 45 | マルチコプターによる計測データ解析に基づく異常診断技術の研究開発             | 福田敏男<br>名城大学    | 構造物の打音・目視点検のためのマルチコプター       | 打音モジュールとカメラモジュールによる打音・目視点検のためのマルチコプターの開発                     |
| 46 | 人体計測技術を用いた直観的な遠隔操作型ロボットの開発                   | 菅野重樹<br>早稲田大学   | 人体計測技術を用いた直観的なロボット操作技術       | 仮想環境下で再現したガス管路の配管点検における熟練者の人体モデルを構築し、構築した人体モデルによるロボットの遠隔操作技術 |
| 47 | 自主適応桁で支えられる橋梁点検ロボットシステムの研究開発                 | 広瀬茂男<br>ハイボット   | 橋梁の損傷を点検するための近接目視・打音点検装置     | 伸展型アーム、クランプ機構、ワイヤ支持ロッドなどによる近接目視・打音点検を実施するロボットの開発             |
| 48 | 橋梁・トンネル点検用打音検査飛行ロボットシステムの研究開発                | 西沢俊広<br>日本電気    | コンクリート構造物の変状検知のための飛行ロボットの開発  | ポール型打検機によるコンクリート構造物の打音による変状検知を実現するための飛行ロボットの開発               |

|    |  |                        |                                    |  |
|----|--|------------------------|------------------------------------|--|
| 49 | トンネル全断面点検・診断システムの研究開発                            | 中村聡<br>東急建設            | トンネルの打音検査・近接目視のための遠隔操作ロボットの開発      | トンネルのコンクリート覆工面の打音検査・近接目視のための可変形状フレームと防護フレームを用いた点検用フレームの開発          |
| 50 | 橋梁の打音検査ならびに近接目視を代替する飛行ロボットシステムの研究開発              | 大野和則<br>東北大学           | 橋梁の打音検査・近接目視のためのマルチコプターの開発         | 点検用ドローンと通信中継ドローンを用いた打音検査・近接目視技術，および損傷位置・程度の判定技術                    |
| 51 | 近接目視・打音検査等を用いた飛行ロボットによる点検システムの研究開発               | 和田秀樹<br>新日本非破壊検査       | 橋梁の打音検査・近接目視のためのマルチコプターの開発         | ドローン技術を用いた打音検査・近接目視のための点検ロボットの開発，および損傷位置・程度の検出技術                   |
| 52 | 二輪型マルチコプターを用いたジオタグ付近接画像を取得可能な橋梁点検支援ロボットシステムの研究開発 | 沢崎直之<br>富士通            | 二輪型マルチコプターを活用した点検用ロボットの開発          | 二輪型マルチコプターを活用した点検用ロボットの開発および点検データの一元管理システムの提案                      |
| 53 | 無人化施工の新展開～遠隔操作による半水中作業システムの実現～                   | 油田信一<br>次世代無人化施工技術研究組合 | 浅水域・水際における無人化施工を目的とした遠隔操作ロボット車両の開発 | 無人化施工の適用範囲を，作業員が入り込むことは危険な浅水域・水際に拡大し，頻発する水災害への迅速な対応を可能とするロボット車両の開発 |
| 54 | 社会インフラの点検高度化に向けたインフラ構造及び点検装置についての研究開発            | 藤野健一<br>土木研究所          | 社会インフラ・ロボット・人が協調した点検システム           | 橋梁・トンネルなどの社会インフラを対象にロボット技術を用いた近接目視の支援・効率化技術                        |

|    |  |                        |                               |  |
|----|--|------------------------|-------------------------------|--|
| 55 | 点検の省力化・精度向上を目指した機械化移動体点検法と構造形態に関する研究開発           | 土木研究所                  |                               |  |
| 56 | 社会インフラ用ロボット情報一元化システムの構築                          | 森川博邦<br>国土交通省          | 社会インフラ用ロボットから取得した情報の一元管理システム  | 社会インフラの維持管理及び災害時対応へのロボット技術の活用と地域実装に向けた情報一元化システムの構築・運用      |
| 57 | 道路インフラマネジメントサイクルの展開と国内外への実装を目指した統括的研究            | 前川宏一<br>東京大学           | 道路インフラの劣化損傷の検出及び適切な維持管理システム   | 道路構造物の維持管理合理化達成のための要素技術の開発と道路管理者向けの維持管理システムの開発             |
| 58 | コンクリート橋の早期劣化機構の解明と材料・構造性能評価に基づくトータルマネジメントシステムの開発 | 鳥居和之<br>金沢大学           | 北陸地方の道路橋に対するメンテナンスマネジメントシステム  | 道路橋を対象とした点検・診断・モニタリング、評価・判定、対策の一連したメンテナンスマネジメントシステムの確立     |
| 59 | 港湾構造物のライフサイクルマネジメントの高度化のための点検診断および性能評価に関する技術開発   | 加藤絵万<br>海上・港湾・航空技術研究所  | 港湾構造物のための点検・評価・マネジメント支援ツールの開発 | 港湾構造物に適した点検診断技術の開発、栈橋の性能評価・将来予測技術、およびライフサイクルマネジメントシステムの高度化 |
| 60 | 基幹的農業水利施設の戦略的なアセットマネジメント技術の開発                    | 中嶋勇<br>農業・食品産業技術総合研究機構 | 農業水利施設の維持管理のための点検・診断技術        | 農業水利施設の維持管理のための点検・診断技術の開発、および維持管理情報データベース・人材育成システムの開発      |

## 第4章 ドローンを用いた橋梁点検データ収集システム

### 4.1 提案の概要

橋梁のモニタリングに求められるものとして、システムの導入やデータ収集の容易さや技術者や周囲の人々や物への安全性の確保、そして、継続的な利用が可能であることが挙げられる。これは、橋梁の維持管理が市民の利用と平行して長期間に渡り、行われるからである。既往研究では、これらの課題を解決するために無線センサネットワークの構築し、橋梁のモニタリングを行う方法や圧電素子を用いたセンサを用いたセンサの適用も試みられているが、電源供給のための設備が必要なことや部材の疲労などから継続的なモニタリングには適さないという問題が生じている。このようなことから、持続可能な橋梁維持管理のための経済性、安全性、省力化に着目した新たなモニタリングシステムを提案する。

提案する橋梁点検データ収集システムは、技術者が直接アクセスすることが困難な箇所にも容易に接近できる小型ドローンと高画質小型カメラで構成される。図4.1のように、小型ドローンを遠隔操作により橋梁の周囲を飛行させ、数秒ごとにシャッターを切るインターバル撮影機能を使い、カメラ撮影を行うことによって、橋梁点検用の画像を取得する。その後、ドローンにより収集した画像から画像処理を行い、損傷の検出、そして、SfMソフトウェアによって解析を行い、3Dモデルの構築を行う。

小型ドローンと高画質カメラを用いたシステムによって、技術者が直接アクセスすることが困難な高所などへ容易に接近することができるため、橋梁に対して足場を組むことや橋梁点検車などを用いることなく、点検に必要な画像を収集することが可能になる。これにより、技術者の安全性の確保の問題やデータ収集の容易さ、点検にかかるコストの問題を解決することが可能であると考えられる。

### 4.2 従来手法との違いと有用性

これまで橋梁などの技術者が容易に接近することができない箇所の点検用のシステムとして、橋梁点検車や高所点検車などが用いられてきたが、点検に大きなコストがかかってしまい、点検の頻度や質が下がってしまうことや、技術者が直接高所で作業を行うことになるため、技術者の安全性の問題が指摘されている。そのため、新たな橋梁点検システムとしてドローンやロボットを用いた遠隔操作により点検作業を行うことができるシステムが多く研究されている。しかし、ドローンは空中を飛行する物体であるため、墜落してしまう危険性を持ち合わせている。ドローンを用いて、橋梁の高所点検作業を行う際には壁面の損傷、コンクリートのひび割れをドローンに搭載している小型カメラで詳細に撮影を行うことが必要となるため、壁面にかなり近くまで接近する必要がある。その際に、ドローンの操作ミスや突風などを受けることになり、橋桁などの壁面に接触してしまうことになれば、ドローンは墜落することになってしまう。ドローンが墜落することになれば、技術者だけではなく、周囲の住民や走行中の自動車をも危険にさらすことになる。また、遠

隔操作が可能で墜落する危険性が極めて少ないと考えられる，ヘリウムラジコン飛行船を用いることも検討したが，橋梁の損傷を撮影するための小型カメラやラジコンユニットなどを搭載して飛行させるためには，飛行船の全長が2.5メートル程度のパルーンが必要になり，非常に大きなものとなり，橋梁の点検作業使用することは難しい．また，ドローンと比較して，ヘリウムラジコン飛行船は一人で飛行準備や飛行などの作業が難しいことや，ヘリウムガスが高価であり，ランニングコストが非常に高くなってしまうことがあったため，ヘリウムラジコン飛行船を橋梁データ収集システムに用いることは難しいと判断した．表4.1に橋梁点検を実施するにあたっての各機材のメリットとデメリットをまとめる．

本研究では，表4.1のドローンの欠点として挙げられている課題を解決するために，橋梁などの壁面や，周囲の障害物などに接触・衝突が発生した際にも墜落を回避し，飛行を続けることが可能な小型ドローンを開発する．

壁面に接触・衝突が発生した際にも墜落せず，飛行を続けることが可能なドローンが実現となれば，突風などの影響を受け，不意に流されてしまった際にも障害物との衝突による墜落の可能性を低くできる．そのため，橋梁点検時にドローンを使うことの懸念事項であった安全性の問題が解消されることが考えられる．




図 4.1 システムの概要

表 4.1 機材のメリット・デメリット

| 機材                   | 利点   | 欠点  |
|----------------------|--|---|
| 足場<br>橋梁点検車<br>高所点検車 | 技術者が直接橋梁などの損傷を目視点検することが可能                              | 足場を組むことや橋梁点検車や高所点検車などの機材にかかるコストが高い<br>技術者が高所で作業を行うため、危険を伴う。<br>安全性の確保のためのコストが高くなる   |
| ラジコン飛行船              | 技術者が高所で点検することが不要になる<br>ドローンと比較して、墜落の恐れが極めて少ない          | ヘリウムガスの浮力で持ち上げることができる質量が非常に小さいため、カメラやラジコンユニット、バルーン本体を持ち上げるためには非常に大きなバルーンと大量のヘリウムガスが必要<br>機体が非常に大きなものになってしまうため、橋梁下部などの場所が狭いところでは使用できない<br>ドローンと比較して、動作が鈍いため、操作性が悪く、機体が大きなものとなるため風の影響も受けやすい |
| ドローン                 | 技術者が高所で点検することが不要になる<br>技術者が直接接近することが困難な箇所へも容易に近づくことが可能 | 橋梁の壁面や、周囲に存在する障害物などに接触した際の墜落の危険性<br>バッテリー持続時間が短い  |

### 4.3 ドローンについて

#### 4.3.1 ドローンの安全対策

橋梁点検データ収集システムにドローンを使用するためには、橋梁の壁面近くまで接近し、橋梁周辺や、コンクリートのひび割れなどの損傷を小型カメラにて撮影出来ること、そして、橋梁の周囲に存在する障害物などにドローンが接触した際にも墜落を防ぐことが出来る装置が必要と考えられる。そのため、ドローンが橋梁の壁面や、その他の障害物に接触してしまうことを前提として考えておく必要がある。また、壁面に接触した状態であっても、ドローンが身動きを取ることができれば、ドローンを衝突させてしまうことを恐れる必要がなくなり、より扱いやすいものとなると考えられる。



4.2 節で述べたように、ドローン（クアッドコプター）には、障害物と接触・衝突した際には、高い確率で墜落するという、橋梁点検データ収集システムにとって致命的な欠点を持っている。そのため、本研究では、ドローンを改造することによって、ドローンの安全性の向上・墜落の危険性を下げを試みる。

一般に市販されているドローンの多くでは、機体の周辺に軽量のプラスチック製（図 4.2）や発泡スチロール製（図 4.3）のバンパータイプのガードを機体の一番外側の部分に装着することによって、障害物や壁面に接触した際の衝撃の吸収やプロペラの接触をある程度防いでいる。



図 4.2 DJI 製 Phantom マルチコプター



図 4.3 Parrot 製 Bebop Drone（メーカーHP より）

しかしながら、このようなバンパータイプのガードには欠点が存在している。バンパーガードが装着されていることによって、障害物にプロペラが接触することを避けることができるため、プロペラが停止することによる墜落は、程度にもよるが防ぐことができていた。しかしながら、壁面に向かって飛行を行っている際に壁面に接触してしまった場合に、バンパーガードと壁面との摩擦抵抗によって、ドローンの動きが制限されてしまう。ドローンは進行方向に機体を傾けて進むため、接触時にドローンの前部が固定されてしまうことになる。ドローン後方部が持ち上がり、バランスを崩してしまう。それによって、壁面にドローン上部が張りついてしまうことが度々発生した（図 4.4）。

壁面にドローン上部が張りついてしまった際には、操縦者からは、なすすべがなく、墜落させることしか選択肢がなかった。バンパーガードによる障害物への接触に対する対策には、このような問題を抱えているため、ドローンに対して、障害物への接触に対する新たな対策を取らなければならないと考えられる。



図 4.4 バンパータイプのガードの欠点による墜落

#### 4.3.2 ドローンの改良

本研究では、橋梁などの壁面に接触・衝突が発生した際にも墜落せず、飛行を続行することができる橋梁点検データ収集システムのためのドローンを開発するために、次のようなものを用いている。

##### 小型ドローン（主要諸元）

機材名：RC EYE One Xtreme

メーカー：RC Logger

種類：クアッドコプター（4つのプロペラを持つ）

寸法：全長 225 ミリ x 全幅 225 ミリ x 全高 80 ミリ

重量：157 グラム（バッテリーを除く）

バッテリー：7.4v 1150mAh

最大積載量：100 グラム

飛行時間：約 10 分

センサ：6 軸センサ，高度センサ

価格：3 万円前後

本研究で採用した図 4.5 に示す RC EYE One Xtreme と呼ばれる小型ドローンは、RTF（Ready to Flight）となっており、機材の組み立ては、ほとんど必要がなく、ドローンに対する専門知識は不要である。そして、大容量バッテリーなどのアフターパーツが豊富であり、容易に分解ができる構造であるため、機体の性能向上を目的としたカスタマイズが可能である。そのため、改造ベースのドローンとして採用した。



図 4.5 RC EYE One Xtreme（メーカーHP より）

4.3.1 で述べたようにバンパータイプのガードは、障害物との接触時において、障害物との摩擦抵抗によってドローンの動きを制限制限してしまう問題を抱えている。その問題点によって、接触時にドローンがバランスを崩してしまうことになり、墜落が発生する場合がある。ドローンをより安全に利用することができるためには、この問題に対する対策が必要であると考える。

本研究では、この問題点を解決するために、ドローンの前後方向にホイールタイプのガードを作成し、装着する。障害物との接触時において、ホイールが回転することによって衝撃を吸収することを試みる。それにより、バンパータイプのガードによるドローンの動きが制限される問題の解決を試みる。

改良のベースとなるドローンは、図 4.5 に示した **RC EYE One Xtreme** である。このドローンの前後方向にホイールタイプのガードを装着するためには、前後方向に向けてドローンのアーム延長しホイールを装着するためのアタッチメントを作成する必要がある。また、ベースとなるドローンは、小型ゆえに積載量可能な重量もそれほど多くはない。そのため、できる限り軽量にガードを作成することが必要である。

さらに、作成するドローンは、壁面や天井などの障害物に接触させることが前提となるため、多少の衝撃を受けた際にも壊れにくいことや、もし破損した際にもすぐに部品を調達し、安価に修理・加工を行うことができるようにするために、部品は主にホームセンターで手に入る部材を使用して、ガードの作成を行った。

使用した部品は以下のものである。部品代は、3,500 円程度であった。

- ・ カラーワイヤー (線径 2.6 ミリメートル)
- ・ アクリルパイプ (直径 1 センチメートル)
- ・ アクリルパイプ固定用ネジ (2 ミリ × 15 ミリメートル)
- ・ Parrot 製ホイール (直径 17 センチメートル)

### 4.3.3 プロトタイプ 1 代目

はじめに作成したプロトタイプ 1 代目 (図 4.6) は、ドローンのプロペラが装着されている 4 本のアームにホームセンターで購入したアクリルパイプを装着して、アームを延長し、その先に Parrot 製のホイールを装着している。

アクリルパイプは、18 センチメートル × 4 本にカットし、Parrot 製のホイールをアクリルパイプに装着するための切り欠きと固定用のネジ穴を作成。作成した 4 本のアクリルパイプは、ドローンのアームに直接ネジ止めすることによりしっかりと固定した。

しかし、アクリルパイプは、カットやネジ穴を開けるなどの加工時に非常に割れやすく、加工がしやすいものとは言えなかった。今回のように加工が必要となる場合は、異なる材質の割れにくいものを使用する方が良いと思われる。

Parrot 製のホイールは、ドローンのアームと同じ高さに回転軸が来るように装着を行っている。このホイールの直径は、17 センチメートルとなっており、ドローンの高さを大き

く上回っている．そのため，前後方向の障害物への接触時のためのガードとして，衝撃を吸収する役割だけではなく，天井へ接触した際の上部方向へのガードとして機能することや，ランディングギアとしての役割も持たせることも可能となった．

作成したホイールタイプのガードを装着した状態での飛行に関しては，非装着時と比較して重量が増えているため，デフォルトのビギナーモード設定(パワー制限)では，離陸が不可能であった．ドローンの変更することで，多少操作が重い感じがあれども，しっかりと飛行させることが可能であった．



a) 斜め前からの写真



b) 上部からの写真

図 4.6 プロトタイプ 1 代目

プロトタイプ 1 代目を作成後，実際に屋外にて飛行実験を行った．主に建物の壁面にドローンを衝突させ，その際に起こるドローンの挙動，また，壁面に接触した状態での移動が可能であるかを検証した．

その結果，バンパータイプのガードと比較して，壁面との接触時には，衝突の衝撃を吸収するとともに，ホイールが回転することによって，壁面との摩擦抵抗が発生せず，バランスを崩して墜落に陥ってしまうことは，軽減された．しかしながら，壁面に接触した状態のまま，ドローンを上昇させるなどの移動をさせようとした場合，壁面に接触しているホイールが回転軸となり，ドローンの後部が持ち上がってしまうことによって，ドローン上部が壁面に張りつく状態が発生した．また，勢いがついた状態で壁面に接触した場合には，ドローンが進行方向に機体を傾けて進んでいることもあり，機体前部がホイールの回転によって，さらに下方向に向いてしまい，機体後部が持ち上がることによって，ドローン上部が壁面に張りつく状態が発生することとなってしまった (図 4.7)．

また，強い力で壁面に衝突させた場合には，アクリルパイプの切り欠きに挟み込んで固定したホイールが脱落してしまう症状も発生した．



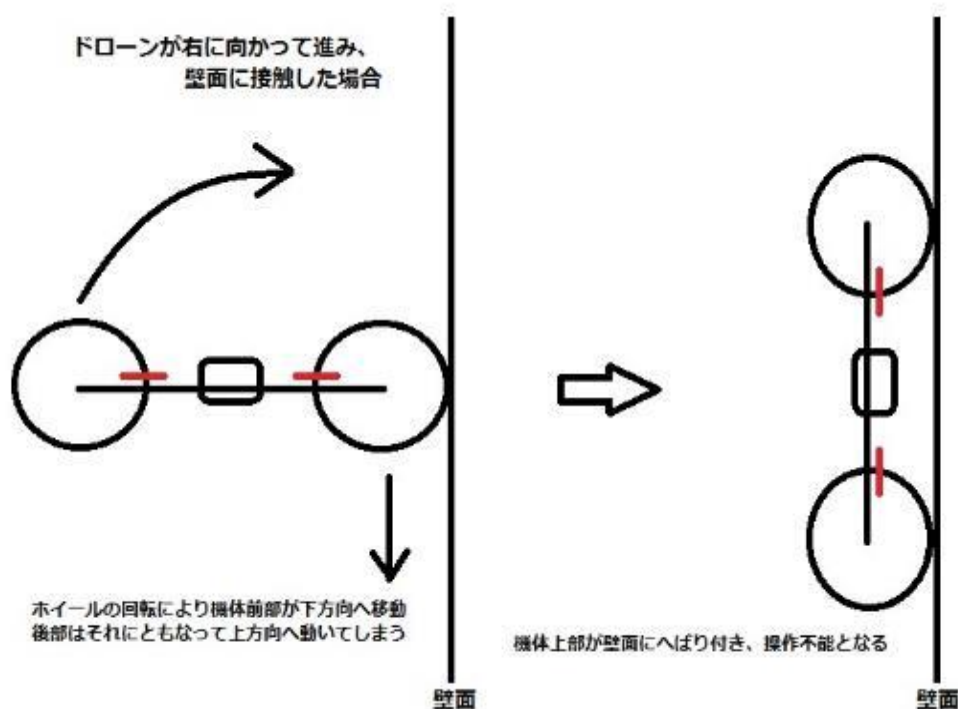


図 4.7 壁面に接触したドローンを横から見た図

このホイールタイプのガードによって、バンパータイプのガードに比べて壁面との摩擦によって機体前部が固定されることが原因でバランスを崩すことは、軽減することができた。

しかしながら、壁面に接触した際にホイールの回転が必要以上に発生することによる機体後部の持ち上がりや、機体前部が下方方向に動いてしまうという症状が発生することとなってしまった。そのため、この新たに発生した問題を解決するために機体前後の動きを抑える対策や、大きな衝撃を受けた際にもホイールが脱落せず、衝撃を吸収するための対策を施す必要がある。

#### 4.3.4 プロトタイプ 2 代目

4.3.3 で作成したプロトタイプ 1 代目での飛行実験の結果より、ベースとなったドローンのアームを延長し、ホイールを装着することによって、バンパータイプのガードの欠点である、機体前部が固定される問題は解消できた。しかしながら、ホイールを機体に装着したことにより、バンパータイプのガードを装着していた場合には発生していなかった動きが発生し、壁面に張りつく現象が新たに発見された。そして、ホイールタイプのガードにより、壁面などの障害物に接触した状態でドローンが動くことを期待したが、実際には、壁面に張り付いてしまい、墜落に陥ることとなってしまった。また、ホイールの固定方法が弱く、ドローンに強い衝撃を与えた際には、ホイールが脱落する症状も発生

した。

そのため、プロトタイプ 2 代目 (図 4.8) では、これらの問題を解決するために、ホイールの取り付け位置を変更を行う。ホイールを固定する箇所に使用する素材は、壁面衝突時の衝撃を吸収する機能を持たせるために、比較的軽量で、柔らかい素材であるカラーワイヤーを使用した。また、強い衝撃を受けた際に、ホイールが脱落する可能性を下げるために、カラーワイヤーとホイールの固定には、ホットボンドを使用することでしっかりと固定を行っている。

プロトタイプ 2 代目のホイール位置は、プロトタイプ 1 代目と比較して、前方に約 10 センチメートル、上方向に約 8.5 センチメートル移動した。また、機体側面にはカラーワイヤーで簡易的なガードを追加で作成している。約 10 センチメートル前方にホイールを移動させた理由としては、衝突時の衝撃を吸収させる領域を作ることと、ドローンのプロペラとの干渉を避けるためである。また、ホイールを上方向に約 8.5 センチメートル移動したため、ホイール下部とドローンのアームの高さが同じ位置となっている。それゆえに、ホイールをランディングギアとして使用することが出来なくなってしまった。そのため、RC EYE One Xtreme の純正オプションにラインナップされている、ランディングレグ (79mm) を加工して、ドローンの底部に接着して取り付けた。



図 4.8 プロトタイプ 2 代目 (ホイールを 1 代目より前方に高く設置)

図 4.8 のように、ホイールをドローン上部より高い位置に移動させることによって、衝突時にドローンが前傾姿勢であった場合でも、ホイールが高い位置に存在することでドローン後部が持ち上がりにくくなること、また、カラーワイヤーで作成したアームを前方向斜め上に向けて設置することで、衝突時にカラーワイヤーが上向きに曲がり、ホイールが下方向に回転しようとしさせないことを狙った。

プロトタイプ 2 代目において、次のような飛行実験を行った。

- ・ドローンの重量がガードの装着によって増えているが飛行することが可能か。
- ・屋外にて建物の壁面に向かって衝突させ、衝突後にも飛行が継続可能であるか。
- ・壁面にドローンが接触した状態でも移動することができるか。
- ・天井など上部に存在するものに衝突しても飛行を継続することができるか。

これらのことに関してを主に検証を行った。屋外での飛行実験の結果、1 点目のドローンの重量がガードの装着によって増えているが飛行することが可能か、の検証について、ドローンの重量がプロトタイプ 1 代目より重量が増えており、ホイールの位置が機体からより離れた位置に変更となったが、無事飛行することが可能であった。ただし、ドローンの操作感は無改造の機体とあまり違いが感じられなかったプロトタイプ 1 とは異なるものになっている。ドローンの重量が増えていることに加え、ドローン中心部から離れた箇所に重量物を装着したことによる影響であると考えられる。操作感としては、操縦者の操作に対するレスポンスが鈍くなり、ドローン操作の微調整が難しくなったように感じられた。そのため、操縦には、慣れが必要になると思われる。しかし、この点については、GPS などの各種センサによる操縦の補助機能が搭載されているドローンをベース機体に変更することである程度、改善できるのではないかと考えられる。

2 点目の項目の、屋外にて建物の壁面に向かって衝突させ、衝突後にも飛行が継続可能であるかの検証について、実験の結果、ドローンが壁面に衝突した後も、継続して飛行することが可能であった。バンパータイプのガードやプロトタイプ 1 代目が壁面に衝突した際に発生していた、壁面にドローンの上部が張り付く現象は、プロトタイプ 2 代目では、発生することはなかった。

ドローンに取り付けたホイールの回転軸が機体の最上部よりも上に設けたことによって、ドローンの後部が持ち上がりにくくなった。さらに、衝突時にカラーワイヤーが上方向に曲がり、ホイールをドローン上部より高い位置で保持するために、ドローンの前部が下方向に動く現象も発生しなくなったのだと考えられる（図 4.9）。また、ホイールを取り付ける箇所にカラーワイヤーを使用したことによって、カラーワイヤーの弾力性により衝撃を受け止めることができていた。カラーワイヤーが衝撃を受け止めた後、カラーワイヤーの反力によって、ドローンが壁面から跳ね返され、ドローン前部が上方向に向けられる現象も確認できた。このこともドローンが壁面に張り付く現象が発生しなくなった原因と考えられる。また、ホイールの取り付けには、ホットボンドを使用し、しっかりと固定を行ったため、衝突によるホイールの脱落も発生することはなかった。





a) 壁面への衝突が発生



b) 衝突時の衝撃をカラーワイヤーで吸収している.



c) ワイヤーの反力もあり，前方が下に移動せず，壁面に張付く現象は起きていない.



d) ホイールの回転によって，前部が固定されることも発生しない.



e) 前方が少し下に移動して，バランスを崩す.



f) 前方が少し上に移動して，バランスを持ち直す.



g) ほぼ水平となり，バランスを持ち直す.



h) 墜落せずに水平飛行に戻ることができた.

図 4.9 壁面への衝突実験

3 点目の壁面にドローンが接触した状態でも移動することができるかの検証について、2 点目の実験を同じ場所にて実験を行った（図 4.10）。

実験の結果、ドローンが壁面に接触した状態のまま、ホイールの回転によってスムーズに動くことが可能であった。プロトタイプ 1 代目の場合は、壁面に接触した状態で上昇を行う操作をしたところ、ドローンの後部が持ち上がり、壁面に張り付くことになってしまっていた。プロトタイプ 2 代目で、壁面に張り付く現象が発生することがなかった理由は、ホイールの回転軸が上に上がり、後部が持ち上がりにくくなったためである。また、ドローンのスロットルを上げることによって、大きな力を加えた場合、後部が持ち上がる現象が発生するかと思われたが、スムーズに機体が上昇しただけであった。



図 4.10 壁面に接触した状態での移動

4 点目の天井など上部に存在するものに衝突してた際に、飛行を継続することができるかの検証について、この実験に関しては、屋内で行った（図 4.11）。

飛行中にドローンを天井まで上昇させ、接触させてみたところ、ドローン本体や、プロペラよりも先にホイールが天井に接触し、カラーワイヤーが衝撃を吸収したため、そのまま飛行を続けることが可能であった。また、天井に沿ったままの移動も問題なく操作が可能であった。



図 4.11 天井などの上部への接触

#### 4.3.5 考察

これらの実験の結果より、プロトタイプ 2 代目では、既存のバンパータイプのガードを装備したドローンや、プロトタイプ 1 代目などで問題となっていた、壁面に接触した際にバランスを崩し、壁面に張り付く現象が起こることによる墜落や、衝突時におけるホイールの脱落を解消し、墜落の可能性を下げる事ができたと考える。プロトタイプ 2 代目では、カラーワイヤーを用いたアームにより、ドローン最上部より高い位置にホイールを装着することによって、衝突時にドローンにかかる力を逃がし、ドローンの衝突安全性を確保することや、壁面や、天井に接触した状態での移動が出来る。それにより、橋梁下部や、橋桁に接近、接触した状態が発生した場合でも、安全に飛行することが可能である。衝突時の安全性が高められたことによって、突風など、風の影響を受けることでドローンが流され、不意に橋梁などの壁面だけでなく、周囲の障害物などに衝突することが発生した際にも、墜落に陥ることなく飛行を続けることができると考えられる。

#### 4.4 ドローンに搭載するカメラについて

本研究で、ドローンに搭載し、橋梁の写真を撮影を行うカメラとして、次のものを採用している。

##### 高画質小型軽量カメラ（主要諸元）

機種名：GoPro HERO 4 Black Edition

カメラサイズ：59 ミリ × 40.5 ミリ × 30 ミリメートル

カメラ重量：88 グラム

静止画撮影時画素数：1200 万画素

動画撮影画質：WVGA から最大 4K 画質まで対応

インターバル撮影モード：あり(0.5, 1, 2, 5, 10, 30, 60 秒間隔)

ワイヤレス通信機能：Wi-Fi, Bluetooth

スマートフォンアプリ：iOS, Android

バッテリー：1160mAh (4K 動画撮影時に約 1 時間使用可能)

記録メディア：microSD (64GB まで)

本研究で採用しているドローンの RC EYE One Xtreme は、小型軽量なドローンである上に、ホイールタイプのガードを自作、取り付けを行っているため、積載可能な重量や、スペースが非改造機体に比べて非常に限られている。そのため、カメラも小型でできる限り軽量である必要があった。また、ドローンで飛行しながら、橋梁の写真を撮るためには、一定間隔でシャッターを切り続ける機能が必要であり、ドローンが飛行している際の揺れが起きる環境であっても高画質な写真を撮れなければならない。

GoPro と呼ばれるカメラは、スポーツや、ウェアラブルなどの用途に特化されたアクションカメラに分類される。そのため、デジタルカメラとしては、非常に軽量・コンパクト

に作られている。また、テレビのバラエティ番組で、体を張ったコーナーのヘルメットマウントカメラとして使用されることも多いことから、画質面での評価の高さも伺うことができる。一定間隔でシャッターを切り続ける、インターバル撮影機能や、スマートフォン・タブレットとの Wi-Fi 接続による、リアルタイムな映像確認、遠隔操作機能も有しており、ドローンのような操縦者から離れた箇所で撮影を行う用途に必要と考えられる機能が一通り揃っている。これらの理由から、GoPro は、ドローンに搭載するカメラの条件を満たしていると考えられたため、GoPro シリーズの最新フラグシップ機である、GoPro HERO 4 Black Edition をドローンに搭載するカメラとして採用した。

## 第 5 章 3 次元モデルの構築スキーム

### 5.1 図面が残されていない橋梁

現在、既存の橋梁の図面を保存・管理できていない自治体が多く存在していることがわかっていて、橋梁の詳細が示された図面がなければ、橋梁の点検後、補修工事をする事ができない。したがって、その橋梁の図面を時間とコストをかけて、作り直す必要性が発生する。

ドローンによって収集した画像から 3D モデルを作成し、橋梁外部の図面を簡易的に作成することで図面の作成の補助が可能となれば、0 から測量し、橋梁の図面を起こす場合に比べて、時間とコストを削減できることが考えられる。

本研究では、ドローンを用いてカメラ撮影を行うことで取得した画像から、3D モデルの作成をすることが可能であるか検証を行った。

### 5.2 3 次元モデルの作成

本研究では、Structure from Motion (SfM) ソフトウェアを使用し、ドローンによって収集した複数の画像から、3D モデルの構築を試みる。

カメラを搭載した小型ドローンを、対象物の周囲を飛行させ、カメラのインターバル撮影機能を使用して、対象物の写真を複数枚連続撮影を行う。撮影後、収集した写真を SfM ソフトウェアによって処理を行い、カメラの位置と 3D モデルを再現する。

Structure from Motion (SfM) [14][15][16][17]とは、複数枚の様々な視点から撮影された画像から、各画像の特徴点抽出と画像間の特徴点の対応付けを行い、撮影時のカメラの位置を推定し、対象物の 3D 形状を再現する技術である。

本研究で使用したソフトウェアは、SfM 法により 3D モデルを作成できる VisualSFM と 3D の点群データを編集・加工ができる MeshLab の 2 つである。ともにフリーウェアである。

3D モデルを作成する際の主な流れは次の通りである。

- 1) ドローンを使用し、対象物の周囲の撮影。複数枚の画像から特徴点を抽出し、画像間で対応付けを行うため、画像間が重なるように撮影を行う。
- 2) 撮影を行った後、VisualSFM に画像を読み込み、特徴点の抽出、画像間の特徴点の探索する。
- 3) 撮影時のカメラの位置の推定と画像間の特徴点の対応付け（マッチング）を行い、粗い点群の作成する（図 5.1）。




図 5.1 カメラの位置の推定，画像間の特徴点の対応付け

- 4) 前項目で推定した，カメラ位置や対応付けた画像間の特徴点などから，密度の高い点群を作成する（図 5.2）




図 5.2 密な点群の作成



- 5) MeshLab に VisualSFM によって作成された点群を読み込み、3D モデルに復元を行う部分以外の不要な点群を削除する (図 5.3)。



図 5.3 不要な点群の削除

- 6) 不要な部分が削除された点群から、サーフェス（面）を作成する。その際に、不要なサーフェス（面）ができた場合は、選択して削除する (図 5.4)。




図 5.4 サーフェス（面）の作成と削除

- 7) 作成したサーフェス（面）にテクスチャを貼り付ける (図 5.5)。




図 5.5 テクスチャの貼り付け

以上で 3D モデルの作成が完了となる。



### 5.3 実験内容

ドローンを用いて撮影を行い、取得した画像から、3D モデルを作成することが可能かを検証するために、いくつかの異なる条件下で撮影を行った画像を用いて、3D モデルの作成実験を行った。

#### 5.3.1 屋内の椅子

はじめの実験として、屋内の椅子を手持ちで 360 度撮影を行い、3D モデルの作成を行った。手持ちでの撮影で対象物全体を撮影することが出来る、小さな対象に設定することで、確実に対象物の周囲を撮影が出来る。後に行うドローンで撮影を行った画像から 3D モデルを作成した場合の結果と比較する。

撮影枚数は、35 枚、上方向や、横方向から画像間が重なるように撮影を行った。VisualSFM で画像間のマッチングに使用できた画像は、35 枚全てである。作成出来た 3D モデルと撮影した画像の一部を図 5.6 に示す。

作成出来た 3D モデルは、撮影時に影が発生した部分に一部欠損している部分が見られるが、ほぼ実物に近いモデルであると感じることが出来る。この結果から、撮影時に、対象物の周囲をきちんとカメラがトレースし、画像間が重なるように撮影することができていれば、ほぼ実物に近い、3D モデルを作成することが可能であることがわかった。




図 5.6 屋内の椅子を 3D モデル化

#### 5.3.2 乗用車

ドローンにカメラを搭載して、乗用車を対象とした撮影を行い、3D モデルを作成した。対象が乗用車となり、1 の実験での対象より大きいものとなった。また、乗用車の上部は、手持ちでの撮影が難しいため、この実験からドローンにカメラを搭載して撮影を行った。

撮影枚数は、135 枚、上部から下部まで、もれなく 360 度撮影した。画像間のマッチングに使用できた画像は、134 枚となった。作成出来た 3D モデルと撮影した画像の一部を図 5.7 に示す。

ドローンにカメラを搭載して空撮による撮影を行った画像からも、3D モデルを作成することが可能であった。しかし、画像間のマッチングの結果において、大幅にずれた点群が作成されている部分が見られた。これは、対象物が単色塗料で塗装されたものであり、表面が非常に滑らかに仕上げられていることと、自動車の塗装は特に光沢やガラスがあり、反射することで、特徴点を抽出しにくいものであることが原因であると考えられる。今回の実験では、乗用車の大きさが小さいことがあり、周囲をドローンで 8 周周回し、空撮を行うことが出来たため、多くの角度から画像間が重なる状態で多くの写真を撮影を行うことが出来た。それゆえに、一部の写真がずれた状態でマッチングが行われ、乗用車から外れた位置に点群が作成された場合にも、異なる角度から撮影された画像により乗用車の 3D モデルが作成されることで、乗用車自体の 3D モデルには影響が感じられなかった。外れた位置に作成された点群は、他の不要な点群と一緒に削除した。このため、なめらかで、反射の強い対象物の場合には、出来る限り多くの写真を様々な角度から撮影を行うことが必要であると考えられる。



図 5.7 乗用車を 3D モデル化

### 5.3.3 建物

ドローンにカメラを搭載し、空撮を行った画像から 3D モデルを作成することが可能であることが実験により検証できたため、建物などの大きな建造物を撮影し、3D モデルの作成を試みる。

対象とした建造物は、関西大学 高槻キャンパス B 棟横の外階段、L 棟(食堂、購買店)に繋がる橋である。

B 棟横の外階段の撮影枚数は、96 枚であるが、撮影を行った全ての写真を使用して、3D モデルの作成を行った場合、画像間のマッチングができた画像は、21 枚となっており、背景に映る建物などが曖昧に再現されてしまい、外階段の 3D モデルを作成することができなかった(図 5.8)。

撮影時は、カメラのインターバル撮影機能を開始させてから、ドローンで空撮を行うため、地面のみが写っている画像やドローンを移動させる際に撮影された対象物がほとんど写っていない画像が多く含まれていた。そのため、3D モデルの作成がうまくいかなかった




図 5.8 対象の外階段ではなく，背景が曖昧に再現されている

と考えられる．また，対象物の外階段が写っている画像に関しても，外階段以外の背景などが占めている割合が比較的大きく，そのため外階段ではなく，背景に写る建物が曖昧に再現されてしまったと考えられる．

対象物以外がほとんど写っていない写真の削除を行い，外階段が写っている 46 枚の画像を使用した．さらに，背景が曖昧に再現され，対象物が再現されないことを避けるために画像の背景を黒く塗りつぶし，再度 3D モデルの作成を試みた．結果を，図 5.9 に示す．



図 5.9 高槻キャンパス B 棟横の外階段を 3D モデル化

撮影画像を整理し，46 枚の画像を使用して 3D モデルの作成を試みた結果，44 枚の画像で画像間のマッチングを行うことが出来，コンクリートで作られた外階段を 3D モデル化することが出来た．背景を塗りつぶした効果もあり，背景が再現され，外階段が 3D モデル化されない現象も起こらず，外階段が忠実に再現された．しかし，外階段の空間が空いている部分や，フェンスの部分などの箇所は，密な点群が作成されておらず，復元が出来てい

ない。そのため、さらにドローンを接近させ、詳細な画像を撮影する必要があると考えられる。また、ドローンをさらに接近させて空撮を行うことにより、対象物以外の背景が写ることを避けること可能だと思われる。画像に背景が写る割合を下げることによって、画像の余分な部分を塗りつぶす必要性はなくなると予想される。

次に L 棟（食堂、購買店）に繋がる橋を対象にドローンを用いて空撮を行い、3D モデルの作成を試みた。今回も、撮影画像を整理し、対象物が写っていない画像を削除した 72 枚の画像を用いて 3D モデルの作成を試みた。結果を図 5.10 に示す。



図 5.10 高槻キャンパス L 棟(食堂、購買店)に繋がる橋を 3D モデル化

72 枚の画像を使用して 3D モデルの作成を試みた結果、画像間のマッチングを行うことが出来た画像は、18 枚の画像であった。作成できた 3D モデルは、橋の中間部分までと、橋の下から繋がる通路が再現されている。このような結果になった理由は、橋の横に存在する木々を避けるために、ドローンでの空撮を橋から離れた箇所から行った部分があることが挙げられる。そのため、接近して撮影できた画像のみ画像間のマッチングが行われ、橋の中間部分までしか再現されなかったのだと考えられる。

## 5.4 考察

5.3 節で行った実験の結果、小型ドローンを用いた空撮によって撮影を行った画像から、3D モデルの作成が出来ることが分かった。しかしながら、本研究で行った実験では、3D モデルの作成を行う対象物の規模が大きくなるにつれて、再現度が下がることが実験の結果から見られる。はじめに行った、屋内の椅子を対象物に設定し、3D モデルの作成実験を行った結果から、確実に対象物の周囲を画像間が重なるように撮影を行うことが出来れば、ほぼ実物に近いモデルが作成出来ることが分かる。

乗用車を対象とした実験の結果からは、対象物が単色塗料で塗装されたものであり、表面が非常に滑らかに仕上げられていることと、自動車の塗装は特に光沢があり、反射することから、大きくずれたとみられる点群が作成される部分が一部存在したが、多くの角度

から画像間が重なる状態で多くの写真の撮影を行うことで、乗用車の外観の形状を再現することができた。これらの結果から、3Dモデルの作成にドローンを用いた空撮による画像を使用する事が出来、多くの角度から画像を撮影できるドローンを用いた空撮は、3Dモデルの作成を行う上で有効である。

屋内の椅子と乗用車の3Dモデル、画像を整理して3Dモデルを作成したB棟横の外階段の場合には、画像のほとんどが画像間のマッチング出来ていたが、L棟（食堂、購買店）に繋がる橋を対象物とした実験では、マッチングできた画像が大きく減っていた。ドローンでの撮影時に、橋の横に存在する木々を避けるために、橋から離れていたため、撮影した画像に写ったものが、橋以外の部分が大きく占めており、橋が小さく写っていたことが原因であると考えている。そのため、橋が大きく写っている画像間でマッチングが行われ、橋の中間部分までしか再現出来ない結果になってしまった。

これらの実験の結果から、ドローンで空撮を行い、3Dモデルを作成することは可能である。しかし、対象物の撮影の出来具合によって大きく結果が変わる。3Dモデルを作成するためには、

- 1) 出来る限り、対象物がメインとなるように大きく写し、対象物以外の写り込みが少ないうように撮影を行う。
- 2) 出来る限り多くの角度から、多くの写真の撮影を行う。

この2点が特に重要になっていることが分かった。また、L棟（食堂、購買店）に繋がる橋を対象物とした実験において、対象物が大きく写っている画像間でマッチングが行われ、写りが小さくなっていた画像がマッチングされなかったことから、撮影時に対象物との距離をある程度保ち、画像に写る対象物の大きさの変化を小さく保つ必要性があることが考えられる。今回建物を対象とした実験では、外階段の3Dモデル化については、比較的再現度が高いと感じられたが、L棟（食堂、購買店）に繋がる橋の3Dモデル化については、再現度が低い結果となった。しかし、撮影方法を改善することによって、再現度が上げることが可能であると予想できる。

以上の結果より、ドローンを用いて空撮を行った画像から3Dモデルを作成することができ、実橋梁の図面の作成のための3Dモデルの作成も可能になると考えられる。



## 第6章 パターン認識

### 6.1 パターン認識とは

人は五感を用いてパターン認識を行っている。目でものを見、耳で聞き、匂いで周囲の状況を認識している。目でものを見る場合は、ものの像が光のパターンとして網膜に投影される。人は網膜に投影された「投影像」そのものを用いてパターン認識を行っているわけではない。投影像が何かを判断するために有効な特徴を抽出する段階が存在する。「何か」を判断することを識別といい、「有効な特徴」を抽出することを特徴抽出という。「有効な特徴」と「何か」を結び付ける規則を識別規則といい、われわれはこの規則を学習している[18]。一般にパターン認識手法というときは、識別を行う主体はコンピュータであり、人間が行っているパターン認識をコンピュータに代行させようというものである。この場合のパターンは画像や音声信号、各種計測装置による測定結果などのように、1次元あるいは多次元の信号を含む。パターンは文字や音声のように人間が意図的に生成したものと、風景画像のように自然に存在するものに分類することができる。このようなパターンを、その内容によって何らかの概念に結びつける処理がパターン認識である。たとえば文字認識では、「あ」という形状の図形パターンを、ひらがなの「あ」という言語概念に対応付ける。また音声認識では、話者によって発せられた「あ」という1次元音声信号パターンを、同様に「あ」という言語概念に対応させる。つまり、パターン認識は既知のパターンを似たパターンごとにいくつかのグループに分けて、各グループをそれぞれ別個の概念に対応させ、未知パターンがどのグループに属するかを決定する機構である。パターン認識においてこのグループをクラスと呼ぶ。これらのような処理をするためには以下のような問題を解決しなければならない。

- 1) パターンを、どのように記述・表現するのか
- 2) ある複数のパターンが似ていることをどのように判断するのか
- 3) 全体をいくつかのクラスに、どのように分ければよいのか
- 4) 未知のパターンがどのクラスに属するかをどのように決定するのか

われわれは無意識のうちにこれらの処理を非常に高速に行っている。また、われわれがどのようにしてこれらの処理を脳の中で行っているかを知るとは非常に困難であり、生物のパターン認識の詳細な理論と機構はいまだ解明されていない。このため、工学的な応用の観点からは、実現したいパターン認識処理を限定し、対象とするパターンの予備知識などを利用して、限定された機能を実現することが行われている。しかし、その実現方法は一般に設計者によって異なり、すべての処理に有効な汎用的手法は存在しない。

### 6.1.1 パターン認識の過程

パターン認識の基礎的な過程は、パターン分類の過程と、パターン識別の過程に分けて考えることができる[19]。はじめに、図6.1にパターン分類の過程を示す。図3.1に示すパターンの分類過程における各処理について画像のパターン認識を例にして以下に示す。




図 6.1 パターン分類の過程

- 1) 入力：パターンを2次元信号として取得する。この際、光学系によって撮影した画像に対するA/D変換により量子化を行う。量子化のサンプリングの幅を十分小さく取らないと、この過程における入力データの劣化および損失が後の処理で問題になる場合がある。
- 2) 前処理：前処理部においては、入力パターンの大きさが一定の大きさになるように入力パターンを拡大または縮小を行うことや、回転角度を一致させるなどの幾何学的な補正や、ノイズ除去などの画像処理を必要に応じて行う。これらの処理は後の処理の実行を容易にするためのものである。
- 3) 特徴空間の設定：入力パターンを的確に表現することができるいくつかの特徴を選択することによって特徴空間を設定する。
- 4) 特徴抽出：特徴抽出部においては、入力パターンに対して、特徴空間の各軸の特徴の大きさを求めることによって、入力パターンを特徴空間上の点に写像する。
- 5) 分類：複数の入力パターンを写像して得られた特徴空間中の複数の点を、いくつかのクラスに分割する。
- 6) 標準パターンの生成：各クラスを代表する特徴空間中の点を決定する。この点は各クラスの平均的な特徴をもった標準パターンである。

パターン分類の過程が終了したら、次に未知パターンの識別を行う。パターンの識別過程を図6.2に示す。パターン入力から特徴抽出までは、パターン分類の過程と同様である。次のパターンマッチングの処理において、入力パターンについて求めた特徴とあらかじめ求めた標準パターンの特徴を比較する。そして標準パターンが代表している特徴空間中の最も近いクラスに、入力パターンが属するものと決定する。

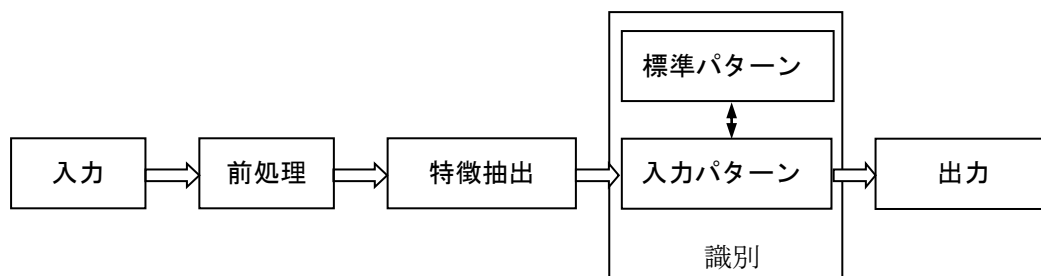


図 6.2 パターン識別の過程

### 6.1.2 学習の必要性

前節において、特徴空間における各クラスに対応した複数の領域に分割することにより、パターン認識が可能になる仕組みについて述べた。前節のパターン識別の過程における、少数のクラスを代表する標準パターンをプロトタイプと呼ぶ。また、未知の入力パターンの属するクラスをプロトタイプが代表している特徴空間中の最も近いクラスとして決定する方式を最近傍決定則方式と呼ぶ。最近傍決定則方式を適用すると、クラス間を分離する境界は二つのプロトタイプからの等距離の線、すなわち垂直2等分線になる。このクラス間を分離する境界を決定境界もしくは識別境界と呼ぶ[20]。最近傍決定則方式を用いる場合、クラス間を分離する識別境界は、プロトタイプを特徴空間上のどの位置に設定するかによって定められる。もし、適切にプロトタイプを設定しない場合、クラスを正しく分割する識別境界を求めることができない。そこで、最適なプロトタイプの正しい位置を自動的に求めるために行うのが学習である。前節までで述べた識別部設計用に収集されたパターンを学習サンプル、もしくは訓練サンプルと呼ぶ。学習サンプルは生起するパターンの傾向を反映していると考え、この学習サンプルを学習することにより識別部を設計することができる。つまり、学習は学習サンプルを正しく識別できるような識別境界を見出すための仕組みである。この学習の手法には様々なものが知られており、これらの学習のアルゴリズムと識別部設計を設計する仕組みを合わせて識別器と呼ぶ。

### 6.1.3 パターン認識の問題点

ここまでが一般的なパターン認識の過程だが、上記のような方法でパターン認識システムを構築したときに、認識系が期待したとおりの性能を発揮するとは限らない。よって、構築したシステムの性能が悪かったとき、性能を低下させた原因を探る必要がある。認識性能は前処理部、特徴抽出部、識別部を含めた認識系全体の評価尺度であるため、認識性能を改善するためにはどの処理部に問題があるのかを探る必要がある[20]。



## 6.2 決定木

決定木は単純な識別規則を組み合わせることによって、複雑な識別境界を得る方法である[20]。図6.3に示すようなデータ分布があった場合、●と○のクラスを識別するための識別関数は非線形になる。しかし、特徴軸  $x_1$  の値がしきい値  $a, d, e$  より大きい小さいか、特徴軸  $x_2$  の値が  $b, c$  より大きい小さいかを判断しさえすれば、●と○を識別することが可能である。ある特徴軸の値と閾値の大小関係を判断する過程は、図6.4に示すような決定木として表現することができる。木を構成する要素は、ノードとノード間を結ぶリンクである。図6.4中の木には、1から11までの番号が付けられたノードと、ノード間を結ぶYesとNoのラベル付けされたリンクが示されている。木の一番上にある1のノードは、木の始まりという意味で根ノードと呼ばれる。また、図6.4中の四角で示されたノードは木の終端ノードであり、葉ノードとも呼ばれる。根ノードと葉ノード以外のノードは内部ノードと呼ばれる。根ノードと内部ノードで閾値判断が行われ、その結果に従ってYesまたはNoのリンクを辿って、次のノードで再び閾値判断が行われる。この閾値判断を再帰的に繰り返し、終端ノードに達した時に与えられたデータがどちらのクラスに属するかを決定する。図6.4の場合、6から11までの終端ノードには図3.3に同じ数字で示された領域が対応しているので、6, 8, 11の終端ノードは●のクラス、7, 9, 10の終端ノードは○のクラスを表していることになる。学習データから決定木を構成する方法には、ボトムアップ的な手法とトップダウン的な手法がある。ボトムアップ的な手法は、ある一つの学習データを正しく識別できる特徴の集合を探して識別規則を作り、特徴に対する制約を緩めながら、ほかの学習データも正しく識別できるよう規則を一般化していく手法である。トップダウン的な手法は、まず根ノードで全ての学習データをできるだけ誤りの少ないようにクラス分けできる特徴軸を探して特徴空間を2分割する規則を求め、2分割された空間をさらにそれぞれ2分割する規則を求めることを繰り返して決定木を成長させる手法であり、分割統治法とよばれる。現在




図 6.3 決定木により得られる識別領域




図 6.4 決定木

ではトップダウン的な手法で決定木を構成するのが主流である。

木は、図6.4の各ノード内に示されているように、0でない有限個の正の整数からなる集合  $T$  と  $T \in T$  からなる  $T \cup \{0\}$  への二つの関数  $left()$  と  $right()$  で構成される。木自身を  $T$  で表すことにする。ノードの番号は  $right(t) = left(t) + 1$  が成り立つように付与するものとする。リンクをたどって親の親の関係にあるノードを祖先という。逆の関係を子孫という。たとえば、 $s$  が  $t$  の祖先であれば、 $t$  から  $s$  への一意のパスがあって、

$$S_m (= t), S_{m-1}, \dots, S_1, S_0 (= s) \quad (6.1)$$

がリンクでつながり、

$$S_{m-1} = \text{parent}(S_m), \dots, S_0 = \text{parent}(S_1) \quad (6.2)$$

の関係が成り立っている。また、パスの長さを  $l(s, t) = m$  で定義する。木  $T$  の終端ノードの集合を  $\tilde{T}$  で表すことにする。差集合  $T - \tilde{T}$  は非終端ノードの集合を表す。空でない  $T$  の部分集合  $T_1$  に対して、 $T_1 \cup \{0\}$  への二つの関数を以下のように定義する。

$$\begin{aligned} left_1(t) &= \begin{cases} left(t) & (left(t) \in T_1 \text{ の場合}) \\ 0 & (\text{それ以外の場合}) \end{cases}, \\ right_1(t) &= \begin{cases} right(t) & (right(t) \in T_1 \text{ の場合}) \\ 0 & (\text{それ以外の場合}) \end{cases} \end{aligned} \quad (6.3)$$

決定木では、各領域  $u(t)$  に特定のクラスを割り当てて、入力データのクラス分類を行う。クラスを  $C_i (i = 1, \dots, K)$  としたとき、終端ノード  $t$  が表すクラスの事後確率を以下のように計算する。クラスラベル付きの学習データ集合を  $\{(x_i, t_i)\} (i = 1, \dots, N)$  とする。クラス  $j$  に属する学習データを  $N_j$  とすれば、クラス  $j$  の事前確率は  $P(C_j) = N_j/N$  である。あるノード  $t$  の領域に属する学習データを  $N(t)$  とする。クラス  $j$  学習データがノード  $t$  に属する確率は、 $p(t|C_j) = N_j(t)/N_j$  なので、それらの同時確率は

$$p(C_j, t) = P(C_j)p(t|C_j) = \frac{N_j}{N} \frac{N_j(t)}{N_j} = \frac{N_j(t)}{N} \quad (6.4)$$

となる。したがって、ノード  $t$  の周辺確率は、

$$p(t) = \sum_{j=1}^K p(C_j, t) = \sum_{j=1}^K \frac{N_j(t)}{N} = \frac{N(t)}{N} \quad (6.5)$$

となるので、 $t$  におけるクラス  $j$  の事後確率は、

$$P(C_j|t) = \frac{p(C_j, t)}{p(t)} = \frac{N_j(t)}{N(t)} \quad (6.6)$$

となる。 $t$  においてクラス識別を行う場合、事後確率が最大となるクラス

$$\text{識別クラス} = \operatorname{argmax} P(C_j|t) \quad (6.7)$$

を選べばよい。

### 6.3 ランダムフォレスト

ランダムフォレストはアンサンブル学習の一種であり、Leo Breimanによって2001年に提案された機械学習アルゴリズムである[21]。アンサンブル学習とは、複数の弱識別器から1つの強識別器を構築する方法である。つまり、強識別器の出力は弱識別器の多数決によって決まる。ランダムフォレストはバギングを改良し、決定木の各非終端ノードにおいて識別に用いる特徴をあらかじめ決められた数だけランダムに選択することで、相関の低い多様な決定木を生成できるようにした手法である[20][22]。このランダム性によって、それぞれの決定木が弱識別器として互いを補い、過学習を防ぐとともに高い汎化性能を得ることができる。ランダムフォレストの学習過程では、それぞれの決定木が独立して学習が行われる。決定木は全学習データからランダムに選ばれた学習データを用いて学習を行う。ランダムフォレストの学習は単純であるが、SVMやAdaBoostなどと同様、あるいは問題によってはそれら以上の性能を持つことが知られている。また、SVMやAdaBoostが2クラス問題の識別器であるのに対して、ランダムフォレストは弱識別器である決定木の多数決により、多クラス問題に自然に拡張することができる。ランダムフォレストを生成するアルゴリズムを以下に示す。

- 1)  $m=1$  から  $M$  まで以下を繰り返す。
  - (a)  $N$  個の  $d$  次元学習データからブートストラップサンプル  $Z_m$  を生成する。
  - (b)  $Z_m$  を学習データとして、以下の手順により各ノード  $t$  を分割し、決定木  $T_m$  を成長させる。終端ノードのデータ数の下限は1とする。
    - (i)  $d$  個の特徴からランダムに  $d'$  個の特徴を選択する ( $d' = \sqrt{d}$  が推奨されているが、問題によって最適な  $d'$  は変わるので、調整パラメータである)
    - (ii)  $d'$  個の中から、最適な分割を与える特徴と分割点を求める。
    - (iii) ノード  $t$  を、分割点で  $left(t)$  と  $right(t)$  に2分割する。
- 2) ランダムフォレスト  $\{T_m\}_{m=1}^M$  を出力する。
- 3) 入力データ  $x$  に対する  $m$  番目の木の識別結果を、

$$y_m(x) \in \{C_1, \dots, C_k\} \quad (6.8)$$

とする。ランダムフォレスト  $\{T_m\}_{m=1}^M$  の識別結果を、

$$C_i = \max_j |C_j| \quad (6.9)$$

とする。  $|C_j|$  はクラス  $C_j$  と判断した木の数である。

ある特徴の値がクラスの識別にどのように寄与しているかを、他の特徴の寄与を加味したうえで見る指標として、部分依存グラフがある。分析対象とする特徴の値を  $x$  とする。  $N$

個の学習データについて分析対象とする特徴のみを  $x$  で置換したベクトルを作る．  $i$  番目の置換ベクトル  $x_i^{(x)}$  に対するクラス  $k$  の得票率を  $p_k(x_i^{(x)})$  としたとき，クラス  $k$  の置換された特徴値  $x$  に対する部分依存グラフの値  $f(x_i^{(x)})$  を，次の式で定義する．

$$f(x_i^{(x)}) = \sum_{i=1}^N \left( \log p_k(x_i^{(x)}) - \frac{1}{K} \sum_{j=1}^K \log p_j(x_i^{(x)}) \right) \quad (6.10)$$

## 6.4 サポートベクタマシン (SVM)

SVMは1960年代にVapnik 等が考案したOptimal Separating Hyperplaneを起源とするパターン認識手法である．SVMはクラスの帰属が既知の学習用のサンプル集合から特徴ベクトルとクラスとの確率的な対応関係を知識として学習する教師あり学習モデルの一つであるが，現在知られている多くの手法の中でも最もパターン認識性能の優れた学習モデルの一つである[20]．SVMの分類の様子を図3.5に示す．図6.5にあるマージンとは，決定境界と，それに最も近い学習用のサンプルとの間の距離として定義する．また，決定境界に最も近い学習用のサンプルは，サポートベクトルと呼ばれる．本研究では，線形ソフトマージンSVM（線形SVM）を用いることとし，以下では，学習サンプルからマージン最大化という基準で線形しきい素子のパラメータを学習する仕組みについて述べた後，多クラス分類問題へのSVMの適用方法について述べる．




図6.5 SVMの図解

### 6.4.1 学習の定式化

SVMは，ニューロンのモデルとして最も単純な線形しきい素子を用いて，2クラスのパターン識別器を構成する手法である．学習サンプル集合から，マージン最大化という基準で線形しきい素子のパラメータを学習する．線形しきい素子はニューロンを単純化したモデルで，入力特徴ベクトルに対し，識別関数（線形識別関数）

$$y = \text{sign}(w^t x + b) \quad (6.11)$$

により 2 値の出力値を計算する．ここで， $w$  はシナプス荷重に対応するパラメータであり， $b$  はしきい値である．また，関数 $\text{sin}(u)$ は， $u > 0$ のとき 1 をとり， $u \leq 0$ のとき -1 をとる符

号関数である．このモデルは入力ベクトルとシナプス荷重の内積がしきい値を超えれば 1 を出力し，超えなければ-1 を出力する．これは幾何学的には識別平面により，入力特徴空間を 2 つに分けることに相当する．今，学習サンプル集合として  $n$  個の特徴ベクトル  $x_i (i=1, \dots, n)$  と，それぞれのサンプルに対する正解のクラスラベル  $t_i (i=1, \dots, n)$  が与えられているとする．また，この学習サンプル集合は線形分離可能であるとする．すなわち，線形しきい素子のパラメータをうまく調整することで，学習サンプル集合を誤りなく分けることができると仮定する．SVM では，最も近い学習サンプルとの余裕をマージンと呼ばれる量で測り，マージンが最大となるような識別平面を求める．

もし，学習サンプル集合が線形分離可能なら

$$t_i(w^t x_i + b) \geq 1, (i = 1, \dots, n) \quad (6.12)$$

を満たすようなパラメータが存在する．これは図1に示すように  $H1: w^t x_i + b = 1$  と  $H2: w^t x_i + b = -1$  の2枚の超平面で学習サンプルが完全に分離されており，2枚の超平面の間にはサンプルがひとつも存在しないことを示している．このとき，識別平面とこれらの超平面との距離（マージンの大きさ）は  $1/\|w\|$  となる．したがって，マージンを最大とする  $w$  と  $b$  を求める問題は，

$$\begin{aligned} \min_{w, b} L(w) &= \frac{1}{2} \|w\|^2 \\ \text{subject to } t_i(w^t x_i + b) &\geq 1, (i = 1, \dots, n) \end{aligned} \quad (6.13)$$

の解  $w^*$ ， $b^*$  を求める問題と等価になる．この最適化問題は，数理計画法の分野で2次計画問題として知られている．ここで，Lagrange乗数  $\lambda_i (\geq 0)$ ， $i=1, \dots, n$  を導入した後， $w$ ， $b$  で微分して得られる式を代入すると式(3.14)に示される Wolfe-dual と呼ばれる双対問題が得られる．

$$\begin{aligned} \min_{\lambda} L_D(\lambda) &= \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j t_i t_j x_i^t x_j \\ \text{subject to } \sum_{i=1}^n \lambda_i t_i &= 0, (0 \leq \lambda_i, i = 1, \dots, n) \end{aligned} \quad (6.14)$$

これは，Lagrange乗数  $\lambda_i (\geq 0)$ ， $i=1, \dots, n$  に関する最適化問題となる．その解で  $\lambda_i^*$  が0でない，すなわち， $\lambda_i^* > 0$  となる学習サンプル  $x_i$  は，先の2つの超平面  $H1: w^t x_i + b = 1$  と  $H2: w^t x_i + b = -1$  のどちらかにのっている．一般にはサポートベクトルは，もとの学習サンプル数に比べてかなり少ない．つまり，沢山の学習サンプルの中から少数のサポートベクトルを選び出し，それらのみを用いて線形しきい素子のパラメータが決定されることになる．実際，双対問題の最適解  $\lambda_i^* (i \geq 0)$ ，および停留点での条件式から，最適なパラメータ  $w^*$  は，

$$w^* = \sum_{i \in S} \lambda_i^* t_i x_i \quad (6.15)$$

となる．ここで， $S$  はサポートベクトルに対応する添え字の集合である．また，最適なし

きい値 $b^*$ は、2つの超平面 $w^t x_i + b = 1$ か $w^t x_i + b = -1$ のどちらかにのっているという関係を利用して求めることができる。すなわち、任意のサポートベクトル $x_s$ ,  $s \in S$ から

$$b^* = t_s - w^t x_s \quad (6.16)$$

により求まる。最終的に、線形 SVM による最適な識別関数 $f(x)$ を双対問題の最適解 $\lambda_i^*(i \geq 0)$ を用いて表現すると、

$$\begin{aligned} f(x) &= \sin(w^{*t} x + b) \\ &= \sin(\sum_{i \in S} \lambda_i^* t_i x_i^t x + b^*) \end{aligned} \quad (6.17)$$

となる。すなわち、 $\lambda_i^* = 0$ となる多くの学習サンプルを無視し、 $\lambda_i^* > 0$ となる識別平面に近い少数の学習サンプルのみを用いて識別関数が構成される。ここで、重要な点はマージン最大化という基準から自動的に識別平面付近の少数の学習サンプルのみが選択されたことであり、その結果として、未学習データに対してもある程度良い識別性能が維持できていると解釈できる。すなわち、サポートベクタマシンは、マージン最大化という基準を用いて、学習サンプルを撰択することで、モデルの自由度を抑制するようなモデル撰択が行われていると解釈できる。

#### 6.4.2 SVM の多クラス識別問題への拡張

SVMはマージン最大化という基準を採用した識別手法であり2次計画問題を解くことにより最適な識別関数が得られることと、カーネルトリックにより非線形識別問題への拡張が可能であることの2つの特徴をもち、現在知られている多くの手法の中でも最もパターン認識性能の優れた学習モデルの一つであると考えられている[20]。しかし、SVMは原理的に2クラスの識別を行う手法であるため、3クラス以上の識別問題である本研究における高力ボルトの軸力の識別にそのままの形では適用できない。そこで、ここではSVMを多クラス識別問題へ拡張するため手法について述べる。SVMを多クラス識別器に拡張する代表的な手法として、one-versus-rest法知られている。本研究では、多クラス識別器への拡張方法としてこのone-versus-rest法を使用する。one-versus-rest法は、あるクラスとその他のクラスを分類する識別器をSVMで構築していき、それらを組み合わせることで多クラス分類を行う手法である。SVMにおける多クラス分類の様子を図6.6に示す。




図6.6 SVMにおける多クラス分類の様子

#### 6.5 ニューラルネットワーク (NN)

近年、パターン認識の分野でもニューラルネットが盛んに利用されるようになってきた[18]。それは、ひとつには多層パーセプトロンの学習法として考案された誤差逆伝播法が、良い識別性能を持つ識別器を学習データから比較的簡単に構成できる効果的な学習法であることが認識されるようになったためである。

ニューラルネットはその構造から階層的なネットワークと相互結合のある非階層的なネットワークに分類して考えることができる。階層型ネットワークは、図 6.7 のように、ユニットが複数の階層をなすようにならび、入力層から出力層へ向かう一方向の結合のみが許されるネットワークである。現在、最もよく使われている多層パーセプトロンは、このタイプのネットワークの代表例である。多層パーセプトロン以外では、Radial Basis Function (RBF) ネットワークなども階層型ニューラルネットワークと考えることができる。階層型のネットワークでは、通常、各ユニットの出力がそのユニットへの入力のみによって決まる。そのため、静的ネットワークと呼ばれることもある。一方、相互結合ネットワークは、任意のふたつのユニット間に双方向の結合を許すようなネットワークである。その代表例は、Hopfield のネットワークと Boltzmann Machine である。これらのネットワークは、ユニットの入出力関係が微分方程式により記述されるので、動的ネットワークと呼ばれることもある[20]。




図 6.7 階層型ニューラルネットワーク

### 6.5.1 誤差逆伝播法 (BP 法)

BP 法は 1986 年にラメルハートらによって入力層、中間層、出力層からなる階層型構造のニューラルネットワークに対して提案された教師データ付きの学習法である[23]。ここで教師データとは、ある入力データに対して期待する出力データのことであり、また入力データと教師データを合わせて学習データという。一般的なものは入力層、中間層、出力層の 3 層で構成された階層型ニューラルネットワークで、応答関数にはシグモイド関数を用いる。

### 6.5.2 中間層ユニットと出力層ユニットの結合定数の修正量の導出

入力層ユニットの応答関数は線形とする．各出力層ユニットの出力を  $Ok$ ，中間層ユニットの出力を  $\delta k$ ，入力層ユニットの出力を  $Sk$ ，教師データを  $Tk$  とする．また，各中間層ユニットのオフセットを  $j$ ，出力層ユニットのオフセットを  $k$  とする．さらに入力層と中間層間の結合係数を  $Wji$ ，中間層と出力層間の結合係数を  $Vg$  とする．そして，出力層の出力と教師データとの差は

$$\delta k = Tk - Ok \quad (6.18)$$

となる．

BP 法ではこの総和の 2 乗誤差曲面において，誤差を最小化する方向で中間層ユニットから出力層ユニットへの結合係数，入力層ユニットから中間層ユニットへの結合係数，中間層ユニットのオフセットと出力層ユニットのオフセットを修正することを主眼としている．

まず二乗誤差を(6.19)式として定義する．

$$E_p = \sum_k (Tk - Ok)^2 \quad (6.19)$$

これを出力層ユニットの出力に関して微分すると，

$$\frac{\delta E_p}{\delta Ok} = -2(Tk - Ok) = -2\delta k \quad (6.20)$$

となる．出力層ユニットへの入力の総和からオフセットを引いたものを，出力層ユニットの内部ポテンシャルとして定義すると，出力層の出力はシグモイド関数  $f(S_k)$  を応答関数として用いて式(6.21)のように表せる．

$$Ok = f(S_k) \quad (6.21)$$

よって，中間層ユニットから出力層ユニットへの結合係数の微小変化に対する二乗誤差への影響は式(6.20)のように変形できるが，これは式(3.21)の微分である，出力層ユニットの内部ポテンシャルの中間層ユニットと出力層ユニットの結合係数に関する微分と，式(6.20)から置き換えられるので，

$$\begin{aligned} \frac{\delta E_p}{\delta V_{kj}} &= 2 \frac{\delta E_p}{\delta Ok} \frac{\delta Ok}{\delta S_k} \frac{\delta S_k}{\delta V_{kj}} = -2\delta k \cdot f'(S_k) \cdot H_j \\ &= -K_1 \delta k \cdot Ok(1 - Ok) \cdot H_j \end{aligned} \quad (6.22)$$

のように書ける．

ここで，3 乗誤差を減少させるための中間層ユニットと出力層ユニットの結合係数の修正量を最急降下法で求めると，式(6.23)のようになる．ただし  $\alpha, K_1$  は定数とする．

$$\Delta Vg = -\alpha \cdot \frac{\delta E_p}{\delta Vg} = \alpha \cdot \delta k \cdot K_1 \cdot Ok(1 - Ok) \cdot H_j \quad (6.23)$$

### 6.5.3 入力層ユニットと中間層ユニットの結合係数の修正量の導出



ここで、中間層ユニットへの入力との総和からオフセットを引いたものを、中間層ユニットの内部ポテンシャルとして定義し、中間層ユニットからの出力をすると、入力層ユニットと中間層ユニットの結合係数の二乗誤差に与える影響は式(6.22)と、中間層ユニットからの出力の微分と、中間層ユニットの内部ポテンシャルに関する微分から式(6.24)のように表せる。ただし、 $K_1$ は定数とする。

$$\begin{aligned}\frac{\delta E_p}{\delta W_{ji}} &= \frac{\delta E_p}{\delta O_k} \cdot \frac{\delta O_k}{\delta S_k} \cdot \frac{\delta S_k}{\delta H_j} \cdot \frac{\delta H_j}{\delta U_j} \cdot \frac{\delta U_j}{\delta W_{ji}} \\ &= -\sum_k \delta k \cdot K_1 \cdot O_k(1 - O_k) \cdot V_g \cdot K_1 \cdot H_j(1 - H_j) \cdot l_i\end{aligned}\quad (6.24)$$

したがって、入力層ユニットと中間層ユニットの結合係数修正量は式(6.24)から最急降下法により

$$\begin{aligned}\Delta W_{ji} &= -\alpha \frac{\delta E_p}{\delta W_{ji}} = \sum_k \alpha \cdot \delta k \cdot K_1 O_k(1 - O_k) \cdot V_{kj} \cdot K_1 H_j(1 - H_j) \cdot l_i \\ &= \sum_k \alpha \cdot \delta k \cdot k_1^2 \cdot O_k(1 - O_k) \cdot V_g \cdot H_j(1 - H_j) \cdot l_i\end{aligned}\quad (6.25)$$

と書ける。ただし、 $\alpha, K_1$ は定数とする。

#### 6.5.4 出力層ユニットと中間層ユニットのオフセットの修正量の導出

式(6.24)、式(6.25)と同様に出力層ユニットのオフセット  $k$  と中間層ユニットのオフセット  $j$  の修正量を求める式はそれぞれ、

$$\begin{aligned}\frac{\delta E_p}{\delta y_k} &= \frac{\delta E_p}{\delta O_k} \cdot \frac{\delta O_k}{\delta S_k} \cdot \frac{\delta S_k}{\delta y_k} = -\delta k \cdot K_1 \cdot O_k(1 - O_k) \\ \frac{\delta E_p}{\delta \theta_j} &= \frac{\delta E_p}{\delta O_k} \cdot \frac{\delta O_k}{\delta S_k} \cdot \frac{\delta S_k}{\delta H_j} \cdot \frac{\delta H_j}{\delta U_j} \cdot \frac{\delta U_j}{\delta \theta_j} \\ &= -\sum_k \delta k \cdot K_1 \cdot O_k(1 - O_k) \cdot V_g \cdot K_1 \cdot H_j(1 - H_j)\end{aligned}\quad (6.26)$$

と表すことができ、それぞれのオフセットの修正量は結合係数の修正量の導出と同様に式(6.26)、式(6.27)から最急降下法を用いて、

$$\Delta y_k = -\beta \frac{\delta E_p}{\delta y_k} = \beta \cdot \delta k \cdot K_1 \cdot O_k(1 - O_k) \quad (6.27)$$

$$\Delta \theta_j = -\beta \frac{\delta E_p}{\delta \theta_j} = \sum_k \beta \cdot \delta k \cdot K_1 \cdot O_k(1 - O_k) \cdot V_g \cdot K_1 \cdot H_j(1 - H_j) \quad (6.28)$$

と書ける。

以上から BP 法を入力層、中間層、出力層の 3 層の階層型ニューラルネットワークに適用する場合に使われる数式をまとめると、式(6.29)～(6.32)のようになる。式の左辺は修正後の結合係数、オフセットを示し、右辺の第一項は修正前の係数、第二項は修正量を示す。

$$Vg^* = Vg + \Delta Vg \quad (6.29)$$

$$W_{ji}^* = W_{ji} + \Delta W_{ji} \quad (6.30)$$

$$Y_k^* = Y_k + \Delta Y_k \quad (6.31)$$

$$\theta_j^* = \theta_j + \Delta \theta_j \quad (6.32)$$

BP 法ではこのように導出した式を使い，入力層に入力データを入力し，出力層から取り出した出力データと教師データとの誤差を逆に入力層側の諸係数修正のために伝搬させる．このことが，BP 法は誤差逆伝搬法と呼ばれる理由である．

## 6.6 深層学習 (Deep Learning)

深層学習とは，適切な特徴抽出能力を持つ教師なしニューラルネットワークを多層にして構築したものである[24]．最大の特徴としては，パターン認識などの際に用いる特徴量の抽出を行う必要がないということが挙げられる．原理的に，ニューラルネットワークはどのようなデータからでも学習が可能であり，複雑で膨大な学習データから知識を獲得可能である．膨大な学習データから知識を獲得するには膨大な計算量が必要となるが，近年のハードウェアの高度化によりその問題は解消されている．しかし，多層のニューラルネットワークを扱う場合に過学習や誤差の消失問題があった．それらを解消する方法として，畳み込みニューラルネットワークやAutoEncoder (自己符号化器) が開発されている．特に，画像認識分野では良好な結果を残しており，本研究においても加速度波形データを画像データとして，深層学習を行う．深層学習の手法としては，畳み込みニューラルネットワークを用いる．

### 6.6.1 畳み込みニューラルネット

畳み込みニューラルネットは，畳み込み層とプーリング層という特別な2種類の層を含む順伝播型ネットワークである[24]．特に，画像認識に応用され，これまでの順伝播型ネットワークと同様，誤差逆伝播法と確率的勾配降下法により最適化を行う．畳み込みネットの特徴は，局所的受容野および重み共有と呼ばれる特別な層間結合を持つことで，この点がこれまでの順伝播型ネットワークとの違いになる．図6.8に画像認識でよく使われる畳み込みネットの典型的な構造を示す．入力層から出力層側へ向けて，畳み込み層とプーリング層がペアでこの順で並び，このペアが複数回繰り返される．畳み込み層とプーリング層の繰り返しの後には，隣接層間のユニットが全結合した層が配置される．これを全結合層と呼び，畳み込み層などと区別している．全結合層は前述した順伝播型ネットワークの各層と同じで，全結合層も一般に，複数連続して配置される．目的がクラス分類であれば，最

終出力層はソフトマックス層となる．ソフトマックス関数はクラス分類問題をニューラルネットワークで解く場合に，出力層の活性化関数として用いられる関数である．ソフトマックス関数の出力は0～1の範囲であり，出力層の各ユニットの出力を合計すると1になる性質をもつ．つまり，出力層の各ユニットの出力があるクラスに属する確率を表していると考えることができる．

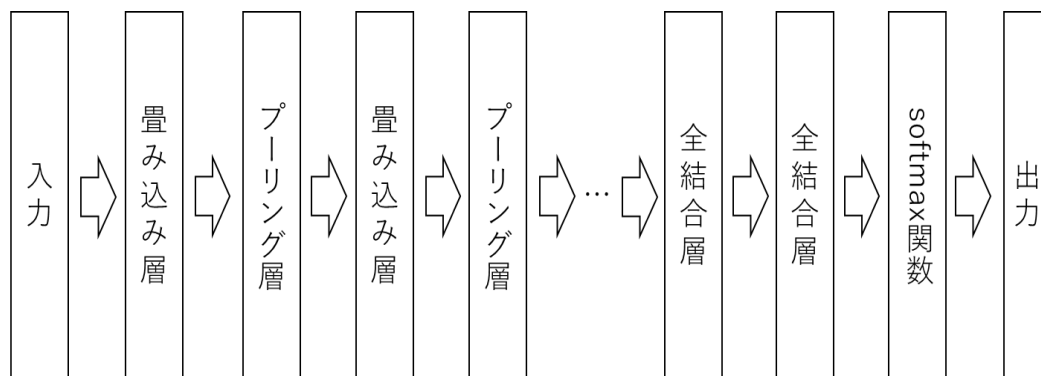


図 6.8 典型的な畳み込みネットワーク

### 6.6.2 畳み込み層

畳み込み層での演算処理を以下に示す．

濃淡値を各画素に格納したグレースケールの画像を考える．画像サイズを $W \times W$ 画素とし，画素をインデックス $(i, j)$  ( $i = 0, \dots, W - 1, j = 0, \dots, W - 1$ )で表す．画素 $(i, j)$ の画素数を $x_{ij}$ と書き，負の値を含む実数値をとるとする．そして，フィルタと呼ぶサイズの小さい画像を考え，それを $H \times H$ 画素とします．フィルタの画素はインデックス $(p, q)$  ( $p = 0, \dots, H - 1, q = 0, \dots, H - 1$ )で表し，画素数を $h_{pq}$ と書く．画像の畳み込みとは，画像とフィルタ間で定義される次の積和計算となる．

$$u_{ij} = \sum_{p=0}^{H-1} \sum_{q=0}^{H-1} x_{i+p, j+q} h_{pq} \quad (6.33)$$

画像の畳み込みは，フィルタの濃淡パターンと類似した濃淡パターンが入力画像上のどこにあるかを検出する働きがある．つまり，フィルタが表す特徴的な濃淡構造を画像から検出する働きになる．式(6.33)のように畳み込みは画像にフィルタを重ねたとき，画像とフィルタの重なり合う画素どうしの積を求めて，フィルタ全体で和を求める計算である．したがって，画像からフィルタがはみ出すような位置に重ねることは本来不可能である．画像内にフィルタ全体が収まる範囲内でフィルタを動かすと，畳み込み結果の画像サイズは入力画像よりも小さくなる．そのサイズは，

$$(W - 2[H/2]) \times (W - 2[H/2]) \quad (6.34)$$

と表すことができる。ただし、 $[\cdot]$ は小数点以下を切り下げて整数化する演算子とする。畳み込みの画像が、入力画像と同サイズにする場合、入力画像の外側に幅 $[H/2]$ のふちをつけて大きくし、出力画像のサイズが元の入力画像と同サイズになるようにする。最も一般的なのは、このふちの部分の画素値を0にセットする方法で、ゼロパディングと呼ぶ。ゼロパディングを行った例を図6.9で示す。図6.9は $5 \times 5$ の画像であり、各ピクセルの画素値は1か0としている。また、フィルタサイズを $3 \times 3$ とする。そして、1画素ずつフィルタをずらし、式(6.33)に従って畳み込みの計算を行う。




図 6.9 ゼロパディング

ここまで、画像上の縦横方向に1方向ずつフィルタをずらしながら、各重なりでの両者の積和を計算した。フィルタの適用位置を1画素ずつでなく、数画素ずつずらして計算する場合があり、このフィルタの適用位置の間隔をストライドと呼ぶ。ストライドを $s$  とするとき、出力画像の画素値は

$$u_{ij} = \sum_{p=0}^{H-1} \sum_{q=0}^{H-1} x_{si+p, sj+q} h_{pq} \quad (6.35)$$

のように計算され、出力画像サイズは約 $1/s$ となる。上述のパディングを行う場合、サイズは正確には

$$([ (W - 1)/s ] + 1) \times ([ (W - 1)/s ] + 1) \quad (6.36)$$

と計算される。大きな入力画像を扱う際、畳み込み層の出力側のユニット数が大きくなりすぎるのを防ぐために、2以上のストライドが用いられることがある。ただし、ストライドを大きくすることは画像特徴を取りこぼす可能性を考えなくてはならない。

上記で説明したものは、グレースケールの入力画像1枚に対して、1つのフィルタを畳み込みというものだが、実際には、多チャネルの画像に対し、複数のフィルタを並行して

畳み込む演算を行う．多チャネルの画像とは，各画素が複数の値を持つ画像であり，チャネル数が $K$ の画像の各画素は $K$ 個の値を持つ．例えば，RGBの3色からなるカラー画像では $K=3$ となる．画像の縦横の画素数が $W \times W$ でチャネル数が $K$ のとき，この画像サイズを $W \times W \times K$ と表す．畳み込み層 $l$ は直前の第 $l-1$ 層から $K$ チャネルの画像 $z_{ijk}^{(l-1)}$ を受け取り，これに $M$ 種類のフィルタ $h_{pqkm}$ を適用する．各フィルタも同様にチャネル数 $K$ を持ち，そのサイズを $H \times H \times K$ とする．各チャネル $k$ について並行に画像とフィルタの畳み込みを行った後，結果を画素ごとに全チャネルにわたって加算するもので

$$u_{ijm} = \sum_{k=0}^{K-1} \sum_{p=0}^{H-1} \sum_{q=0}^{H-1} z_{i+p, j+q, k}^{(l-1)} h_{pqkm} + b_{ijm} \quad (6.37)$$

となる．また，ここでバイアス $b_{ijm}$ を導入している．バイアスは，フィルタごとに各ユニット共通( $b_{ijm} = b_m$ )とするのが一般的である．次に得られた $u_{ijm}$ に活性化関数を適用する．

$$z_{ijm} = f(u_{ijm}) \quad (6.38)$$

この $z_{ijm}$ の値が畳み込み層の最終的な出力となり，その後の層へと伝わる．これらは，フィルタの数 $M$ と同数のチャネル数を持つ多チャネルの画像と見なせる．つまり，入力サイズが $W \times W \times K$ のとき，畳み込み層のフィルタ数を $M$ とすると，出力サイズは $W \times W \times M$ となる．

式(6.37)(6.38)は，層間の結合に特別な構造のある単層ネットワークとして表現できる．まず，この層の入力と出力のユニット数はそれぞれ $W \times W \times K$ および $W \times W \times M$ である．そして，畳み込み計算の局所性を反映して，出力層のユニット1つは入力層の $H \times H \times K$ 個のユニットとのみ結合する．その結合の重みがフィルタの係数 $h_{pqkm}$ である．この重みは出力層の同一チャネルの全ユニットで同じであり，これを重み共有と呼ぶ．このような結合の局所性と重みを共有することが，畳み込み層の特徴である．畳み込みネットでも一般の順伝播型ネットワーク同様，勾配降下法によるパラメータ最適化を行う．畳み込み層の重みはフィルタそのものなので，最適化の対象となるパラメータはフィルタおよびバイアスになる．

### 6.6.3 プーリング層

プーリング層は通常，畳み込み層の直後に設置される．プーリング層のユニットは，複雑型細胞のモデルになっており，畳み込み層で抽出された特徴の位置感度を若干低下させることで，対象とする特徴量の画像内での位置が若干変化した場合でも，プーリング層の出力が不変になるようにする役割がある．プーリング層での計算内容を以下で述べる．サイズ $W \times W \times K$ の入力画像上で画素 $(i, j)$ を中心とする $H \times H$ 正方領域をとり，この中に含まれる画素の集合を $P_{ij}$ で表す．畳み込みと同様に適当なパディングを行えば，入力画像の端を含むすべての点を中心とする $P_{ij}$ をとることができる．この $P_{ij}$ 内の画素について，チャネル $k$ ごとに独立に， $H^2$ 個ある画素数を使って1つの画素値 $u_{ijk}$ を求める．今回の研究では，最大

プーリングを用いて、 $H^2$ 個の画素値の最大値を選ぶ。

$$u_{ijk} = \max_{(p,q) \in P_{ij}} z_{pqk}$$

(6.39)

畳み込み層と同様にプーリング層でも2以上のストライドを設定することができる。その場合、出力画像の縦横サイズを $W \times W$ 、プーリングの開始点を $(i, j) = (0, 0)$ とすると、 $[(W-1)/s] + 1$ となる。プーリング層のユニットにも活性化関数を適用することは理屈の上で可能だが、通常適用しない。プーリング層も畳み込み層同様、2層構造のネットワークで表現することができ、畳み込み層同様に層間の結合が局所的に限定されたものになる。ただし結合の重みは調節可能なものではなく、固定されている。したがって、プーリング層には学習によるパラメータの変化はない。

#### 6.6.4 ドロップアウト

ドロップアウトは、多層ネットワークのユニットを確率的に選別して、学習を行う方法であり、その概念を図6.10に示す[24]。ドロップアウトは、ネットワークの学習過程と学習後の推論過程を、それぞれ以下のように修正する。学習時において、中間層の各層と入力層のユニットを決まった割合 $p$ でランダムに選出し、それら以外を無効化、つまりそもそも存在しないかのように扱う。図6.10のように選出したユニットのみからなるネットワークを最適化する。すなわち、学習サンプルをネットワークに入力する順伝播計算を行い、誤差を求めた後、逆伝播計算を行って誤差の勾配を計算し、重みを更新する。なお、ユニットの選出は重み更新のたびにランダムに行う。学習終了後の推論では、すべてのユニットを用いて順伝播計算を行う。ただしドロップアウトで無効化の対象とした層のユニットは、すべて一律にその出力を $p$ 倍する。これは、これらの層では推論時のユニット数が学習時と比べて $1/p$ 倍に増えていることを補償している。




図6.10 ドロップアウトの概念

(左：通常の多層ネットワーク 右：ドロップアウトを適用した多層ネットワーク)

以上の手続きからなるドロップアウトの目的は、学習時にネットワークの自由度を強制的に小さくし、過学習を避けることにある。これは、ドロップアウト時のユニットをランダムに無効化したネットワークを多数独立に学習し、推論時にそれらの結果を平均するのと同じ効果があると考えられている。複数のネットワークの平均をとると推論の精度が一般に向上することが知られており、ドロップアウトはこれと同じ効果をより小さな計算コストで得ていると解釈できる。本研究では、畳み込みニューラルネットワークにドロップアウトを適用することを考えた。ドロップアウトが広まった当初は、畳み込みニューラルネットワークの全結合層のみに適用されていたが、畳み込み層に適用しても同様に、性能を向上できることが確かめられている[25].

## 第7章 撮影画像データによる損傷度診断スキーム

### 7.1 診断スキームの検証データ

本研究では、橋梁の床版部分を撮影した、図7.1に一部示すような床版部分にひび割れによる損傷を含む画像47枚を使用した。

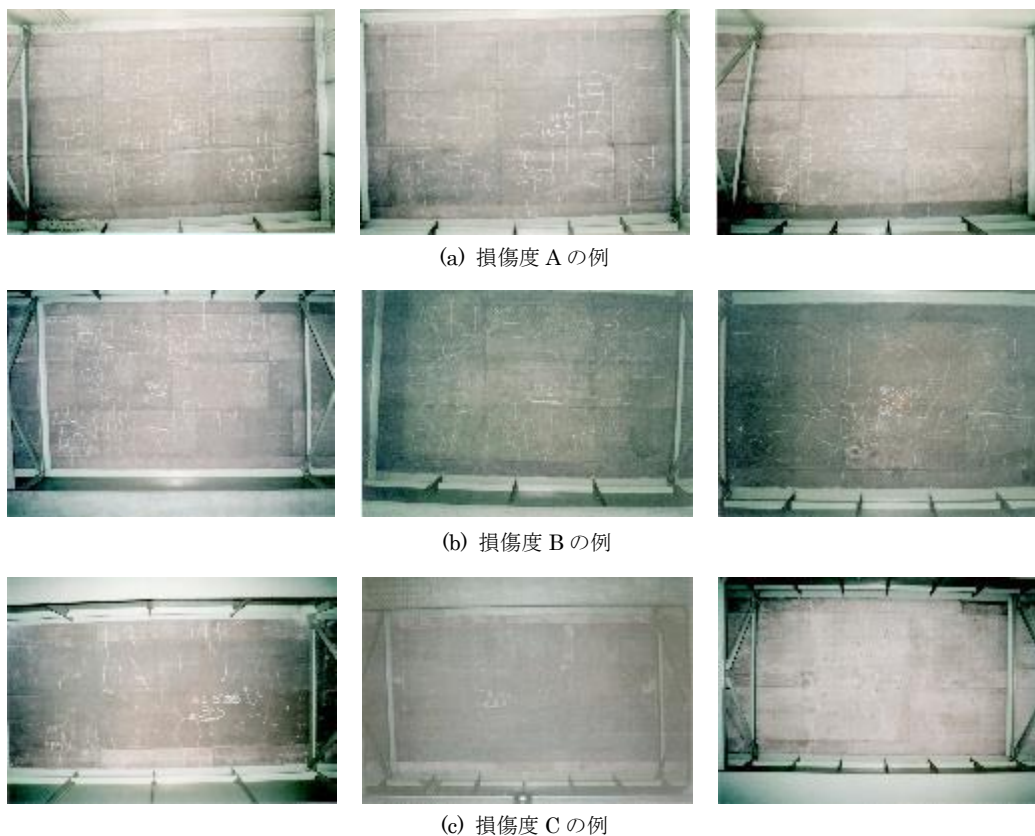


図7.1 本研究で用いた床版画像

図7.1に示した画像は本研究で使用したひび割れ画像の1例である。それぞれの画像は、床版ひび割れの各点検項目における判定基準に基づき、専門家によって床版の損傷度のより大きなものから、A, B, Cの3段階の評価付けが行われている。床版ひび割れの点検項目および判定基準については次項で述べる。また、本研究に使用した画像は観測時において、ホワイトチョークによるひび割れのトレースが行われている。

本研究で用いた専門家によるひび割れ画像の評価付けは、表7.1に示すような判定基準[26]に従い行われたものである。また、画像に付けられた評価付けは、識別部における教師信号として用いる。



表 7.1 床版ひび割れ判定基準

| ひび割れの種類   |                                       | 判定要素         |             | 判定 |
|-----------|---------------------------------------|--------------|-------------|----|
|           |                                       | 平均ひび割れの幅     | 平均ひび割れの間隔   |    |
| 二方向性のひび割れ | 平均的ひび割れ発生密度による判定                      | 0.1mm 程度以上   | 40cm 以下     | A  |
|           |                                       |              | 40cm ～ 60cm | B  |
|           |                                       |              | 60cm 以上     | C  |
|           | 局所的に集中したひび割れ、または局所的に発生した亀甲状ひび割れに対する判定 | 0.2mm 程度以上   | ————        | A  |
|           |                                       | 0.1～0.2mm 程度 | ————        | B  |
|           | ひび割れに角落ち、ずれを伴う場合                      | ————         | ————        | A  |
| 一方向性のひび割れ | 平均的ひび割れ発生密度による判定                      | 0.2mm 程度以上   | 50cm 以下     | A  |
|           |                                       |              | 50cm ～ 1m   | B  |
|           |                                       |              | 1m 以上       | C  |
|           |                                       | 0.1～0.2mm 程度 | 1m 未満       | B  |
|           |                                       |              | 1m 以上       | C  |
|           | 局所的に集中したひび割れ、または局所的に発生した亀甲状ひび割れに対する判定 | 0.2mm 程度以上   | ————        | A  |
|           |                                       | 0.1～0.2mm 程度 | ————        | B  |

注：局所的に集中したひび割れとは、主桁近傍で橋軸方向に連続した線状ひび割れや、部分的にひび割れの発生密度が高くなっている箇所を示す。

## 7.2 前処理部

### 7.2.1 処理の流れ

データとして入力されたひび割れ画像から、線幅1の細線としてひび割れの抽出を行う。画像からひび割れを抽出する手順を図7.2に示す。次に、画像の正規化、2値化処理、ノイズの除去、4-連結細線化処理、特徴転換連結処理の各過程において、本研究で用いた手法についての解説を行う。

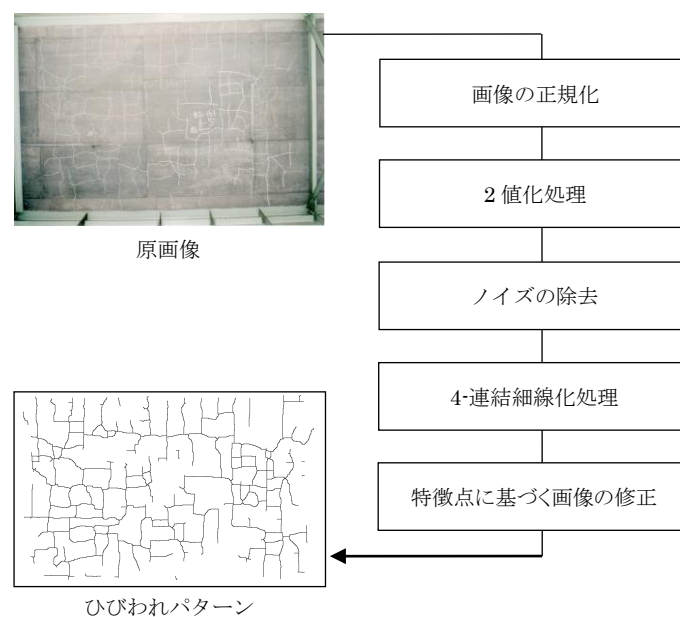


図7.2 画像処理によるひび割れの抽出

### 7.2.2 画像の正規化

識別部におけるパターンの分類をより正確に行うために、正規化操作を行う必要がある<sup>[8]</sup>. まず初めに、ひび割れ領域を含む床版部分を矩形として抽出する. 実際には、床版部分の画像に対して座標変換を行い、その外接矩形の形状への変形を行う. このような、任意形状へ画像を貼り付ける処理をテクスチャマッピングと呼ぶ. この任意形状への変形を実現するテクスチャマッピングは、アフィン変換で近似して実現される (図7.3).




図7.3 任意形状の変形

図7.3(a)に示すように、原画像から変換を行う部分画像をブロックとして選択する。さらにこのブロックに対角線を引いて四つの三角形に分割する。この画像が図7.3(b)のように変形されたとして、ブロックAに注目すると、頂点 $p, q, r$ で構成される三角形は、頂点 $P, Q, R$ で構成される三角形に変形されている。三角形の変形はアフィン変換で記述できるので、各頂点座標の変換式 $(x_p, y_p) \rightarrow (X_p, Y_p)$ ,  $(x_q, y_q) \rightarrow (X_q, Y_q)$ ,  $(x_r, y_r) \rightarrow (X_r, Y_r)$ を式に代入すると、点 $p$ に関して、

$$\left. \begin{aligned} x_p &= AX_p + BY_p + C \\ y_p &= DX_p + EY_p + F \end{aligned} \right\} \quad (7.1)$$

点 $q$ に関して、

$$\left. \begin{aligned} x_q &= AX_q + BY_q + C \\ y_q &= DX_q + EY_q + F \end{aligned} \right\} \quad (7.2)$$

点 $r$ に関して、

$$\left. \begin{aligned} x_r &= AX_r + BY_r + C \\ y_r &= DX_r + EY_r + F \end{aligned} \right\} \quad (7.3)$$

のように合計6つの方程式が得られる。式(7.1)～(7.3)は、未知数が $A \sim F$ の6個なので、解を一意に計算することができる。この変換式のパラメータがわかれば、三角形内部の画素をマッピングすることができる。さらに、この処理をすべての三角形に対して行えば、全面のマッピングが可能になる。しかし、三角形ごとに独立したパラメータでマッピングを行うため、三角形間の境界は滑らかにつながらない。そこで本研究では、三角形の境界のアドレスを計算し、その近傍のみの平滑化を行った。

また、出力座標 $(x, y)$ は、拡大・縮小率によっては、必ずしも入力画像の画素位置（格子点）には一致しない。通常、このような画素と画素の間のデータが必要になった場合には、最近傍法（近傍2点の画素のうち、どちらか距離的に近い画素の値を使う方法）、および、線形補間法（近傍2点の画素の平均値を使う方法）などが、簡易な手法として用いられている。本研究では、最近傍法は変形後の画質がよくないので、線形補間法を用いる。

一般的には、線形補間処理は図7.4のように、逆変換して求めた位置 $(x, y)$ の近傍4画素のデータを用いて処理が行われる。近傍4画素の重み付けの比率は、 $(x, y)$ と四つの画素 $g$ との各距離によって求められ、 $(x, y)$ における画素データ $G(x, y)$ は、以下の式(7.4)で計算される。ここで、 $[x]$ ,  $[y]$ はそれぞれ、 $x$ ,  $y$ を超えない整数である。

$$G(x, y) = (1-p)(1-q) \cdot g([x], [y]) + p(1-q) \cdot g([x]+1, [y]) \\ + (1-p)q \cdot g([x], [y]+1) + pq \cdot g([x]+1, [y]+1) \quad (7.4)$$

矩形として抽出された各画像に対して768×480（単位：pixel）のサイズ変換を行い，最後に，階調数256のグレイスケール画像に変換を行う．




図7.4 画素の補間処理


### 7.2.3 2値化処理によるひび割れの抽出

濃度変換の特殊な例である2値化は，ある濃度値をしきい値として，背景領域と対象領域に分割を行う．一般に背景領域を0-画素，対象領域を1-画素の2値で表現する．しかし，本研究で扱う画像の中には，照明条件が一樣ではないため，背景領域の濃度値や対象領域の濃度値が画像全体で一定していないものが含まれている．

すなわち，背景領域の濃度値が対象領域より高い場合，あるいはその逆の場合が生じる．図7.5(a)に照明むらのある画像を示す．このヒストグラムは図7.5(b)のように明確な谷がなく，このような画像に対して，しきい値 $t$ を用いて固定しきい値処理を行うと図7.6に示すように，対象領域が背景領域に埋もれてしまう．




(a) 照明むらのある画像




(b) ヒストグラム

図7.5 照明むらのある画像とそのヒストグラム



(a)  $t=215$



(b)  $t=195$



(c)  $t=175$

図7.6 固定しきい値処理

このような場合、画素ごとにしきい値を変化させる動的しきい値処理（可変しきい値処理）が有効である。動的しきい値処理はしきい値 $T$ は画素 $(m,n)$ 、その濃度値（画素値） $f(m,n)$ 、 $(m,n)$ の近傍の局所的な性質 $S(m,n)$ （たとえば、 $(m,n)$ の近傍の平均の濃度値）の関数 $F$ として、一般的には次のように表される。

$$T=F[(m,n),f(m,n),S(m,n)] \quad (7.5)$$

上のよう決定されるしきい値を動的しきい値という。

しかし、この方法をそのまま使用すると背景領域の微妙な濃淡変化に対しても敏感に反応し雑音の多い画像が得られるという欠点がある。そこで本研究では、局所的しきい値法と判別分析法を併用する手法を用いた。まず初めに、画像をブロックに分割し、ブロック単位に判別分析法を適用して2値化処理のしきい値を設定する。判別分析法<sup>[11]</sup>は画像を2つクラス $C_1$ ならびに $C_2$ に分割する場合、次に示す分離度 $\eta(T)$ が最大になるようにしきい値 $T$ を選定する。

$$\eta(T)=\left[\frac{\sigma_B^2(T)}{\sigma_W^2(T)}\right]_{\max} \quad (7.6)$$

ここで、 $\sigma_B^2(T)$ はクラス間分散、 $\sigma_W^2(T)$ はクラス内分散で、これらは次の式で与えられる。

$$\begin{aligned} \text{クラス内分散 } \sigma_W^2 &= w_1 \sigma_1^2 + w_2 \sigma_2^2 \\ &= \frac{1}{N} \left\{ \sum_{i \in S_1} (i - \mu_1)^2 n_i + \sum_{i \in S_2} (i - \mu_2)^2 n_i \right\} \end{aligned} \quad (7.7)$$

$$\begin{aligned} \text{クラス間分散 } \sigma_B^2 &= w_1 (\mu_1 - \mu_T)^2 + w_2 (\mu_2 - \mu_T)^2 \\ &= \frac{1}{N} \left\{ \sum_{i \in S_1} (\mu_1 - \mu_T)^2 n_i + \sum_{i \in S_2} (\mu_2 - \mu_T)^2 n_i \right\} \end{aligned} \quad (7.8)$$

ここで  $\sigma_W^2 + \sigma_B^2 = \sigma_T^2$  ( $\sigma_T^2$ : 全分散),  $w_1$ ならびに  $w_2$ はクラス  $C_1$ ならびに  $C_2$ の生起確率 (正規化された画素数),  $\mu_1$ ならびに  $\mu_2$ と  $\sigma_1^2$ ならびに  $\sigma_2^2$ はそれぞれ  $C_1$ ならびに  $C_2$ に属する画素の濃度の平均値と分散である。

次に、個々のブロックをいくつかの小領域に分割し、動的しきい値処理を用いてひび割れを含む小領域を決定し、ひび割れ領域を含む小領域に対して、ブロック単位に設定されたしきい値による2値化処理を行う。本研究で用いた手法による2値化処理例を図7.7に示す。原画像はである。本研究で用いたプログラムでは、ブロックのサイズ  $s_b$  と小領域のサイズ  $s_l$  をパラメータとして与える。

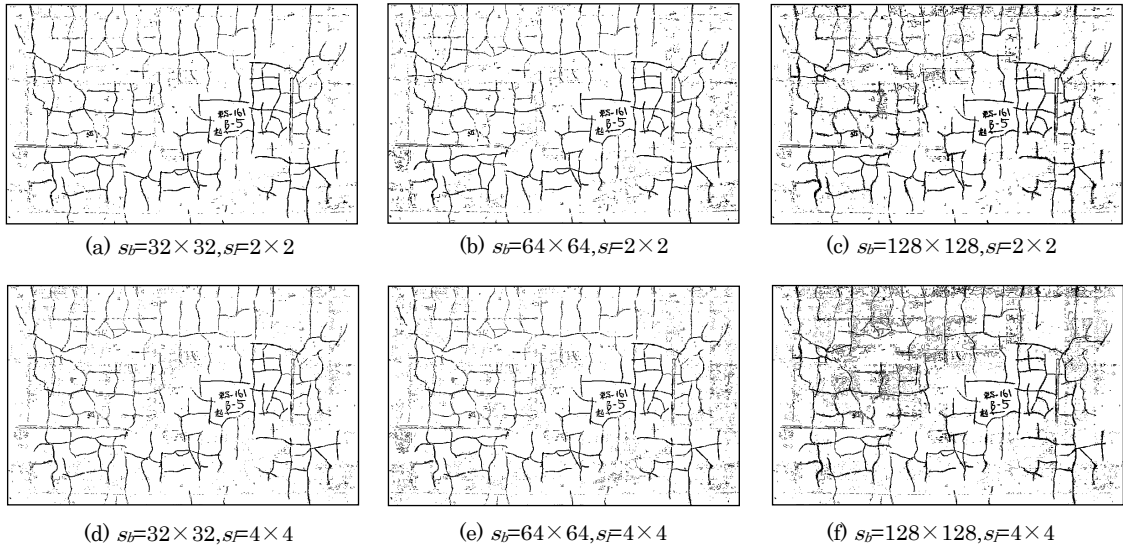


図7.7 2値化処理の実行例

#### 7.2.4 ノイズの除去

2値化処理をした画像をそのまま利用することは問題がある場合が多い。なぜなら、2値化処理の性質上、図7.7のようにひび割れ領域以外の細かな領域が多々抽出されている場合がある。本研究では2値化処理をした画像に対して、まず1pixel程度の小さな孔や溝、孤立点や突起などの小さなノイズの除去を行う。次に画像に4-連結細線化処理を行い、その後に近接する特徴点間の距離に基づく修正を行い、最終的なひび割れのパターンを作成する。通常はこれらの細かな領域を取り除く方法として、膨張と収縮がある。しかし、画像中におけるひび割れ領域の面積はこれらのノイズと同様に小さいため、この方法でノイズの除去を行うと、ひび割れ領域も同様に除去されてしまう。そこで、本研究ではカウントフィルタを応用して画像からノイズの除去を行う。カウントフィルタは、フィルタが重なる領域内のピクセルの値を調べ同じ値をもつピクセルをカウントし、その1つを出力値とするフィルタである。本研究で用いたフィルタは、領域内の1-画素の総数がしきい値より多い場合は1-画素をその領域の中心画素の出力値とし、また少ない場合は0-画素を中心画素の出力値とする。

#### 7.2.5 4-連結細線化処理

2値化図形から線幅1の中心線を抽出する操作を細線化という。2値化画像は線図形化することにより、その幾何学的特徴を把握しやすくなり、パターン認識の前処理として用いられる。細線化は、図形や文字の本質的な構造が保存されるように、

- ・ 中心線の線幅が1であること
- ・ 中心線が元の図形の中心であること
- ・ 途中で切断されたり、孔が生じたりしないこと（連結性の保存）
- ・ 不必要なひげが生じないこと
- ・ 中心線が必要以上に縮まないこと
- ・ 交差部において中心線がひずまないこと

などに注意して行う。

線図形の形態としては、8-連結と4-連結がある。以下に、本研究における3×3のマスクを用いた4-連結細線化処理のアルゴリズムについての説明を行う。対象領域（ひび割れ領域）を1-画素、背景領域を0-画素とする。

画像を左上からラスタ走査し、注目点*i,j*が1-画素であるとき、その8-近傍を調べ、0-画素に反転（以後、0-反転という）できるかどうかを判断する。右下までスキャンが終了した時点で、0-反転した個数が0でなければ、まだ完全に細線化が終了していないので、いま処理した結果を新しい原画像として、操作を繰り返す。図7.8は8-近傍の例を示したものである。

|                         |                       |                         |
|-------------------------|-----------------------|-------------------------|
| $x_3$<br>( $i-1, j-1$ ) | $x_2$<br>( $i, j-1$ ) | $x_1$<br>( $i+1, j-1$ ) |
| $x_4$<br>( $i-1, j$ )   | $x_0$<br>( $i, j$ )   | $x_7$<br>( $i+1, j$ )   |
| $x_5$<br>( $i-1, j+1$ ) | $x_6$<br>( $i, j+1$ ) | $x_7$<br>( $i+1, j+1$ ) |

図7.8 画素の近傍

図7.8に示した8-近傍の1-画素の個数を

$$sum = \sum_{k=0}^7 x_k \quad (7.9)$$

によって求め、処理を分岐する． $sum=0$ のときは、注目点だけが1-画素なので雑音とみなし、0-反転する． $sum=1$ および $sum=2$ のとき、8-近傍の画素値は、それぞれ図7.9(a)，図7.9(b)（およびこれらの $90^\circ$ ， $180^\circ$ ， $270^\circ$ 回転したパターン）のようになる．灰色部分が1-画素である．

このようなパターンでは注目点（図形の中心）は端点であり、0-反転すると最終的に、線状のパターンは消失する．しかし、本研究で用いたプログラムでは、ある回数まで0-反転を許可することにより、ひげの発生をある程度防ぐようにした．なお、図7.9(b)以外の $sum=2$ の場合は、0-反転することにより図形が切断される．




図7.9 線図形化処理

$sum=3,4,5$ の代表的なパターンをそれぞれ図7.9(c)，図7.9(d)，図7.9(e)に示す．これらのパターンの中で、図7.9(d)の右側の場合、0-反転することにより切断が生じる．それ以外は0-反転可能である．しかし、注目画素から上部の3点と左真横の1点は、これまでの処理で0-



反転している可能性がある。例えば，図7.9(c)のパターンでは，真上が0-反転しているときは，注目点を0-反転することにより切断される。また，図7.9(c)の右側の場合，左上が0-反転しているとき，注目点を0-反転することで，線図形の形態が4-連結でなくなる。このように，図7.8の $x_1, x_2, x_3, x_4$ の4点については特別な注意が必要である。4-連結細線化処理例を図7.10に示す。

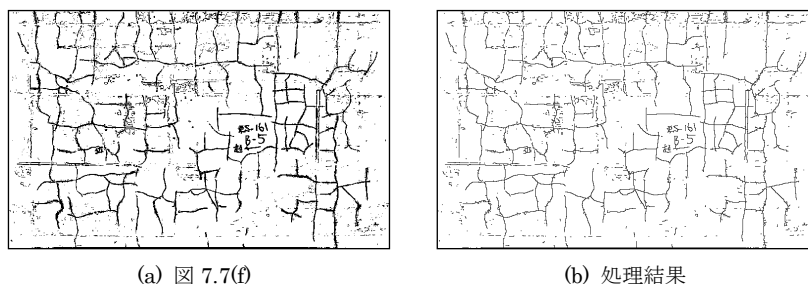


図7.10 細線化処理の実行例

### 7.2.6 特徴点に基づく画像の修正

4-連結細線化処理を行った画像に対して特徴点を利用して修正を施し，ひび割れ領域以外のノイズの除去，また2値化処理で発生したかすれなどの補間を行う。特徴点の抽出方法については節の特徴点抽出で述べる。画像中の線図形から，端点，分岐点，交差点，角点をそれぞれ抽出し，それぞれの特徴点について次の手順で画素の反転を行う。設定されたしきい値以内の最も近接する他の特徴点との間が連結されている場合は，その特徴点間の画素を0-反転し，また連結されていない場合はその特徴点間が4-連結されるように画素の1-反転を行う。

特徴点間距離のしきい値は初め小さく設定し，4-連結細線化処理と同様に，画像の左上から処理を行い，反転した個数が0であれば，しきい値を上げて同様の操作を行う。これをしきい値が一定の値になるまで繰り返す。以下に修正を行った画像の例を図7.11に示す。

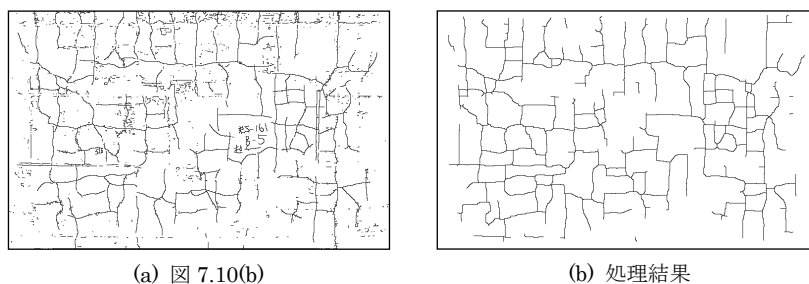


図7.11 特徴点に基づく修正の実行例

以上の処理を前処理として47枚の画像それぞれに対して行い、ひび割れパターンとして特徴抽出に用いる。

### 7.3 特徴量の抽出

#### 7.3.1 ひび割れ画像からの特徴抽出

パターン認識を実現するためには、まず、認識対象から何らかの特徴量を計測(抽出)する必要がある。一般には、特徴量は1種類だけではなく、複数の特徴量を計測し、それらを同時に用いることが多い。そのような特徴量は、通常、まとめて

$$x' = (x_1, x_2, \dots, x_n) \quad (7.10)$$

として表される。ここで $x'$ は、ベクトル $x$ の転置を表す。また、 $n$ は特徴量の個数である。

特徴抽出は認識性能を左右する極めて重要な処理である。この特徴注主をいかに巧みに設計するかで性能の大半が決定付けられてしまう。しかし、特徴抽出は認識対象に依存し、統一的、一般的な特徴抽出法を実現することは不可能である。そこで本研究では、実際に専門家が行うひび割れの評価手法に基づき特徴抽出部の設計を行った。

実際の専門家によるひび割れの評価においては、ひび割れの連続性、ひび割れの集中性、亀甲状・線状の種別、一方向性・二方向性の種別、の4つの点検項目において判定がなされている。そこで本研究では、これらの情報を反映する特徴量として、周辺分布ヒストグラム、特徴点の出現度数を特徴量として用いた。

#### 7.3.2 ひび割れ画素の周辺分布ヒストグラム

細線で表現されたひび割れパターンは、文字パターンと同様に方向を持った線素の集合によって構成されていると考えることができ、周辺分布ヒストグラムによる特徴抽出は有効であると考えられる。ひび割れパターンから水平、垂直、さらには斜め方向の黒画素数を抽出し、それぞれの方向に垂直な軸上に射影して得られる周辺分布を特徴ベクトルとして利用することができる。

ひび割れ領域（黒画素）を1画素とした2値画像を $f[i, j]$ 、画像サイズを $m \times n$ としたとき、横方向、縦方向へ射影した文字パターンの周辺分布はそれぞれ次のようになります。

$$\begin{aligned} \text{横方向分布（垂直軸への射影）} : P_h[j] &= \sum_{i=0}^{m-1} f[i, j] \\ \text{縦方向分布（水平軸への射影）} : P_v[i] &= \sum_{j=0}^{n-1} f[i, j] \end{aligned} \quad (7.11)$$

周辺分布特徴はパターンの位置情報、量的情報を反映しているので、ひび割れの連続性、およびひび割れの集中性を表現する特徴量として分類に利用することができる。図7.12に示すようにひび割れパターンから水平方向、垂直方向の直交軸上へ射影したヒストグラムを、特徴ベクトルの次元数に応じて量子化し特徴量として用いる。




図7.12 ひび割れ画素の周辺分布ヒストグラム

### 7.3.3 ひび割れによって囲まれた領域の周辺分布ヒストグラム

ひび割れによって囲まれた領域は剥離が発生する恐れがあるため、専門家はこれらの領域が大きい場合の損傷度を高く評価する。本研究では、ひび割れ画素によって囲まれた領域の周辺分布ヒストグラムも特徴量として用いる。ひび割れパターンから、ひび割れ画素によって囲まれた領域の抽出を行うために、本研究では画像処理におけるラベリングのアルゴリズムを使用する。以下にラベリングの手順について述べる。

画像においてつながっている画素を連結成分と呼ぶ。また、複数の連結成分が存在するとき、各連結成分に識別子を付けることをラベリングと呼ぶ。ラベリングを行うに際しては、まず始めに境界線追跡を行い、境界上のラベリングを行う本研究で使用した4連結の境界線追跡のアルゴリズムは以下の通りである。

図7.13に示すように画像左上からラスタ走査し、境界上の未追跡の1画素を探し、無ければ終了する。あれば、その位置を始点として記録する。その画素の周囲を反時計回りに境界上の1画素を探し、新しい1画素を境界点とする。その新しい1画素が始点に一致していなければ、(b)に戻る。一致したならば(a)に戻り、新しい境界の始点を探索する。

上記のアルゴリズム(a)において、左側が0画素のときは外側境界の始点、右側が0画素のときは内側境界の始点になる。




図7.13 ラベリングの手順

左上から水平方向に走査した場合、図7.13の例では、右側図形の $a$ 点が最初の境界となる。ラベリングの識別子を1から与えるものとする、右側図形の外側境界を1でラベリングする。次に、未追跡の境界を探索すると、 $b$ 点が新しい境界の始点になる。これも外側境界なのでラベリングの識別子を2に更新し、左側図形の境界をすべて2でラベリングする。次の未追跡の境界として内側境界である $c$ 点が求まる。内側境界のときは、その点の座標 $(i,j)$ とすると、 $i$ を1ずつデクリメント（左側を探索）、またはインクリメント（右側を探索）してその連結成分の外側境界の識別子を求め、内側境界も同じ識別子でラベリングを行う。すべての境界のラベリングを終えたならば、再度左上から走査し、まだラベリングされていない1画素があれば、その左側がその識別子でラベリングを行う。

以上の手順でラベリングを行うことにより、ひび割れパターンからひび割れ画素によって囲まれた領域の抽出を行った例を図7.14に示す。




図7.14 ひび割れ画素によって囲まれた領域の抽出例

ラベリングによって抽出した領域に対して、前節で述べた手法を用いて水平方向、垂直方向の直交軸上へ射影したヒストグラムを作成し、特徴ベクトルの次元数に応じて量子化し特徴量として用いる。

### 7.3.4 ひび割れ線図形における特徴点

細線化された図形の1-画素は端点、連結点、分岐点、交差点などの特徴点として表現される。これらの特徴点はパターンの構造的な特徴を表しており、特徴点の出現度数による特徴抽出は有効であると考えられる。

画素中にある黒画素（1-画素）を注目点とし、図7.15に示すようにそのまわりの画素の状態によって特徴点を決定する。3×3マスクを用いた場合は、端点、連結点、分岐点、交差点に分類できます。連結点は画素と画素を接続する特徴点（すなわち、他の特徴点以外の1-画素は全て連結点）となるので、連結点を除いた他の特徴点の出現度数を特徴量として用いる。

これらの特徴点は、注目点の周囲8画素を調べ、独立している1-画素の個数によって分類できる。この個数を連結数と呼ぶ。通常は8方向量子化符号を用い、 $x_k$ を画素位置 $k$ の画素値とすると連結数 $N$ は

$$x_k=1かつx_{k-1}=1のときN=N+1 \quad (k=1,2,...,8) \quad (7.12)$$

によって求められる（ただし、 $x_8=x_0$ ）。連結数と特徴点の関係は

$N=1$ ：端点

$N=2$ ：連結点

$N=3$ ：分岐点

$N=4$ ：交差点

となる。




図7.15 特徴点の種類

また、4-連結細線で表されたパターンであれば、注目画素の上下左右に存在する1-画素の個数から求めることができる。しかし、細線化の過程で、交差点が図7.16のように落ち着く

ことがある．図7.16(a)の場合は，式(7.12)で求めると中央の4個が全て連結点となり，左右上下の画素数で求めると分岐点になる．また，図7.16(b)の場合はどちらで判断しても2個の分岐点となります．本研究では，上下左右の1画素の個数から求め，分岐点や交差点が近接しているときは1個の交差点として扱う．




図7.16 交差点が複数の連結点や分岐点に分かれる例

本研究では，特徴抽出に用いる特徴点として端点，分岐点，交差点の他に角点（交差点）を用いることにする．

デジタル曲線からこのような角点を検出する方法として曲率を利用する方法が通常用いられる．本研究では，デジタル曲線上で，ある画素間隔で代表点を求め，隣り合う代表点を結ぶ直線の勾配が急激に変化するとき，その代表点を角点として認識する方法を用いた．図7.17において代表点を $a$ ， $b$ で示しており，これらの代表点を結ぶ2つの直線を2次元ベクトル $a$ ， $b$ で表現したとき，相関係数は，

$$R = \cos \theta = \frac{\langle a, b \rangle}{\|a\| \cdot \|b\|} = \frac{(x_1 - x_0)(x_2 - x_1) + (y_1 - y_0)(y_2 - y_1)}{\sqrt{(x_1 - x_0)^2 + (y_1 - y_0)^2} \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}} \quad (7.13)$$

で求められる．角度 $\theta$ があるしきい値以上，すなわち相関係数 $R$ がある値以下のとき，中心にある代表点を角点とし，2つの角点が近すぎる場合にはそれらの中間点を角点とする．

特徴点はひび割れパターンの形状情報を反映しているので，ひび割れ方向（1方向性，2方向性の種別），亀甲状ひび割れ，または線状ひび割れの種別を表現する特徴量として分類に利用することができる．特徴ベクトルの次元数に応じて，ひび割れパターンを複数のブロックに分割し，個々のブロック内における4種類の特徴点の出現度数を特徴量として用いる．




図6.17 2次元ベクトルのなす角

図7.18は特徴点抽出の実行例である．交差点を●，分岐点を○，端点を■，角点を□で表示している．




図7.18 特徴点抽出実行例

## 7.4 識別実験

本研究では，橋梁の床版を撮影したデジタル画像47枚を対象とし，7.3節で述べた手順により抽出した特徴量を用いてひびわ割れ画像の分類を行う．分類の手法としてLVQ，線形SVM，および非線形SVMを適用し，それぞれの識別精度について比較を行う．LVQの学習アルゴリズムにはOLVQ1を使用し，テストケースごとに150回の学習を行う．線形SVMではソフトマージンSVMに拡張したモデルを使用し，非線形SVMには多項式型カーネルとGaussian型カーネルの2種類を使用する．また学習段階においては，それぞれの画像に対して専門家が行った3段階の床版損傷度による評価を教師信号として用いる．識別結果の評価指標は精度  $prec(h)$  を用いる．テストにおける識別精度の評価はleave-one-outで行う．

#### 7.4.1 学習ベクトル量子化による識別実験

まず，周辺分布ヒストグラムの特徴量を用いたLVQによる，ひび割れ画像の分類を行う．作成する特徴ベクトルの次元数はそれぞれ4次元，8次元，16次元，32次元である．それぞれの手法における識別結果を表7.2に示す．

表 7.2 LVQ 識別結果（周辺分布ヒストグラム）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 50    | 46.2  | 87.5  | 68.1  |
| 8   | 80    | 61.5  | 91.7  | 80.9  |
| 16  | 80    | 61.5  | 91.7  | 80.9  |
| 32  | 70    | 61.5  | 91.7  | 78.7  |

LVQの識別結果における最大識別率は特徴次元数8，および16において80.9%となった．これらの結果からひび割れの分類において周辺分布ヒストグラムによる特徴量が有効であるといえる．周辺分布ヒストグラムにおける分類では，LVQではクラスBの識別率にくらべクラスAの識別率が高くなることが確認できた．このことは，より損傷どの高い床版画像を識別できることは，損傷度の診断においてより重要であるといえるため，パターン認識系の識別器としてLVQを使用することは有効であると言える．

次に，特徴点の出現度数による特徴量を用いてひび割れ画像の分類を行う．周辺分布ヒストグラムの場合と同様に，作成する特徴ベクトルの次元数はそれぞれ4次元，8次元，16次元，32次元である．それぞれの手法における識別結果を表7.3に示す．

表 7.3 LVQ 識別結果（特徴点の出現度数）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 60    | 76.9  | 91.7  | 80.9  |
| 8   | 60    | 61.5  | 91.7  | 76.6  |
| 16  | 60    | 61.5  | 91.7  | 76.6  |
| 32  | 60    | 61.5  | 91.7  | 76.6  |



LVQの識別結果における最大識別率は特徴次元数4, および, 16において80.9%となり, また, SVMの識別結果における最大識別率は特徴次元数16において83.0%となり, 周辺分布ヒストグラムを用いた場合と同様に80%を越える高い識別率を得ることができた. これらの結果からひび割れの分類において特徴点の出現度数による特徴量は有効であると言える.

各特徴量を単独で用いた場合でも80%を超える識別率を得ることができた. しかし, それぞれの特徴量において各クラスの識別結果の被覆が異なることから, これら2つの特徴量をうまく組み合わせることにより, より高い識別率が得られると考えられる. そこで, 周辺分布ヒストグラム特徴と特徴点の出現度数特徴を組み合わせた特徴量を用いて, LVQによる学習識別を行った. 識別結果を表7.4に示す.

表 7.4 LVQ 識別結果 (特徴量の組み合わせ)

| 次元数      | 識別精度  |       |       |       |
|----------|-------|-------|-------|-------|
|          | A(10) | B(13) | C(24) | TOTAL |
| 20(4+4)  | 50    | 61.5  | 87.5  | 72.3  |
| 24(8+4)  | 60    | 69.2  | 91.7  | 78.7  |
| 32(16+4) | 70    | 69.2  | 91.7  | 80.9  |
| 48(32+4) | 80    | 46.2  | 91.7  | 76.6  |

LVQにおける最大識別率は特徴次元数32において80.9%となり, 各特徴量単体で用いた場合と同様の識別率であり, 特徴量を組み合わせて用いることにより識別率を改善することはできなかった.

#### 7.4.2 線形サポートベクトルマシンによる識別実験

次に, 周辺分布ヒストグラムの特徴量を用いて, ソフトマージンで拡張した線形サポートベクトルマシンによるひび割れ画像の分類を行った<sup>[16]</sup>. 作成する特徴ベクトルの次元数はそれぞれ4次元, 8次元, 16次元, 32次元である. それぞれの手法における識別結果を表7.5に示す.

線形SVMの識別結果における最大識別率は特徴次元数32において80.9%となった. LVQにおける結果と同様に80%を超える高い識別率が得られた. これらの結果からひび割れの分類において周辺分布ヒストグラムによる特徴量が有効であるといえる. 周辺分布ヒストグラムにおける分類では, LVQではクラスAの識別率に比べて全体的に高いのに対し, 線形SVMではクラスAの識別率がLVQの場合ほど高くないことが確認できる.

表 7.5 線形 SVM 識別結果（周辺分布ヒストグラム）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 50    | 69.2  | 91.7  | 76.6  |
| 8   | 60    | 69.2  | 91.7  | 78.7  |
| 16  | 60    | 61.5  | 91.7  | 76.6  |
| 32  | 70    | 69.2  | 91.7  | 80.9  |

次に，特徴点の出現度数による特徴量を用いてひび割れ画像の分類を行う．周辺分布ヒストグラムの場合と同様に，作成する特徴ベクトルの次元数はそれぞれ4次元，8次元，16次元，32次元である．それぞれの手法における識別結果を表7.6に示す．

表 7.6 線形 SVM 識別結果（特徴点の出現度数）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 50    | 84.6  | 91.7  | 80.9  |
| 8   | 60    | 76.9  | 91.7  | 80.9  |
| 16  | 60    | 84.6  | 91.7  | 83.0  |
| 32  | 50    | 84.6  | 91.7  | 80.9  |

線形SVMの識別結果における最大識別率は特徴次元数16において83.0%となり，特徴点の出現度数における画像の分類では，LVQによる識別精度と比べ線形SVMを用いた場合により良い結果が得ることができた．これらの結果からひび割れの分類において特徴点の出現度数による特徴量は有効であると言える．

LVQの場合と同様に，周辺分布ヒストグラ特徴と特徴点の出現度数特徴を組み合わせた特徴量を用いて，線形SVMによる学習識別を行った．それぞれの手法における識別結果を表7.7に示す．

LVQにおいては特徴量を組み合わせて用いることにより識別率を改善することはできなかったが，一方，SVMの識別結果における最大識別率は特徴次元数24において85.1%となり，特徴量を組み合わせて用いることにより識別率が改善されることを確認できた．以上の結果から，識別器としてLVQとSVMを比べた場合に，SVMの方がより良い結果を得ることが

できることを確認した。

表 7.7 線形 SVM 識別結果（特徴量の組み合わせ）

| 次元数      | 識別精度  |       |       |       |
|----------|-------|-------|-------|-------|
|          | A(10) | B(13) | C(24) | TOTAL |
| 20(4+4)  | 50    | 84.6  | 91.7  | 80.9  |
| 24(8+4)  | 60    | 92.3  | 91.7  | 85.1  |
| 32(16+4) | 60    | 69.2  | 91.7  | 78.7  |
| 48(32+4) | 70    | 69.2  | 91.7  | 80.9  |

### 7.4.3 非線形サポートベクトルマシンによる識別実験

最後に、カーネルトリックを用いて非線形識別器に拡張したSVMによる識別を行う。本研究では、カーネルとして多項式型カーネルおよびGaussian型カーネルの2種類を用いて実験を行った。ここでは、他の手法との識別精度の比較、および2種類のカーネルによる識別精度の比較を行う。

#### (1) 多項式型カーネルを用いた場合

周辺分布ヒストグラムの特徴量を用いて、多項式型カーネルで拡張した非線形SVMによるひび割れ画像の分類を行った識別結果を表7.8に示す。作成する特徴ベクトルの次元数はそれぞれ4次元、8次元、16次元、32次元である。

表 7.8 多項式型カーネル非線形 SVM 識別結果（周辺分布ヒストグラム）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 50    | 84.6  | 91.7  | 80.9  |
| 8   | 60    | 84.6  | 91.7  | 83.0  |
| 16  | 50    | 84.6  | 91.7  | 80.9  |
| 32  | 70    | 69.2  | 91.7  | 80.9  |

最大識別率は特徴次元数8において83%となった。周辺分布ヒストグラムを用いた、線形SVMによる結果では、最大識別率は80.9%であることから、カーネルを用いて非線形に拡張

したSVMを用いることによってより高い識別率が得られることを確認した。

次に、特徴点の出現度数による特徴量を用いてひび割れ画像の分類を行う。周辺分布ヒストグラムの場合と同様に、作成する特徴ベクトルの次元数はそれぞれ4次元、8次元、16次元、32次元である。それぞれの手法における識別結果を表7.9に示す。

表 7.9 多項式型カーネル非線形 SVM 識別結果（特徴点の出現度数）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 60    | 76.9  | 91.7  | 80.9  |
| 8   | 60    | 76.9  | 91.7  | 80.9  |
| 16  | 60    | 92.3  | 91.7  | 85.1  |
| 32  | 70    | 69.2  | 91.7  | 80.9  |

最大識別率は特徴次元数16において85.1%となった。特徴点の出現度数を用いた、線形SVMによる結果では、最大識別率は83%であることから、特徴点の出現度数を特徴量として用いた場合でも、カーネルを用いて非線形に拡張したSVMを用いることによってより高い識別率が得られることを確認した。

他の手法の場合と同様に、2つの特徴量を組み合わせて多項式型カーネルで拡張した非線形SVM学習識別を行った。識別結果を表7.10に示す。

表 7.10 多項式型カーネル非線形 SVM 識別結果（特徴量の組み合わせ）

| 次元数      | 識別精度  |       |       |       |
|----------|-------|-------|-------|-------|
|          | A(10) | B(13) | C(24) | TOTAL |
| 20(4+4)  | 70    | 69.2  | 91.7  | 80.9  |
| 24(8+4)  | 70    | 69.2  | 91.7  | 80.9  |
| 32(16+4) | 80    | 69.2  | 91.7  | 83.0  |
| 48(32+4) | 80    | 76.9  | 91.7  | 85.1  |

多項式型カーネルで拡張した非線形SVMによる最大識別率は特徴次元数48において85.1%となった。特徴量を組み合わせて用いた結果において、クラスAの識別率が全体的に

高いことから、識別器として線形SVMとカーネルによって拡張したSVMを比べた場合に、より良い診断結果を得ることができることを確認した。

## (2) Gaussian 型カーネルを用いた場合

周辺分布ヒストグラムの特徴量を用いて、Gaussian型カーネルで拡張した非線形SVMによるひび割れ画像の分類を行った識別結果を表7.11に示す。作成する特徴ベクトルの次元数はそれぞれ4次元、8次元、16次元、32次元である。

表 7.11 Gaussian カーネル非線形 SVM 識別結果（周辺分布ヒストグラム）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 50    | 61.5  | 91.7  | 74.5  |
| 8   | 70    | 69.2  | 91.7  | 80.9  |
| 16  | 80    | 61.5  | 91.7  | 80.9  |
| 32  | 80    | 61.5  | 91.7  | 80.9  |

Gaussian型カーネルで拡張した非線形SVMによる最大識別率は特徴次元数8, 16, および、32において80.9%となった。Gaussian型カーネルで拡張した非線形SVMによる識別結果では、他の手法と比べてクラスAにおいて高い識別率が得られており、パターン認識系の識別器としてGaussian型カーネルで拡張した非線形SVMを使用することは有効であると言える。

次に、特徴点の出現度数による特徴量を用いてひび割れ画像の分類を行う。周辺分布ヒストグラムの場合と同様に、作成する特徴ベクトルの次元数はそれぞれ4次元、8次元、16次元、32次元である。それぞれの手法における識別結果を表7.12に示す。Gaussian型カーネルで拡張した非線形SVMによる最大識別率は特徴次元数16において85.1%となり、線形SVMや多項式型カーネルを使用した場合と同様に高い識別率が得られた。

周辺分布ヒストグラ特徴と特徴点の出現度数特徴を組み合わせた特徴量を用いて、Gaussian型カーネルで拡張した非線形SVMによる学習識別を行った結果を表7.13に示す。最大識別率は特徴次元数32および48において85.1%となり、線形SVMや多項式型カーネルを使用した場合と同様に高い識別率が得られた。しかし、Gaussianカーネルを用いた場合より多くの特徴ベクトルにおいて85.1%の識別率が得られることから、Gaussian型カーネルで拡張した非線形SVMを用いることにより他の手法より識別精度が向上することを確認できた。

表 7.12 Gaussian カーネル非線形 SVM 識別結果（特徴点の出現度数）

| 次元数 | 識別精度  |       |       |       |
|-----|-------|-------|-------|-------|
|     | A(10) | B(13) | C(24) | TOTAL |
| 4   | 50    | 84.6  | 91.7  | 80.9  |
| 8   | 70    | 76.9  | 91.7  | 83.0  |
| 16  | 70    | 84.6  | 91.7  | 85.1  |
| 32  | 60    | 92.3  | 87.5  | 83.0  |

表 7.13 Gaussian カーネル非線形 SVM 識別結果（特徴量の組み合わせ）

| 次元数      | 識別精度  |       |       |       |
|----------|-------|-------|-------|-------|
|          | A(10) | B(13) | C(24) | TOTAL |
| 20(4+4)  | 50    | 92.3  | 91.7  | 83.0  |
| 24(8+4)  | 50    | 84.6  | 91.7  | 80.9  |
| 32(16+4) | 60    | 92.3  | 91.7  | 85.1  |
| 48(32+4) | 70    | 84.6  | 91.7  | 85.1  |

## 第8章 打音点検データによる軸力診断スキーム

### 8.1 診断スキームの検証データ

本研究では様々なソフトコンピューティングの手法を用いて、高力ボルトをハンマーで打撃した際の振動加速度データを学習し、非熟練技術者でも振動加速度データとコンピュータを用いることにより、軸力の診断が可能なシステムの開発を目的とした。本システムは鋼板を高力ボルトで締結した試験体を用いて、それから得た振動加速度データを周波数データに変換し、得られた周波数データから特徴量の抽出を行い、抽出した特徴量を用いて軸力を推定する。本システムのパターン認識における各処理について以下に述べる。また、処理のフローチャートを図 8.1 に示す。

- 1) 入力: 本研究では、高力ボルト打音診断実験により得られた振動加速度データから、高速フーリエ変換を用いて周波数データを取得し、入力データとして使用する。
- 2) 前処理: 前処理部において、得られた周波数データのレスポンスの範囲を1~0の値に正規化を行うことで不規則変動を少なくしたデータを抽出する。これらの処理を行ったデータを、周波数パターンとして特徴抽出に用いる。
- 3) 特徴抽出: 次に特徴抽出部では、周波数データのレスポンスに注目し、レスポンスがピークとなっている周波数とレスポンスを特徴量として取得する。また、元の振動加速度データから、移動平均法を用いて、振動加速度データの減衰率を特徴量として取得する。
- 4) 識別: 特徴抽出部で抽出した特徴量を用いて識別処理を行う。識別処理は入力パターンに対して複数のクラスのうち一つを対応させることによって行われる。通常のパターン認識系においては、あらかじめ識別辞書を用意し、抽出された特徴をこの辞書と照合することにより入力パターンの所属するクラスを出力する。しかし、実際に特徴ベクトルとして生起しうる全ての可能性を網羅する識別辞書を構成することは非現実である。そこで、収集されたパターンを学習することにより識別部の設計を行う。本実験で収集した軸力のパターンは軸力100%, 80%, 60%, 40%の4つのパターンである。




図 8.1 軸力診断のフローチャート

## 8.2 フーリエ変換

本実験では振動加速度データをフーリエ変換することで、時系列の加速度波形を周波数成分として表すデータにすることができる。ここでは、フーリエ変換の解説をする。フーリエ変換とは波形を正弦波の重ね合わせで表現し、時間を変数である関数を周波数に変数である関数に変換することが可能な変換である[27]。音声信号が時間  $x$  ( $-\infty < x < \infty$ ) を独立変数とする関数  $f(x)$  で与えられ、 $\omega$  を角周波数、 $e$  をネイピア数、 $i$  を虚数単位、 $\pi$  を円周率とすると、この関数  $f(x)$  に対してフーリエ変換と逆フーリエ変換はそれぞれ

$$F(\omega) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} f(x) e^{-i\omega x} dx \quad (8.1)$$

$$f(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} F(\omega) e^{i\omega x} d\omega \quad (8.2)$$

と定義され、これら二つの式(8.1) (8.2)をフーリエ変換対と呼ぶ。式(8.1)のフーリエ変換により得られる関数  $F(\omega)$  は角周波数  $\omega$  を変数とした連続関数であり、音声信号全体のフーリエスペクトル分布を表す。また、式(8.2)の逆フーリエ変換は、フーリエスペクトル  $F(\omega)$  から信号  $f(x)$  の再構成を表している。

### 8.2.1 離散フーリエ変換

離散フーリエ変換 (DFT ; discrete Fourier transform) とは離散関数に対するフーリエ変換であり、信号処理などで離散化されたデジタル信号の周波数解析などによく使われる[27]。また偏微分方程式や畳み込み積分を効率的に計算するためにも使われる。離散フーリエ変



換は計算機上で後述する高速フーリエ変換（FFT；Fast Fourier Transform）を使って高速に計算することが可能である． $n$  個の複素数列  $x_0, \dots, x_{n-1}$  に対して DFT することで  $n$  個の複素数列  $x = (x_0, \dots, x_{n-1})$ ,  $f = (f_0, \dots, f_{n-1})$

$$f(j) = \sum_{k=0}^{n-1} x_k e^{\frac{-2\pi i}{n} jk} \quad (8.3)$$

また，この変換を という記号で表し， $x = (x_0, \dots, x_{n-1})$ ,  $f = (f_0, \dots, f_{n-1})$  とおいて

$$f = F(x) \quad (8.4)$$

のように略記することが多い．

この逆変換にあたる逆離散フーリエ変換（IDFT；inverse discrete Fourier transform）は

$$x_k = \frac{1}{n} \sum_{j=0}^{n-1} f_j e^{\frac{2\pi i}{n} jk} \quad (8.5)$$

正規化係数（DFT は 1，IDFT は  $1/n$ ）や指数の符号は単なる慣習的なものであり，上式とは異なる式を扱うことがある．DFT と IDFT の差について，それぞれの正規化係数を掛けると  $1/n$  になることと，指数の符号が異符号であるということが重要であり，根本的には同一の変換作用素と考えられる．DFT と IDFT の正規化係数を両方とも  $1/\sqrt{n}$  にすると，両方ともユニタリ作用素（ユニタリ変換）になる．理論的にはユニタリ作用素にする方が好ましいが，実用上数値計算を行なう時は上式のように正規化係数を一つにまとめて，スケーリングを一度に行なうことが多い．

### 8.2.2 高速フーリエ変換

高速フーリエ変換とは，離散フーリエ変換（DFT）を計算機上で高速に計算するアルゴリズムである．逆変換を IFFT（Inverse FFT）という．代表的な高速フーリエ変換（FFT）アルゴリズムとして，Cooley-Tukey 型アルゴリズムが挙げられる．分割統治法（divide and conquer）を使ったアルゴリズムであり，再帰的に  $N = N_1, N_2$  のサイズの変換を，ガウス平面における回転因子である 1 の冪根を  $N$  程度のオーダーかけて，より小さいサイズである  $N_1, N_2$  のサイズの変換にしていくことで高速化を図っている．

最もよく知られた Cooley-Tukey 型アルゴリズムは，ステップごとに変換のサイズをサイズ  $N/2$  の 2 つの変換に分割するので，2 の累乗回数に限定される．しかし，一般的に次数は 2 の累乗にはならないので，素因数が偶数と奇数とで別々のアルゴリズムに分岐する．

Cooley-Tukey 型アルゴリズムは変換をより小さい変換に分解していくので，他の離散フーリエ係数のアルゴリズムと任意に組み合わせることができる．特に  $N \leq 8$  あたりまで分解すると，固定次数の高速なアルゴリズムに切り替えることが多い．

### 8.3 正規化

特徴抽出を行う場合に注意しなければならないのは、パターン間の類似性が特徴空間上の距離として反映されなければならない。すなわち、類似したパターン同士は特徴空間上で互いに近接した位置を占めるのが望ましい。一般に特徴ベクトルは、重さ、長さといった性質の異なる要素から構成されている。そのため、単位の取り方を変えるだけで特徴空間上のパターンの位置関係は様相が一変する。例えば、4つの2次元特徴ベクトル  $x_1, x_2, x_3, x_4$  が、特徴空間上で図8.2のような配置であったとする。今、 $x_1$  が長さを表す特徴で、図8.2(a)ではmmが採用されていたとする。ここで  $x_1$  の単位をcmに変更したとすると、 $x_1$  は1/10にスケーリングされ、図8.2(b)のようになる。図8.2(a)と比べてみると明らかなように、全く無視してしまうような状況を生ずる。単位の取り方、言い換えればスケーリングはどの特徴を重視するかという重み付けを施していることにほかならない。単位の選び方によってその重み付けが決まってしまうという恣意性を回避するには、ある方針の下で各特徴軸を正規化しておく必要がある。本実験では、フーリエ変換した周波数データのレスポンスが同じ軸力間のデータごとで異なってしまう。そこで、レスポンスを1~0の範囲に収めることで、軸力間でのレスポンスの違いを顕著にさせる。




図 8.2 単位の違いによる分布の変化

ここで、正規化の方法として、本研究ではパターン相互の距離を最小化するというものを適用する。今  $d$ 次元特徴空間上の  $n$ 個のパターン集合の中で、 $p$ 番目 ( $1 \leq p \leq n$ ) のパターンを  $x_p$  で表し、

$$x_p = t(x_{p1}, x_{p2}, \dots, x_{pc}) \quad (8.6)$$

とする。正規化のための変換行列  $A$  を

$$A = \begin{pmatrix} a_1 & 0 & \cdots & 0 \\ 0 & a_2 & & \vdots \\ \vdots & & \ddots & 0 \\ 0 & \cdots & 0 & a_d \end{pmatrix} \quad (8.7)$$

とし、 $x_p$  に正規化処理を施して得られたパターンを  $y_p$  とすると

$$y_p = t(y_{p1}, y_{p2}, \dots, y_{pd}) = A^t x_p \quad (8.8)$$

で表せる．要素ごとに書くと以下のように表せる．

$$y_{pj} = a_j x_{pj} (p = 1, 2, \dots, nj = 1, 2, \dots, d) \quad (8.9)$$

$n$ 個のパターン集合の中の $p$ 番目のパターンと，ほかの $(n-1)$ 個のパターンとの平均距離を  $r_p$  とすると，正規化した後では

$$r_p^2 = \frac{1}{n-1} \sum_{p=1}^n \sum_{q=1}^n \sum_{j=1}^d (y_{pj} - y_{qj})^2 \quad (8.10)$$

となる．したがって，正規化後の各パターン間の平均距離を  $R$  とすると

$$R^2 = \frac{1}{n} \sum_{p=1}^n r_p^2 = \frac{1}{n(n-1)} \sum_{p=1}^n \sum_{q=1}^n \sum_{j=1}^d (y_{pj} - y_{qj})^2 \quad (8.11)$$

となる．式(8.9)を代入して

$$\begin{aligned} R^2 &= \frac{1}{n(n-1)} \sum_{p=1}^n \sum_{q=1}^n \sum_{j=1}^d a_j^2 (y_{pj} - y_{qj})^2 \\ &= \frac{1}{n-1} \sum_{j=1}^d a_j^2 \frac{1}{n} \sum_{p=1}^n \sum_{q=1}^n \left( \frac{1}{n} x_{pj}^2 - \frac{2}{n} x_{pj} x_{qj} + \frac{1}{n} x_{qj}^2 \right) \\ &= \frac{n}{n-1} \sum_{j=1}^d a_j^2 \left( \frac{1}{n} \sum_{q=1}^n \frac{1}{n} \sum_{p=1}^n x_{pj}^2 - 2 \cdot \frac{1}{n} \sum_{p=1}^n x_{pj} \frac{1}{n} \sum_{q=1}^n x_{qj} + \frac{1}{n} \sum_{p=1}^n \frac{1}{n} \sum_{q=1}^n x_{qj}^2 \right) \\ &= \frac{n}{n-1} \sum_{j=1}^d a_j^2 \left( \frac{1}{n} \sum_{q=1}^n \overline{x_j^2} - 2 \overline{x_j}^2 + \frac{1}{n} \sum_{p=1}^n \overline{x_j^2} \right) \\ &= \frac{2n}{n-1} \sum_{j=1}^d a_j^2 (\overline{x_j^2} - \overline{x_j}^2) \end{aligned} \quad (8.12)$$

が得られる．ここで  $\overline{x}$  は  $x$  の集合平均を表す．一方、 $j$  番目の特徴  $x_j$  の分散  $\sigma_j^2$  は

$$\sigma_j^2 = \frac{1}{n-1} \sum_{p=1}^n (x_{pj} - \overline{x_j})^2$$

$$\begin{aligned}
&= \frac{1}{n-1} (\overline{x_j^2} - 2\bar{x}_j^2 + \bar{x}_j^2) \\
&= \frac{1}{n-1} (\overline{x_j^2} - \bar{x}_j^2)
\end{aligned} \tag{8.13}$$

である．式(8.13)を式(8.12)に代入することにより

$$R^2 = 2 \sum_{j=1}^d a_j^2 \sigma_j^2 \tag{8.14}$$

が得られる．ここで式(8.14)を最小化する  $a_j$  を，次の制約条件の下で求める．

$$\prod_{j=1}^d a_j = 1 \tag{8.15}$$

この制約は，特徴空間の単位超立方体の体積を，正規化の前後で一定に保つという条件に相当する．ラグランジュの未定乗数法を用いて

$$L = 2 \sum_{j=1}^d a_j^2 \sigma_j^2 - \lambda (\prod_{j=1}^d a_j - 1) \tag{8.16}$$

の極値を求める． $L$ を  $a_j$  で偏微分した結果を0と置き

$$\frac{\partial L}{\partial a_j} = 0 \tag{8.17}$$

を得る．これより

$$4a_j \sigma_j^2 - \lambda \prod_{k \neq j}^d a_k = 0 \tag{8.18}$$

となるので，両辺に  $a_j$  を掛けて式(8.15)を用いると

$$a_j = \frac{\sqrt{\lambda}}{2\sigma_j} \tag{8.19}$$

が得られる．再度，式(8.15)に代入して

$$\lambda = 4(\prod_{j=1}^d \sigma_j)^2 \tag{8.20}$$

となる．したがって  $a_j$  は

$$a_j = \frac{1}{\sigma_j} (\prod_{k=1}^d \sigma_k)^{\frac{1}{d}} \tag{8.21}$$

となる．式(6.60)の  $(\prod_{k=1}^d \sigma_k)$  は各特徴軸に共通であるから  $a_j$  は  $1/\sigma_j$  に比例することになる．すなわち

$$a_j \propto \frac{1}{\sigma_j} \tag{8.22}$$

である．これは各特徴軸を標準偏差で正規化し，平均の回りの分散すなわちパターンの広がり等を等しくするという直感的にも自然な処理になっている．

## 8.4 特徴量の抽出

本研究では、振動加速度データから抽出した様々な特徴量を用いて、軸力の推定を行う。軸力推定時に用いる特徴量として、振動加速度データから抽出した周波数特徴量とレスポンス特徴量、減衰率特徴量の3種類の特徴量を用いる。周波数特徴量とレスポンス特徴量、減衰率特徴量の抽出方法を以下に述べる。周波数特徴量とレスポンス特徴量は、周波数データの周波数やレスポンスに注目し、レスポンスの値がピークとなっている周波数やレスポンスの値を上位から特徴量として取得する。また、減衰率特徴量は移動平均法を適用して、元の振動加速度データを加工後、特徴量を抽出する

### 8.4.1 周波数特徴量とレスポンス特徴量の抽出

周波数特徴量とレスポンス特徴量の抽出は、振動加速度データを変換した周波数データを用いる。周波数データは高速フーリエ変換で振動加速度データを周波数データに変換した後、ウェーブレット変換と平滑化、正規化を適用したものである。図8.3に特徴量抽出時に用いる周波数データを示す。図8.3の縦軸は周波数データのレスポンス、横軸は周波数を示す。周波数特徴量は周波数データのレスポンスの値がピークとなっている周波数の上位5つを抽出する。図8.3中の $F_1 \sim F_5$ が特徴量として抽出する周波数である。また、レスポンス特徴量においても、レスポンスの値がピークとなっているレスポンスの上位5つを抽出する。図8.3中の $R_1 \sim R_5$ が特徴量として抽出するレスポンスである。尚、レスポンスの1位は本実験で用いた全てのデータにおいて、図8.3中の $R_1$ の値は正規化によりすべて1であり、軸力推定には使用しない。つまり、ピーク周波数の1位～5位の5個とピークレスポンスの2位～5位の4個の計9個の特徴量を使用して、軸力の推定を行う。




図8.3 周波数・レスポンスの抽出方法

#### 8.4.2 移動平均法

減衰率特徴量の抽出方法について述べる前に、移動平均法について説明する。移動平均法とは、観測したデータからある一定の区間を定め、現データの値をその区間中のデータの平均値をとり、プロットし直す方法である[28]。移動平均法の特徴として、時系列データを平滑化することによって、変動の激しい時系列データの傾向を把握することが可能な点が挙げられる。しかし、平滑化することによるデータの欠損が発生することがある。移動平均法には大きく分けて単純移動平均、加重移動平均、指数移動平均などが挙げられる。単純移動平均 (SMA ; Simple Moving Average) は、直近の  $n$  個のデータに対して重み付けをしない単純な平均である。区間  $n$  における単純移動平均を求める式は次のようになる。  $V(t)$  はある時点  $t$  での振幅を表す。

$$SMA(n) = \sum_{t=0}^{n-1} v(t)/n \quad (8.23)$$

加重移動平均 (Weighted Moving Average : WMA) とは、個々のデータに異なる重みをつけて平均を計算するものである。区間  $n$  の WMA では、現在のデータに最も近い重みを  $n$  とし、その前のデータを  $n-1$ 、などと重みを減らしていったり、最終的にゼロにする。区間  $n$  での加重移動平均  $WMA(n)$ を求める式は次のようになる。

$$WMA(n) = \sum_{t=0}^{n-1} \{(n-1) \times v(t)\} / \sum_{t=0}^{n-1} t \quad (8.24)$$

指数移動平均 (Exponentially Weighted Moving Average : EMA または EWMA) は指数関数的に重み付けを減少させる。指数関数的に減少する重み付けは、最近のデータを重視すると共に古いデータを完全には切り捨てない。重み付けの減少度合いは平滑化係数と呼ばれる0と1の間の値をとる定数  $\alpha$  で決定される。 $\alpha$  は百分率で表現されることもあり、平滑化係数が10%というのは、 $\alpha=0.1$ と同じことを表している。 $\alpha$ の時系列区間を  $n$  で表すこともあり、その場合は

$$\alpha = \frac{2}{n+1} \quad (8.25)$$

となる。例えば、 $n=9$ なら $\alpha=0.2$ となる。 $t$ 時点における指数移動平均値 $EMA(t)$ は

$$EMA(n) = \sum_{t=0}^{n-1} v(t)/n \quad (8.26)$$

$$EMA(n) = EMA(n-1) + \alpha\{v(t) - EMA(n-1)\} \quad (8.27)$$

で求められる。 $EMA(n)$ の最初の値は式(8.26)を用いて求め、それ以降は式(8.27)を用いて求める。本研究では、最も基本的な方法である単純移動平均を用いて、減衰率特徴量の抽出を行う。

### 8.4.3 移動平均法を適用した減衰率特徴量の抽出

減衰率特徴量の抽出には、元の振動加速度データに移動平均法を適用したものをを用いる。元の振動加速度データを図 8.4、振動加速度データに移動平均法を適用した振動加速度を図 8.5、図 8.6、図 8.7 に示す。図 8.4～図 8.7 の縦軸は振動加速度データの振幅、横軸は時間を示す。図 8.5～図 8.7 はそれぞれ 50 点ずつ、100 点ずつ、200 点ずつの平均を取り、プロットし直したものである。振動加速度データのサンプリング周波数が 5000Hz なので、50 点ずつ、50 の 2 倍である 100 点ずつ、50 の 4 倍である 200 点ずつとした。図 8.5～図 8.7 より、移動平均法を適用することによって波形が崩れて、減衰の傾向が把握できない状態になっていることが分かる。




図 8.4 元の振動加速度データ




図 8.5 移動平均を適用した振動加速度  
(50 点ずつの平均)




図 8.6 移動平均を適用した振動加速度  
(100 点ずつの平均)




図 8.7 移動平均を適用した振動加速度  
(200 点ずつの平均)

そこで、図 8.8 のように振動加速度の振幅の絶対値をとることによって、振動加速度データを加工したものをを用いて、移動平均法を適用する。図 8.8 のデータに対して移動平均法を適用した結果を図 8.9、図 8.10、図 8.11 に示す。図 8.9～図 8.11 は図 8.5～図 8.7 と同様に 50 点ずつ、100 点ずつ、200 点ずつの平均を取り、プロットし直したものである。図 8.9～図 8.11 より、波形の傾向が把握できる状態になっていることが分かる。よって、振動加

速度データの振幅の絶対値をとり，加工したものを減衰率特徴量の抽出に用いることとした．




図 8.8 振動加速度データの加工データ




図 8.9 移動平均を適用した振動加速度  
(50 点ずつの平均)




図 8.10 移動平均を適用した振動加速度  
(100 点ずつの平均)




図 8.11 移動平均を適用した振動加速度  
(200 点ずつの平均)

減衰率特徴量は最大振幅の時間から最大振幅の  $1/2$ ,  $1/3$ ,  $\dots$  となるまでの時間を計測したものとする．つまり，図 8.12 のように最大振幅から一定の振幅に減衰するまでの時間を減衰率特徴量とする．図中の  $W_1$ ,  $W_2$  が抽出する減衰率特徴量である．本研究で用いる移動平均法を適用した減衰率特徴量の個数は，最大振幅の  $1/2$ ,  $1/3$ ,  $\dots$ ,  $1/11$  の 10 個とした．

つまり， $W_1 \sim W_{10}$  までの特徴量を抽出し，軸力推定に用いる．識別実験では，特徴量の個数によって識別率がどのように変化するかを検証するために個数を変えて識別実験を行う．また，平均値の取り方として，50 点ずつ，100 点ずつ，200 点ずつの 3 パターンにおいて識別実験を行い，比較検証をした．






図 8.12 減衰率特徴量の抽出方法

## 8.5 特徴量を用いた診断スキームの識別実験

### 8.5.1 実験の概要

実験で使用するデータは、図 8.13 に示すような小型試験体を用いてデータ収集を行った。図 8.14 は小型試験体の軸力を測るためのひずみゲージの設置図であり、図 8.15 は小型試験体に取り付ける振動加速度センサの位置とハンマーで打撃する位置を示した図である。実験に用いた試験体は 2 種類であり、軸力を変えて振動加速度データを収集した。データ収



図 8.13 小型試験体の写真




図 8.14 小型試験体の構成




図 8.15 センサ位置と打撃位置

集をした時の状況を表 8.1 に示す。試験体 TYPE-1 は軸長が 80mm の M22×80 の F10T 高力ボルトで締結しており，試験体 TYPE-2 は軸長が 110mm の M22×105 の F10T 高力ボルトで締結している。また，高力ボルトは摩擦接合設計をしており，摩擦抵抗力を 48kN で規定して設計している。さらに，摩擦係数は 0.4 以上となるようにして，橋梁においては安全率を 1.7 程度とるので， $48 \times 1.7 / 0.4$  から 204kN となる。示方書では 205kN を設計軸力としているため，それを基準として軸力を設定している。表 8.1 の条件のもと，ハンマーで各 10 回ずつ打撃し，その際に発生した振動を振動計デジバイプロ MODEL-1332B を用いて，5000Hz のサンプリング周波数で振動加速度データを収集した。データ収集で得た振動加速度データは，軸力 100% が 40 個，軸力 80% が 40 個，軸力 60% が 40 個，軸力 40% が 40 個の計 160 個である。実際の技術者からの意見により，軸力 100% と軸力 80% を安全な状態とし，軸力 60% と軸力 40% を危険な状態と設定する。各識別実験において，表 8.1 の各条件で得られた 20 個のデータの内，16 個を学習データ，残り 4 個をテストデータとして実験を行った。つまり，学習データは軸力 100%，80%，60%，40% が各 32 個ずつの合計 128 個で，テストデータは軸力 100%，80%，60%，40% が各 8 個ずつの合計 32 個である。学習データとテストデータの抽出はランダムで行った。データのサンプリング，学習，評価のサイクルを 10 回行い，その平均値を結果としてまとめた。

表 8.1 振動加速度データの採取表

| タイプ                            | 軸力(%) | 軸力(kN) | 収集回数 |
|--------------------------------|-------|--------|------|
| TYPE-1<br>(HTB M22 × 80 F10T)  | 100%  | 205.5  | 20   |
|                                | 80%   | 161.2  | 20   |
|                                | 60%   | 122.8  | 20   |
|                                | 40%   | 82.4   | 20   |
| TYPE-2<br>(HTB M22 × 105 F10T) | 100%  | 206    | 20   |
|                                | 80%   | 163.8  | 20   |
|                                | 60%   | 122.6  | 20   |
|                                | 40%   | 82.4   | 20   |

また，本研究では，識別器の性能評価として識別誤差と F 値を用いた。本研究における識別誤差とは，推定軸力が実際の軸力とどれだけ離れているかを考慮するための指標である。識別誤差の算出方法を図 8.16 に示す。例えば，図 8.16 のように軸力 100% のものを軸力 60% と識別した場合，2 クラス分ずれているので，軸力 60% と識別している値に 2 をかけた値を識別誤差とする。軸力ごとに誤差を集計し，その合計値を識別器の識別誤差とする。識別誤差はその値が低ければ低いほど，軸力診断の精度が高いものとする。また，実際の軸力診断を想定したときに，低軸力のボルトを見逃さない，誤推定しないことが重要である。本実験では，軸力 60% と軸力 40% を危険な状態とするので，軸力 60% と軸力 40% を軸力 100% と軸力 80% として推定していないかどうかを考慮する必要がある。その評価指標と

して F 値を用いる。F 値の説明の前に、適合率と再現率について説明する[20]。適合率と再現率は、情報検索の分野で利用されているもので、適合率とは出力された結果の中に、どれだけ正解が含まれているかを示す指標である。再現率とは、正解のクラスの中からどれだけ、結果として出力できたかを示す指標である。適合率と再現率の間には、トレードオフの関係があるので、両者の調和平均をとった F 値と呼ばれるものが利用される。本研究では、この F 値を利用して、識別器の性能評価を行うこととした。本実験で算出する F 値は軸力 100%と軸力 80%の 2 クラスにおける F 値になる。このようにすることで、軸力 60%と軸力 40%が軸力 100%と軸力 80%として識別していないかどうかと、軸力 100%と軸力 80%を軸力 60%と軸力 40%として識別していないかどうかを判定することができる。F 値は 1~0 の範囲で、値が高いほど性能が良いと考えることができる。

|       |      | 推定軸力 |     |     |     | 合計    |
|-------|------|------|-----|-----|-----|-------|
|       |      | 100% | 80% | 60% | 40% |       |
| 実際の軸力 | 100% | 5    | 1   | 1   | 1   | 6.00  |
|       | 80%  | 1    | 5   | 1   | 1   | 4.00  |
|       | 60%  | 1    | 1   | 5   | 1   | 4.00  |
|       | 40%  | 1    | 1   | 1   | 5   | 6.00  |
| 評価指標  |      | 識別誤差 |     |     |     | 20.00 |

図 8.16 識別誤差の算出方法

### 8.5.2 識別実験（周波数・レスポンス特徴量を用いた識別）

識別実験 1 では基礎的な実験として、周波数特徴量とレスポンス特徴量を用いて識別実験を行い、比較検証した。まず、特徴量の個数によって識別率がどのように変化するかを検証するために、特徴量の個数を変えた識別実験を行った。さらに、パターン認識手法によって、識別率がどう変化するかも検証するために、パターン認識手法を変えた識別実験も行った。

#### (1) 周波数・レスポンス特徴量を用いた識別（RF）

表 8.2～表 8.7 はランダムフォレストを用いて識別実験を行った結果である。表 8.2 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量のみを用いて識別実験を行った結果である。表 8.3 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量のみを用いて識別実験を行った結果である。表 8.4 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量とレスポンスの上位 2 位～3 位までの 2 個のレスポンス特徴量を用いて識別実験を行った結果である。表 8.5 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量とレスポンスの上位 2 位～3 位までの 2 個のレスポンス特徴量を用いて識別実験を行った結果である。表 8.6 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量とレスポンスの上位 2 位～5 位までの 4 個のレスポンス特

表 8.2 周波数 3 個のみの識別結果 (RF)

|       |      | 推定軸力 |     |            |     | 識別率    |
|-------|------|------|-----|------------|-----|--------|
|       |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力 | 100% | 3.2  | 1.6 | 2.4        | 0.8 | 40.00% |
|       | 80%  | 2.2  | 3.1 | 1.6        | 1.1 | 38.75% |
|       | 60%  | 1.1  | 1.2 | 3.3        | 2.4 | 41.25% |
|       | 40%  | 0.8  | 2   | 2.4        | 2.8 | 35.00% |
| 平均識別率 |      |      |     |            |     | 38.75% |
| 評価指標  | 識別誤差 |      |     | F値         |     |        |
|       | 29.4 |      |     | 0.40427618 |     |        |

表 8.3 周波数 5 個のみの識別結果 (RF)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.1  | 1.2 | 0.7         | 0   | 76.25% |
|       | 80%  | 1.5  | 5.1 | 1.3         | 0.1 | 63.75% |
|       | 60%  | 0.2  | 2.6 | 4.3         | 0.9 | 53.75% |
|       | 40%  | 0.3  | 0.6 | 1.7         | 5.4 | 67.50% |
| 平均識別率 |      |      |     |             |     | 65.31% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 13.3 |      |     | 0.671356104 |     |        |

表 8.4 周波数 3 個とレスポンス 2 個の識別結果 (RF)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 5.1  | 0.9 | 1.2         | 0.8 | 63.75% |
|       | 80%  | 0.9  | 4.7 | 1.1         | 1.3 | 58.75% |
|       | 60%  | 0.3  | 1.7 | 4.8         | 1.2 | 60.00% |
|       | 40%  | 0.2  | 1.1 | 2.1         | 4.6 | 57.50% |
| 平均識別率 |      |      |     |             |     | 60.00% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 18.7 |      |     | 0.640903582 |     |        |

表 8.5 周波数 5 個とレスポンス 2 個の識別結果 (RF)

|       |      | 推定軸力 |     |            |     | 識別率    |
|-------|------|------|-----|------------|-----|--------|
|       |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力 | 100% | 5.6  | 1.6 | 0.6        | 0.2 | 70.00% |
|       | 80%  | 0.2  | 5.3 | 2.2        | 0.3 | 66.25% |
|       | 60%  | 0.2  | 1.9 | 5.2        | 0.7 | 65.00% |
|       | 40%  | 0    | 0.8 | 1.7        | 5.5 | 68.75% |
| 平均識別率 |      |      |     |            |     | 67.50% |
| 評価指標  | 識別誤差 |      |     | F値         |     |        |
|       | 12.7 |      |     | 0.71065289 |     |        |

微量を用いて識別実験を行った結果である。表 8.7 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量とレスポンスの上位 2 位～5 位までの 4 個のレスポンス特徴量を用いて識別実験を行った結果である。

表 8.6 周波数 3 個とレスポンス 4 個の識別結果 (RF)

|       |      | 推定軸力 |     |            |     | 識別率    |
|-------|------|------|-----|------------|-----|--------|
|       |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力 | 100% | 5.3  | 2   | 0.5        | 0.2 | 66.25% |
|       | 80%  | 0.8  | 5.2 | 1.8        | 0.2 | 65.00% |
|       | 60%  | 0.3  | 1.7 | 4.8        | 1.2 | 60.00% |
|       | 40%  | 0    | 0.7 | 2.1        | 5.2 | 65.00% |
| 平均識別率 |      |      |     |            |     | 64.06% |
| 評価指標  | 識別誤差 |      |     | F値         |     |        |
|       | 13.6 |      |     | 0.67026699 |     |        |

表 8.7 周波数 5 個とレスポンス 4 個の識別結果 (RF)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.1  | 1.4 | 0.5         | 0   | 76.25% |
|       | 80%  | 0.4  | 5.8 | 1.6         | 0.2 | 72.50% |
|       | 60%  | 0.4  | 0.8 | 5.2         | 1.6 | 65.00% |
|       | 40%  | 0    | 0.6 | 1.8         | 5.6 | 70.00% |
| 平均識別率 |      |      |     |             |     | 70.94% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 11   |      |     | 0.761080674 |     |        |

表 8.2～表 8.7 より、各実験における平均識別率は、周波数特徴量 3 個のみが 38.75%、周波数特徴量 5 個のみが 65.31%、周波数特徴量 3 個とレスポンス特徴量 2 個が 60.00%、周波数特徴量 5 個とレスポンス特徴量 2 個が 67.50%、周波数特徴量 3 個とレスポンス特徴量 4 個が 64.06%、周波数特徴量 5 個とレスポンス特徴 4 個が 70.94%となった。これらの結果から、軸力推定時に用いる周波数特徴量の個数は 3 個よりも 5 個の方が良く、レスポンス特徴量の個数は 2 個よりも 4 個の方が精度良く識別できることが分かる。

## (2) 周波数・レスポンス特徴量を用いた識別 (SVM)

表 8.8～表 8.13 はサポートベクタマシンを用いて識別実験を行った結果である。表 8.8 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量のみを用いて識別実験を行った結果である。表 8.9 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量のみを用いて識別実験を行った結果である。表 8.10 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量とレスポンスの上位 2 位～3 位までの 2 個のレスポンス特徴量を用いて識別実験を行った結果である。表 8.11 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量とレスポンスの上位 2 位～3 位

表 8.8 周波数 3 個のみの識別結果 (SVM)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 3.4  | 1.4 | 2.6         | 0.6 | 42.50% |
|       | 80%  | 2.3  | 3.2 | 1.5         | 1   | 40.00% |
|       | 60%  | 1.2  | 1.1 | 3.2         | 2.5 | 40.00% |
|       | 40%  | 0.8  | 1.8 | 2.6         | 2.8 | 35.00% |
| 平均識別率 |      |      |     |             |     | 39.38% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 28.8 |      |     | 0.423030411 |     |        |

表 8.9 周波数 5 個のみの識別結果 (SVM)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.2  | 1.3 | 0.5         | 0   | 77.50% |
|       | 80%  | 1.5  | 4.8 | 1.3         | 0.4 | 60.00% |
|       | 60%  | 0.9  | 1.7 | 4.3         | 1.1 | 53.75% |
|       | 40%  | 0.2  | 0.6 | 1.8         | 5.4 | 67.50% |
| 平均識別率 |      |      |     |             |     | 64.69% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 14.1 |      |     | 0.661818739 |     |        |

表 8.10 周波数 3 個とレスポンス 2 個の識別結果 (SVM)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 4.9  | 1.1 | 1.6         | 0.4 | 61.25% |
|       | 80%  | 1.5  | 4.6 | 1.2         | 0.7 | 57.50% |
|       | 60%  | 0.7  | 1.3 | 5.1         | 0.9 | 63.75% |
|       | 40%  | 0.2  | 0.3 | 2.8         | 4.7 | 58.75% |
| 平均識別率 |      |      |     |             |     | 60.31% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 17.2 |      |     | 0.620915033 |     |        |

表 8.11 周波数 5 個とレスポンス 2 個の識別結果 (SVM)

|       |      | 推定軸力 |     |           |     | 識別率    |
|-------|------|------|-----|-----------|-----|--------|
|       |      | 100% | 80% | 60%       | 40% |        |
| 実際の軸力 | 100% | 5.5  | 1.3 | 0.6       | 0.6 | 68.75% |
|       | 80%  | 0.8  | 5.4 | 1.6       | 0.2 | 67.50% |
|       | 60%  | 0    | 1.6 | 5.2       | 1.2 | 65.00% |
|       | 40%  | 0    | 0.8 | 1.6       | 5.6 | 70.00% |
| 平均識別率 |      |      |     |           |     | 67.81% |
| 評価指標  | 識別誤差 |      |     | F値        |     |        |
|       | 13.1 |      |     | 0.7062762 |     |        |

までの 2 個のレスポンス特徴量を用いて識別実験を行った結果である．表 8.12 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量とレスポンスの上位 2 位～5 位までの 4 個のレスポンス特徴量を用いて識別実験を行った結果である．表 8.13 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量とレスポンスの上位 2 位～5 位までの 4 個のレスポンス特徴量を用いて識別実験を行った結果である．

表 8.12 周波数 3 個とレスポンス 4 個の識別結果 (SVM)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 5.7  | 0.9 | 1.2         | 0.2 | 71.25% |
|       | 80%  | 1.5  | 5.2 | 1.3         | 0   | 65.00% |
|       | 60%  | 1.2  | 0.8 | 4.6         | 1.4 | 57.50% |
|       | 40%  | 0    | 0.7 | 1.6         | 5.7 | 71.25% |
| 平均識別率 |      |      |     |             |     | 66.25% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 14.3 |      |     | 0.681320481 |     |        |

表 8.13 周波数 5 個とレスポンス 4 個の識別結果 (SVM)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.1  | 1.1 | 0.8         | 0   | 76.25% |
|       | 80%  | 1.7  | 5.7 | 0.4         | 0.2 | 71.25% |
|       | 60%  | 0.8  | 1.2 | 4.8         | 1.2 | 60.00% |
|       | 40%  | 0    | 1   | 1.4         | 5.6 | 70.00% |
| 平均識別率 |      |      |     |             |     | 69.38% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 12.6 |      |     | 0.702854392 |     |        |

表 8.8～表 8.13 より，各実験における平均識別率は，周波数特徴量 3 個のみが 39.38%，周波数特徴量 5 個のみが 64.69%，周波数特徴量 3 個とレスポンス特徴量 2 個が 60.31%，周波数特徴量 5 個とレスポンス特徴量 2 個が 67.81%，周波数特徴量 3 個とレスポンス特徴量 4 個が 66.25%，周波数特徴量 5 個とレスポンス特徴 4 個が 69.38%となった．この結果から，軸力推定時に用いる周波数特徴量の個数は 3 個よりも 5 個の方が良く，レスポンス特徴量の個数は 2 個よりも 4 個の方が精度良く識別できることが分かる．また，ランダムフォレストによる識別実験の結果と比べてみると，ランダムフォレストのほうが SVM よりも軸力診断には有効であることが考えられる．

### (3) 周波数・レスポンス特徴量を用いた識別 (NN)

表 8.14～表 8.19 はニューラルネットワークを用いて識別実験を行った結果である．表 8.14 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量のみを用いて識別実験を行った結



果である。表 8.15 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量のみを用い識別実験を行った結果である。表 8.16 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量とレスポンスの上位 2 位～3 位までの 2 個のレスポンス特徴量を用いて、識別実験を行った結果である。表 8.17 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量とレスポンスの上位 2 位～3 位までの 2 個のレスポンス特徴量を用いて識別実験を行った結果である。表 8.18 は周波数の上位 1 位～3 位までの 3 個の周波数特徴量とレスポンスの上位 2 位～5 位までの 4 個のレスポンス特徴量を用いて識別実験を行った結果である。表 8.19 は周波数の上位 1 位～5 位までの 5 個の周波数特徴量とレスポンスの上位 2 位～5 位までの 4 個のレスポンス特徴量を用いて識別実験を行った結果である。

表 8.14 周波数 3 個のみの識別結果 (NN)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 3.3  | 2.1 | 1.8         | 0.8 | 41.25% |
|       | 80%  | 2    | 3.2 | 1.8         | 1   | 40.00% |
|       | 60%  | 1.1  | 1.6 | 3.1         | 2.2 | 38.75% |
|       | 40%  | 1.3  | 1.3 | 2.4         | 3   | 37.50% |
| 平均識別率 |      |      |     |             |     | 39.38% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 28.8 |      |     | 0.407822721 |     |        |

表 8.15 周波数 5 個のみの識別結果 (NN)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 5.8  | 1.5 | 0.7         | 0   | 72.50% |
|       | 80%  | 1.5  | 5.5 | 0.7         | 0.3 | 68.75% |
|       | 60%  | 0.1  | 0.2 | 5.4         | 2.3 | 67.50% |
|       | 40%  | 0    | 0.6 | 2           | 5.4 | 67.50% |
| 平均識別率 |      |      |     |             |     | 69.06% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 11.6 |      |     | 0.724849898 |     |        |

表 8.16 周波数 3 個とレスポンス 2 個の識別結果 (NN)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 5.2  | 2.1 | 0.7         | 0   | 65.00% |
|       | 80%  | 2.1  | 4.9 | 0.8         | 0.2 | 61.25% |
|       | 60%  | 0.1  | 0.7 | 5           | 2.2 | 62.50% |
|       | 40%  | 0.2  | 0.6 | 2.1         | 5.1 | 63.75% |
| 平均識別率 |      |      |     |             |     | 63.13% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 13.8 |      |     | 0.634253633 |     |        |



表 8.17 周波数 5 個とレスポンス 2 個の識別結果 (NN)

|       |      | 推定軸力 |     |            |     | 識別率    |
|-------|------|------|-----|------------|-----|--------|
|       |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力 | 100% | 5.6  | 1.6 | 0.6        | 0.2 | 70.00% |
|       | 80%  | 0.2  | 5.3 | 2.2        | 0.3 | 66.25% |
|       | 60%  | 0.2  | 1.9 | 5.2        | 0.7 | 65.00% |
|       | 40%  | 0    | 0.8 | 1.7        | 5.5 | 68.75% |
| 平均識別率 |      |      |     |            |     | 67.50% |
| 評価指標  | 識別誤差 |      |     | F値         |     |        |
|       | 12.7 |      |     | 0.71065289 |     |        |

表 8.18 周波数 3 個とレスポンス 4 個の識別結果 (NN)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 5.4  | 2.1 | 0.5         | 0   | 67.50% |
|       | 80%  | 2.1  | 5.1 | 0.6         | 0.2 | 63.75% |
|       | 60%  | 0.3  | 1.2 | 5.1         | 1.4 | 63.75% |
|       | 40%  | 0    | 0.5 | 2.2         | 5.3 | 66.25% |
| 平均識別率 |      |      |     |             |     | 65.31% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 12.6 |      |     | 0.644244672 |     |        |

表 8.19 周波数 5 個とレスポンス 4 個の識別結果 (NN)

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.2  | 1.5 | 0.3         | 0   | 77.50% |
|       | 80%  | 1.7  | 6   | 0.3         | 0   | 75.00% |
|       | 60%  | 0    | 0.9 | 5.5         | 1.6 | 68.75% |
|       | 40%  | 0    | 0.4 | 1.9         | 5.7 | 71.25% |
| 平均識別率 |      |      |     |             |     | 73.13% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 9.3  |      |     | 0.747622345 |     |        |

表 8.14～表 8.19 より，各実験における平均識別率は，周波数特徴量 3 個のみが 39.38%，周波数特徴量 5 個のみが 69.06%，周波数特徴量 3 個とレスポンス特徴量 2 個が 63.13%，周波数特徴量 5 個とレスポンス特徴量 2 個が 67.50%，周波数特徴量 3 個とレスポンス特徴量 4 個が 65.31%，周波数特徴量 5 個とレスポンス特徴 4 個が 73.13%となった．これらの結果から，軸力推定時に用いる周波数特徴量の個数は 3 個よりも 5 個の方が良く，レスポンス特徴量の個数は 2 個よりも 4 個の方が精度良く識別できることが分かる．また，ランダムフォレストとサポートベクタマシンによる識別実験の結果と比べてみると，平均識別率が上がっているものがある．特に周波数特徴量 5 個とレスポンス特徴量 4 個での平均識別率は 73.13%とほかの手法による平均識別率より大きく上回っている．このことから，ニュー

ラルネットワークが軸力診断に最も有効であることが考えられる。

#### (4) 周波数特徴量の個数を増加させた識別 (NN)

3 種類のパターン認識手法を用いて識別実験を行った。その結果、周波数特徴量の個数が増加すると識別率が向上する傾向があるので、さらに周波数特徴量を増やして識別実験を行った。周波数特徴量を最大 9 個抽出し、レスポンス特徴量を 4 個とする。パターン認識手法としては、これまでの識別実験から最も平均識別率の高かったニューラルネットワークを用いる。その結果を踏まえて、平均識別率の違いを図 8.17 に示す。図 8.17 から周波数特徴量 7 個を用いると、平均識別率は 69.58% となった。周波数特徴量 9 個を用いると、平均識別率は 65.14% となった。これらの結果から周波数特徴量は 5 個より多く用いると、その平均識別率は低下してしまうことがわかった。このような結果になった原因としては、周波数特徴量を 6 個以上抽出しようとする、周波数ピークの位置がわかりづらくなってしまい、同じ軸力でもピーク位置が違うものになってしまったことが挙げられる。ピーク位置の違いは、高力ボルトをハンマーで打撃する際に、同じ力で打撃できなかったことと打撃位置もずれてしまったことまうために起きたと考えられる。




図 8.17 周波数特徴量の個数による識別率の変化

#### (5) 識別実験 1 (周波数・レスポンス特徴量を用いた識別) の考察

識別実験 1 の結果、周波数特徴量 5 個とレスポンス特徴量 4 個を用いると、平均識別率が高くなった。また、ニューラルネットワークを用いた識別実験において、平均識別率が 73.13% と最も高くなった。さらに、識別誤差においても、9.3 と最も低い値となっている。このことから、ニューラルネットワークが軸力診断に最も有効であると考えられる。しかし、F 値を見ると、周波数特徴量 5 個とレスポンス特徴量 4 個を用いて、ランダムフォレスト

トで学習した場合 0.7610 と最も高くなっている．このことから，ニューラルネットワークを用いた識別では，実際に軸力診断を行うことを考えるとランダムフォレストによる軸力診断に劣っているため，改善する必要があると考えられる．また，どのパターン認識手法においても周波数特徴量 5 個のみにおける平均識別率は，周波数特徴量 3 個とレスポンス特徴量 2 個を用いた識別率よりは高い精度であるため，レスポンス特徴量よりも周波数特徴量の方が軸力推定に大きな影響を与えていることが考えられる．しかし，周波数特徴量を 5 個より多く用いると平均識別率が低下してしまうことから，特徴量の個数には注意が必要である．識別実験 1 の結果を見ると，平均識別率が最大でも 73.13%としかなく，上記した問題点もあるため，実際の軸力診断にはまだ利用できないものとする．

### 8.5.3 識別実験 2（減衰率特徴量を用いた識別）

識別実験 1 の結果から，周波数特徴量とレスポンス特徴量を用いた軸力推定では，実際の軸力診断には利用できないものとなった．そこで，識別実験 2 では，平均識別率向上のために減衰率特徴量を用いた識別実験を行い，比較検証した．実験は，識別実験 1 の時と同様に，3 種類のパターン認識手法を用いて，識別率の違いを比較した．減衰率特徴量に関しては，移動平均法を適用して特徴量抽出したものをを用いて，減衰率特徴量の個数についても比較検証を行った．移動平均法を適用する際，何点ずつの平均を取るかによって平滑化の程度が変化する．本実験では，振動加速度データのサンプリング周波数が 5000Hz なので，50 点ずつ，50 の 2 倍である 100 点ずつ，50 の 4 倍である 200 点ずつの 3 種類において平均を取り，識別結果の比較検証を行った．

#### (1) 減衰率特徴量を用いた場合の識別実験（RF）

移動平均法を用いる場合，時系列データの重要な値が欠損してしまうかもしれないという欠点がある．その影響を測るために，平均の取り方を 50 点ずつ，100 点ずつ，200 点ずつで変更する．50 点ずつの平均を取り，識別実験を行った結果を表 8.20，表 8.21，表 8.22，表 8.23，表 8.24，に示す．100 点ずつの平均を取り，識別実験を行った結果を表 8.25，表 8.26，表 8.27，表 8.28，表 8.29 に示す．200 点ずつの平均を取り，識別実験を行った結果を表 8.30，表 8.31，表 8.32，表 8.33，表 8.34 に示す．また，表 8.20～表 8.34 はランダムフォレストを用いて，識別実験を行った結果である．表 8.20，表 8.25，表 8.30 は減衰率特徴量を 2 個用いた識別結果で，表 8.21，表 8.26，表 8.31 は減衰率特徴量を 4 個用いた識別結果で，表 8.22，表 8.27，表 8.32 は減衰率特徴量を 6 個用いた識別結果で，表 8.23，表 8.28，表 8.33 は減衰率特徴量を 8 個用いた識別結果で，表 8.24，表 8.29，表 8.34 は減衰率特徴量を 10 個用いた識別結果である．

表 8.20 減衰率特徴量 2 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.1  | 1.6 | 1.4         | 0.9 | 51.25% |
|         | 80%  | 1.6  | 3.5 | 1.7         | 1.2 | 43.75% |
|         | 60%  | 0.4  | 2.5 | 3.3         | 1.8 | 41.25% |
|         | 40%  | 0.7  | 1.4 | 2.5         | 3.4 | 42.50% |
| 平均識別率   |      |      |     |             |     | 44.69% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 25.3 |      |     | 0.485232245 |     |        |

表 8.21 減衰率特徴量 4 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.4  | 2.5 | 0.9         | 0.2 | 55.00% |
|         | 80%  | 1.6  | 3.5 | 2.3         | 0.6 | 43.75% |
|         | 60%  | 0.3  | 2.1 | 3.7         | 1.9 | 46.25% |
|         | 40%  | 0.2  | 1.4 | 2.6         | 3.8 | 47.50% |
| 平均識別率   |      |      |     |             |     | 48.13% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 20.6 |      |     | 0.507799547 |     |        |

表 8.22 減衰率特徴量 6 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.6  | 2   | 1.4         | 0   | 57.50% |
|         | 80%  | 2.4  | 4.8 | 0.7         | 0.1 | 60.00% |
|         | 60%  | 0.5  | 1.7 | 4.7         | 1.1 | 58.75% |
|         | 40%  | 0.2  | 1.1 | 1.8         | 4.9 | 61.25% |
| 平均識別率   |      |      |     |             |     | 59.38% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 16.5 |      |     | 0.567438205 |     |        |

表 8.23 減衰率特徴量 8 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 6.2  | 1.4 | 0.4         | 0   | 77.50% |
|         | 80%  | 2.6  | 5.1 | 0.3         | 0   | 63.75% |
|         | 60%  | 0    | 1   | 5.3         | 1.7 | 66.25% |
|         | 40%  | 0    | 0.6 | 1.3         | 6.1 | 76.25% |
| 平均識別率   |      |      |     |             |     | 70.94% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 10.3 |      |     | 0.686110388 |     |        |

表 8.24 減衰率特徴量 10 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 6.1  | 1.8 | 0.1         | 0   | 76.25% |
|         | 80%  | 1.3  | 5.7 | 0.8         | 0.2 | 71.25% |
|         | 60%  | 0    | 1.2 | 5.7         | 1.1 | 71.25% |
|         | 40%  | 0    | 0.7 | 1.4         | 5.9 | 73.75% |
| 平均識別率   |      |      |     |             |     | 73.13% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 9.6  |      |     | 0.726258034 |     |        |

表 8.25 減衰率特徴量 2 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 3.7  | 1.7 | 1.6         | 1   | 46.25% |
|          | 80%  | 1.5  | 3.7 | 1.3         | 1.5 | 46.25% |
|          | 60%  | 0.7  | 1.8 | 3.4         | 2.1 | 42.50% |
|          | 40%  | 0.5  | 1.5 | 2.7         | 3.3 | 41.25% |
| 平均識別率    |      |      |     |             |     | 44.06% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 26.2 |      |     | 0.481305996 |     |        |

表 8.26 減衰率特徴量 4 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.3  | 1.7 | 1.8         | 0.2 | 53.75% |
|          | 80%  | 1.8  | 3.6 | 2.5         | 0.1 | 45.00% |
|          | 60%  | 0.7  | 1.1 | 3.6         | 2.6 | 45.00% |
|          | 40%  | 0.3  | 1.6 | 2.4         | 3.7 | 46.25% |
| 平均識別率    |      |      |     |             |     | 47.50% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 22   |      |     | 0.510215424 |     |        |

表 8.27 減衰率特徴量 6 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.7  | 2.6 | 0.7         | 0   | 58.75% |
|          | 80%  | 1.3  | 4.6 | 2.1         | 0   | 57.50% |
|          | 60%  | 0    | 1.8 | 4.9         | 1.3 | 61.25% |
|          | 40%  | 0    | 1.3 | 2.3         | 4.4 | 55.00% |
| 平均識別率    |      |      |     |             |     | 58.13% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 15.4 |      |     | 0.597633621 |     |        |

表 8.28 減衰率特徴量 8 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 5.7  | 1.9 | 0.4         | 0   | 71.25% |
|          | 80%  | 1.1  | 5.8 | 1.1         | 0   | 72.50% |
|          | 60%  | 0    | 0.3 | 5.4         | 2.3 | 67.50% |
|          | 40%  | 0    | 0.6 | 1.5         | 5.9 | 73.75% |
| 平均識別率    |      |      |     |             |     | 71.25% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 10.2 |      |     | 0.737059846 |     |        |

表 8.29 減衰率特徴量 10 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |            |     | 識別率    |
|----------|------|------|-----|------------|-----|--------|
|          |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力    | 100% | 6.3  | 1.2 | 0.5        | 0   | 78.75% |
|          | 80%  | 1    | 5.5 | 1.3        | 0.2 | 68.75% |
|          | 60%  | 0    | 0.8 | 6.1        | 1.1 | 76.25% |
|          | 40%  | 0    | 0.6 | 1.6        | 5.8 | 72.50% |
| 平均識別率    |      |      |     |            |     | 74.06% |
| 評価指標     | 識別誤差 |      |     | F値         |     |        |
|          | 9.6  |      |     | 0.75388425 |     |        |

表 8.30 減衰率特徴量 2 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 3.3  | 1.7 | 1.9         | 1.1 | 41.25% |
|          | 80%  | 1.4  | 3.4 | 1.5         | 1.7 | 42.50% |
|          | 60%  | 0.8  | 1.7 | 3.8         | 1.7 | 47.50% |
|          | 40%  | 0.7  | 1.1 | 2.8         | 3.4 | 42.50% |
| 平均識別率    |      |      |     |             |     | 43.44% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 27.2 |      |     | 0.447859693 |     |        |

表 8.31 減衰率特徴量 4 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.2  | 1.8 | 1.4         | 0.6 | 52.50% |
|          | 80%  | 2.3  | 3.8 | 1.7         | 0.2 | 47.50% |
|          | 60%  | 0.6  | 1.7 | 3.6         | 2.1 | 45.00% |
|          | 40%  | 0.5  | 1.2 | 2.5         | 3.8 | 47.50% |
| 平均識別率    |      |      |     |             |     | 48.13% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 22.2 |      |     | 0.499922589 |     |        |

表 8.32 減衰率特徴量 6 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.7  | 2.6 | 0.7         | 0   | 58.75% |
|          | 80%  | 1.8  | 4.7 | 1.5         | 0   | 58.75% |
|          | 60%  | 0    | 1.7 | 4.6         | 1.7 | 57.50% |
|          | 40%  | 0    | 0.6 | 2.7         | 4.7 | 58.75% |
| 平均識別率    |      |      |     |             |     | 58.44% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 14.6 |      |     | 0.596766562 |     |        |

表 8.33 減衰率特徴量 8 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.1  | 1.1 | 0.8         | 0   | 76.25% |
|          | 80%  | 1.3  | 5.8 | 0.9         | 0   | 72.50% |
|          | 60%  | 0    | 0.7 | 5.8         | 1.5 | 72.50% |
|          | 40%  | 0    | 0.2 | 1.9         | 5.9 | 73.75% |
| 平均識別率    |      |      |     |             |     | 73.75% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 9.4  |      |     | 0.763324422 |     |        |

表 8.34 減衰率特徴量 10 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.5  | 1.5 | 0           | 0   | 81.25% |
|          | 80%  | 1.2  | 6.1 | 0.7         | 0   | 76.25% |
|          | 60%  | 0    | 1.1 | 5.7         | 1.2 | 71.25% |
|          | 40%  | 0    | 0   | 2.3         | 5.7 | 71.25% |
| 平均識別率    |      |      |     |             |     | 75.00% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 8    |      |     | 0.780005669 |     |        |

表 8.20～表 8.34 より，50 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 44.69%，減衰率特徴量 4 個が 48.13%，減衰率特徴量 6 個が 59.38%，減衰率特徴量 8 個が 70.94%，減衰率特徴量 10 個が 73.13%となった．100 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 44.06%，減衰率特徴量 4 個が 47.50%，減衰率特徴量 6 個が 58.13%，減衰率特徴量 8 個が 71.25%，減衰率特徴量 10 個が 74.06%となった．200 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 43.44%，減衰率特徴量 4 個が 48.13%，減衰率特徴量 6 個が 58.44%，減衰率特徴量 8 個が 73.75%，減衰率特徴量 10 個が 75.00%となった．本実験結果と識別実験 1 の結果から，周波数特徴量とレスポンス特徴量のみを用いて軸力推定を行うよりも，

減衰率特徴量のみを用いて軸力推定を行う方が精度良く識別が可能なが分かる。この結果から、識別実験 1 の結果と同様に減衰率特徴量も軸力推定に大きな影響を及ぼしていることが考えられる。また、減衰率特徴量の個数においては、全体的に 8 個～10 個の時に識別精度が 70%を超える結果となった。特に、200 点ずつの平均を取った減衰率特徴量を 10 個用いた時に平均識別率が 75.00%となった。この結果から、最大振幅の 1/9, 1/10, 1/11 周辺に各軸力における特徴が現れていると考えられる。また、200 点ずつ平均をとった減衰率特徴量を用いると全体的に平均識別率が高くなっているため、200 点ずつ平均をとった減衰率特徴量が軸力診断に有効であると考えられる。

## (2) 減衰率特徴量を用いた場合の識別実験 (SVM)

50 点ずつの平均を取り、識別実験を行った結果を表 8.35, 表 8.36, 表 8.37, 表 8.38, 表 8.39, に示す。100 点ずつの平均を取り、識別実験を行った結果を表 8.40, 表 8.41, 表 8.42, 表 8.43, 表 8.44 に示す。200 点ずつの平均を取り、識別実験を行った結果を表 8.45, 表 8.46, 表 8.47, 表 8.48, 表 8.49 に示す。また、表 8.35～表 8.49 は SVM を用いて、識別実験を行った結果である。表 8.35, 表 8.40, 表 8.45 は減衰率特徴量を 2 個用いた識別結果で、表 8.36, 表 8.41, 表 8.46 は減衰率特徴量を 4 個用いた識別結果で、表 8.37, 表 8.42, 表 8.47 は減衰率特徴量を 6 個用いた識別結果で、表 8.38, 表 8.43, 表 8.48 は減衰率特徴量を 8 個用いた識別結果で、表 8.39, 表 8.44, 表 8.49 は減衰率特徴量を 10 個用いた識別結果である。

表 8.35 減衰率特徴量 2 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.1  | 0.8 | 1.4         | 1.7 | 51.25% |
|         | 80%  | 1.6  | 3.5 | 1.7         | 1.2 | 43.75% |
|         | 60%  | 1.4  | 1.6 | 3.2         | 1.8 | 40.00% |
|         | 40%  | 0.3  | 2.1 | 2.5         | 3.1 | 38.75% |
| 平均識別率   |      |      |     |             |     | 43.44% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 28.2 |      |     | 0.485166174 |     |        |

表 8.36 減衰率特徴量 4 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.4  | 0.9 | 1.4         | 1.3 | 55.00% |
|         | 80%  | 1.6  | 3.4 | 2.3         | 0.7 | 42.50% |
|         | 60%  | 0.3  | 0.8 | 3.6         | 3.3 | 45.00% |
|         | 40%  | 0.2  | 2.2 | 1.8         | 3.8 | 47.50% |
| 平均識別率   |      |      |     |             |     | 47.50% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 24.4 |      |     | 0.526099991 |     |        |



表 8.37 減衰率特徴量 6 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.8  | 1.4 | 1.8         | 0   | 60.00% |
|         | 80%  | 1.6  | 4.6 | 1.7         | 0.1 | 57.50% |
|         | 60%  | 0.5  | 1.7 | 4.7         | 1.1 | 58.75% |
|         | 40%  | 0.2  | 1.4 | 1.8         | 4.6 | 57.50% |
| 平均識別率   |      |      |     |             |     | 58.44% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 17.5 |      |     | 0.589133158 |     |        |

表 8.38 減衰率特徴量 8 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 6.1  | 0.8 | 0.7         | 0.4 | 76.25% |
|         | 80%  | 2.6  | 4.8 | 0.5         | 0.1 | 60.00% |
|         | 60%  | 0.3  | 0.8 | 5.2         | 1.7 | 65.00% |
|         | 40%  | 0    | 0.6 | 0.7         | 6.7 | 83.75% |
| 平均識別率   |      |      |     |             |     | 71.25% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 11.7 |      |     | 0.681497926 |     |        |

表 8.39 減衰率特徴量 10 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 5.6  | 1.8 | 0.6         | 0   | 70.00% |
|         | 80%  | 1.3  | 5.7 | 0.8         | 0.2 | 71.25% |
|         | 60%  | 0.3  | 1.2 | 5.6         | 0.9 | 70.00% |
|         | 40%  | 0    | 1.5 | 0.4         | 6.1 | 76.25% |
| 平均識別率   |      |      |     |             |     | 71.88% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 11.6 |      |     | 0.686751464 |     |        |

表 8.40 減衰率特徴量 2 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 3.8  | 1.6 | 1.8         | 0.8 | 47.50% |
|          | 80%  | 1.7  | 3.7 | 1.2         | 1.4 | 46.25% |
|          | 60%  | 1.7  | 1.6 | 3.4         | 1.3 | 42.50% |
|          | 40%  | 0.2  | 2.2 | 2.7         | 2.9 | 36.25% |
| 平均識別率    |      |      |     |             |     | 43.13% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 27.3 |      |     | 0.464361016 |     |        |

表 8.41 減衰率特徴量 4 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.3  | 1.7 | 1.8         | 0.2 | 53.75% |
|          | 80%  | 1.8  | 3.4 | 2.1         | 0.7 | 42.50% |
|          | 60%  | 1    | 1.1 | 3.8         | 2.1 | 47.50% |
|          | 40%  | 0.3  | 1.8 | 2.4         | 3.5 | 43.75% |
| 平均識別率    |      |      |     |             |     | 46.88% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 23.3 |      |     | 0.491904067 |     |        |

表 8.42 減衰率特徴量 6 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.8  | 2.2 | 0.7         | 0.3 | 60.00% |
|          | 80%  | 1.3  | 4.2 | 2.1         | 0.4 | 52.50% |
|          | 60%  | 0.8  | 2.3 | 3.7         | 1.2 | 46.25% |
|          | 40%  | 0.4  | 1.3 | 1.6         | 4.7 | 58.75% |
| 平均識別率    |      |      |     |             |     | 54.38% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 19.2 |      |     | 0.550377834 |     |        |

表 8.43 減衰率特徴量 8 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 5.8  | 0.9 | 0.4         | 0.9 | 72.50% |
|          | 80%  | 1.2  | 5.5 | 1.1         | 0.2 | 68.75% |
|          | 60%  | 0.7  | 0.8 | 5.3         | 1.2 | 66.25% |
|          | 40%  | 0    | 0.6 | 1.3         | 6.1 | 76.25% |
| 平均識別率    |      |      |     |             |     | 70.94% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 13   |      |     | 0.717535476 |     |        |

表 8.44 減衰率特徴量 10 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |            |     | 識別率    |
|----------|------|------|-----|------------|-----|--------|
|          |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力    | 100% | 6.1  | 0.7 | 1.1        | 0.1 | 76.25% |
|          | 80%  | 1.6  | 5.4 | 0.8        | 0.2 | 67.50% |
|          | 60%  | 0.4  | 0.8 | 5.9        | 0.9 | 73.75% |
|          | 40%  | 0    | 0.6 | 1.4        | 6   | 75.00% |
| 平均識別率    |      |      |     |            |     | 73.13% |
| 評価指標     | 識別誤差 |      |     | F値         |     |        |
|          | 11.1 |      |     | 0.72753783 |     |        |

表 8.45 減衰率特徴量 2 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 3.4  | 1.4 | 2.1         | 1.1 | 42.50% |
|          | 80%  | 1.4  | 3.3 | 1.8         | 1.5 | 41.25% |
|          | 60%  | 1.6  | 1.7 | 3.8         | 0.9 | 47.50% |
|          | 40%  | 1    | 0.7 | 3.2         | 3.1 | 38.75% |
| 平均識別率    |      |      |     |             |     | 42.50% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 28.5 |      |     | 0.439369181 |     |        |

表 8.46 減衰率特徴量 4 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.1  | 1.6 | 1.7         | 0.6 | 51.25% |
|          | 80%  | 1.9  | 3.8 | 2.1         | 0.2 | 47.50% |
|          | 60%  | 0.3  | 1   | 3.6         | 3.1 | 45.00% |
|          | 40%  | 0.5  | 1.8 | 2.2         | 3.5 | 43.75% |
| 平均識別率    |      |      |     |             |     | 46.88% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 23.2 |      |     | 0.512707054 |     |        |

表 8.47 減衰率特徴量 6 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.7  | 2.1 | 1.2         | 0   | 58.75% |
|          | 80%  | 1.6  | 3.9 | 1.8         | 0.7 | 48.75% |
|          | 60%  | 0.7  | 1.7 | 4.3         | 1.3 | 53.75% |
|          | 40%  | 0.4  | 1.1 | 2.4         | 4.1 | 51.25% |
| 平均識別率    |      |      |     |             |     | 53.13% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 19.5 |      |     | 0.538327961 |     |        |

表 8.48 減衰率特徴量 8 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.1  | 1.1 | 0.8         | 0   | 76.25% |
|          | 80%  | 1.3  | 5.6 | 0.9         | 0.2 | 70.00% |
|          | 60%  | 0    | 1.2 | 5.4         | 1.4 | 67.50% |
|          | 40%  | 0    | 0.7 | 1.4         | 5.9 | 73.75% |
| 平均識別率    |      |      |     |             |     | 71.88% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 10.7 |      |     | 0.734482427 |     |        |

表 8.49 減衰率特徴量 10 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.2  | 0.9 | 0.9         | 0   | 77.50% |
|          | 80%  | 1.6  | 5.9 | 0.5         | 0   | 73.75% |
|          | 60%  | 0.4  | 0.7 | 6.1         | 0.8 | 76.25% |
|          | 40%  | 0    | 0.5 | 1.7         | 5.8 | 72.50% |
| 平均識別率    |      |      |     |             |     | 75.00% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 9.8  |      |     | 0.751494675 |     |        |

表 8.35～表 8.49 より，50 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 43.44%，減衰率特徴量 4 個が 47.50%，減衰率特徴量 6 個が 58.44%，減衰率特徴量 8 個が 71.25%，減衰率特徴量 10 個が 71.88%となった．100 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 43.13%，減衰率特徴量 4 個が 46.88%，減衰率特徴量 6 個が 54.38%，減衰率特徴量 8 個が 70.94%，減衰率特徴量 10 個が 73.13%となった．200 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 42.50%，減衰率特徴量 4 個が 46.88%，減衰率特徴量 6 個が 53.13%，減衰率特徴量 8 個が 71.88%，減衰率特徴量 10 個が 75.00%となった．減衰率特徴量の個数においては，全体的に 8 個～10 個の時に識別精度が 70%を超える結果となった．特に，200 点ずつの平均を取った減衰率特徴量を 10 個用いた時に平均識別率が 75.00%となった．この結果から，最大振幅の 1/9，1/10，1/11 周辺に各軸力における特徴が現れていると考えられる．また，200 点ずつ平均をとった減衰率特徴量を用いると全体的に平均識別率が高くなっているため，200 点ずつ平均をとった減衰率特徴量が軸力診断に有効であると考えられる．ランダムフォレストによる識別実験の結果と比べると，ほとんど識別率の差はなかった．しかし，200 点ずつ平均をとった減衰率特徴量を用いた場合，識別率は同じであるが，F値を比べると SVM を用いたほうが少し高くなっているため，SVM を用いて生成した識別器の方が性能は高いと考えられる．

### (3) 減衰率特徴量を用いた場合の識別実験 (NN)

50 点ずつの平均を取り，識別実験を行った結果を表 8.50，表 8.51，表 8.52，表 8.53，表 8.54，に示す．100 点ずつの平均を取り，識別実験を行った結果を表 8.55，表 8.56，表 8.57，表 8.58，表 8.59 に示す．200 点ずつの平均を取り，識別実験を行った結果を表 8.60，表 8.61，表 8.62，表 8.63，表 8.64 に示す．表 8.50～表 8.64 は NN を用いて，識別実験を行った結果である．表 8.50，表 8.55，表 8.60 は減衰率特徴量を 2 個用いた識別結果で，表 8.51，表 8.56，表 8.61 は減衰率特徴量を 4 個用いた識別結果で，表 8.52，表 8.57，表 8.62 は減衰率特徴量を 6 個用いた識別結果で，表 8.53，表 8.58，表 8.63 は減衰率特徴量を 8 個用いた識別結果で，表 8.54，表 8.59，表 8.64 は減衰率特徴量を 10 個用いた識別結果である．

表 8.50 減衰率特徴量 2 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 3.9  | 1.5 | 1.5         | 1.1 | 48.75% |
|         | 80%  | 1.6  | 3.4 | 1.8         | 1.2 | 42.50% |
|         | 60%  | 0.5  | 2.5 | 3.2         | 1.8 | 40.00% |
|         | 40%  | 0.9  | 1.7 | 2.1         | 3.3 | 41.25% |
| 平均識別率   |      |      |     |             |     | 43.13% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 27.1 |      |     | 0.462742226 |     |        |

表 8.51 減衰率特徴量 4 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 4.2  | 1.8 | 1.8         | 0.2 | 52.50% |
|         | 80%  | 1.5  | 3.8 | 2           | 0.7 | 47.50% |
|         | 60%  | 0.3  | 1.6 | 3.8         | 2.3 | 47.50% |
|         | 40%  | 0.3  | 1.4 | 2.4         | 3.9 | 48.75% |
| 平均識別率   |      |      |     |             |     | 49.06% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 21.5 |      |     | 0.525735294 |     |        |

表 8.52 減衰率特徴量 6 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 5    | 2.5 | 0.5         | 0   | 62.50% |
|         | 80%  | 2.4  | 4.7 | 0.8         | 0.1 | 58.75% |
|         | 60%  | 0.2  | 1.1 | 4.8         | 1.9 | 60.00% |
|         | 40%  | 0.1  | 1.3 | 1.7         | 4.9 | 61.25% |
| 平均識別率   |      |      |     |             |     | 60.63% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 14.9 |      |     | 0.587283106 |     |        |

表 8.53 減衰率特徴量 8 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 6.2  | 1.1 | 0.7         | 0   | 77.50% |
|         | 80%  | 2.2  | 5.5 | 0.3         | 0   | 68.75% |
|         | 60%  | 0    | 0.3 | 5.7         | 2   | 71.25% |
|         | 40%  | 0    | 0.1 | 1.7         | 6.2 | 77.50% |
| 平均識別率   |      |      |     |             |     | 73.75% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 9.2  |      |     | 0.746262707 |     |        |

表 8.54 減衰率特徴量 10 個の識別結果 (50 点ずつの平均)

| 50点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|---------|------|------|-----|-------------|-----|--------|
|         |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力   | 100% | 6.3  | 1.7 | 0           | 0   | 78.75% |
|         | 80%  | 2    | 5.8 | 0.2         | 0   | 72.50% |
|         | 60%  | 0    | 0.4 | 5.8         | 1.8 | 72.50% |
|         | 40%  | 0    | 0   | 1.8         | 6.2 | 77.50% |
| 平均識別率   |      |      |     |             |     | 75.31% |
| 評価指標    | 識別誤差 |      |     | F値          |     |        |
|         | 7.9  |      |     | 0.751397401 |     |        |

表 8.55 減衰率特徴量 2 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |            |     | 識別率    |
|----------|------|------|-----|------------|-----|--------|
|          |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力    | 100% | 3.8  | 1.8 | 1.6        | 0.8 | 47.50% |
|          | 80%  | 1.6  | 3.6 | 1.6        | 1.2 | 45.00% |
|          | 60%  | 0.7  | 1.8 | 3.5        | 2   | 43.75% |
|          | 40%  | 1.2  | 1.5 | 1.9        | 3.4 | 42.50% |
| 平均識別率    |      |      |     |            |     | 44.69% |
| 評価指標     | 識別誤差 |      |     | F値         |     |        |
|          | 26.7 |      |     | 0.46482353 |     |        |

表 8.56 減衰率特徴量 4 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.3  | 1.7 | 1.4         | 0.6 | 53.75% |
|          | 80%  | 2.9  | 4   | 0.8         | 0.3 | 50.00% |
|          | 60%  | 0.6  | 1.1 | 3.7         | 2.6 | 46.25% |
|          | 40%  | 1    | 1.3 | 2           | 3.7 | 46.25% |
| 平均識別率    |      |      |     |             |     | 49.06% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 23.1 |      |     | 0.504615996 |     |        |

表 8.57 減衰率特徴量 6 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.8  | 2.3 | 0.9         | 0   | 60.00% |
|          | 80%  | 1.6  | 4.7 | 1.7         | 0   | 58.75% |
|          | 60%  | 0.2  | 1.6 | 4.9         | 1.3 | 61.25% |
|          | 40%  | 0    | 1.2 | 2.3         | 4.5 | 56.25% |
| 平均識別率    |      |      |     |             |     | 59.06% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 15.4 |      |     | 0.598551988 |     |        |

表 8.58 減衰率特徴量 8 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 5.6  | 1.8 | 0.6         | 0   | 70.00% |
|          | 80%  | 1.8  | 5.7 | 0.5         | 0   | 71.25% |
|          | 60%  | 0    | 0.5 | 5.7         | 1.8 | 71.25% |
|          | 40%  | 0    | 0.3 | 1.8         | 5.9 | 73.75% |
| 平均識別率    |      |      |     |             |     | 71.56% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 10   |      |     | 0.713916795 |     |        |

表 8.59 減衰率特徴量 10 個の識別結果 (100 点ずつの平均)

| 100点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.2  | 1.7 | 0.1         | 0   | 77.50% |
|          | 80%  | 0.7  | 6   | 1.3         | 0   | 75.00% |
|          | 60%  | 0    | 0.2 | 6.1         | 1.7 | 76.25% |
|          | 40%  | 0    | 0   | 2.1         | 5.9 | 73.75% |
| 平均識別率    |      |      |     |             |     | 75.63% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 7.9  |      |     | 0.794370857 |     |        |

表 8.60 減衰率特徴量 2 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 3.5  | 1.9 | 1.5         | 1.1 | 43.75% |
|          | 80%  | 1.3  | 3.4 | 1.7         | 1.6 | 42.50% |
|          | 60%  | 0.8  | 1.4 | 3.7         | 2.1 | 46.25% |
|          | 40%  | 0.7  | 1.3 | 2.6         | 3.4 | 42.50% |
| 平均識別率    |      |      |     |             |     | 43.75% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 26.8 |      |     | 0.458873399 |     |        |

表 8.61 減衰率特徴量 4 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 4.4  | 2   | 1.6         | 0   | 55.00% |
|          | 80%  | 2.5  | 3.9 | 1.3         | 0.3 | 48.75% |
|          | 60%  | 0.6  | 1.5 | 3.8         | 2.1 | 47.50% |
|          | 40%  | 0.2  | 1.5 | 2.5         | 3.8 | 47.50% |
| 平均識別率    |      |      |     |             |     | 49.69% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 20.5 |      |     | 0.511687853 |     |        |

表 8.62 減衰率特徴量 6 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |            |     | 識別率    |
|----------|------|------|-----|------------|-----|--------|
|          |      | 100% | 80% | 60%        | 40% |        |
| 実際の軸力    | 100% | 4.8  | 2.6 | 0.6        | 0   | 60.00% |
|          | 80%  | 2.1  | 4.9 | 1          | 0   | 61.25% |
|          | 60%  | 0    | 1.4 | 4.7        | 1.9 | 58.75% |
|          | 40%  | 0    | 1   | 2.4        | 4.6 | 57.50% |
| 平均識別率    |      |      |     |            |     | 59.38% |
| 評価指標     | 識別誤差 |      |     | F値         |     |        |
|          | 14.6 |      |     | 0.60072553 |     |        |

表 8.63 減衰率特徴量 8 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.1  | 1.8 | 0.1         | 0   | 76.25% |
|          | 80%  | 1.6  | 6   | 0.4         | 0   | 75.00% |
|          | 60%  | 0    | 0.3 | 5.8         | 1.9 | 72.50% |
|          | 40%  | 0    | 0.2 | 1.9         | 5.9 | 73.75% |
| 平均識別率    |      |      |     |             |     | 74.38% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 8.5  |      |     | 0.756899282 |     |        |

表 8.64 減衰率特徴量 10 個の識別結果 (200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 6.5  | 1.5 | 0           | 0   | 81.25% |
|          | 80%  | 1.6  | 6.2 | 0.2         | 0   | 77.50% |
|          | 60%  | 0    | 0.1 | 6           | 1.9 | 75.00% |
|          | 40%  | 0    | 0   | 1.9         | 6.1 | 76.25% |
| 平均識別率    |      |      |     |             |     | 77.50% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 7.2  |      |     | 0.796202631 |     |        |

表 8.50～表 8.64 より、50 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 43.13%，減衰率特徴量 4 個が 49.06%，減衰率特徴量 6 個が 60.63%，減衰率特徴量 8 個が 73.75%，減衰率特徴量 10 個が 75.31%となった。100 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 44.69%，減衰率特徴量 4 個が 49.06%，減衰率特徴量 6 個が 59.06%，減衰率特徴量 8 個が 71.56%，減衰率特徴量 10 個が 75.63%となった。200 点ずつの平均を取った減衰率特徴量を用いた時の平均識別率は減衰率特徴量 2 個が 43.75%，減衰率特徴量 4 個が 49.69%，減衰率特徴量 6 個が 59.38%，減衰率特徴量 8 個が 74.38%，減衰率特徴量 10 個が 77.50%となった。減衰率特徴量の個数においては、全体的に 8 個～10 個の時に識別精度が 70%を超える結果となった。特に、200



点ずつの平均を取った減衰率特徴量を 10 個用いた時に平均識別率が 77.50% となった。この結果から、最大振幅の 1/9, 1/10, 1/11 周辺に各軸力における特徴が現れていると考えられる。また、200 点ずつ平均をとった減衰率特徴量を用いると全体的に平均識別率が高くなっているため、200 点ずつ平均をとった減衰率特徴量が軸力診断に有効であると考えられる。RF と SVM による識別実験の結果と比べると、わずかであるが、平均識別率が向上していた。さらに、F 値を比べると NN を用いた識別器は 0.7962 と最も高くなっており、このことから NN を用いた識別器の方が性能は高いと考えられる。

#### (4) 識別実験 2 (減衰率特徴量を用いた識別) の考察

本実験結果と識別実験 1 の結果から、周波数特徴量とレスポンス特徴量のみを用いて軸力推定を行うよりも、減衰率特徴量のみを用いて軸力推定を行う方が精度良く識別が可能なが分かった。また、減衰率特徴量の個数においては、8 個～10 個の時に識別精度が 70% を超える結果となった。この結果から、最大振幅の 1/9, 1/10, 1/11 周辺に各軸力における特徴が現れていると考えられる。また、200 点ずつ平均をとった減衰率特徴量を用いると平均識別率が高くなっているため、200 点ずつ平均をとった減衰率特徴量が軸力診断に有効であると考えられる。特に、200 点ずつの平均を取った減衰率特徴量を 10 個用いて NN で学習させた場合に平均識別率が 77.50% となった。200 点ずつ平均をとった減衰率特徴量の個数による平均識別率の違いを図 8.18 に示す。パターン認識手法ごとの結果を見ると、NN を用いた識別実験の結果が、全体的に高い平均識別率となっている。このことから、減衰率特徴量を用いた軸力診断においては、NN を用いるのが最も有効であると考えられる。しかし、実際の軸力診断に用いるには、まだ識別性能が足りないとする。図 8.18 を見ると、減衰率特徴量を増加させると平均識別率が向上する傾向が見られるが、減衰率特徴量を 10 個以上用いて識別実験を行うと平均識別率の向上は見られなくなっている。




図 8.18 減衰率特徴量の個数による識別率の変化

#### 8.5.4 識別実験3（周波数・レスポンス・減衰率特徴量を用いた識別）

識別実験1，識別実験2の結果から振動加速度データを用いた軸力診断における有効な特徴量の数，機械学習手法を導出することができた．周波数特徴量は5個，レスポンス特徴量は4個，減衰率特徴量は8～10個のとき，高い識別率を出すことができた．パターン認識手法においては，ニューラルネットワークを用いると，高い識別率を出すことができた．そこで，識別実験1，識別実験2で用いた特徴量を組み合わせることで，より高い識別率を出すことを目指す．これまでの実験結果より，周波数特徴量を5個，レスポンス特徴量を4個，200点ずつ平均をとった減衰率特徴量を8～10個を用いて，ニューラルネットワークで学習させた識別器を生成する．減衰率特徴量の数を8～10で変化させながら，その識別率を比較検討した．

識別実験を行った結果を表8.65，表8.66，表8.67に示す．表8.65は，周波数特徴量を5個，レスポンス特徴量を4個，200点ずつ平均をとった減衰率特徴量を8個用いた結果を示す．表8.66は，周波数特徴量を5個，レスポンス特徴量を4個，200点ずつ平均をとった減衰率特徴量を9個用いた結果を示す．表8.67は，周波数特徴量を5個，レスポンス特徴量を4個，200点ずつ平均をとった減衰率特徴量を10個用いた結果を示す．

表 8.65 周波数特徴量 5 個，レスポンス特徴量 4 個，減衰率特徴量 8 個の識別結果  
(200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 7.2  | 0.8 | 0           | 0   | 90.00% |
|          | 80%  | 0.9  | 7.1 | 0           | 0   | 88.75% |
|          | 60%  | 0    | 0.1 | 6.9         | 1   | 86.25% |
|          | 40%  | 0    | 0.2 | 1           | 6.8 | 85.00% |
| 平均識別率    |      |      |     |             |     | 87.50% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 4.2  |      |     | 0.885484904 |     |        |

表 8.66 周波数特徴量 5 個，レスポンス特徴量 4 個，減衰率特徴量 9 個の識別結果  
(200 点ずつの平均)

| 200点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|----------|------|------|-----|-------------|-----|--------|
|          |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力    | 100% | 7.2  | 0.8 | 0           | 0   | 90.00% |
|          | 80%  | 0.9  | 7   | 0.1         | 0   | 87.50% |
|          | 60%  | 0    | 0.1 | 6.9         | 1.1 | 85.19% |
|          | 40%  | 0    | 0.1 | 0.8         | 7.1 | 88.75% |
| 平均識別率    |      |      |     |             |     | 87.86% |
| 評価指標     | 識別誤差 |      |     | F値          |     |        |
|          | 4    |      |     | 0.884713501 |     |        |

表 8.67 周波数特徴量 5 個，レスポンス特徴量 4 個，減衰率特徴量 10 個の識別結果  
(200 点ずつの平均)

| 200 点ずつ平均 |      | 推定軸力 |     |             |     | 識別率    |
|-----------|------|------|-----|-------------|-----|--------|
|           |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力     | 100% | 7.2  | 0.8 | 0           | 0   | 90.00% |
|           | 80%  | 0.7  | 7.2 | 0.1         | 0   | 90.00% |
|           | 60%  | 0    | 0.2 | 6.9         | 0.9 | 86.25% |
|           | 40%  | 0    | 0.2 | 0.7         | 7.1 | 88.75% |
| 平均識別率     |      |      |     |             |     | 88.75% |
| 評価指標      | 識別誤差 |      |     | F値          |     |        |
|           | 3.8  |      |     | 0.892064457 |     |        |

表 8.65～表 8.67 より，周波数特徴量を 5 個，レスポンス特徴量を 4 個，200 点ずつ平均をとった減衰率特徴量を 8 個用いた場合の平均識別率は 87.50%となった．周波数特徴量を 5 個，レスポンス特徴量を 4 個，200 点ずつ平均をとった減衰率特徴量を 9 個用いた場合の平均識別率は 87.86%となった．周波数特徴量を 5 個，レスポンス特徴量を 4 個，200 点ずつ平均をとった減衰率特徴量を 10 個用いた場合の平均識別率は 88.75%となった．本実験結果から，周波数特徴量とレスポンス特徴量に加えて，減衰率特徴量を用いて軸力診断をすると大きく識別率が上がった．これらの結果から，周波数特徴量とレスポンス特徴量，減衰率特徴量を用いることが軸力診断において有効であると考えられる．

#### 8.5.5 特徴量を用いた識別実験を通しての考察

識別実験 1，識別実験 2，識別実験 3 の結果から，周波数特徴量とレスポンス特徴量に加えて減衰率特徴量を併用することによって，どの軸力においても全体的に識別率を向上させることができた．周波数特徴量とレスポンス特徴量を用いた識別の結果から，どの機械学習手法においても周波数特徴量 5 個とレスポンス特徴量 4 個を用いた場合の識別率が高くなった．このことから周波数特徴量とレスポンス特徴量を増やせば識別率が上がるように考えられるが，周波数特徴量を増加させると平均識別率の低下が見られた．また，周波数特徴量 5 個のみの識別率が周波数特徴量 3 個とレスポンス特徴量 2 個の識別率を超えていたことから周波数特徴量が軸力推定において重要な要素であると考えられる．減衰率特徴量のみを用いた識別実験の結果から，減衰率特徴量が軸力推定に大きな影響を及ぼしており，軸力推定に必要な要素であることが分かった．移動平均法の適用の際，平均を取る間隔を 50 点ずつ，100 点ずつ，200 点ずつ変更したが，200 点ずつと平均を取った場合の識別率が高いことがわかった．このような結果になった理由として，平均を取る間隔が狭いと振動加速度データがあまり平滑化されず，同じ軸力でも減衰率特徴量がうまく取れていないと考えられる．また，減衰率特徴量を 8 個以上用いると大きく識別率が向上したことから，最大振幅の 1/9，1/10，1/11 周辺に各軸力における特徴が現れていると考えられる．こちらでも減衰率特徴量を増やすと識別率が向上しているが，減衰率特徴量を 10 個以上用い

て識別実験を行うと平均識別率の向上は見られなくなった。識別実験 3 では、周波数特徴量 5 個、レスポンス特徴量 4 個、減衰率特徴量 10 個を用いて識別を行うと、88.75%の識別率を出すことができた。表 5.67 を見ると、軸力 100%と軸力 80%に関しては 90%以上の識別率を出すことができたが、軸力 60%と 40%の識別率は 90%に届いていない。また、軸力 40%の識別において、10 回中 2 回は軸力 80%という誤った識別をしており、対策の必要があると考える。このような結果となる原因として、ランダムに学習データを変化させているので、学習データの内容が偏っていると、うまく学習できなくなってしまうことが挙げられる。そのため、学習に最適な学習データを抽出する必要があると考える。評価指標を見ると、周波数特徴量 5 個とレスポンス特徴量と、移動平均法を適用し 200 点ずつの平均を取った減衰率特徴量 10 個を用いた時において 3.8 と全識別実験の中で最も低い値となっている。また F 値においても、0.8920 と最も高い値となっているため、識別性能が最も高い識別器といえる。しかし、少数ではあるが、低軸力のものを高軸力のものと推定しているものがあり、まだ改善の余地があると考ええる。

## 8.6 深層学習による識別実験

### 8.6.1 実験の概要

前節までの結果から、振動加速度データから特徴量を抽出し、機械学習を行うことで軸力診断が可能であることがわかった。また、振動加速度データの持つさまざまな要素を特徴量とすることで、高い精度での軸力診断が可能であることがわかった。しかし、特徴量を増やすことで軸力診断の精度は向上する傾向にあるが、特徴量の抽出処理が増え、効率が悪くなってしまう。そこで、深層学習を用いて高力ボルトの軸力診断を検討する。深層学習とは、適切な特徴抽出能力を持つ教師なしニューラルネットワークを多層にして構築したものである。最大の特徴としては、パターン認識などの際に用いる特徴量の抽出を行う必要がないということが挙げられる。この特徴を利用して、振動加速度データのみを入力データとして軸力診断を行う。振動加速度データはサンプリング周波数が 5000Hz のデータであるため、高力ボルト打撃時から 1 秒間、つまり 5000 個の振動加速度データの振幅を入力データとする。振動加速度データの振幅の変位を入力データとすることで、特徴量の抽出処理を一切行うことなく軸力診断が可能となる。深層学習の手法として、本研究では畳み込みニューラルネットワークでの識別実験を行う。畳み込みニューラルネットは、畳み込み層とプーリング層という特別な 2 種類の層を含む順伝播型ネットワークである。特に、画像認識に応用され、これまでの順伝播型ネットワークと同様、誤差逆伝播法と確率的勾配降下法により最適化を行う。畳み込みネットの特徴は、局所的受容野および重み共有と呼ばれる特別な層間結合を持つことで、この点がこれまでの順伝播型ネットワークとの違いになる。畳み込みニューラルネットワークは画像認識の応用が多いため、2 次元データを入力データとすることがほとんどであるが、本研究では振動加速度データの振幅である 1 次元の時系列データを用いる。畳み込みニューラルネットワークを用いた理由と

しては、フィルタによる畳み込みが振動加速度データの波形の特徴を学習できるのではないかと考えたからである。実験で使用するデータは、前章の実験と同様にナットに振動加速度センサを取り付け、ナット辺をハンマーで打撃した振動加速度データを用いた。振動加速度データは、軸力 100% が 40 個、軸力 80% が 40 個、軸力 60% が 40 個、軸力 40% が 40 個の計 160 個である。識別実験において、軸力ごとに 40 個のデータの内、32 個を学習データ、残り 8 個をテストデータとして実験を行った。つまり、学習データは軸力 100%, 80%, 60%, 40% が各 32 個ずつの合計 128 個で、テストデータは軸力 100%, 80%, 60%, 40% が各 8 個ずつの合計 32 個である。学習データとテストデータの抽出は識別実験のたびにランダムで行った。データのサンプリング、学習、評価のサイクルを 10 回行い、その平均を結果として出力した。

### 8.6.2 畳み込みニューラルネットワークによる識別実験

まず、畳み込みニューラルネットワークで軸力診断が可能なのかどうかを検討するために、図 8.19 のようなネットワークを構成した。ネットワークの構成として、入力層 (Raw data) は 5000 個のノードを持ち、畳み込み層 (Convolutional layer) は 20 個のフィルタを持ち、プーリング層 (Max pooling layer) とのペアを 2 層構成し、全結合層 (FC layer) を 2 層、全結合層の最終である出力層は 4 個のノードを持つ。つまり、隠れ層としては、畳み込み層とプーリング層のペアが 2 つと全結合層が 1 つの 3 層構造になっている。識別実験として、データのサンプリング、学習、評価のサイクルを 10 回行い、各軸力の平均識別率を表 8.68 に示す。

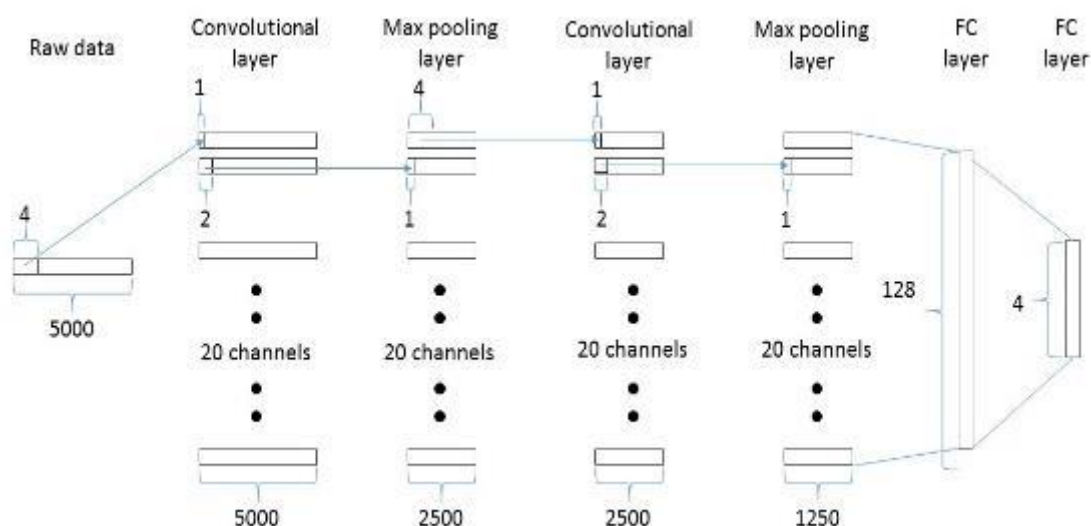


図 8.19 識別実験で用いるネットワーク構成

表 8.68 識別実験 10 回分の平均識別率

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.2  | 0   | 0.2         | 1.6 | 77.50% |
|       | 80%  | 0.9  | 6.8 | 0           | 0.3 | 85.00% |
|       | 60%  | 0    | 0.1 | 6.9         | 1.1 | 85.19% |
|       | 40%  | 0    | 0.2 | 0.9         | 6.9 | 86.25% |
| 平均識別率 |      |      |     |             |     | 83.48% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 9.2  |      |     | 0.860927152 |     |        |

表 8.68 から軸力 100%の平均識別率は 77.50%，軸力 80%の平均識別率は 85.00%，軸力 60%の平均識別率は 85.19%，軸力 40%の平均識別率は 86.25%，全軸力の平均識別率は 83.48%となった。全体的に、8.5 節での周波数特徴量とレスポンス特徴量、減衰率特徴量を用いた識別実験の結果に比べると精度が低下している。10 回の実験の中で一度きりではあるが、軸力 60%と軸力 40%の識別において、識別率 100%を出しているものもあったが、誤った場合において軸力 60%と軸力 40%は軸力 80%と識別してしまう場合があるので注意が必要である。識別誤差は 9.2 と誤りが多くなっている。特に、軸力 100%を軸力 60%や軸力 40%と識別しているもの、軸力 80%を軸力 40%と識別しているものがあり、改善する必要があると考える。F 値においては、周波数特徴量とレスポンス特徴量、減衰率特徴量を用いた識別実験の結果に比べると評価は下がっているが、周波数特徴量のみ、減衰率特徴量のみでの識別実験の結果より高くなっているため、畳み込みニューラルネットワークを用いた軸力診断は可能であると考えられる。

### 8.6.3 ドロップアウトを適用した畳み込みネットによる識別実験

8.6.2 項での識別実験の結果、振動加速度データそのものを入力データとして、畳み込みニューラルネットワークでの軸力診断は可能であるとわかった。しかし、その精度は低いことと過学習が起きてしまうという問題が生まれた。その解決策として、畳み込みニューラルネットワークにドロップアウトを適用する。ドロップアウトは、多層ネットワークのユニットを確率的に選別して、学習を行う方法である。学習時において、中間層の各層と入力層のユニットを決まった割合  $p$  でランダムに選出し、それら以外を無効化、つまりそもそも存在しないかのように扱い、ネットワークを最適化する。その学習終了後の推論では、すべてのユニットを用いて順伝播計算を行うという手法である。ドロップアウトの目的は、学習時にネットワークの自由度を強制的に小さくし、過学習を避けることにある。これは、ドロップアウト時のユニットをランダムに無効化したネットワークを多数独立に学習し、推論時にそれらの結果を平均するのと同じ効果があると考えられている。複数のネットワークの平均をとると推論の精度が一般に向上することが知られており、この性質を活かして、軸力診断の精度向上を図る。本実験では  $p=0.25$  と  $p=0.5$  と  $p=0.75$  の 3 パター

ンの識別実験を行う。ネットワークの構成は、前節の識別実験と同じものを用いる。 $p=0.25$ における各軸力の平均識別率を表 8.69 に示す。 $p=0.5$ における各軸力の平均識別率を表 8.70 に示す。 $p=0.75$ における各軸力の平均識別率を表 8.71 に示す。

表 8.69 識別実験 10 回分の平均識別率 ( $p=0.25$ )

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 7.3  | 0   | 0           | 0.7 | 91.25% |
|       | 80%  | 0.4  | 7.2 | 0           | 0.4 | 90.00% |
|       | 60%  | 0    | 0.1 | 7.1         | 0.8 | 88.75% |
|       | 40%  | 0    | 0.1 | 1.1         | 6.8 | 85.00% |
| 平均識別率 |      |      |     |             |     | 88.75% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 5.5  |      |     | 0.932592588 |     |        |

表 8.70 識別実験 10 回分の平均識別率 ( $p=0.5$ )

|       |      | 推定軸力 |     |             |     | 識別率     |
|-------|------|------|-----|-------------|-----|---------|
|       |      | 100% | 80% | 60%         | 40% |         |
| 実際の軸力 | 100% | 8    | 0   | 0           | 0   | 100.00% |
|       | 80%  | 0.5  | 7.5 | 0           | 0   | 93.75%  |
|       | 60%  | 0    | 0   | 7.9         | 0.1 | 98.75%  |
|       | 40%  | 0    | 0   | 2           | 6   | 75.00%  |
| 平均識別率 |      |      |     |             |     | 91.88%  |
| 評価指標  | 識別誤差 |      |     | F値          |     |         |
|       | 2.6  |      |     | 0.969668246 |     |         |

表 8.71 識別実験 10 回分の平均識別率 ( $p=0.75$ )

|       |      | 推定軸力 |     |             |     | 識別率    |
|-------|------|------|-----|-------------|-----|--------|
|       |      | 100% | 80% | 60%         | 40% |        |
| 実際の軸力 | 100% | 6.5  | 0   | 0.2         | 1.3 | 81.25% |
|       | 80%  | 0.3  | 7.5 | 0           | 0.2 | 93.75% |
|       | 60%  | 0    | 0   | 7.7         | 0.3 | 96.25% |
|       | 40%  | 0    | 0   | 1.9         | 6.1 | 76.25% |
| 平均識別率 |      |      |     |             |     | 86.88% |
| 評価指標  | 識別誤差 |      |     | F値          |     |        |
|       | 7.2  |      |     | 0.923611111 |     |        |

表 8.69 から軸力 100%の平均識別率は 91.25%，軸力 80%の平均識別率は 90.00%，軸力 60%の平均識別率は 88.75%，軸力 40%の平均識別率は 85.00%，全軸力の平均識別率は 88.75%となった。表 8.70 から軸力 100%の平均識別率は 100.00%，軸力 80%の平均識別率は 93.75%，軸力 60%の平均識別率は 98.75%，軸力 40%の平均識別率は 75.00%，全軸力の平均識別率は 91.88%となった。表 8.71 から軸力 100%の平均識別率は 81.25%，軸力 80%の平均

識別率は 93.75%，軸力 60%の平均識別率は 96.25%，軸力 40%の平均識別率は 76.25%，全軸力の平均識別率は 86.88%となった。ドロップアウトを適用するとどの軸力においても、平均識別率が大きく向上した。  $p=0.25$  のとき、どの軸力の平均識別率においても 80%を超えており、軸力 100%と軸力 80%においては 90%を超えている。しかし、軸力 100%を軸力 40%と識別しているものがあるため、識別誤差は特徴量ベースの識別器の性能に劣る。  $p=0.5$  のとき、軸力 100%の平均識別率が 100%となっており、高い精度を出すことができた。しかし、軸力 40%に関しては 75.00%となっており、かなり低い精度となっている。ただ、軸力 40%で誤った場合において、軸力 60%と識別しているものしかないため、F 値が 0.9697 とこれまでの識別実験の結果の中で最も高い値になった。識別誤差に関しても 2.6 とこれまでの識別実験の結果の中で最も低い値になった。  $p=0.75$  のとき、平均識別率が 86.88%となった。しかし、  $p=0.5$  のときに比べて、平均識別率が低下してしまうので、  $p$  の値は 0.5 程度にとどめておくのが良いと考えられる。この原因として、ドロップアウトはユニットをランダムに無効化したネットワークを多数独立に学習し、識別器を生成するため、  $p=0.75$  にすると、半分以上のユニットが無効化されてしまい、うまく学習できなかったと考えられる。ドロップアウトさせるユニットの割合を適切に設定すると、軸力診断の精度を向上させることができた背景として、ドロップアウトのランダム性が有効だったと考えられる。ランダムにユニットを無効化することで、局所解に陥らず、最適な重みを学習できたと考えられる。これらの結果と特徴量を用いた識別実験の結果を比べると、周波数特徴量、レスポンス特徴量、減衰率特徴量を用いた識別結果に比べて、平均識別率、識別誤差、F 値とすべて良好な結果となっており、深層学習による軸力診断の有用性は高いと考えられる。今後の課題としては、軸力 60%と軸力 40%の細かい違いをうまく識別する必要があると考えられる。しかし、本研究において高力ボルトの危険な状態は軸力 60%以下であるので、実際の軸力診断でも用いることのできる識別器が生成できたと考える。



## 第9章 おわりに

近年、高度成長期に建設された橋梁の多くは、適切な維持管理を必要としている。一方、わが国では熟練技術者の多くが団塊の世代であるため、若手技術者が圧倒的に不足している。技術者の育成には時間がかかるため、今後、技術者不足は更に深刻になると予想される。同時に、国土交通省は2014年7月1日から、トンネルや2メートル以上の道路橋などを、近接目視によって、5年に1度の頻度で点検するよう義務付けた。罰則等は設けられてはいないが、予算や技術者確保等の面で苦しむ自治体が多く出ている。このような状況の中、橋梁の維持管理の効率化・省力化のための新たなモニタリングシステムおよび健全度の診断スキームの構築が望まれている。

そこで本研究では、申請書を基に初回の打ち合わせ(2015年9月24日実施、参考資料(初回研究打ち合わせメモ)参照)を実施し、2年間で検討すべき具体的研究計画を議論した。この議論を経て具体的な研究の進め方は、1) ロボットによるデータ収集(検査ロボットの制御)、2) 画像と打音による健全度の評価(収集データの評価)、3) 実装実験(供試体による評価と実橋による評価)の3つの課題について検討を進めることとした。上記1)~3)の具体的な内容は以下の通りである。

- 1) ロボットによるデータ収集(検査ロボットの制御)
  - ・ロボットによるひび割れ画像の撮影(複数画像からの3Dモデルの作成)
  - ・ロボットによる打音の収集
  - ・ドローンを使って上記のデータ収集を検討(優先順位は、画像→打音)
  - ・様々なロボットの利活用に関する調査(吸着型ロボットなど)
- 2) 画像と打音による健全度の評価(収集データの評価)
  - ・ひび割れ画像データ(視覚情報)による健全度の評価
  - ・打音データ(聴覚情報)による健全度の評価
  - ・加速度データ(触覚情報)による健全度の評価を追加で検討
- 3) 実装実験(供試体による評価と実橋による評価)
  - ・小型の供試体を作り、実際にデータを収集して、健全度の評価実験を実施
  - ・実際の橋梁での収集データによる健全度の評価実験を実施

これらの課題の中で、「1) ロボットによるデータ収集(検査ロボットの制御)」に関する研究課題については、現在、内閣府を主体として進められている戦略的イノベーションプロジェクトの中で進められている「インフラ維持管理・更新・マネジメント技術」の研究プロジェクトにおける様々なデータ収集スキームについて調査した。これらの技術の中でもUAVやロボット(自動化するればロボットになりうる装置も含む)を用いた、新たなモニタリングシステムに関する技術開発が多くみられ、今後のモニタリングの方向性を示唆するものと理解できる(第3章)。また、本研究でもドローンを用いたモニタリングシステムに関する検討を行い、構造物との接触等による落下を防ぐ方法としてバンパーガードを

取り付けることの有効性等を確認することができ、その成果についてまとめることができた（第4章）。また、ドローンによって撮影した画像をもとに構造物の3次元モデルを作成する仕組みを提案して、様々な対象物での実証実験を実施した。これらの実験を通して、対象物の規模が大きくなれば3次元モデルの再現精度が落ちる傾向となったが、対象物の周囲を複数の画像が重なるよう、きめ細かく撮影することができれば、ほぼ実物に近い3次元モデルが構築できることを確認することができた（第5章）。

「2) 画像と打音による健全度の評価(収集データの評価)」に関する研究課題については、ドローン等で収集した視覚情報（ひび割れ画像データ）、聴覚情報（打音データ）、および触覚情報（加速度データ）を用いた橋梁の健全度診断スキームについて検討した。健全度診断スキームには、AIに関する研究分野において提案されている様々な方法を用いることを検討し、本研究で用いた様々な方法論の概要を第6章でまとめた。第7章では、健全度診断の対象として橋梁の床版のひび割れ損傷を取り上げ、視覚情報（ひび割れ画像データ）を用いた床版健全度の診断スキームの検討結果をまとめた。具体的には、阪神高速道路等で利用されている判定基準（ひび割れ幅、ひび割れ間隔、ひび割れ形状）を参考に、画像に含まれるひび割れ画素・交差点・分岐点・端点・角点などの分布量をひび割れの特徴量として設定し、第6章で説明した様々な方法論を用いて健全度の診断スキームの検証を実施した。実証実験の結果、多項式型カーネルや Gaussian カーネルを用いた非線形サポートベクタマシンによる識別実験において85%程度の識別精度を得ることができ、さらに有効な特徴量を検討していくことによって、診断スキームの有用性を高めていくことが可能であることを確認することができた。第8章では、健全度診断の対象として高力ボルトの軸力低下を取り上げ、触覚情報（加速度データ）を用いた軸力の診断スキームの検討結果をまとめた。聴覚情報（打音データ）での実証実験も実施したが、打音は環境音による雑音が多く含まれていたため、加速度データによって得られた識別精度を超えることができず、本報では、触覚情報（加速度データ）による検討結果のみの記載とした。加速度データから、周波数や減衰率に関する特徴量を抽出し、その組み合わせによって軸力の識別実験を実施した結果、周波数やレスポンスの上位5つの特徴量と200点ずつの移動平均から減衰傾向を10点で取り出した特徴量を組み合わせて用いた識別実験で、精度が約89.2%と最も高くなった。まだまだデータ数は少なく、学習データを充実させていくことによってさらなる識別精度の向上が期待できる。さらに、最近 AlphaGo で話題となっている特徴量を考えなくてもよい深層学習（Deep Learning）を用いた識別実験も実施した。実験の結果、確率0.5の割合でドロップアウトを適用した畳み込みネットワークによる識別実験で約91.9%の精度を得ることができた。ブラックボックスで特徴量ベースでの診断スキームに比べて説明能力に劣る面はあるものの、90%を超える識別精度が得られた。本手法の有用性を高めていくためには、今後、ネットワークの意味理解などに関する研究が進み、説明能力を高めていく工夫が重要と考える。

## 参考文献

- [1] 国土交通省：維持修繕に関する省令（案）・告示（案）について，  
<http://www.mlit.go.jp/common/001029238.pdf>
- [2] 国土交通省：道路橋定期点検要領，  
[http://www.mlit.go.jp/road/ir/ir-council/pdf/yobo4\\_1.pdf](http://www.mlit.go.jp/road/ir/ir-council/pdf/yobo4_1.pdf)
- [3] 国土交通省：橋梁定期点検要領，  
[http://www.mlit.go.jp/road/ir/ir-council/pdf/yobo3\\_1\\_6.pdf](http://www.mlit.go.jp/road/ir/ir-council/pdf/yobo3_1_6.pdf)
- [4] NHK：クローズアップ現代問われる“維持管理” ～笹子トンネル事故の波紋～，  
[http://www.nhk.or.jp/gendai/kiroku/detail02\\_3303\\_all.html](http://www.nhk.or.jp/gendai/kiroku/detail02_3303_all.html)
- [5] 株式会社横河ブリッジホールディングス，株式会社横河技術情報：橋梁の総合保全をめざして！なくなった図面の復元～情報システムからのアプローチ～，  
[http://www.ybhd.co.jp/ir/pdf/settlement\\_20141112-2.pdf](http://www.ybhd.co.jp/ir/pdf/settlement_20141112-2.pdf)
- [6] 山本鎮男 編著：ヘルスモニタリング-機械・プラント・建築・土木構造物・医療の健全性監視-，共立出版株式会社，1999.
- [7] 宮川豊章，森川英典：図説 わかる メンテナンス，土木・環境・社会基盤施設の維持管理
- [8] 日本道路協会，道路橋補修・補強事例集(2012 年版)，2012.3 日本道路協会：道路橋示方書・同解説 IV 下部構造編，pp.110-119，1996
- [9] 国土交通省，橋梁定期点検要領(案)，2004.3
- [10] 鈴木俊晴，稲岡喜作，福岡俊道：ひずみゲージによる計測の理論と実際，神戸大学大学院海事科学研究科紀要 第7号，2010
- [11] 東日製作所：東日トルクハンドブック Vol.8
- [12] 上野幹二，山口隆司，小林昭一：超音波縦波および横波を用いた高力ボルト軸力測定に関する基礎的研究，構造工学論文集，土木学会，Vol.46A，pp.1147-1152，2000
- [13] 柏谷賢治：交流消磁法を併用した磁気異方性センサによる応力測定，非破壊検査，第34巻，第3号，1985
- [14] 満上育久：私の研究開発ツール（第46回） Bundler: Structure from Motion for Unordered Image Collections，映像情報メディア学会誌 Vol. 65 (2011) No. 4 P 479-482
- [15] 味岡 収，渡邊 弘行：画像解析による 3 次元形状復元の可能性についての再考，日本建築学会大会学術講演梗概集 (近畿) 2014 年 9 月
- [16] 鳥居秋彦，岡谷貴之，延原章平：多視点 3 次元復元の研究動向，情報処理学会研究報告 Vol.2011-CVIM-176 No.1
- [17] 小花和宏之，早川裕式，ゴメス クリス トファー：UAV 空撮と SfM を用いたアクセス困難地の 3D モデリング，地形 第35巻第3号 283-294 頁 (2014)

- [18] 石井健一郎, 上田修功, 前田英作, 村瀬洋: わかりやすいパターン認識, オーム社, 1998.8.
- [19] 安居院猛, 長尾智晴: 画像の処理と認識, 昭晃堂, 1992.11
- [20] 平井有三: はじめてのパターン認識, 森北出版株式会社, 2012.7
- [21] Leo Breiman: Random Forests, Machine Learning, Vol.45, No.1, pp.5-32, 2001
- [22] Leo Breiman: Bagging Predictors, Machine Learning, Vol.24, No.2, pp.123-140, 1996
- [23] David E. Rumelhart: BACKPROPAGATION Theory, Architectures, and Applications, 1986
- [24] 岡谷貴之: 深層学習, 講談社, 2015
- [25] N.Srivastava, G.E.Hinton, A.Krizhevsky, I.Sutskever, R.salakhutdinov: Dropout:A simple way to prevent neural networks from overfitting, Journal of Machine Learning Research, pp1929-1958, 2014
- [26] 林秀直, 川村勝, 金本功: 阪神高速道路の RC 床版の点検, 第一回鋼橋床版シンポジウム講演論文集, pp.265-270, 1998
- [27] 三谷政昭: 今日から使えるフーリエ変換, 講談社, 2005.1
- [28] 馬場俊雄: 移動平均法によるノイズ除去と波形変化の關係の具体的考察, 九州大学応用力学研究所技術レポート Vol.7, pp110-113

## 謝辞

本研究の遂行にあたり，特に深層学習を用いた診断スキームを提案する際，立命館大学の野村泰稔氏から，得られた結果の評価や深層学習における数々のパラメータの設定方法などの指導をいただき，本報告書の取りまとめに多大なるご助言をいただきました．心より厚くお礼申し上げます．