

惑星探査ローバのための 深層学習を用いた環境地図の理解に基づく行動モード選択法

○本橋優俊（東京大学） 久保田孝（JAXA）

1. はじめに

1997年にNASA/JPLの探査ローバ Sojourner が火星に着陸して以降、ローバによる火星探査が活発に行われてきた。ローバは探査対象を直接観測することができ、また移動により広範囲を探索することが可能である。そのため非常に多くの科学的成果を得ることができる。例えば、火星探査ローバ Opportunity はメリディアニ平原にて水の存在が示唆される証拠を発見した [1]。2021年にはNASA/JPLの探査ローバ Perseverance や CNSA の探査ローバ祝融が火星に着陸した。特に Perseverance は Mars Sample Return Mission 計画におけるサンプル採取の役割を担っており、その活躍に期待が寄せられている。

ローバミッションにおいて目的地まで安全に走行することが要求される。科学的成果を多く得るためには、天体表面を移動できるというローバ独自の利点を十分に引き出すことが必要となる。未知で不整地な天体表面を走行するためには高度な不整地走行技術が求められる。また地球－火星間の片道通信遅延は4～20分あり、リアルタイムでの遠隔操作は困難である。そのため探査ローバには目的地まで自律的に走行できるナビゲーションシステムが搭載されてきた。NASA/JPLが行った Mars Exploration Rover (MER) ミッションや Mars Science Laboratory (MSL) ミッションでは自己位置推定、環境認識、経路計画をローバが自律的に行うナビゲーションを実証した [2–4]。その有用性が示され、現在はローバの走行効率向上のためナビゲーションに関する研究が盛んに行われている [5, 6]。

ローバの走行効率向上のためには個々のナビゲーション技術の向上はもちろんのこと、それらの環境に対する柔軟性も必要である。自己位置推定手法やセンシング・経路計画の実施の是非を環境に応じて切替えられる

ことで、より効率的な走行が可能となる。しかし、過去の探査ローバでは環境に応じてナビゲーション機能を切替える手法は用いられてこなかった。火星探査ローバ Curiosity ではオペレータが確認できる近い領域と視認限界を超えた遠方の領域で行動モードを変更する運用が行われていた (図1) [7, 8]。この手法はあくまで距離に応じて行動モードを変更させているにすぎない。障害物の有無や地質状況といった周囲環境に応じてナビゲーション機能の切替えを行うことができれば、探査効率の向上を期待できる。

以上の議論をもとに、より効率的な探査の実現のため惑星探査ローバの自律的な行動モード選択法を提案する。本研究ではセンシングと経路計画に着目する。それらの実施の是非を障害物の量や配置に応じて決定することで走行時間を削減する。また環境地図を深層学習によって理解することで、適切な行動モード選択を実現する。

2. 探査ローバの行動モード

本論文では Directed モード、Guarded モード、AutoNav モードの3つの行動モードの切替えを検討する。それぞれセンシングと経路計画の実施の是非によって分類した。Directed はセンシングも経路計画も行わないモードであり、目的地に向かって直線的に移動する。計算負荷がほとんどかからないため非常に高速に移動できるが、障害物に衝突してしまうリスクがある (図2a)。そのため安全が確保された場所でのみ使用することができる。Guarded はセンシングを行いながら目的地まで直線的に移動するモードである。センシングを行うため障害物を回避することができるが、経路計画を行わないため障害物に囲まれた領域に入ると抜け出せなくなる恐れがある (図2b)。AutoNav はセンシングと経路計画を常に行い、経路計画で得られた経路に沿って目的地まで移動する。目的地まで安全に確実に移動できる一方、計算負荷が大きいという欠点がある (図2c)。

本研究では以上の3つの行動モードを環境に応じて切替える。センシングした情報のみから適切なモード




図1 火星探査ローバ Curiosity の距離による行動モード選択 [7]




図2 行動モードと各モードの特徴

を決定することで環境に適応可能なナビゲーションシステムを構築する。

3. 行動モード選択法

行動モード切替えでは、障害物に衝突せず安全に目的地まで移動すること、目的地までの走行時間を最小限に抑えること、を目標とする。そこで提案手法では図3に示すモード遷移図に従って行動モードの切替えを行うこととした。以下、Directed—Guarded間のモード切替え及びGuarded—AutoNav間のモード切替えの詳細を述べる。

3.1 Directed—Guarded間のモード切替え

Directedはセンシングを行わないため、障害物に衝突してしまう危険性がある。そのため障害物が全くない環境でのみ使用できる。そこでDirectedとGuardedのモード切替えは図4に示す形で行う。ローバはGuardedモードで走行している際、センシングを行う。センシングした領域内に障害物が全くない場合は、Directedモードへ切替える。センシング領域内はDirectedで走行し続け、領域外に近づいたらGuardedモードへ切替えセンシングを行う。Guardedでセンシングした際に障害物が少しでもある場合、引き続きGuardedモードで走行を行う。以上のようにDirected, Guarded間のモード切替えは障害物の有無によって行う。

3.2 Guarded—AutoNav間のモード切替え

提案手法において、GuardedからAutoNavへの切替えは障害物の量によって、AutoNavからGuardedへの切替えは環境地図に基いて行うこととした。まずGuardedからAutoNavへの切替えについて述べる。GuardedとAutoNavの違いは経路計画を行うかどうかである。袋小路の環境では経路計画が必要となるため、AutoNavモードで走行しなければならない。経路計画が必要となる環境は、障害物が多く存在していることが多いため、障害物の量があらかじめ設定した閾値以上となった場合AutoNavモードへ切替える。

一方で、AutoNavからGuardedへの切替えは障害物の量のみで決めることができない。障害物の量のみで判断すると袋小路から完全に抜け出す前にGuardedに切替えてしまい、再び袋小路に入り込んでしまう恐れがあるからである。そのため、AutoNavからGuardedへの切替えは経路計画の際に使用する環境地図から判



図3 モード切替え



図4 Directed—Guarded間のモード切替え




図5 環境地図

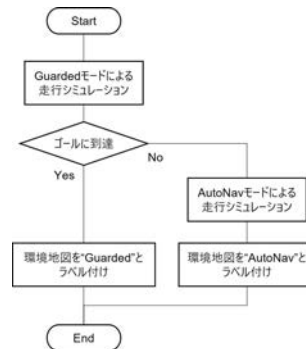


図6 データ収集アルゴリズム

断することとした。環境地図の例を図5に示す。黒色は未知領域、灰色は障害物、白色は走行可能な領域を表す。この環境地図からローバ周囲の環境が袋小路かどうかを判別し、モード切替えを行う。環境マップから袋小路であるかを判別するためには、多種多様なマップを学習することが必要であると考えた。そこで本手法では深層学習を活用することで環境地図から袋小路かどうかを判別する。以下に深層学習の手順を述べる。

3.2.1 データセットの準備

深層学習を行うためには環境地図と対応する行動モードをラベル付けした教師データが必要となる。本研究では図6に示す手順でデータ収集とラベル付けを行った。はじめにGuardedモードのみでスタートからゴールまで走行するシミュレーションを行う。Guardedのみでゴールに到達した場合、周囲の環境は袋小路ではないためマップを”Guarded”とラベリングする。一方、ゴールに到達できなかった場合、袋小路であるためAutoNavモードで再度シミュレーションを行い、その際得られた地図を”AutoNav”とラベリングする。

さらに、学習が正しく行えるように収集したデータの前処理を行った。前処理の手順を図7に示す。前処理では、ローバが地図の中心となるように平行移動し、目的地が上側に来るように回転する。そのうえ、クリップ処理を行った。

以上の手順でデータを収集し、訓練データ 30000、テストデータ 5000 のデータセットを構築した。

3.2.2 学習手法および結果

前項で収集したデータセットを用いて深層学習を行った。4層の畳み込み層と3層の全結合層からなる畳み込みニューラルネットワークを、最適化アルゴリズムAdam [9]によって100エポック分学習した。学習後のテストデータの混同行列を表1に示す。AutoNavに




図7 深層学習のための環境地図の前処理

表1 テストデータの混同行列推論

		推論	
		Guarded	AutoNav
真	Guarded	80.6%	19.4%
	AutoNav	6.92%	93.1%

関しては高い正答率を獲得することができた．一方で Guarded に関しては正答率は高くなく，本来 Guarded であるべきマップを誤って AutoNav と推論することが多かった．AutoNav であるべきマップを Guarded と推論してしまうことは袋小路から抜け出せなくなる恐れがあるため避けなければならない．しかし Guarded であるべきマップを AutoNav と推論することに関しては引き続き問題なく走行を続けることができる．そのため提案手法では以上で学習完了とした．

4. シミュレーション検討

提案手法の有効性を示すためにシミュレーションを行った．以下にその詳細を示す．

4.1 疑似的な探索環境の作成

シミュレーション環境は平面を仮定し，ローバが走行できない障害物領域と走行可能な領域の2種類の地形が存在するとした．本シミュレーションでは9個の疑似環境を用意し，それぞれ障害物占有率に基づき障害物をランダムに配置した．疑似環境の例を図8に示す．黒い領域は障害物を，白い領域は走行可能な領域を表す．疑似環境は格子地図で表現されており，地図の大きさは縦，横ともに100グリッドである．ローバのサイズは1グリッドと同じサイズである．

4.2 評価方法

提案手法の比較対象として BUG Algorithm [10]，Guarded モードのみ，AutoNav モードのみの3種類の手法を用いた．また各アルゴリズムの性能を表す指標として以下の3つを用意した．

- 経路効率 (PE: Path Efficiency)
ローバが走行した距離を表し，小さいほど良い．最適経路との比で表される．

$$PE = \frac{\sum_{i=0}^{i_{end}} \text{distance}(g_i, g_{i-1})}{\text{Optimal Path Distance}} \quad (1)$$

最適経路は経路計画アルゴリズム A* [11] によって求めた．

- 走行時間 (TT: Traveling Time)
ローバが走行するのに要する時間を表し，小さいほど良い．走行距離と単位距離当たりの走行時間の積和で表される．

$$TT = \sum_{i=0}^{i_{end}} \text{distance}(g_i, g_{i-1}) \text{Cost}_M(g_i) \quad (2)$$

$$\text{Cost}_M(g_i) = \begin{cases} 1.0 & \text{if w/o sensing, w/o path planning} \\ 1.2 & \text{if w/ sensing, w/o path planning} \\ 5.0 & \text{if w sensing, w/ path planning} \end{cases} \quad (3)$$

単位距離当たりの走行時間は計算負荷が高いほど大きい値とし，火星探査ローバ Curiosity の走行実績に基づいて設定した [4]．

- 成功率 (SR: Success Rate)
ゴールに到達した割合を表し，大きいほど良い．

$$SR = \frac{\text{Number of Times to Reach the Goal}}{\text{Number of Simulation Times}} \quad (4)$$

4.3 シミュレーションの実施

本稿ではモンテカルロシミュレーションにより従来手法，提案手法における各指標を求めた．モンテカルロシミュレーションではローバがスタートからゴールまで走行するエピソードシミュレーションを各手法，各マップで100回ずつ行った．またエピソードシミュレーションごとにスタートとゴールをランダムに設定しなおした．

4.4 結果

モンテカルロシミュレーションの結果を図9～11に示す．経路効率では障害物占有率が上昇すると効率が下がり，特に BUG Algorithm は大幅に悪化した．一方で，提案手法は AutoNav と同程度であり，ローバが走行しなければならない距離は提案手法を用いても悪




図8 シミュレーション用のマップと障害物占有率




図9 経路効率




図10 走行時間




図11 成功率

化しなかった。走行時間についても同様に、障害物占有率が増加すると走行時間が長くなった。AutoNavは障害物の有無にかかわらず常にセンシング・経路計画を行うため、障害物占有率が低い環境であっても走行時間が長かった。一方、提案手法は障害物が少ない場所ではセンシングおよび経路計画の実行頻度が下がるため走行時間が大幅に短縮し、走行効率向上を実現できた。成功率に関してはGuardedを除いて障害物占有率に関係なく高い成功率であった。このことから提案手法は障害物が多く走行が困難な環境でも有効であることを示せた。

5. まとめ

本論文では周囲環境に合わせた探索ローバナビゲーションの行動モード選択法を提案し、走行効率を向上できることを示した。本方式ではセンシングした情報から周囲の環境を推測しセンシングと経路計画の実施の是非を決定した。センシングは、障害物が全くない場合には頻度を少なくすることで計算処理の低減を達成した。また深層学習によってローカルな環境地図から行き止まりかどうかを判定することで経路計画を行うべきかどうかを判断した。今後はより現実的な環境を想定し、センシングの不確かさや自己位置推定の不

確かさを考慮に入れた行動モード選択法の実現に取り組む。

参考文献

- [1] SW Squires, RE Arvidson, J FIII Bell, J Brückner, NA Cabrol, W Calvin, MH Carr, PR Christensen, BC Clark, L Crumpler, et al. The opportunity rover's athena science investigation at meridiani planum, mars. *science*, Vol. 306, No. 5702, pp. 1698–1703, 2004.
- [2] Mark Maimone, Yang Cheng, and Larry Matthies. Two years of visual odometry on the mars exploration rovers. *Journal of Field Robotics*, Vol. 24, No. 3, pp. 169–186, 2007.
- [3] Joseph Carsten, Arturo Rankin, Dave Ferguson, and Anthony Stentz. Global planning on the mars exploration rovers: Software integration and surface testing. *Journal of Field Robotics*, Vol. 26, No. 4, pp. 337–357, 2009.
- [4] Arturo Rankin, Mark Maimone, Jeffrey Biesiadecki, Nikunj Patel, Dan Levine, and Olivier Toupet. Driving curiosity: Mars rover mobility trends during the first seven years. In *2020 IEEE Aerospace Conference*, pp. 1–19. IEEE, 2020.
- [5] Kyohei Otsu, Guillaume Matheron, Sourish Ghosh, Olivier Toupet, and Masahiro Ono. Fast approximate clearance evaluation for rovers with articulated suspension systems. *Journal of Field Robotics*, Vol. 37, No. 5, pp. 768–785, 2020.
- [6] Jared Strader, Kyohei Otsu, and Ali-akbar Aghamohammadi. Perception-aware autonomous mast motion planning for planetary exploration rovers. *Journal of Field Robotics*, Vol. 37, No. 5, pp. 812–829, 2020.
- [7] Richard Rieber. Autonav: intuitive autonomy on mars and at sea; the mobility system for mars2020. 2018.
- [8] Jeffrey J Biesiadecki, P Chris Leger, and Mark W Maimone. Tradeoffs between directed and autonomous driving on the mars exploration rovers. *The International Journal of Robotics Research*, Vol. 26, No. 1, pp. 91–104, 2007.
- [9] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [10] Vladimir J Lumelsky and Alexander A Stepanov. Path-planning strategies for a point mobile automaton moving amidst unknown obstacles of arbitrary shape. *Algorithmica*, Vol. 2, No. 1, pp. 403–430, 1987.
- [11] Peter E Hart, Nils J Nilsson, and Bertram Raphael. A formal basis for the heuristic determination of minimum cost paths. *IEEE transactions on Systems Science and Cybernetics*, Vol. 4, No. 2, pp. 100–107, 1968.