

確率論理と場所概念モデルの結合による 確率的プランニング

○ 長谷川 翔一 谷口 彰 萩原 良信 エル ハフィ ロトフィ 中島 毅士 谷口 忠大 (立命館大学)

1. はじめに

人と同じ空間で活動するロボットは事前知識に基づいた論理推論を行い、環境から観測データを活用した知識獲得を行いながら、人が指示したタスクを遂行することが望まれる。本研究で述べる事前知識とは、“コーヒーは飲み物というクラスに属する”といった物体の属性、“コーヒーが飲み物であれば、お茶と同じ飲み物のグループである”といった規則、どの場所に物体が配置されることが多いかを表す物体の存在確率を指す。ロボットが事前知識を用いず局所的な観測に依存した行動を計画した場合、しらみつぶしに環境内を探索する必要があるため、環境に素早く適応することが難しい [1]。一方で Paulius らは、“事前知識を活用した論理的な推論によりロボットの取るべき行動を選択し、不確実性を考慮するために環境からの観測データを併用することはタスクの効率を高めることができる”と述べている [2]。そのためロボットが事前知識に基づく論理推論と観測データからの知識獲得を組み合わせることは、家庭環境におけるタスクの即時実行に期待できる。

ここで“人が家庭内にある物体の場所を探すタスク”を考えると、人は探す対象物が存在する場所を知らない場合でも、“コーヒーは飲み物で、飲み物は冷蔵庫に保管されるため、冷蔵庫にあるのではないか？”と論理的に推論できる。また、“コーヒーは父が飲むことが多いので、父の部屋にあるのではないか？”とも推論できる。上記のような論理推論から得た“コーヒーが存在する可能性が高い場所”から順番に探索行動を選択し、対象物を発見したときに物体の場所に関する知識を更新することができる。我々は人がこのようなプロセスを生活の中で自然に行っていると考えており、ロボットに人の思考プロセスを取り入れることはタスク遂行のために有用だと考えられる。

ロボットが家庭環境内における物体の場所に関する知識獲得を行う研究では、Furuta らは長期間にわたりロボットが環境を観測して得られた物体の位置とラベルを利用し、物体が存在しやすい位置をクラスタリングすることで、確率的物体配置地図を生成した [3]。しかしながらこの手法は、41 日間にわたる長期的な観測データに基づき物体の場所に関する知識獲得が行われているため、ロボットが素早く環境に適応することは難しい。一方で Veiga らはロボットに物体の場所に関する知識獲得を行わせるために、ロボットに意味理解を可能にする地図表現を獲得させる Semantic Mapping [4] と述語論理に確率を付与した確率論理 [5] を組み合わせた [6]。またこの研究では、ロボットが持つ物体の存在する場所に関する信念状態と完全な信念状態の差をヘリンガー距離で表現し、目的地までの移動ごとのヘリンガー距離の遷移を定性的に

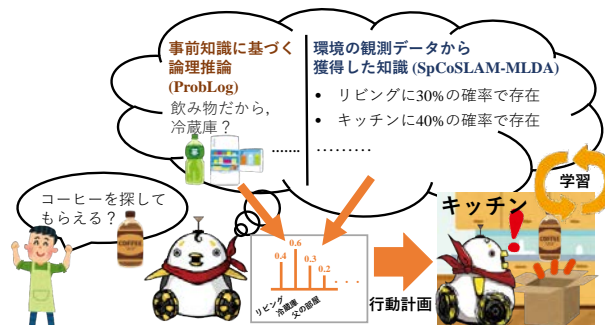


図1 提案手法の概要図

評価している。しかしながら評価には Veiga らが提案したモデルの評価のみを行っているため、環境からの観測データのみの手法と比較したときに、どのくらい効率的に物体の存在する場所の知識獲得を行うことができるかは不明である。

本研究ではロボットが物体探索タスクを遂行するために、各環境における物体が存在する場所の知識をロボットが効率的に獲得することを研究目的とする。そこで我々は Veiga らが行った研究 [6] のアプローチに着目し、確率的論理型プログラミング言語の ProbLog [5]、SLAM (Simultaneous Localization and Mapping)・マルチモーダル情報に基づく場所概念獲得を同時行う SpCoSLAM [7]、同じくマルチモーダル情報に基づく物体概念獲得の MLDA を組み合わせた手法を提案する。そしてロボットの探索場所への移動回数や移動距離を検証することで、提案手法の有用性を示す。

2. 提案手法

本研究では下記の3点を組み合わせたモデルを提案し、図1に提案する手法の概要図を示す。

- 確率的論理型プログラミング言語の ProbLog [5]
- SLAM と位置・単語・画像のマルチモーダル情報に基づく場所概念獲得を同時に行う SpCoSLAM [7]
- 物体の画像・単語のマルチモーダル情報に基づく物体概念モデルの MLDA [8]

SpCoSLAM と MLDA に関しては一つの確率的生成モデルで結合させており、以降、このモデルを SpCoSLAM-MLDA と呼ぶ。

また提案手法による学習の流れを図2に示す。はじめに Step1 と Step2 では、ロボットは人から物体探索を指示されたときに、人の発話文に含まれる物体の単語から提案手法を用いて、物体が存在する場所の確率を計算する。次に Step3 のときに、マルチモーダル情報から構成

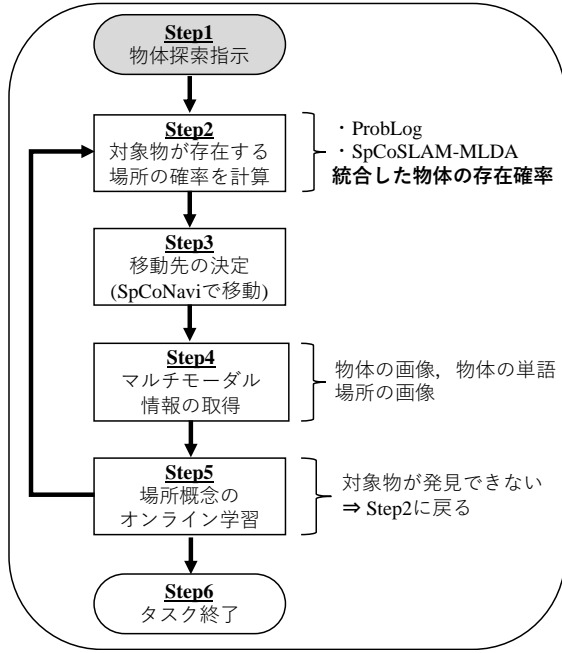


図2 提案手法による学習の流れ

される場所概念を用いてナビゲーションをすることが可能な SpCoNavi[9] を用いて、目的地までの経路計画を行う。そして Step4 において、物体検出器により物体を検出することができれば、ロボットは“これは～ですか”と人に探索対象の物体かを尋ね、Step5 で人から返答された発話文・物体の画像・場所の画像をもとに場所概念形成を行う。最後に探索対象物の物体であればタスクを終了 (Step6) し、それ以外であれば Step2 に戻り、対象物を発見するまで繰り返す。

2.1 SpCoSLAM-MLDA

図3に SpCoSLAM と MLDA を組み合わせたグラフィカルモデル、各変数の定義を表1に示す。図3のグラフィカルモデルは、青色、黄色、橙色、緑色のモジュールから構成されている。青色のモジュールは、SLAM を表す。ここでは、ロボットの制御とレーザセンサから得られる計測をもとに自己位置を推定する。次に黄色のモジュールは Gaussian Mixture Model (GMM) を表し、場所概念の空間領域をガウス分布により表現する。橙色のモジュールは場所のカテゴリゼーションを表し、場所の位置情報・場所の単語情報・場所の画像情報・物体概念 index から場所のカテゴリゼーションを行う。最後に、緑色のモジュールは物体のカテゴリゼーションを表し、物体の画像情報と物体の単語情報から物体のカテゴリゼーションを行う。SpCoSLAM は青色・黄色・橙色のモジュール、MLDA は緑色のモジュールに該当する。

SpCoSLAM-MLDA の学習では、MLDA と SpCoSLAM の学習を個別に行う。具体的には、MLDA 単体で物体概念パラメータの学習後、学習したパラメータを固定した状態で SpCoSLAM の場所概念パラメータの学習を行う。

また既存の SpCoSLAM と MLDA から変更した部分

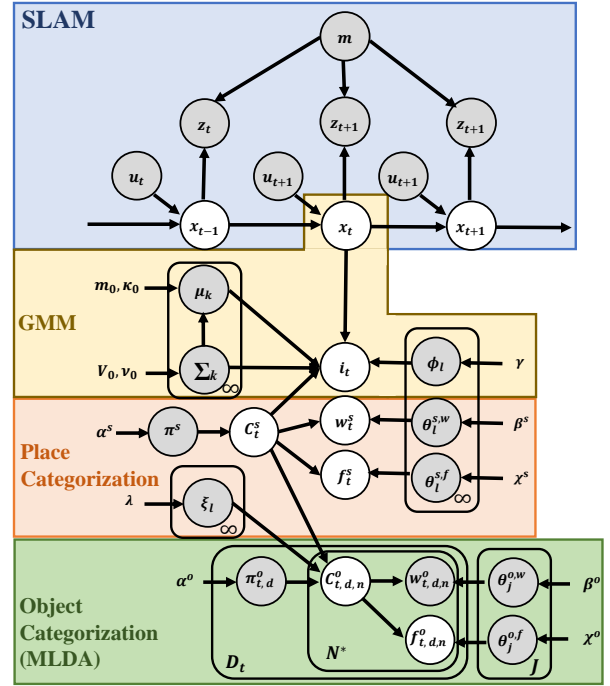


図3 SpCoSLAM-MLDA のグラフィカルモデル

の SpCoSLAM-MLDA の生成過程を式 (1)～(3) に示す。具体的な変更点としては、既存の SpCoSLAM では人の音声発話命令からテキストの文章に変換し、単語分割を行っていた。本研究では人からの発話命令はテキストでロボットに与え、単語の頻度情報を表す Bag-of-Words 表現に変換している。本研究では人の音声信号処理は想定していないため、このような変更を行っている。また地図は既知としている。ここで、 $\text{Cat}(\cdot)$ はカテゴリカル分布、 $\text{Mult}(\cdot)$ は多項分布、 $\text{Dir}(\cdot)$ はディリクレ分布を表す。

$$w_t^s \sim \text{Mult}(\theta_t^{s,w}) \quad (1)$$

$$\xi_t \sim \text{Dir}(\lambda) \quad (2)$$

$$C_{t,d,n}^o \sim P(C_{t,d,n}^o | \xi_{C_t^s}, \pi_{t,d}^o) \quad (3)$$

また、 $C_{t,d,n}^o$ は以下の式 (4) で定義する。

$$P(C_{t,d,n}^o | \xi_{C_t^s}, \pi_{t,d}^o) = \frac{\text{Cat}(C_{t,d,n}^o | \xi_{C_t^s}) \text{Cat}(C_{t,d,n}^o | \pi_{t,d}^o)}{\sum_{C_{t,d,n}^o = b} \text{Cat}(b | \xi_{C_t^s}) \text{Cat}(b | \pi_{t,d}^o)} \quad (4)$$

2.2 ProbLog

物体の存在確率を確率論理により推論するために、単語同士の関係を確率的に記述することができる確率的論理型プログラミング言語の ProbLog (Probabilistic Logic Programming) [5] を使用する。物体の存在確率は、“ボトルがキッチンに 30 % の確率で存在する”であれば、“0.3::exist(bottle, kitchen)”と記述できる。本研究では、ProbLog と SpCoSLAM-MLDA を組み合わせることで、物体が存在する場所の確率を計算する。

表1 グラフィカルモデルの各変数定義

m	環境地図
x_t	ロボットの自己位置情報
z_t	深度センサの観測情報
u_t	モータの制御情報
C_t^*	カテゴリ index
i_t	位置分布 index
w_t^*	単語情報
f_t^*	画像情報
μ, Σ	位置分布 (平均ベクトル, 共分散行列)
π_t^o	物体概念 index の 多項分布のパラメータ
π^s	場所概念 index の 多項分布のパラメータ
ϕ	位置分布 index のための 多項分布のパラメータ
ξ	場所概念 index のときに 物体概念 index を生成するための 多項分布のパラメータ
$\theta^{*,w}$	単語情報のための 多項分布のパラメータ
$\theta^{*,f}$	画像情報のための 多項分布のパラメータ
$\alpha^*, \beta^*, \chi^*$	事前分布のハイパーパラメータ
$\gamma, \lambda, m_0, \kappa_0, V_0, \nu_0$	
D_t	時刻 t で観測される物体の総数
N^*	各モダリティごとの特徴の次元数
J	物体のカテゴリ数

2.3 統合した物体の存在確率

ProbLog により推論した物体の存在確率と SpCoSLAM-MLDA から推論した物体の存在確率を統合するために、本研究では以下の式 (5) を用いる。

$$P_{com} = \eta P(w_t^s | w_t^o) + (1 - \eta) P_G \quad (5)$$

ここで P_{com} は ProbLog と SpCoSLAM-MLDA から推論した確率を統合した物体の存在確率、 η は重みパラメータであり 0 ~ 1 の値がヒューリスティックに与えられる。 $P(w_t^s | w_t^o)$ は SpCoSLAM-MLDA によって人の発話文に含まれる物体の単語から場所の単語を推論した条件付き確率である。 P_G は ProbLog によって論理推論した際に出力される確率を示している。本研究では式 (5) で統合された物体の存在確率から対象物が存在する場所の単語を選択し、ロボットは選択された場所の単語に該当する場所領域で探索を行う。

3. 実験

本研究では、ロボットが環境からの観測情報のみで知識獲得を行う手法に、事前知識に基づく論理推論を組み込むことで、物体の存在場所の知識獲得を効率的に行えるか検証することを実験目的とする。

実験は事前知識に基づく論理推論が与える影響を検証するために、2 種類の実験を行った。実験 1 は ProbLog




図4 実験環境

を用いることで物体探索の影響を検証した。具体的には人からの物体探索の命令後、ロボットは一度の場所領域の訪問で対象物を発見できるかを調査した。実験 1 では、場所概念と物体概念のパラメータ、ProbLog に定義される物体の存在確率の更新はしないものとした。実験 2 では、ProbLog を用いることで、対象物の存在確率の更新に与える影響を検証した。具体的には人からの物体探索の命令後、ロボットが対象物を発見する移動回数を調査した。実験 2 では、物体概念と場所概念パラメータの更新は行いが、ProbLog に定義される物体の存在確率の更新はしないものとした。

3.1 実験条件

本実験では Gazebo を用いたシミュレーション環境で実験を行い、1 種類の環境で実施した。環境内に配置する物体は 9 種類の物体を使用し、ロボットは Turtlebot3 Waffle Pi を用いた (図 4)。また、物体検出器は YOLOv3 [10] を用いた。実験前準備として、ロボットは事前に地図は取得済みであること、MLDA による物体概念パラメータと SpCoSLAM-MLDA による場所概念パラメータは事前に学習済み、YOLOv3 が検出できる物体は訓練済みであることとした。次に ProbLog が持つ事前知識に関しては、表 2 に事前知識の例とそれに対応する ProbLog における表現を示し、実験では表 2 のように事前知識を定義した。ProbLog はこれらの知識を使用して論理推論を行った。物体の配置方法は、物体概念と場所概念の事前学習終了後、学習を行った場所領域に人手で物体を配置した。また、MLDA のギブスサンプリングのイテレーション数は 100 回とし、物体カテゴリ数は 3、 $\alpha^o = 1.0$ 、 $\beta^o = 1.0$ 、 $\chi^o = 1.0$ と設定した。SpCoSLAM-MLDA 側のパラメータは、場所カテゴリ数は 4、ハイパーパラメータは SpCoSLAM [7] で使用した値を用いた。

3.2 検証手法

本研究では下記の手法を評価項目に従い比較を行った。

- 提案手法：SpCoSLAM-MLDA + ProbLog
- 比較手法：SpCoSLAM-MLDA

3.3 評価項目

比較手法に比べて提案手法の方が効率的に物体が存在する場所を学習できるかを検証するために、評価項目は以下の 6 項目を用いた。

表 2 ProbLog で使用する事前知識の例

物体の属性	doll (rabbit_doll) ウサギのぬいぐるみはぬいぐるみである
述語間の関係	same_group (X, rabbit_doll):- doll (X) 任意 X がぬいぐるみであれば, X はウサギのぬいぐるみと同じグループである
確率的な規則	0.4 :: exist (rabbit_doll, living) ウサギのぬいぐるみは 40%の確率でリビングに存在する

- ロボットが対象物を探索する際に, 最初に訪問した場所で発見できた回数
- ロボットが対象物を発見するまでの総移動回数
- ロボットが対象物を発見するまでの総移動距離
- 総移動回数の中で, 最初に訪問した場所で発見できた割合
- 総移動回数の中で, 対象物が存在する場所に移動できた割合
- ロボットが対象物を選択する際に, 対象物を正しく選択できた割合

3.4 実験結果

実験 1 及び実験 2 の結果は口頭発表にて報告する.

4. おわりに

本研究ではロボットが物体探索タスクを遂行するために, 各環境における物体が存在する場所の知識をロボットが効率的に獲得することが可能な手法を提案した. 具体的には, 確率的論理型プログラミング言語の ProbLog, 場所概念獲得モデルの SpCoSLAM, 物体概念獲得モデル MLDA を結合することにより構築した. また提案手法の有効性について実験を通して検証した.

謝 辞

本研究は JST【Moonshot R&D – MILLENNIA Program】課題番号 JPMJMS2011-44, JSPS KAKENHI JP20K19900 の一部支援を受けた.

参 考 文 献

- [1] Y. Zhang, G. Tian, L. Jiaying, M. Zhang, and S. Zhang, “Efficient Dynamic Object Search in Home Environment by Mobile Robot: A Priori Knowledge-Based Approach,” *IEEE Transactions on Vehicular Technology*, vol. 68, no. 10, pp. 9466–9477, 2019.
- [2] D. Paulius and Y. Sun, “A Survey of Knowledge Representation in Service Robotics,” *Robotics and Autonomous Systems*, vol. 118, pp. 13–30, 2019.
- [3] Y. Furuta, K. Okada, Y. Kakiuchi, and M. Inaba, “An Everyday Robotic System that Maintains Local Rules using Semantic Map based on Long-term Episodic Memory,” in *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Spain, 2018.
- [4] L. Kostavelis and A. Gasteratos, “Semantic mapping for mobile robotics tasks: A survey,” *Robotics and Autonomous Systems*, vol. 66, pp. 86–103, 2015.
- [5] L. De Raedt, A. Kimmig, and H. Toivonen, “ProbLog: A Probabilistic Prolog and Its Application in Link Discovery,” in *International Joint Conference on Artificial Intelligence (IJCAI)*, India, 2007.
- [6] S. T. Veiga, M. Silva, R. Ventura, and U. P. Lima, “A Hierarchical Approach to Active Semantic Mapping Using Probabilistic Logic and Information Reward POMDPs,” in *International Conference on Automated Planning and Scheduling (ICAPS)*, USA, 2019.
- [7] A. Taniguchi, Y. Hagiwara, T. Taniguchi, and T. Inamura, “Improved and scalable online learning of spatial concepts and language models with mapping,” *Autonomous Robots*, vol. 44, pp. 927–946, 2020.
- [8] T. Nakamura, T. Araki, T. Nagai, and N. Iwahashi, “Grounding of word meanings in latent dirichlet allocation-based multimodal concepts,” *Advanced Robotics*, vol. 25, no. 17, pp. 2189–2206, 2011.
- [9] A. Taniguchi, Y. Hagiwara, T. Taniguchi, and T. Inamura, “Spatial Concept-Based Navigation with Human Speech Instructions via Probabilistic Inference on Bayesian Generative Model,” *Advanced Robotics*, vol. 34, no. 19, pp. 1213–1228, 2020.
- [10] J. Redmon and A. Farhadi, “YOLOv3: An Incremental Improvement,” 2018, arXivpreprint arXiv:1804.02767.