

柔軟接触センサを搭載したロボットハンドを用いたアクティブセンシングによる物体認識

○徳野将士（九州工業大学） 田中悠一朗（九州工業大学） 川節拓実（大阪大学）
細田耕（大阪大学） 田向権（九州工業大学）

1. はじめに

近年、少子高齢化社会による労働人口の減少が問題となっている。この問題を解決するため、人の負担を減らしてくれるホームサービスロボットが注目されている [1]。ホームサービスロボットは家庭内で人に頼まれたものを持って来たり、床に散らばったものを片付けたりするロボットである。

ホームサービスロボットに求められる機能を実現するためには物体認識システムが必要である。一般的に物体認識はカメラから取得した視覚情報を処理することで実現されるが、認識結果が照明の色などの周囲の環境に左右されたり、類似する見た目の物体を誤認識するという問題点がある。そのため、カメラから得られる視覚情報以外の情報を加えた認識が必要である。そこで、本研究は生物を模倣した物体認識システムを考案する。例えば、人間は見た目が全く同じものでも、それに触れてみることで、その硬さや重さといった特徴を捉えながら物を判別することができる。本研究は人間の柔らかい皮膚を模倣し、柔らかいセンサから得られる触覚情報を用いた物体認識システムを考える。

一方、触覚を使う問題として、同じものでも把持する箇所によって硬さや形状の違いが存在することが挙げられる。Fig. 1 に接触センサを搭載したロボットハンドを使い、直方体のブロックを一度把持したときの時系列データの変化を示す。それぞれの時系列データはブロックの向きを変えて取得した。Fig. 1 に示すように、同じ物体でも把持する箇所によって接触センサの値は変化する。よって、一つの物体を学習するために、様々な箇所の触覚情報を取得しなければならず、学習データが増大する。そこで、人が触覚に基づいて物体を認識する場合、様々な方向から何度も触り物体を判断することを模倣して、本研究はロボットに把持する箇所を探索させ、学習したことがある物体の把持箇所を見つけるアプローチをとる。




図 1: Example of tactile data




図 2: Structure and working principle of the flexible tactile sensor

2. 柔軟接触センサ

本研究では、Hamaguchi ら [2] が提案する柔軟接触センサを用いる。Fig. 2 に柔軟接触センサの構造と動作原理を示す。このセンサはシリコンゴムと液体金属、回路基板に印刷されたコイルからなるセンサである。円形状の液だまりである接触リザーバー（Contact reservoir）に力が加わるとセンサ内の液体金属が半円状の液だまりである検出リザーバー（Detection reservoir）に流れる。そうすると検出リザーバーが膨張し、検出リザーバーの下に配置されているコイルのインダクタンスが電磁誘導により変化する。この変化を測定することでセンサに加わった接触力を推定することができる。

3. 触覚情報を用いたアクティブセンシングによる物体認識システム

提案するシステムの構成図を Fig. 3 に示す。このシステムは柔軟接触センサを搭載したロボットハンドから得た触覚情報を Echo State Network (ESN) [3] に与えて物体認識を行うシステム（Object recognition part）[4, 5] とアクティブセンシングによってロボットの記憶にある触覚情報を取得する把持箇所を探索するシステム（Memory-and-search part）に分かれている。

ESN は Reservoir Computing (RC) [6] の一種であり、RC は時系列データの扱いに特化した Recurrent Neural Network (RNN) の一種である。ESN は非線形の活性化関数を持ち、入力層、レザー層、出力層の三層で構成される。ESN は出力層の結合荷重のみを更新するため、すべての結合荷重を更新する RNN に比べ計算コストが低いという特徴がある。

Object recognition part は触覚情報を入力し、それに応じて認識結果を出力する ESN で実装する。また、Memory-and-search part は物体を特定の掴み方で把持したときの触覚情報を記憶する ESN（オートエンコーダレザー層、Autoencoder reservoir）を備える。このオートエンコーダレザー層を用いて、ある掴み方によって得られた触覚情報が記憶にあるかどうかに基づいて

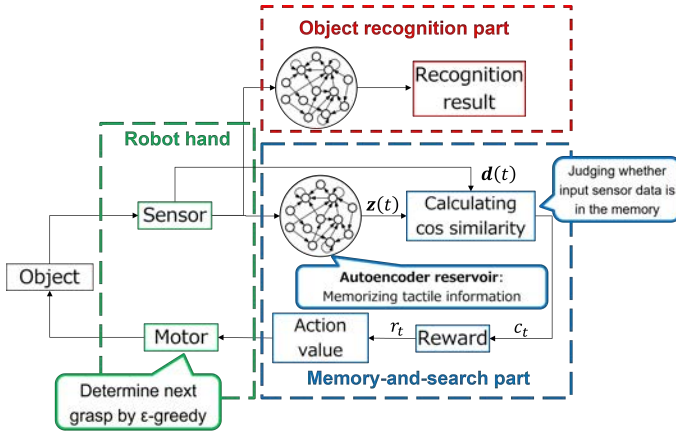



図 3: Object recognition system by active sensing



(a) Training data (b) Not training data

図 4: Autoencoder reservoir's input and output

報酬を与える強化学習を行い、学習した把持箇所の推定を行う。

3.1 ESN による物体認識

ここでは、ESN による把持物体の認識方法について説明する。学習モードでは物体を把持したときの時系列データを ESN に入力し、リッジ回帰により、出力層の結合荷重を算出する。このとき、教師データは正解ラベルを 1 とする one-hot ベクトルとする。推論モードでは時系列データを学習済みの ESN に入力し、その出力を確認する。各把持物体の ESN の出力の時間平均を把持物体の推定尤度とする。

3.2 オートエンコーダレザバーの学習

まず、特定の 1 方向から物体を把持したときの時系列データをオートエンコーダレザバーに入力する。すべての時系列データを入力し終わったらリッジ回帰によって出力層の結合荷重を更新する。このとき、教師データとして、入力データを 1 時刻分遅らせたものを使用する。学習する際は学習データにオーバーフィッティングさせるようにリッジ回帰のハイパーパラメータを調整する。Fig. 4 にオートエンコーダレザバーの入力データと出力データの例を示す。Fig. 4a のように学習したデータを入力した場合、入力データを想起するようなデータが出力され、Fig. 4b のように未学習のデータを入力した場合、入力データを想起できない。ここで生じる入力データと出力データの違いによってロボットが記憶した把持方向かどうか判断する。本研究では、入力データとオートエンコーダレザバーから出力されるデータの cos 類似度 c_t を求めることによって記憶し




図 5: Histogram of cos similarity c_t

ている把持方向か判断する。式 1 に cos 類似度を求める式を示す。

$$c_t = \frac{z(t)}{\|z(t)\|} \cdot \frac{d(t)}{\|d(t)\|} \quad (1)$$

ここで、 $z(t)$ はオートエンコーダレザバーからの出力、 $d(t)$ は入力データを 1 時刻分遅らせたものとする。Fig. 5 に学習した把持方向のデータとその他の把持方向のデータをオートエンコーダレザバーに入力し、出力されたデータとの cos 類似度のヒストグラムを示す。Fig. 5 に示すように学習した方向のデータを表す青色のヒストグラムは cos 類似度が相対的に高い領域に分布し、そのほかのデータを表すオレンジ色のヒストグラムは cos 類似度が相対的に低い領域に分布する。

3.3 アクティブセンシングによる把持箇所の探索

ここでは、強化学習によるアクティブセンシングによってロボットの記憶にある把持方向を探索する方法について説明する。探索を行う前に 3.2 節による方法によって、オートエンコーダレザバーを学習しておく。まず、ロボットハンドを動かし、物体を把持したときの時系列データを取得する。次に、オートエンコーダレザバーに時系列データを入力し、オートエンコーダレザバーからの出力と入力データを 1 時刻分ずらしたものの cos 類似度を求める。ここで、求めた cos 類似度を正規化したものを、その行動に対する報酬とする。式 2 に cos 類似度を正規化する式を示す。

$$r_t = \tanh\left(\frac{c_t - c_{TH}}{\beta}\right) \quad (2)$$

ここで、 c_{TH} 、 β は報酬を調整するパラメータである。実験の結果、記憶にある掴み方をした場合、cos 類似度は概ね 0.91 を超え、それ以外の掴み方をした場合は 0.89 を下回った。 $c_{TH} = 0.9$ 、 $\beta = 0.01$ としたとき、cos 類似度が 0.91 の場合、報酬はおよそ 0.76、cos 類似度が 0.89 の場合、報酬はおよそ -0.76 となり、報酬の正負を適切に設定できる。求めた報酬を基に反復法により行動価値を更新する。式 3 に行動価値を更新する式を示す。

$$v(a_t) \leftarrow v(a_t) + \sigma(r_t - v(a_t)) \quad (3)$$

ここで、 a_t は時刻 t の行動、 $v(a_t)$ は行動 a_t の行動価値、 σ は学習率を示す。学習の初期は探索を行い、学習が進むにつれて、行動価値の高い行動を選択させるように、探索確率 ϵ を単調減少させていく ϵ -グリーディ方策をとる。これらを繰り返して、学習した把持方向



(a) Full picture of the robot hand



(b) Front of the robot hand

図 6: Flexible tactile sensor on the robot hand



(a) Sponge



(b) Block


図 7: Grasping objects in the experiments

の探索を行う。この手法を用いることで、一方向からの学習だけで、様々な向きに置かれた物体認識にも対応でき、ロボットが学習していない掴み方による誤認識を防ぐことができる。


4. 実験

本実験では、トヨタ自動車株式会社の HSR (Human Support Robot) [1] のロボットハンドに 2. 章の柔軟接触センサを搭載して実験を行った。Fig. 6 に HSR のロボットハンドに搭載したときの柔軟接触センサを示す。ESN に入力する時系列データはロボットハンドに搭載した二つの柔軟接触センサのセンサ値、ロボットハンドの開閉角度とする。

Fig. 7 に示す同じ大きさや形状の物体 (Sponge, Block) を用いて、把持物体の認識実験を行った。学習は特定の 1 方向から把持したときの時系列データを取得して行う。テストを行う時は物体を任意の角度で再配置し、学習した把持方向をロボットに探索させる。Fig. 8 に各物体の学習した把持面を示す。ここでは、Fig. 9 に示すように探索のためのロボットハンドの行動 (Action 1, Action 2, Action 3) を 3 種類用意し、Action 1 を行ったときに学習した面に触れるように物体を配置したとき (Situation 1) と、Action 2 と Action 3 を行ったときに学習した面に触れるように物体を配置したとき (Situation 2) の 2 つの状況で実験した。各状況において、ロボットに行動選択を 15 回試行させ、行動価値の変化と試行毎の行動と認識結果を調べた。Situation 1 の行動価値の変化を Fig. 10, その時の試行毎の行動と認識結果を Table 1, Situation 2 の行動価値の変化を Fig. 11, その時の試行毎の行動と認識結果を Table 2 に示す。Fig. 10a と Table 1a のように、Action 1 を行ったときに行動価値が上昇し、他の行動価値が減少している。そして、試行回数が増えるに連れて行動価値が上がった Action 1 が選択されるようになった。他の条件でも同様に試行回数が増えるにつれて、学習した面を把持する行動価値が大きくなりその行動が選択されるようになった。また、学習した面を把持する行動を行った際に、正しい認識結果を得られた。



Grasping surface




Grasping surface

(a) Sponge's grasping surface

(b) Block's grasping surface


図 8: Grasping surface



(a) Situation 1

(b) Situation 2


図 9: Grasping action and situation



(a) Grasping the sponge

(b) Grasping the block

図 10: Action value's change in Situation 1



(a) Grasping the sponge

(b) Grasping the block

図 11: Action value's change in Situation 2

5. おわりに

本研究ではアクティブセンシングによる物体認識システムについて提案した。このシステムは時系列データの処理に特化する ESN を用いて、特定の 1 方向から把持したときの触覚の時系列データのみを学習し、アクティブセンシングによって学習した把持方向の探索を行った。このシステムを導入することで特定の方向から把持した場合のデータのみで学習が可能になる。今回の実験で使用したような直方体の物体の面をすべて学習する場合、3 方向から把持したときのデータを取得しなければならないが、1 方向から把持したときのデータのみで学習できるため、学習量を 1/3 に削減することができる。

今後の課題は、家庭内等で起こりうるロボットハンドを用いたタスクへ応用することである。例えば、未

表 1: Selected action and recognition result in Situation 1

(a) Grasping sponge

Trial	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Action	1	2	3	1	1	2	3	1	3	1	1	1	1	1	2
Result	sponge	block	block	sponge	sponge	sponge	block	sponge	block	sponge	sponge	sponge	sponge	sponge	sponge

(b) Grasping block

Trail	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Action	1	2	3	2	3	2	3	1	2	3	1	1	1	2	1
Result	block	block	block	block	block	block	block	block	block	block	block	block	block	block	block

表 2: Selected action and recognition result in Situation 2

(a) Grasping sponge

Trial	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Action	1	2	3	3	2	3	3	2	3	2	1	2	3	3	2
Result	sponge	sponge	sponge	block	sponge	sponge	block	sponge	sponge	sponge	block	sponge	block	sponge	sponge

(b) Grasping block

Trial	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Action	1	2	3	2	2	1	1	3	2	2	1	1	1	2	2
Result	block	block	block	block	block	block	block	block	block	block	block	block	block	block	block

知のドアを開けるというタスクの場合、ドアノブを回す方向を考えたり、ドアを押すか引くかなどの判断をロボットがしなければならない。しかし、このタスクでは新しい行動パターンの生成が必要になるため、今回の実験のように予め定義された動作からの行動選択では解決が困難である。そこで、ロボットハンドを制御するモータコマンドを直接生成するレザバーを追加し、Q学習[7]によって最適なモータコマンドの獲得方法を考える。ESNを用いたQ学習はInadaら[8]が提案しており、これを活用することを検討する。

謝 辞 この成果は、国立研究開発法人新エネルギー・産業技術総合開発機構 (NEDO) の委託業務 (JPNP16007) の結果得られたものです。

参 考 文 献

- [1] T. Yamamoto, Y. Takagi, A. Ochiai, K. Iwamoto, Y. Itozawa, Y. Asahara, Y. Yokochi, and K. Ikeda: "Human Support Robot as Research Platform of Domestic Mobile manipulator", ROBOMECH journal, vol. 6, no. 1, pp.457-465, 2019.
- [2] S. Hamaguchi, T. Kawasetsu, T. Horii, H. Ishihara, R. Niiyama, K. Hosoda, and M. Asada: "Soft Inductive Tactile Sensor Using Flow-Channel Enclosing Liquid Metal", IEEE Robotics and Automation Letters, vol. 5, no. 3, pp. 4028-4034, 2020.
- [3] H. Jaeger: "The "echo state" approach to analysing and training recurrent neural networks-with an Erratum not", Bonn, Germany: German National Research Center for Information Technology GMD Technical Report, vol. 148, no. 34, 2001.
- [4] 徳野 将士, 田中 悠一朗, 川節 拓実, 細田 耕, 田向 権: "柔軟接触センサを搭載したロボットハンドによる触覚情

報からの物体認識", 第 38 回日本ロボット学会学術講演会, 3E1-04, 2020.

- [5] S. Tokuno, Y. Tanaka, T. Kawasetsu, K. Hosoda, and H. Tamukoh: "Object Recognition Using Flexible Tactile Sensor", Asia Pacific Conference on Robot IoT System Development and Platform 2020, 2020.
- [6] M. Lukoševičius and H. Jaeger: "Reservoir computing approaches to recurrent neural network training", Computer Science Review, vol. 3, no. 3, pp. 127-149, 2009.
- [7] C. J. C. H. Watkins and P. Dayan: "Q-Learning", Machine Learning, vol. 8, no. 3, pp.279-292, 1992.
- [8] M. Inada, Y. Tanaka, H. Tamukoh, K. Tateno, T. Morie, and Y. Katori: "A Reservoir Based Q-learning Model for Autonomous Mobile Robots", 2020 International Symposium on Nonlinear Theory and Its Applications, pp. 213-216, 2020.