

中間知覚と LSTM によるロボットの動的障害物回避動作計画

○星野智史 (宇都宮大学) 吉田遊友 (宇都宮大学)

1. 序論

ロボットの自律移動に向けては、障害物を回避するための動作計画は重要な技術となる。従来、モデルベースの動作計画法では、センサにより対象となる障害物の位置を計測し、計測値を入力とした回避が行われてきた。動的障害物に対して、著者らは Velocity Obstacle や人工ポテンシャル法に基づく動作計画法を提案した [1] [2]。しかしながら、動作計画器への入力として、位置に加え障害物の動きに関する計測も必要となる。

一方、モデルの代わりに深層ニューラルネットワークを用いた End-to-End な動作計画法 [3] も提案されている。この動作計画では、深層学習 [4] により、センサ入力に対する動作出力の関係が対応付けられる。その結果、障害物の位置や動きに関する計測が不要となり、例えばカメラ画像を入力に、画像中の障害物を回避するための動作を出力することができる。

画像入力に対する End-to-End な動作計画には、行動反射 (Behavior reflex) と中間知覚 (Mediated perception) の 2 つのアプローチがある [5]。著者らは従来研究にて、RGB-D 画像を入力とした行動反射型の動作計画法 [6] や、画像中の障害物の存在を知覚し、この中間知覚画像を入力とした動作計画法 [7] を提案した。これによりロボットは、特定の静的障害物に対する回避動作の教示ならびに模倣学習を通じて、その他の未教示障害物に対しても、同様に障害物と知覚し回避に成功した。

本研究では、静的な障害物に加え、歩行者のような動的障害物をも対象とする。そのためロボットは、まず、これらが異なる障害物であると知覚できなくてはならない。さらに、動的障害物に対して回避動作を計画するためには、入力画像上での障害物の時系列的な変化を考慮できなくてはならない。そこで、CNN [8] に LSTM [9] を適用した動作計画器を提案し、模倣学習により構築された本動作計画器の有効性について論じる。

2. 動作計画器

本研究では、ロボットが、動的障害物の時系列的な変化に応じた回避動作を計画することに焦点をあてる。そのため、従来研究 [7] にて提案した CNN に基づく動作計画器に LSTM ブロックを追加する。図 1 に、提案する動作計画器の概要を示す。

ロボットには、RGB-D カメラが搭載されているものとする。カメラから得られた RGB-D 画像 I_{RGB-D} は、RGB 画像 I_{RGB} と深度画像 I_D に分けられる。 I_{RGB} は物体検出器へ入力され、静的障害物と動的障害物の 2 クラスに分類される。この分類結果に基づき、中間知覚画像 I_P が生成される。そして、 I_P と I_D がそれぞれの CNN に入力され、畳み込みとプーリング、全結合層を経て速度 v_t と角速度 ω_t が出力される。途中、全結




図 1 End-to-End motion planner based on CNN with LSTM

合層にて 1 ステップ前の速度 v_{t-1} と角速度 ω_{t-1} 、さらに目的地方向 ϕ_G が入力される。速度と角速度入力の後には、LSTM ブロックが適用される。LSTM ブロックでは、入力、忘却、出力の 3 つのゲートならびに記録セルにより、過去から現在までの入出力値を保持や忘却することができる。これにより、画像中の障害物の時系列的な写り方の変化を考慮した動作計画を行う。

3. 中間知覚

2. 章で述べたように、本動作計画器ではまず、入力画像に対する中間知覚が行われる。そのため、図 1 における物体検出器は、RGB 画像 I_{RGB} を入力に、物体を囲うバウンディングボックスならびに、静的か動的かの 2 クラスの分類結果を出力する。そして、分類結果に応じた色でバウンディングボックスを塗りつぶし、それ以外を黒色で塗りつぶすことで中間知覚画像が生成される。これにより、ロボットは画像中のどこに静的あるいは動的障害物が存在するか知覚することができる。図 2 に、静的障害物と動的障害物の写った I_{RGB} から生成された中間知覚画像 I_P 、RGB-D 画像から分けられた深度画像 I_D を示す。

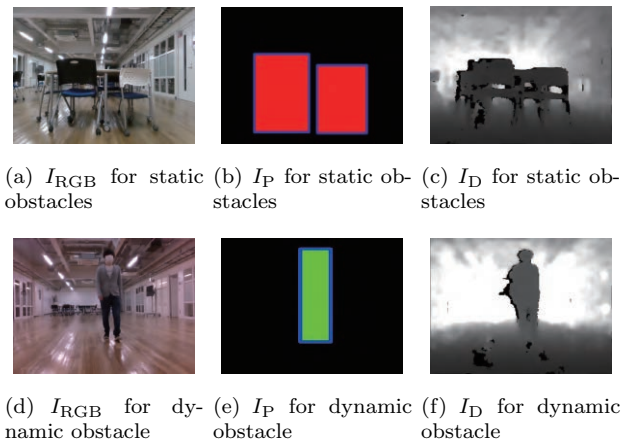


図 2 Input images through mediated perception

図 2(a)～図 2(c) は、テーブルと椅子の写った RGB

画像、中間知覚画像、深度画像である。図 2(b) の中間知覚画像では、2つの椅子が検出され、静的障害物として赤色で塗りつぶされている。図 2(d)～図 2(f) では、人物が検出され、図 2(e) にて、動的障害物として緑色で塗りつぶされている。

検出器が認識できる物体は、全て静的か動的障害物に分類されることとなる。これにより、障害物ごとに回避動作を教示せずとも、ある種類の静的障害物と動的障害物に対する回避動作の教示で十分となる。なお、本研究では YOLOv2 [10] を物体検出器として用いる。さらに、RGB 画像ではなく、図 2(b) や図 2(e) の中間知覚画像を動作計画器への入力に用いることで、画像全体ではなく障害物のみを注視し、静的か動的障害物に対して教示された回避動作を計画する。

4. 動作計画器の模倣学習

4.1 模倣学習

本動作計画器を構築するためには、ロボットが時刻 t にてセンサで観測したデータ o_t に対して、とるべき動作 a_t を決定するための方策が必要となる。方策は、 o_t を入力に a_t を出力するための近似関数の役割を担う。しかしながら、 o_t と a_t は一般的に非線形な関係にある。そのため本研究では、CNN を用いて方策を表現する。そして、入力に対する所望の動作を教示し、これらをデータセットとした方策の模倣学習を行う。

模倣学習では、人がロボットを操縦することで動作を教示する。動作中のロボットは、式 (1) の教示データを記録する。

$$D = \{ \langle o_i, a_i^* \rangle \}_{i=1}^N \quad (1)$$

o_i は教示時にロボットがセンサを通じて観測したデータ、 a_i^* は o_i の入力に対して教示された所望の動作である。

o_i を入力に、動作 a_i^* を出力する操縦者の意思決定を最適の方策 π^* とする。同様に、動作計画を行うロボットの方策も式 (2) にて、センサで観測されたデータ o_i を入力に動作 a_i を出力するための π として表現することができる。

$$a_i = \pi(o_i; \theta) \quad (2)$$

θ は π を決定するパラメータであり、図 1 では、CNN における畳み込みフィルタや全結合層における重み、LSTM ブロックにおける入力・忘却・出力ゲートの重みのことである。そのため、方策パラメータ θ を式 (3) の評価関数に基づき最適化する。


$$\underset{\theta}{\text{minimize}} \sum_i \ell(\pi(o_i; \theta), \pi^*(o_i)) \quad (3)$$

ℓ は、方策パラメータ θ による損失関数である。


以上、操縦者による動作の教示から得られた式 (1) の D がデータセットとして用いられ、式 (3) の評価関数を最小化するパラメータ θ に基づく方策 π により、操縦者の最適方策 π^* が模倣されることとなる。そのため、学習後は、式 (2) における方策 π がロボットの動作計画器にて用いられる。

4.2 動作の教示

ロボットに対する障害物回避および目的地に向けた移動のための動作教示は、操縦者が後方から俯瞰して行う。図 3 に、静的障害物と動的障害物それぞれに対する動作教示の例を示す。動作の教示は、ロボットと障害物の位置関係から、操縦者がコントローラを通じてロボットに速度と角速度指令を送ることで行う。その際、左のジョイスティックを前に倒すことで前進し、右のジョイスティックを左右に倒すことで旋回する。また、上下のボタンを押すことで加減速する。



(a) Static obstacles



(b) Dynamic obstacles

図 3 Obstacle avoidance motion instructed by operator

図 3(a) では静的障害物として箱に対する回避動作、図 3(b) では動的障害物として歩行者に対する回避動作、そして回避後の目的地に向けた移動が教示されている。静的障害物に対しては、ロボットが接近してからでも回避することはできる。一方で、動的障害物に対しては、回避の際中にも両者の距離が接近してしまう。そのため、距離を保つよう回避動作を教示しなくてはならない。ロボットは、センサを用いて地図上での自己位置を推定し、目的地までの経路を計画する。その際、経路上のサブゴールとのなす角 ϕ_G を目的地方向とする。

動作教示の際、ロボットは図 2 の中間知覚画像および深度画像、図 3 の目的地方向、ならびに 1 ステップ前の速度 v_{t-1} と角速度 ω_{t-1} を、式 (1) の教示データにおける入力 $o_t = \{I_P^t, I_D^t, \phi_G^t, v_{t-1}, \omega_{t-1}\}$ とする。また、操縦によって教示された速度 v_t^* と角速度 ω_t^* を動作出力 $a_t^* = \{v_t^*, \omega_t^*\}$ とする。そして、これらの入出力から構成される式 (1) の D を、模倣学習におけるデータセットとして用いる。

5. 移動ロボットによる障害物回避

5.1 移動ロボット

図 4 に、実験で用いる移動ロボットを示す。ロボットは、最高で 0.5[m/s]、減速時は 0.4[m/s] で移動する。

図 4(a) では、ロボットに RGB-D カメラと 2D LiDAR が搭載されている。2D LiDAR は、自己位置推定ならびに目的地までの経路計画のために用いられる。RGB-D




図4 Mobile robot equipped with three RGB-D cameras

カメラは3台設置した。図4(b)より、ロボットは、約180度の水平視野角を有し、10[m]の範囲で 80×50 [px]のRGB-D画像を取得する。

5.2 CNNの構造

本ロボットには3台のRGB-Dカメラが搭載されているため、中間知覚画像および深度画像は、それぞれ3枚ずつ動作計画器へと入力される。図5に、ロボットに適用する2つの動作計画器の構造を示す。

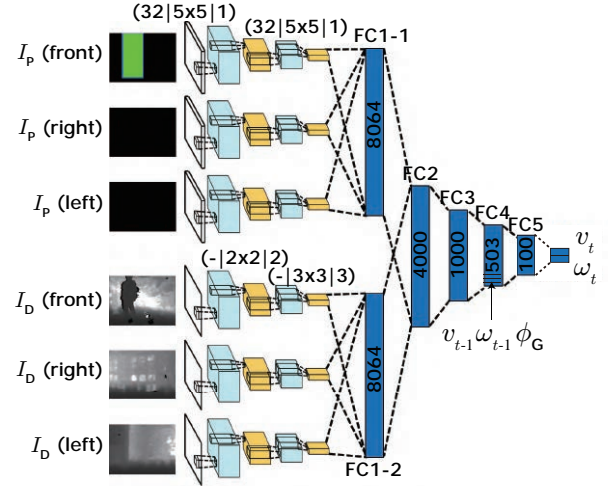
図5(a)は従来研究[7]で提案した構造、図5(b)は本研究で提案する構造である。中間知覚画像および深度画像がそれぞれのCNNへと入力され、畳み込みとプーリングが繰り返される。各フィルタは、(チャンネル数 | サイズ | スライド)で表されている。全結合層における各ノードの活性化関数には、ReLUが用いられる。図5(a)では、全結合4層目にて1ステップ前の速度 v_{t-1} と角速度 ω_{t-1} 、ならびに目的地方向 ϕ_G が入力される。一方図5(b)では、LSTMブロックが全結合層に設けられ、その前の層に1ステップ前の速度 v_{t-1} と角速度 ω_{t-1} が、後の層に目的地方向 ϕ_G が入力される。

5.3 実験


図6に、ロボットが自律移動を行う環境を示す。本環境にて、ロボットに対する障害物回避の教示も行う。

図6(a)は、事前にSLAMによって構築された環境の2次元格子地図である。ロボットは、 7×22 [m²]の空間をSからGに向け自律移動する。図6(b)は、実験環境の様子であり、障害物として、Oの位置に人が立っている。動的障害物を想定した実験では、人が一定の速度でSに向かって歩いてくる。

動作教示では、ロボットは、直立あるいは歩行する人物を回避かつGに向かって移動するよう操縦される。その際、 0.5 [m/s]で移動するロボットは、回避のため 0.4 [m/s]に減速し、回避後 0.5 [m/s]に加速する。また、入力 o_t とそれに対して教示された動作出力 a_t^* を記録し続け、これを式(1)における教示データ D とする。式(3)における損失関数 ℓ は平均二乗誤差に基づき計算され、これが最小化された式(2)の方策 π が動作計画器にて用いられる。なお、図6(b)の人物は、直立と歩行に関係なく、中間知覚画像 I_P では動的障害物として検出される。図7にて、テストデータの入力に対す

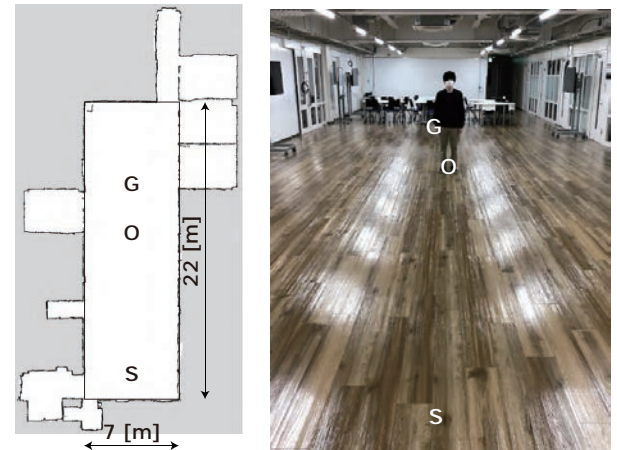


(a) Mediated perception: previous CNN



(b) Mediated perception and LSTM: CNN+LSTM

図5 Architectures of CNNs



(a) Occupancy grid map

(b) Target obstacle

図6 Environment for obstacle avoidance

る方策の近似性能として、教示された速度 v_t^* と出力された v_t を比較する。

図7(a)と図7(b)に比べ、図7(c)と図7(d)では、よ

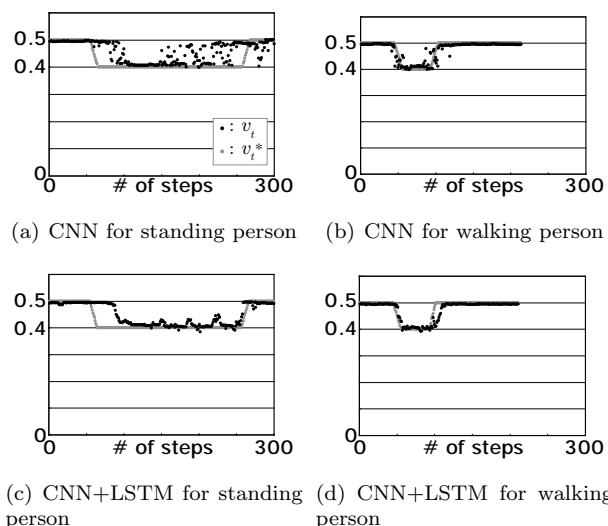


図7 Comparison of input-output mapping: v [m/s]

り v_t が v_t^* に一致していることが見てとれる。二乗誤差の平均は、図7(a)で 21×10^{-4} 、図7(c)で 9.8×10^{-4} 、図7(b)で 2.9×10^{-4} 、図7(d)で 2.8×10^{-4} と、いずれも LSTM を用いることで、動作計画器における方策の近似性能が向上した。そこで表1にて、ロボットが各5回の自律移動を行った結果を比較する。

表1 Comparison of navigation results (5 trials)

Policy	# of successes		Av. distance [m]	
	Stand	Walk	Stand	Walk
CNN	5	1	5.1	3.2
CNN+LSTM	5	4	5.2	4.4

直立する人物に対しては、いずれの方策でもロボットは5回全て目的地に到達した。また、ロボットが回避動作を始めた時の人物との距離も5.1と5.2[m]とほぼ同じとなった。一方、歩行中の人物に対しては、CNNではロボットは1度しか目的地に到達できなかったのに対して、CNN+LSTMでは4回目的地に到達することができた。回避に成功した際でも、CNNではロボットが3.2[m]まで人物と接近していたのに対して、CNN+LSTMでは4.4[m]と距離を保っていたことが分かる。

以上の結果から、CNNにLSTMブロックを追加することにより、動的障害物の時系列的な変化を考慮した動作計画が可能となり、直立と歩行する人物のいずれも回避することに成功した。そこで図8にて、方策の違いによるロボットの障害物回避動作を比較する。

図8(a)では、ロボットと人物が衝突寸前の距離まで接近してしまい、回避動作を開始した直後に緊急停止する結果となった。一方図8(b)では、ロボットが人物と約4[m]以上離れて回避動作を開始したため、この間人物が歩き続けても途中で停止することなく目的地に向けた移動に成功することとなった。

6. 結論

本研究では、静的な障害物に加え歩行者のような動的障害物を対象とした移動ロボットの End-to-End 動

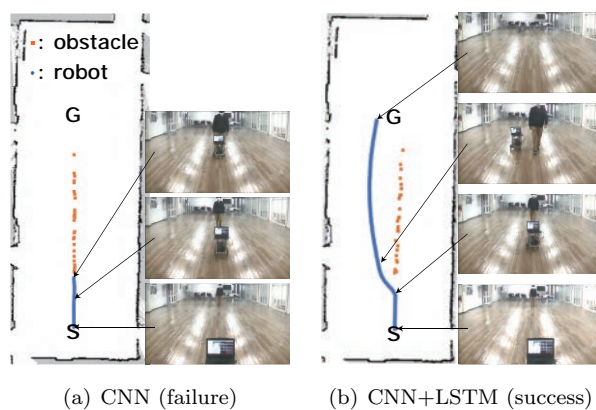


図8 Comparison of obstacle avoidance motions

作計画法を提案した。本動作計画器ではまず、搭載されたカメラから得られた入力画像に写る障害物の静的か動的かの中間知覚が行われた。さらに、中間知覚画像を入力に動作を出力するための方策として、CNNにLSTMブロックが適用された。方策の模倣学習後、ロボットは、画像上での障害物の写り方に関する時系列的な変化を考慮した動作計画が可能となった。その結果ロボットは、立っている人物や歩行者を回避しながら、かつ、目的地に向けて自律移動することに成功した。

謝辞 本研究はJSPS 科研費 20K04394 の助成を受けたものです。

参考文献

- [1] 星野智史, 芳川知樹: 遮蔽領域における障害物をも考慮した移動ロボットの動作計画法, 日本機械学会論文集, Vol.85, No.872, p. 18-00353, 2019.
- [2] S. Hoshino and K. Maki: Safe and Efficient Motion Planning of Multiple Mobile Robots based on Artificial Potential for Human Behavior and Robot Congestion, *Advanced Robotics*, Vol. 29, No. 17, pp. 1095–1109, 2015.
- [3] A. Carballo *et al.*: End-to-End Autonomous Mobile Robot Navigation with Model-Based System Support, *Journal of Robotics and Mechatronics*, Vol. 30, No. 4, 2018.
- [4] G. E. Hinton *et al.*: A Fast Learning Algorithm for Deep Belief Nets, *Neural Computation*, Vol. 18, No. 7, pp. 1527–1554, 2006.
- [5] C. Chen *et al.*: DeepDriving: Learning Affordance for Direct Perception in Autonomous Driving, *IEEE International Conference on Computer Vision*, pp. 2722–2730, 2015.
- [6] 吉田遊友 他: RGB-D 画像を用いた End-to-End 学習による移動ロボットの動作計画法, ロボティクス・メカトロニクス講演会 2019, 2A2-B14, 2019.
- [7] 吉田遊友, 星野智史: 物体検出画像と深度画像を用いた CNN による移動ロボットの End-to-End 動作計画, 日本ロボット学会誌, Vol. 39, No. 5, pp. 479–482, 2021.
- [8] Y. LeCun *et al.*: Gradient-Based Learning Applied to Document Recognition, *Proceedings of the IEEE*, Vol. 86, Issue. 11, pp. 2278–2324, 1998.
- [9] S. Hochreiter and J. Schmidhuber: Long Short-Term Memory, *Neural Computation*, Vol. 9, No. 8, pp. 1735–1780, 1997.
- [10] J. Redmon *et al.*: You Only Look Once: Unified, Real-Time Object Detection, *IEEE Computer Vision and Pattern Recognition*, pp. 779–788, 2016.