

分光情報を用いた3DCGによるイネ科植物の教師データの生成

○川田 悠貴 (愛媛大学) 杉本 大志 (愛媛大学) 曾利 仁 (津山高専) 井上浩行 (津山高専)
都築 伸二 (愛媛大学)

1. はじめに

近年、人手不足が深刻化する農家を対象とした、機械学習による画像処理技術を取り入れたロボットの開発が盛んに行われている [1]. 著者らのグループでも、農業の人手不足や農薬取締法による農薬の制限を背景に、小規模稲作農家を対象とした画像処理技術を用いた自律型稲作用除草ロボットの開発を行っている. しかしながら、農業においては作物の育成状況が多岐に渡り、データを収集できる適性期間が限られているため、農業の自動化を進める上で十分なデータを用意できないことが自動化の妨げになっている. その問題に対し、著者らは3DCGを用いた教師データを作成することで、データ不足を補う方法について検討を行った.

3DCGを使用した教師データを用いる際の課題として、3DCGモデリングの精度と光のライティングの精度が認識精度に大きく影響することが先行研究文献から判明している. そこで、本研究では光のライティングや色を調整することにより認識精度を向上させることを目的とし、OpenGL上でイネの3DCGモデルのライティングや色を変化させることで、精度がどのように変化するか検証を行う.

教師データに用いる画像は、デバイスの光感度により画像の色や明るさが変化してしまう. 本研究では、デバイスの光感度に依存しない物体固有の色情報である分光反射率の情報を用いて色の再現を行うことで、教師データとしてより精度が高いものになるかその有効性を確認する.

2. 3DCGによる光反射モデルと色の再現

2.1 反射光の計算

本研究で用いる手法で3DCGで物体表面の色を再現するためには、表面下散乱と分光情報を組み込んだ光反射モデルを使用する必要がある. しかし、光の表面化散乱を厳密に計算すると莫大な計算量になるため、本研究では簡易的に近似して陰影処理を行うモデルを使用する. 一般的な拡散反射モデルであるランバート反射モデルに分光情報を乗算する形で色を再現する. 拡散反射光を *diffuse*, 鏡面反射光を *specular*, 物体の色を k , 照明方向のベクトルを L , 視線方向のベクトルを V , 物体法線のベクトルを N , 光の強度を m とし、

L と N の内積を計算すると、以下の通りとなる.

$$diffuse = kLm\cos\theta \quad (1)$$

$$specular = k(R \cdot L)^n m \cos\theta \quad (2)$$

式中の n は鏡面反射の度合である. 本研究では $n=5$ とした. この時の正反射ベクトル R は

$$R = 2N(L \cdot N) - L \quad (3)$$

と計算される. その反射の様子を図1に示す.




図1 反射光のモデル

2.2 分光情報を用いたピーク波長の推定

稲の色を再現するために、色のピーク波長を分光反射率から推定を行う. 分光器等を用いた九月時点の稲の葉における一点の分光反射率を測定した結果 [2] からピーク波長の推定を行う. 実際に測定した結果のままでは曲線に大きなばらつきが生じるため、一次関数とガウス関数を用いて実測値と近似した曲線を作成し平滑化を行った. その時の分光反射率が図4である. ピーク波長は550nm前後であり、葉の色が緑色から黄色に変化している最中の色である. この一点の色を稲全体の色と仮定して、葉全体のピクセルに色を転送する.




図2 分光反射率の推定結果

2.3 波長から色への変換

先ほど求めた反射スペクトルから色の再現を行う。ピーク波長からでは最も光が強い波長の色のみしか求められないため、反射スペクトルから可視広域内の全波長の計算を行う。反射スペクトルを XYZ 表色系の値に変換し、sRGB の値に変換したあと、ガンマ補正により明るさを調整する。波長から XYZ 値に変換する時に以下の式を用いる。

$$X = \sum_{\lambda=360}^{740} R(\lambda) \cdot P(\lambda) \cdot x(\lambda) \quad (4)$$

$$Y = \sum_{\lambda=360}^{740} R(\lambda) \cdot P(\lambda) \cdot y(\lambda) \quad (5)$$

$$Z = \sum_{\lambda=360}^{740} R(\lambda) \cdot P(\lambda) \cdot z(\lambda) \quad (6)$$

$R(\lambda)$ は反射率、 $x(\lambda)$ は等色関数、 $P(\lambda)$ は光源の分光分布を表す。本研究では光源に LED 電灯を用いた。等色関数は図 3、光源の分光分布は図 4 の通りである。

この後、先ほど求めた XYZ 表色系の値を sRGB 系に変換する。パソコンではモニターで XYZ 表色系で色を表現できないため、そこからさらに変換する必要がある。変換式は以下の通りである。

$$R = 3.2406X - 1.53722Y - 0.4986Z \quad (7)$$

$$G = -0.9689X + 1.8758Y + 0.0415Z \quad (8)$$

$$B = 0.0557X - 0.20401Y + 1.05703Z \quad (9)$$

各計算値が 1.0 を超えた場合は 1.0 に、0 以下になれば 0 に補正する。そこから 0.000313 を基準にガンマ補正をかけ、明るさの調整を行う。




図 3 等色関数




図 4 LED の分光分布

3. YOLO による物体検出と検出結果

3DCG により作成した教師データをもとに、YOLO と呼ばれる深層学習を用いた画像認識手法を用いて認識精度を検証する。稲の画像とその座標データから構成された教師データを用いて学習する。テクスチャのみを用いて色を再現した場合と分光情報から色を再現した場合を比較したのが図 5 である。本研究では 6 月時点のイネを再現した 3DCG モデルの図 6 を教師データに用いる。ランダムな角度と照明位置から物体の撮影を行い、イネの全長が映る範囲の画像を教師データとして使用した。その時の学習条件が表 1 である。検証画像には自分で撮影した画像に加え、インターネット等から収集した画像も含まれる。

また、比較対象として実写画像を教師データに用いた場合の学習も同時に行った。その時に使用した画像の撮影条件が表 2 である。

最適化関数の変更や各種パラメータの調整を行い、どの条件で効率よく学習できるか検討を行った。その上で、実写画像を用いて学習を行った場合、テクスチャのみで色を再現した場合、分光情報により色を再現した場合のイネに対しての適合率を比較した結果が表 3 である。検出領域の面積に関わらず物体を正しく判別できた場合を正解とし、画像ラベルに対して検出を正しく行っているかどうかで全体の平均から算出した。数値は少数第一位を四捨五入した値である。また、その時のテスト画像の検出結果の例が図 7 である。

この結果において、3DCG 画像では色や明るさを調整することで僅かに高い検出精度が出た。しかし、ほとんど数値に変わりがなく、教師データの偏りの影響も含まれるため、色情報がどの程度検出精度に影響したか今後精査する必要がある。色の正確性についても、推定値から色の再現を行っているため、実物と完全に一致しているわけではない。また、実写画像に比べると 3DCG は現在の条件では検出精度が低くなっている。原因として、3DCG の場合は背景が黒いことで検出精度が低下していると考えられる。ポリゴンで検出するので、背景の再現まで行わないと精度が落ちると考えられる。また、今回は光源に LED を用いて色の再現を行ったため、実際の太陽光で再現した場合と比べて色が変わっていると考えられる。今後は天候のシミュレーションも行うことを視野に入れて、太陽光での再現も行いたい。




図5 テクスチャのみ (左) と色の乗算あり (右) の比較



図6 分光情報から色を再現した6月末のイネの3DCGモデル

表1 検出対象と学習条件

| | |
|---------|------------------|
| 検出対象 | イネ (作物), ヒエ (雑草) |
| 学習枚数 | イネの画像 300 枚 |
| 検証テスト枚数 | イネとヒエの混合 100 枚 |
| 入力サイズ | 512 × 512 |
| バッチサイズ | 16 |
| エポック数 | 100 |

表2 実写画像の撮影環境

| | |
|------|-------------|
| 撮影時期 | 6 月末 |
| 解像度 | 4224 × 5632 |
| 焦点距離 | 27mm |
| 絞り値 | F1.8 |
| iso | 50 |

表3 YOLO による検証結果

| 教師データ対象 | 適合率 (%) |
|-----------------|---------|
| 実写画像のイネ | 72 |
| 3DCG イネ (テクスチャ) | 12 |
| 3DCG イネ (分光情報) | 14 |




図7 テスト用画像における検出結果の例

4. おわりに

今回は光源に LED 光源を使用した が、天候に応じた太陽光のスペクトルを用いることにより、天候に応じた反射光の色のシミュレーションが可能になるかもしれない。また、工業製品と異なり植物の反射スペクトルは成長段階に応じて変化するため、成長度合を考慮した分光情報を用いてシミュレーションを行うことで、より認識精度の向上を見込める。今後は背景も含めた再現も考慮していくことと、より正確な光の反射のアルゴリズムを構築していくことで、農業においても 3DCG で汎用的な教師データの作成を目指したい。

謝辞

本研究成果は、JSPS 科研費 20K06331(代表: 曾利仁) の助成を受けたものである。また、圃場での撮影に協力いただいた農学部附属農場の阿立真崇氏、有澤雅音氏に感謝する。

参 考 文 献

- [1] 上垣俊平, 荒木秀和, 戸島亮, 新崎誠, 上田大介, 山崎龍次: 環境認識に AI を用いたトマト収穫ロボット, Panasonic Technical Journal Vol.64, pp.54-59, 2018, <https://www.panasonic.com/jp/corporate/technology-design/ptj/pdf/v6401/p0112.pdf>.
- [2] シーシーエス株式会社, 光と色の話 第一部, https://www.ccsinc.co.jp/guide/column/light_color/vol13.html.

- [3] 田中法博, 望月宏裕: 分光反射率分析に基づいた化粧と肌の CG 再現, 長野大学紀要, 第 41 巻第 1 号, pp.65-72, 2019.
- [4] 色空間の変換 (1), <https://fujiwaratko.sakura.ne.jp/infosci/colorspace/colorspace1.html>.
- [5] LED のスペクトル (分光分布) とは? , http://www.my-craft.jp/html/aboutled/led_supekutoru.html.