

CNNによる欠陥検出と Grad-CAM による欠陥部分の可視化性能を向上させる画像拡張法の一提案

○阿部 凌真, 有馬 滉宜, 清水 竜樹, 三木 康平, 永田 寅臣,
加藤 博久 (山口東京理科大学), 渡辺 桂吾 (岡山大学大学院)

A Proposal for an Image Augmentation Method to Improve the Performance of CNN-based Defect Detection and Grad-CAM Visualization of Defect Areas

Ryoma ABE, Koki ARIMA, Tatuki SHIMIZU, Kohei MIKI,

Fusaomi NAGATA, Hirohisa KATO, Sanyo-Onoda City University

Keigo WATANABE, Graduate School of Natural Science and Technology, Okayama University

Abstract : The authors have been developing a design and training application with a user-friendly operation interface for CNN (Convolutional Neural Network), CAE (Convolutional Auto Encoder) and SVM (Support Vector Machine). in this paper, a method for efficiently generating new training images from a limited number of product images was proposed by extracting only the product parts in the image and pasting them in various background images prepared in advance while shifting their positions little by little. By training the CNN on these training images, we were able to improve not only the recognition rate of the test images but also the accuracy of the mapping when visualizing the basis of the decision using Grad-CAM.

1. 緒言

様々な工業製品の検査工程においては一部で自動化が進んでいるものの、それぞれの製品の品質管理に精通した検査員の目視検査に頼るところが大きい状況である。最近、深層学習の技術を画像認識に特化させた CNN (Convolutional Neural Network) や SVM (Support Vector Machine) を製品の欠陥検出に応用しようとする試みが活発に行われている。例えば、重村らは構造表面損傷の誤検出を減らし、高速かつ高精度にひび割れを検出するために深層学習の物体検出技術である YOLOv2 と CNN を組み合わせた構造を提案し、ひび割れ検出精度を向上させた [1]。また、タナットらは CNN を用いて電子部品の光沢のある金属表面の画像から欠陥を検出する手法を提案した [2]。

筆者らは、製造業が抱える品質管理に関する課題を解決するために、熟練した検査員のような不良品の識別能力を有する CNN, SVM, CAE (Convolutional Auto Encoder) などの AI の設計と訓練を簡単な操作で効率的に実行できるように図 1 に示す設計支援ツールの開発を行っている [3]。これまでの研究成果として、幾つかの工業製品についてそれぞれの製造メーカーが求める目標認識率を達成することが出来たが、不良品の根拠となった部分の可視化に対しては不十分な結果であった。

本研究では、事前に 3 つの訓練データセットを作成し、CNN&SVM 設計支援ツールを用いて学習済み CNN である InceptionV3[4] の転移学習により新たな 3 つの CNN を

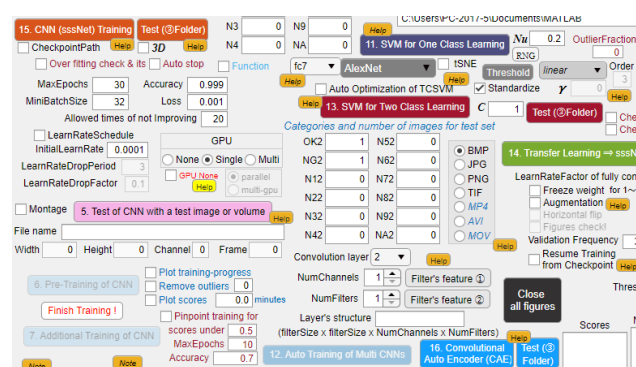


Fig. 1: A part of main dialog developed on MATLAB system to user-friendly design CNN, SVM and CAE.

設計し、分類実験を行う。分類実験後、製品に含まれている欠陥部分の可視化を行い、欠陥と判定した根拠となった領域を確認する。今回は MATLAB 上で開発するアプリケーションにも実装が可能な Grad-CAM を適用することとした。Grad-CAM は、勾配を用いてクラス分類を行う際に重要なピクセルを可視化する技術である。まず CNN を通してクラス分類を行い、その際に得られる畳み込み層の出力とクラス分類の結果を得る。このクラス分類の後に誤差逆伝搬を行い、畳み込み層の各要素に対する出力の勾配を計算する。次にそれぞれの畳み込み層の勾配の平均を求め、全ての畳み込み層を加算することで畳み込み層の活性

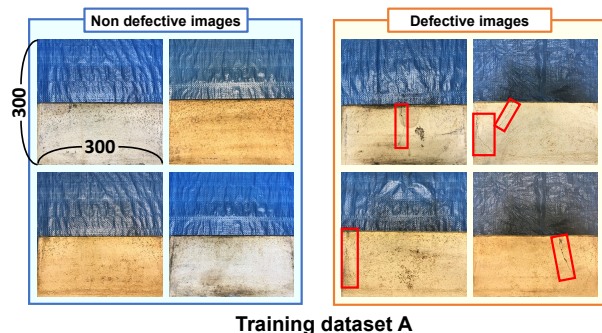


Fig. 2: Examples of images of products.

化を可視化することが可能になっている [5]。Grad-CAM を用いることでラベル判定の根拠となった領域がカラーマップで表示されるようになっており、予測に強い影響を与えた領域ほど赤くマッピングされる。Grad-CAM を用いて CNN が分類のために注視している箇所をカラーマップで表示させ、欠陥と判定した根拠となった領域の可視化を試みる。

2. CNN を用いた工業製品の欠陥検出

2.1 オリジナル画像および提案する画像拡張法で作成する訓練データセット

2.1.1 オリジナル画像

本研究では、まず、図 2 のような工業製品に含まれる欠陥の検出を行う。300 × 300 ピクセルの良品と不良品画像それぞれ 1,444 枚、76 枚の計 1,520 枚を採集し、実験を行う。良品画像は 1,380 枚を訓練用に、残りの 64 枚をテスト用に用いる。また、不良品画像は 56 枚を訓練用に、残りの 20 枚をテスト用に用いる。ここで得られた良品と不良品画像それぞれ 1,380 枚、56 枚を訓練データセット A とし、残りの良品と不良品画像それぞれ 64 枚、20 枚をテストデータセットとする。

2.1.2 ランダムに用意した背景の中心に製品を貼り付ける画像拡張法

次に、画像内に含まれる製品の背景にはブルータープ（ブルーシート）があり、それらのしわや陰などが可視化性能に悪影響を及ぼすと判断されたため、製品の背景をタープ以外に変更させることで可視化実験の際によりいっそう製品部分に注目するのではと考察した。これまでも実際に物体検出の精度向上に関する研究では、同じ物体に対し背景を変更したデータセットを訓練に用いることで認識精度を向上できたという報告がある [6]。




Fig. 3: Examples of images of dataset B.

また、生産ラインで安定的に製造される工業製品の場合、不良品の発生頻度が非常に低いことが多いため欠陥が含まれた画像を蓄積していくことが容易ではない。このため、不良品画像のみに対し画像拡張を施し、画像データを増やすことが必要である。

具体的には、訓練データセット A の不良品画像にのみ水平反転の操作を行い、112 枚に増やすことによって良品と不良品画像それぞれ 1,380 枚、112 枚の計 1,492 枚とし、これとは別に 7,500 枚の背景用画像を用意する。図 3 のように 1,492 枚の画像内の製品のみをそれぞれ約 150 × 300 ピクセルで切り抜き、それらを 7,500 枚の中からランダムに抽出した 1 枚の背景画像の中心にそれぞれ張り付けることで新たに 1,492 枚からなる訓練データセット B を作成する。

2.1.3 ランダムに抽出した背景画像に対して製品の貼り付け位置を変化させる画像拡張法

さらに、実際の生産ラインにおいて撮影される製品の位置にはばらつきがあり、規則正しく固定されていない場面がある。このような場面でも十分な分類と可視化を行える CNN を設計するために次のような画像処理を行う。さきほどの 7,500 枚の中からランダムに抽出した 150 枚の背景画像に対してある 1 枚の製品画像を貼り付ける位置を上部から下部に 1 ピクセルずつずらすことで 150 枚の新たな画像が生成される。この時、背景画像は 300 × 300 ピクセル、切り抜いた製品画像は約 150 × 300 ピクセルであるため、製品画像 1 枚につき 150 枚の新たな画像が生成されることになり、良品が $1,380 \times 150 = 207,000$ 枚、不良品が $112 \times 150 = 16,800$ 枚の計 223,800 枚の画像が得られることになる。最後に、良品画像が多いことによる過学習を防止するため、良品画像の中から 22,000 枚を無作為に抽出した。結果的に良品と不良品画像それぞれ 22,000 枚、16,800 枚




Fig. 4: Examples of images of dataset C.

からなる訓練データセット C を作成した．図 4 には幾つかの例を示す．

次節ではこれらの訓練データを用いて学習済み CNN である InceptionV3 の転移学習による新たな CNN を設計する．訓練データセット A, B, C を用いて訓練した CNN をそれぞれ IncA, IncB, IncC とする．なお，分類評価には 2.1.1 節で記述した，良品と不良品画像それぞれ 64 枚，20 枚からなるテストデータセットを用いる．

2.2 学習と評価

2.2.1 IncA の学習と評価

訓練データセット A を用いた IncA の学習では，最大エポックを 1000，ミニバッチサイズを 40，畳み込み層の学習率を 0.0001，全結合層の学習率を 0.001 などの条件に設定して訓練を開始したところ，274 エポックで訓練データセットに対する認識率が 100 % に達成したため学習を終了させた．表 1 には，テストデータセットを IncA に分類させた結果を示す．良品画像は全て正確に分類され，不良品画像は 15 枚が誤認識されたことが確認された．これは訓練に用いた不良品画像の枚数が良品画像のそれと比べて非常に少なかったことが原因だと考えられる．

Table 1: Confusion matrix classified by IncA (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	64	15
Anomaly	0	5

2.2.2 IncB の学習と評価

次に，訓練データセット B を用いた IncB の学習及び分類実験は IncA と同様の条件で行い，82 エポックで訓練

データセット B に対する認識率が 100 % に達成したため学習を終了させた．表 2 には，IncA の時と同じテストデータセットに対して IncB が分類した結果を示す．

Table 2: Confusion matrix classified by IncB (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	64	4
Anomaly	0	16

良品画像については IncA と同様に IncB も全て正確に分類できていた．誤分類された不良品画像の枚数は 4 枚に減少していたため，分類性能が改善できていることがわかる．

2.2.3 IncC の学習と評価

最後に，訓練データセット C を用いた IncC の学習及び分類実験は IncA, IncB と同様の条件で行い，3 エポックで訓練データセット C に対する認識率が 100 % に達成したため学習を終了させた．表 3 には，テストデータセットに対する IncC を用いた場合の分類結果を示す．

Table 3: Confusion matrix classified by IncC (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	64	1
Anomaly	0	19

IncA, IncB と同様に良品画像は全て正確に分類され，誤分類された不良品画像の枚数は 1 枚に減少させることができた．以上の結果から，今回取り上げた工業製品の欠陥検出の CNN の設計においては提案する画像オーギュメンテーションの有効性が確認された．

次節では，これら IncA, IncB, IncC に対し Grad-CAM を適応し，欠陥部分の可視化を評価する．

3. Grad-CAM による欠陥部分の可視化

図 5，図 6 及び図 7 にはそれぞれ，IncA, IncB, IncC を用いて不良品のテストデータセットを分類したときの根拠となった領域を Grad-CAM により可視化したものを示す．図 5 より IncA の場合は，欠陥部分以外のブルータープのしわや影を注視しており不十分な可視化であると確認できる．




Fig. 5: Visualization result of defect area obtained by applying Grad-CAM to IncA.




Fig. 6: Visualization result of defect area obtained by applying Grad-CAM to IncB.

次に、IncB の場合は図 6 より、IncA とは異なりターゲットのしわや影を注視しておらず、欠陥部分を注視していることが確認できる。さらに IncC の場合は、図 7 のように IncB に比べてより鮮明に欠陥の中心部を赤くマッピングできており、より欠陥部分を注視していることが確認できる。

IncB と IncC の結果より、分類実験で用いたテストデータセットの製品は画像の下部に位置していたが、Grad-CAM による可視化実験では画像下部の製品の欠陥部分を注視できていたことがわかる。また、画像内に製品が含まれていればその位置に依存せず欠陥部分を注視できることが分かった。以上の結果から、製品と関係ない任意に用意した背景画像の中に製品画像を組み込む画像拡張法は、欠陥部分の認識率向上に加えて、Grad-CAM による可視化性能も向上できることが確認できた。

4. 結言

本研究では、InceptionV3 の転移学習により新たな 3 つの CNN の設計とテスト画像の分類実験を行い、Grad-CAM を用いて分類結果に影響を及ぼした欠陥部分の可視化を行った。その結果、製品の背景を変更する処理を施した画像を用いて訓練した CNN(IncB, IncC) では、オリジナル画像のみで訓練した CNN(IncA) を用いたときと比較




Fig. 7: Visualization result of defect area obtained by applying Grad-CAM to IncC.

して分類精度と欠陥部分の可視化性能はともに向上させることができた。CNN(IncB) の場合は背景画像の中心に製品画像を貼り付ける処理を、CNN(IncC) の場合は背景画像に製品画像を貼り付ける位置を上部から下部へと変化する処理をそれぞれ加えている。さらに、CNN(IncB) と CNN(IncC) を比較した結果、CNN(IncC) の方が分類精度と欠陥部分の可視化性能ともに優れていた。

以上の結果から、生産ラインにおいて撮影される製品の位置にばらつきがあり、規則正しく固定されていない場面でも提案手法を用いることで欠陥部分の認識精度とその可視化性能を改善できることが確認できた。今後は、提案した画像拡張法を他の工業製品にも適用しながら、より高い分類精度と欠陥部分の可視化性能を有する CNN の設計を行っていきたい。

参考文献

- [1] 重村知輝, 野村泰稔, “深層学習に基づく物体検出・認識技術を用いた二段階構造表面ひび割れスクリーニング”, Vol. 69, No. 3, pp. 218–225, Mar. 2020
- [2] クーイペンシー・タナット, 保田俊行, 神代充, “CNN を用いた画像分類に基づく電子部品の表面欠陥の検出”, 第 63 回自動制御連合講演会, pp. 268–269, 2020
- [3] 永田, 渡辺, 畳み込みニューラルネットワーク (CNN)・畳み込みオートエンコーダ (CAE)・サポートベクタマシン (SVM) のための設計支援ツールの開発, 画像ラボ, 2021.
- [4] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna “Rethinking the Inception Architecture for Computer Vision,” *Procs. of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2818–2826, 2016.
- [5] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. “Grad-CAM: Visual Explanations from Deep Networks via GradientBased Localization,” *Procs. of the IEEE Conference on IEEE European Conference on Computer Vision (ICCV)*, pp. 618–626, 2017.
- [6] D. Dwibedi, I. Misra, and M. Hebert, “Cut, Paste and Learn: Surprisingly Easy Synthesis for Instance Detection,” *Procs. of the IEEE Conference on International Conference on Computer Vision (ICCV)*, pp. 1301–1310, 2017.