

CNN, CAE および SVM の設計と評価のための支援ツールの開発

– CAE (Convolutional Auto Encoder) による工業製品の欠陥部分の可視化と位置推定 –

Development of Design and Evaluation Tool for CNN, CAE and SVM

- Visualization and location estimation of defective parts of industrial products Using CAE -

○ ¹ 有馬 滉宜 ¹ 永田 寅臣 ¹ 清水 竜樹 ¹ 三木 康平 ² 松山 弘樹 ² 加藤 博久 ³ 渡辺 桂吾

○ ¹Koki ARIMA ¹Fusaomi NAGATA ¹Tatuki SHIMIZU ¹Kohei MIKI

²Hiroki MATUYAMA ²Hirohisa KATO ³Keigo WATANABE

¹ 山口東京理科大学大学院工学研究科, ² 山口東京理科大学工学部機械工学科

³ 岡山大学大学院自然科学研究科

¹Graduate School of Science and Engineering, Sanyo-Onoda City University

²Department of Mechanical Engineering, Faculty of Engineering, Sanyo-Onoda City University

³Graduate School of Natural Science and Technology, Okayama University

Abstract: The authors have been developing a design and training application with a user-friendly operation interface for CNN (Convolutional Neural Network), CAE (Convolutional Auto Encoder) and SVM (Support Vector Machine), which can be used for the defect detection of various types of industrial products even without deep skills and knowledges concerning information technology. The application is required to have a visualization ability of small defects which would be the causes of classification results, however, it seems to be not easy to provide such a promising function as clearly identifying the position of defect. In this presentation, CAE is applied to the visualization and position detection of such small defects included in images of industrial products. The effectiveness and promise are evaluated through visualization experiments of defect areas included in test images.

1 はじめに

様々な工業製品の検査工程においては一部で自動化が進んでいるものの、それぞれの製品の品質管理に精通した検査員の目視検査に頼るところが大きい状況である。最近、深層学習の技術を画像認識に特化させた CNN (Convolutional Neural Network) や SVM (Support Vector Machine) を製品の欠陥検出に応用しようとする試みが活発に行われている。例えば、寺野らは VGG16 アーキテクチャを用いた転移学習によるコンクリート構造物のひび割れ抽出及び判別方法に関する研究を行っている [1]。また、Perez らは建造物の欠陥と劣化を自動検出し、位置特定ができるように VGG16 の転移学習を用いて 4 カテゴリ分類用に新たな CNN を設計し、分類性能を評価する研究を行っている [2]。

筆者らは、製造業が抱える品質管理に関する課題を解決するために、熟練した検査員と同等以上の不良品の識別能力を有する CNN, SVM, CAE (Convolutional Auto Encoder)[3] などの AI の設計と訓練を簡単な操作で効率的に実行できるように図 1 に示すアプリケーションの開発を行っている。これにより、CNN, SVM, CAE といった分類器に対して転移学習、追加学習などの学習アルゴリズムを適用し、静止画や動画に含まれる工業製品の欠陥を検出するためのシステム構築の支援が可能になってきた。実際、地域のものづくり産業の現場では作業者が環境設定から運用までを容易に行えるシステムへのニ

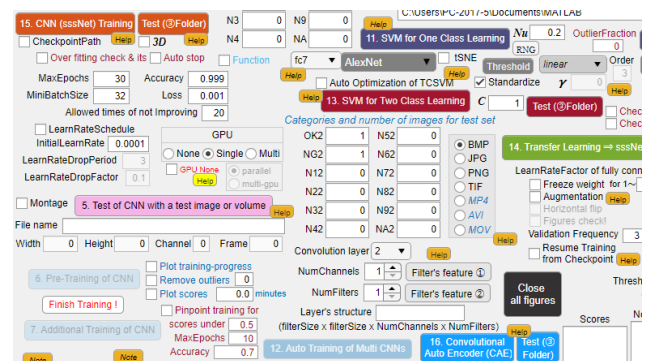


Fig. 1: A part of main dialog developed on MATLAB system to user-friendly design CNN, SVM and CAE.

ズが高いため、試用を通じた改善と普及、および利用者からのフィードバックに基づく機能改善を図っている。

本研究では、アプリケーション内に実装した CAE の設計機能を用いて工業製品の画像に含まれる欠陥部分の可視化と画像内での位置特定を試みたので報告する。

2 内容

開発中のアプリケーションを使ってこれまでに幾つかの工業製品の欠陥検出を試みてきたところ、不良品の検出精度としては製造メーカーが求める数値をクリアできたものの、判定の根拠となった欠陥部分を正確に表示させた




Fig. 2: Examples of images of brake rotor.

いというニーズには十分に対応できていなかった [4, 5]. 例えば, 訓練後の CNN に欠陥が含まれるテスト画像を与え, 畳み込み層で生成される特徴マップの中でより活性化度の高いものを重ねることで後半の全結合層部でのクラス分類に影響を及ぼした領域の可視化を行ったが, 鮮明さという点では十分ではなかった. また, Grad-CAM (Gradient-weighted Class Activation Mapping) [6] を適用した場合には, 欠陥ではない部分が強調表示されてしまうことがあった.

本章では, アプリケーション内に実装した SegNet [7] ベースの CAE と, より浅くかつ重みパラメータの少ないネットワーク構造の CAE を工業製品であるブレーキロータの画像内に含まれる欠陥部分の可視化と画像内での位置の特定に適用し, 性能を評価する.

2.1 CNN の設計, 学習と分類実験

はじめに, SegNet のエンコーダ部分に使用されている VGG16 [8] の転移学習により設計した 2 クラス分類用の CNN である VGG16A と, オリジナル設計のコンパクトな 2 クラス分類用 CNN である sssNet それぞれについて, 図 2 のようなブレーキロータの良品画像 2,875 枚と不良品画像 3,758 枚からなる画像データセットを用いて学習を行い, テスト画像を用いて汎化性の評価を行う.

訓練後の VGG16A と sssNet の汎化性能を評価するためにテスト用データセットとして良品画像 262 枚と不良品画像 453 枚の計 715 枚を用いて分類実験を行った. 表 1 と表 2 にはそれぞれ, VGG16A と sssNet の全体的な認識結果を表す混同行列を示す. VGG16A と sssNet はともに良品画像を全て正しく分類できており, 誤分類した不良品画像の枚数も 1 枚あるいは 2 枚と少数であった結

表 1: Confusion matrix classified by VGG16A (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	262	2
Anomaly	0	451

表 2: Confusion matrix classified by sssNet (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	262	1
Anomaly	0	452




Fig. 3: Visualization results of the most activated area for classification using Grad-CAM.

果が確認された.

2.2 Grad-CAM による可視化

ここでは例として, VGG16A と sssNet を用いた分類実験において正確に不良品と分類できた不良品画像 2 枚をそれぞれ Grad-CAM で可視化したものを図 3 に示す. VGG16A の場合, 欠陥の他にも特徴として捉えた分布が疎らに散らばっていた. 一方, sssNet の場合は, 欠陥部分との見分けがつかず, 画像全体を同色で分布してるような結果が得られた. このように高い分類性能を有する CNN でも, Grad-CAM を用いて分類結果に影響を及ぼした領域を可視化しようとする, 欠陥ではない部分が強調表示されてしまう場合があることが確認された.

2.3 CAE の設計と学習

一般的な 3 層構造を持つオートエンコーダ (Auto Encoder : AE) の場合, 入力層と出力層は同じ数のニューロンを持ち, 隠れ層 (中間層) はそれより少ない次元のニューロンを持つ構造となる. このネットワークの学習では入力パターンがそのまま出力されるように重みが調整されるため, 中間層では入力データが持つ有効な特徴が抽出されることとなる. このオートエンコーダのコンセプトを CNN に応用したモデルとして CAE が提案され

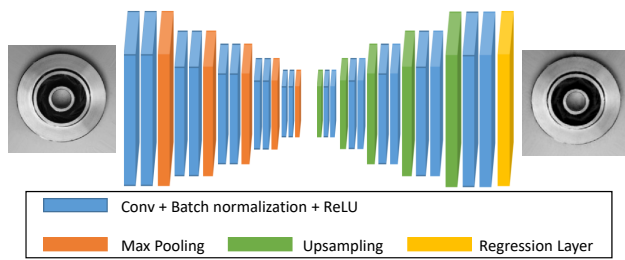


Fig. 4: CAE structure designed using VGG16 for the encoder part.




Fig. 5: CAE structure designed using sssNet for the encoder part.

ている [3].

本研究では、分類実験で用いた学習済み CNN である VGG16 とオリジナル設計の CNN である sssNet をエンコーダ部分に用いた CAE をそれぞれ図 4 と図 5 のように設計した。設計した 2 種類の CAE を 2.1 節で用いたブレーキロータの訓練用データセットの良品画像のみの 2,875 枚を用いて学習させた。

2.4 CAE による欠陥部分の可視化性能の評価

CAE の学習では、良品のみの訓練データセットで学習させるとテスト画像 A が良品画像の場合にはそれに非常に似た画像 A' を出力できるようになるため、差分の絶対値 $|A - A'|$ を求めて表示させると全てのピクセル要素がほぼ 0 となり、黒色単色に近い画像として得られる。これに対し、欠陥を含む不良品の画像 B が入力された場合、CAE は訓練データにはなかった欠陥部分の特徴を再構成できずに結果的に出力画像 B' には欠陥部分を正確に再現できないこととなる。そのため、 $|B - B'|$ を表示させると入力画像から再現できなかった欠陥部分が黒以外の明るい色で表示され、さらに画像を構成する全ピクセルの値を補数で置き換えると欠陥部分の特徴が可視化できる。

2.2 節で紹介したの Grad-CAM による可視化実験で用いた 2 枚の不良品画像を用いて、設計した 2 種類の CAE

による可視化実験の結果を図 6 に示す。エンコーダ部分に VGG16 と sssNet を用いた CAE をそれぞれ CAE1, CAE2 とする。CAE1 を用いた場合、2 枚のテスト画像ともに外形の欠陥や凹みのような欠陥を正確に再現できていることがわかる。一方、CAE2 を用いた場合、欠陥部分の可視化はできているものの、CAE1 に比べると欠陥部分の鮮明さが若干劣っていることが確認できた。

3 結言

本研究では、これまでに開発してきた CNN, SVM および CAE の設計アプリケーションを用いて構築した畳み込みオートエンコーダ (Convolutional Auto Encoder: CAE) を用いて工業製品の画像に含まれる欠陥部分の可視化と画像内での位置特定を試みた。はじめに、SegNet のエンコーダ部分に使用されている VGG16 の転移学習により設計した 2 クラス分類用の CNN と、オリジナル設計のコンパクトな 2 クラス分類用の CNN である sssNet を用いて分類実験を行った。その結果、どちらも分類性能は高かったものの、従来の Grad-CAM を用いた欠陥部分の可視化実験では欠陥でない部分までも強調表示されてしまう場合があった。

次に、エンコーダ部分に VGG16 と sssNet をそれぞれ用いた 2 つの CAE を設計し、ブレーキロータの良品画像のみを用いて訓練させた。その後、Grad-CAM で可視化の検証を行った欠陥を含む 2 枚の不良品画像を用いて、これら 2 つの CAE による欠陥部分の可視化性能を比較評価した。その結果、設計した 2 つの CAE を用いた場合は、ブレーキロータの画像に含まれる欠陥部分の表示の鮮明さに強弱の違いがあったものの、良好に欠陥部分の可視化と位置の特定ができていた。

今後は、CAE からの出力画像に含まれる欠陥部分を強調させた画像を用いた欠陥検出機能について検討し、CAE を欠陥検出システムに応用した場合の有効性を検証していきたい。

参考文献

- [1] 寺野 聡恭, 出水 享, 古賀 掲維, 中島 賢哉, 松田 浩, “深層学習を用いたコンクリート構造物のひび割れ抽出・判別方法に関する研究,” 長崎大学大学院工学研究科研究報告, pp. 71–76, 2020.
- [2] H. Perez, J. H. M. Tah, A. Mosavi, “Deep Learning for Detecting Building Defects Using Convolutional Neural Networks,” *Sensors*, Vol. 19, No. 16, pp. 3556–3579, 2019.

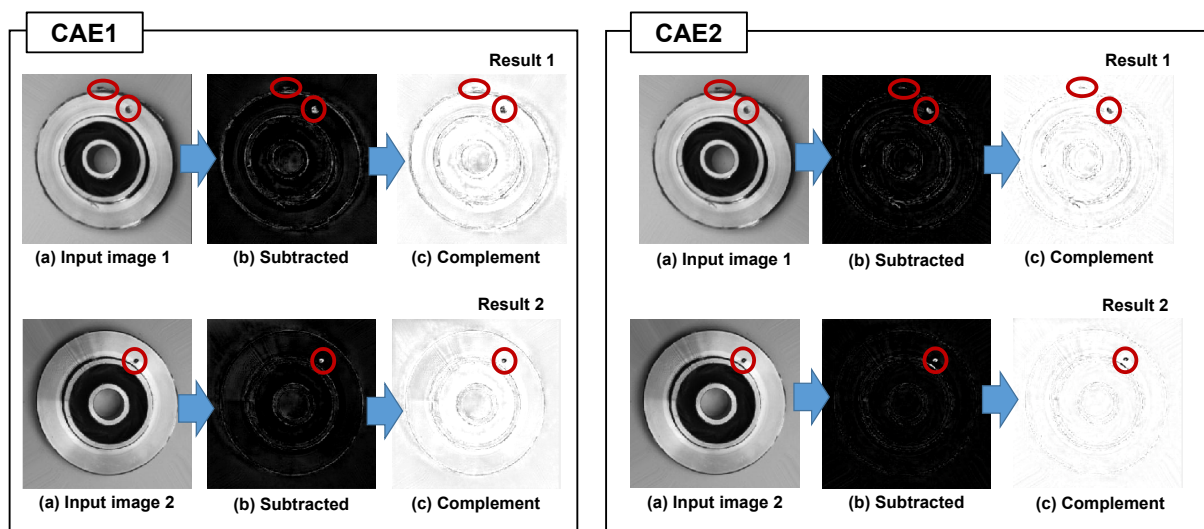


Fig. 6: Visualization results using designed two types of CAEs.

- [3] G.E. Hinton, R.R. Salakhutdinov, “Reducing the Dimensionality of Data with Neural Networks,” *Science*, Vol. 313, pp. 504–507, 2006.
- [4] F. Nagata, K. Tokuno, K. Watanabe, “Design and Training Application for Deep Convolutional Neural Networks,” *Procs. of Joint 10th International Conference on Soft Computing and Intelligent Systems and 19th International Symposium on Advanced Intelligent Systems in conjunction with Intelligent Systems Workshop 2018*, pp. 618–620, Toyama International Conference Center, 2018.
- [5] 中島 健斗, 永田 寅臣, 畳み込みニューラルネットワークを用いたラップロール製品の不良品検出, 第36回ファジィシステムシンポジウム FSS2020 講演論文集, pp. 111–115, 2020.
- [6] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. ”Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization.” *Procs. of 2017 IEEE International Conference on Computer Vision (ICCV2017)*, pp. 618–626, 2017.
- [7] V. Badrinarayanan, A. Kendall, R. Cipolla, “A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 39, No. 12, pp. 2481–2495, 2017.
- [8] K. Simonyan, A. Zisserman, “Very Deep Convolutional Networks for Large-scale Image Recognition,” *Procs. of International Conference on Learning Representations 2015 (ICLR2015)*, 14 pages, 2015.