

欠陥検出のための CNN & SVM 設計支援ツールの開発と適用実験 - 2 クラス分類用の CNN の場合 -

有馬 滉宜† 三木 康平† 中島 健斗† 永田 寅臣† 渡辺 桂吾†

† 山口東京理科大学大学院 工学研究科 ‡ 岡山大学学術研究院 自然科学学域

E-mail: nagata@rs.socu.ac.jp

1 はじめに

様々な工業製品における欠陥の種類やサイズは多岐にわたり、最終的な検査作業は検査員の目視検査に頼ることが大きな状況にある。しかし、検査員の育成には時間がかかり、また熟練の検査員でもその日の体調や気分によっては良品と不良品の判断基準の曖昧さが生じる。そこで近年では、AI 技術の中でも深層学習を画像認識に特化させた深層畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) [1] を応用して製品の検査工程における不良品検出や欠陥検出を行おうとするシステム開発の取り組みがなされている。例えば、T. Koeipensri らは、光沢のある金属製品における表面欠陥を CNN モデルである VGGNet を用いて検出を行う手法の有効性を提案した [2]。また、中島らは、筆記具部品の欠陥の有無をディープラーニングによる画像認識を用いて検査する研究を行った [3]。しかしながら、類似した多くの画像の中から微小な欠陥を高精度に検出し、不良品として分類することは困難だけでなく、ソフトウェアに関する高度な専門知識も必要とされるため製造メーカが検査システムを自社開発する上での大きな課題となっている。

筆者らは、これまでもプログラム開発や画像処理の初心者であっても高性能な不良品検出用 AI を設計できるように CNN&SVM 設計支援ツールや画像オーギュメンテーションなどの専用アプリケーションを提案してきた [4]。本稿では、図 1 のように実際に製造メーカから提供のあったラップフィルム製品の画像を用いて、開発中の CNN&SVM 設計支援ツールの有用性を検証する。マークのある部分には今回対象となる欠陥が含まれている。具体的には、学習済み CNN である InceptionV3 [5] の転移学習により新たに 2 種類の CNN を設計し、汎化性を発揮できるように画像拡張を施した多数の良品と不良品の画像を用いて訓練する。別途提供のあったテスト画像の分類実験によって設計した CNN を比較評価する。なお、数値目標はラップフィルム製造メーカの求める目標認識率 0.95 である。

2 画像オーギュメンテーションダイアログ

2.1 画像オーギュメンテーション

図 2 には様々な画像処理を加えて効率的に訓練データセットの水増しを行うために開発した画像オーギュメンテーションのためのダイアログを示す。このダイアログでは、限られた数のオリジナルの良品画像と不良品画像をもとに、生成させたい画像枚数を入力後にワンタッチ操作で多数の訓練画像を生成できる機能を持たせている。例えば、垂直または水平方向への反転、拡大縮小、指定した角度の回転、コントラストの変更、




Figure 1 Target images of wrap film products without and with defects.

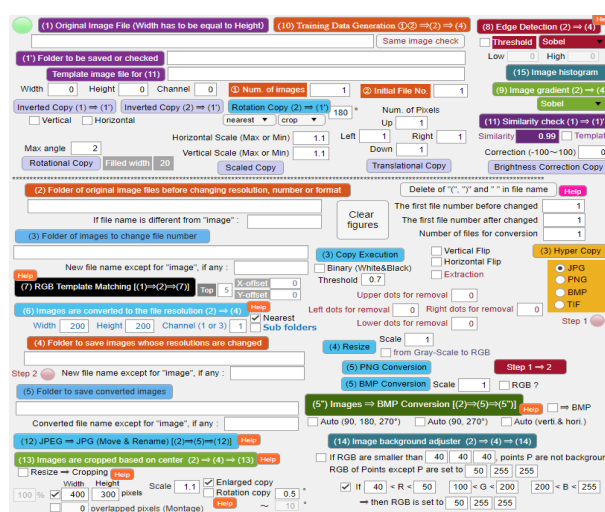


Figure 2 Image generator dialogue to augment limited number of training images.

エッジ検出、テンプレートマッチングなどである。生産ラインを流れてくるラップフィルムはジグにサポートされ方向が一定であり、上下左右の位置のバラツキも小さいため、水平方向への反転、テンプレートマッチング、エッジ検出などの画像処理を適用した。

図 3 には、ラップフィルム製品の不良品画像に対して画像オーギュメンテーションダイアログを用いて、回転、拡大縮小、水平・垂直反転の画像処理を施した画像の例を示している。±5 度だけ回転させた画像、オリジナルサイズから 90% に縮小させた画像、110% に拡大させた画像、水平および垂直反転させた画像をそれぞれ示している。不良品の発生頻度が低いためにこのような画像拡張の処理は、訓練データを準備する上で非常に有効であった。

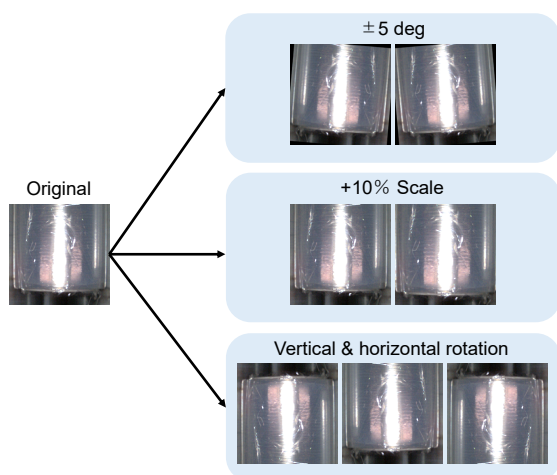


Figure 3 Examples of wrap film images augmented from an original one with a defect.

2.2 テンプレートマッチングによるターゲット領域の抽出

様々な課題に対する画像処理の中で広く利用されているテンプレートマッチングは、撮影されたワークの中で欠陥が含まれやすい領域を抽出するためにも非常に有効である。これから設計する CNN への入力画像のサイズを大幅に減らすことができ、計算コスト、メモリ占有コストも軽減することができる。このため、開発中のメイン、オプション及びオーギュメンテーションのダイアログの中ではテンプレートマッチング機能を利用できるようにしている。

(M, N) のサイズのテンプレートをターゲット画像内でラスタースキャンさせて相関係数の高い位置を検出する場合、周辺領域でもマッチング評価ができるように図 4 に示すようにパディング処理を行う。テンプレートとパディングにより拡張されたターゲット画像内の同面積の領域との相関係数 $\alpha(u, v)$ は次式から計算される。

$$\alpha(u, v) = \frac{s_{it}(u, v)}{s_i(u, v)s_t(u, v)} \quad (1)$$

$$s_{it}(u, v) = \sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \left\{ f(x, y) - \bar{f}_{u,v} \right\} \left\{ t(x-u, y-v) - \bar{t} \right\} \quad (2)$$

$$s_i(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \left\{ f(x, y) - \bar{f}_{u,v} \right\}^2} \quad (3)$$

$$s_t(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \left\{ t(x-u, y-v) - \bar{t} \right\}^2} \quad (4)$$

ここで、 (u, v) はターゲット画像内におけるテンプレート左上コーナーの座標である。 $s_t(u, v)$ と $s_i(u, v)$ はそれぞれ、テンプレートとターゲット画像内の比較領域の標準偏差であり、 $s_{it}(u, v)$ は共分散である。 $f(x, y)$ は




Figure 4 Configuration among a target image, padding area and template image with the size of (M, N) .




Figure 5 An example of extracted image using the template matching technique.

拡張された画像内の (x, y) におけるグレースケール 256 階調値を正規化した値である． $t(x-u, y-v)$ はテンプレート内の $(x-u, y-v)$ における同様の値である． M と N はそれぞれ，テンプレートの幅と高さである． \bar{t} と $\bar{f}(u, v)$ はそれぞれ，テンプレート内のグレースケール値の平均値と，ターゲット画像内のテンプレート真下の領域のそれである．式 (1) で与えられる相関係数 $\alpha(u, v)$ は，テンプレートをターゲット画像内の左上から右下までラスタースキャンさせることで計算される．ラスタースキャン後，テンプレートと最もマッチする領域，すなわち最も大きな値 $\alpha(u, v)$ を持つ領域が抽出される．図 5 には，ラップフィルム品のオリジナル画像からテンプレートで抽出された画像の例を示している．今回の実験では，図 5 のようにテンプレートマッチングにより 640×480 の解像度を持つラップフィルム製品の全体画像から目標領域をテンプレートと同じ正方形 347×347 の解像度で抽出し，ダウンサイジングした．

2.3 エッジ抽出による輪郭部の強調

エッジ抽出はオーソドックスな画像処理ではあるが、欠陥が周囲に点在するような製品を対象とする場合などは有効である。提案する画像拡張のアプリケーションでは Edge detection ボタンのクリックにより、ソーベル近似、プレウィット近似、ロバーツ近似など7種類のエッジ検出法を適用し、輪郭情報を抽出できるようにしている。これにより、輪郭を際立たせた画像に加工することで輪郭周辺に含まれる欠陥に対する検出精度を向上させることができるだけでなく、欠陥検出に不要な画像内の特徴情報を削減させることでJPGなど




Figure 6 Original image including a defect of core deformation and extracted images using the edge detection technique.

のフォーマットで個々の画像を圧縮保存する場合の容量も小さくできることが期待される。なお、図6のようにラップフィルム製品の場合は内部にも欠陥が含まれるケースが多いことや、欠陥部分が際立つような輪郭を生成できなかったため、ラップフィルムの欠陥検出を目的としたCNN構築にはエッジ検出法を適用しないこととした。

3 ラップフィルム製品の欠陥検出のための2クラス分類用CNNの設計と評価

図7に示すCNN&SVM設計支援ツールのメインダイアログでは、AlexNetなど学習済みのCNNの終段にある全結合層部を目的のクラス分類用に置き換える転移学習による新たなCNNの設計を可能にしている。例えば、訓練及び検証に用いるデータセットのあるフォルダの選択、学習率など詳細な学習条件の設定、プレートマッチング関連の設定、訓練終了後の評価に用いるテスト用データセットのあるフォルダの選択など、簡便な操作環境を提供している。

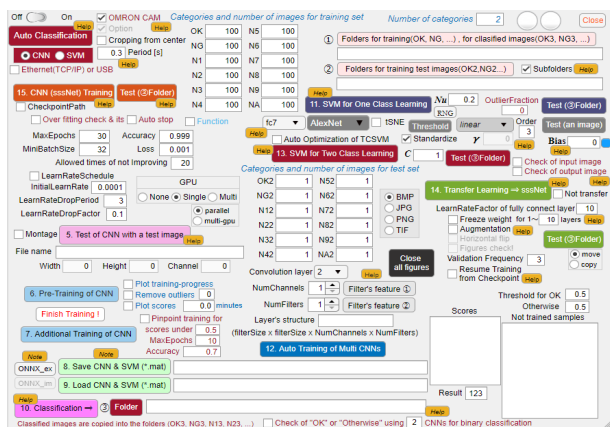


Figure 7 Main dialogue to user-friendly design and train CNNs and SVMs.

3.1 転移学習によるCNNの設計と訓練及び検証

図7のアプリケーションを用いて、InceptionV3の転移学習による2クラス分類用CNNを新たに設計す

る。図8には、オリジナルのInceptionV3と各モジュールの構造を示している。InceptionV3は、ILSVRC2014で優勝したGoogLeNetの畳み込みフィルタのサイズ変更とバッチ正規化を導入したアーキテクチャを持つ[5]。InceptionV3はImageNetデータベースの100万枚を超える画像で事前に学習されており、入力画像のサイズは $299 \times 299 \times 3$ に固定されている。図9には、InceptionV3の終段にある全結合層部を2クラス分類用に置き換え、新たに設計したCNNの構造を示す。

転移学習によりCNNを構築する上での学習法としてファインチューニングがある[6]。KandelらはInceptionV3、VGG16、VGG19それぞれに対して、幾つかのブロックごとにファインチューニングを適用し、組織病理画像をより高い精度で分類できる方法についての研究を行っている[7]。その中ではInceptionV3のネットワーク全体をファインチューニングさせることにより、最も良い結果が得られたと報告されている。本稿ではKandelらと同様に、転移元の学習済みCNNのモデルの畳み込み層の重みをそのまま初期値とし、適用先のボリュームの小さいデータセットで畳み込み層および全結合層の重みの学習を行う。

具体的には、畳み込み層を学習率0.0001でファインチューニングさせたものをIncA、畳み込み層の重みは更新させないものをIncBとし、2種類のCNNを設計した。このため、学習後のIncBについては、全結合層部以外の全ての層の重みはInceptionV3のそれと同値を持つことになる。IncAとIncB共通の学習条件として、最大エポックを4、ミニバッチサイズを50、全結合層の学習率を畳み込み層のその10倍となる0.001に設定した。また、訓練用データセットは良品画像34,482枚と不良品画像2,233枚で構成した。

3.2 分類実験

訓練後のIncAとIncBの汎化性能を評価するためにテスト用データセットとして良品画像4,035枚と不良品画像42枚の計4,077枚を用いて分類実験を行った。表1にはIncAの全体的な認識結果を表す混同行列を示す。誤認識された合計枚数は4枚で、その内3枚の不良品画像は良品画像として誤認識され、1枚の良品画像は不良品画像として誤認識されていた。この1枚の良品画像を観察すると、図10のように不良品の画像に類似したグレーな状態であったことが観察された。

表1と同様に表2にはIncBの全体的な認識結果を表す混同行列を示す。誤認識した合計枚数は29枚であり、この中にはIncAが誤認識していた4枚の画像も含まれていた。

3.3 比較評価

次に本実験で使用した3つの評価基準である認識率、精度、再現率について説明する。認識率はテスト画像データセットに対する正解率を、精度は不良品と判断された画像のうち実際に不良品であった割合を、再現率は実際に不良品である画像が正しく不良品と判断された割合をそれぞれ表す。これらの指標をもとにIncAとIncBの汎化性能を評価する。全体のデータの中で不良品を不良品として分類したものを T_P 、良品を良品として分類したものを T_N 、不良品を良品として誤分類したものを F_N 、さらに良品を不良品として誤分類したものを F_P としたとき認識率 A_c 、精度 P_r 、再現率 R_e はそれぞれ、次式で与えられる。表3には表1, 2の結果に基づき算出した認識率、精度、再現率の結果を示している。

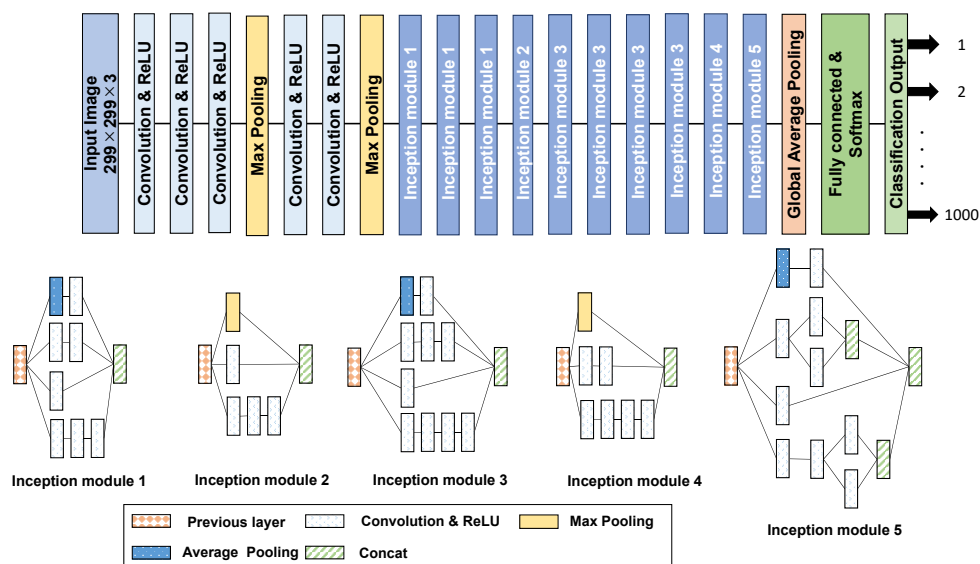


Figure 8 Architecture of original InceptionV3.




Figure 9 Reconstructed InceptionV3 architecture for binary classification using transfer learning technique.




Figure 10 Problem of similarity between non-defective image in test and defective images in training.

Table 1 Confusion matrix classified by IncA (row: true labels, column: predicted labels).

	Normal	Anomaly
Normal	4034	3
Anomaly	1	39

Table 2 Confusion matrix classified by IncB (row: true labels, column: predicted labels).

	Normal	Anomaly
Normal	4017	11
Anomaly	18	31

Table 3 Statistical evaluation results of IncA and IncB.

CNN	Accuracy	Precision	Recall
IncA	0.999	0.975	0.928
IncB	0.992	0.633	0.738

IncA の認識率及び再現率はそれぞれ、0.999 と 0.928 であり、ラップフィルム製造メーカーの求める目標認識率 0.95 を超えることができた。また、不良品を取りこぼすことなく検出できていることを示す再現率の数値も高くなっていたことが分かった。一方、IncB の認識率

及び再現率はそれぞれ、0.992 と 0.738 であった。IncA と同様に、認識率はラップフィルム製造メーカーの求める目標認識率 0.95 を超えていたが、不良品画像を良品

画像と誤認識した枚数が 11 枚と多かったため、再現率は IncA より低い値となった。製造ラインにおける不良品の検出ミスは流通後の商品回収、リコールなど重大な問題に発展するため、不良品を不良品として検出できた割合である再現率の値が重視される。以上の結果から、今回試行したラップフィルム製品の欠陥検出実験では、転移学習により新たに設計した CNN に対し、畳み込み層を軽微にファインチューニングさせた IncA の方が優れていたと言える。

実際の生産ラインでは一つ一つのワークの分類に要する時間が少ないことが望まれる。IncA に対し画像を与える前と結果が出力された後のタイムスタンプの差から分類に要した時間を 5 回計測し、平均したところ 0.333 ms であった。なお、今回使用したコンピュータは、CPU: Intel Core i9-10980XE 3.00 GHz、メモリ: 64 GB、GPU: NVIDIA TITAN RTX 24 GB である。

4 おわりに

本稿では、開発中である CNN&SVM 設計支援ツールを用いて学習済みの CNN である InceptionV3 の転移学習による新たな CNN を設計し、ラップフィルム製品の製造工程で発生する欠陥の検出を試みた。治具を含むラップフィルムの全体画像に対してテンプレートマッチングを適用し、ラップフィルム製品部分のみを抽出する画像処理を行うことで、良品と不良品のターゲット領域のオリジナル画像を採集した。次に、これらのオリジナル画像と、それらに水平反転の画像拡張を施し増やした多数の画像を加えてデータセットを構成し、転移学習時の畳み込み層の重み更新を軽微に行うファインチューニングを適用した。畳み込み層をファインチューニングさせた CNN (IncA) と、畳み込み層の重みを更新させない CNN (IncB) をそれぞれ設定し、どちらの場合も後段の全結合層は通常の学習率で訓練を行った。不良品の画像を含むテスト画像を用いた分類実験を行ったところ、2 つの CNN はラップフィルム製造メーカーが求める目標認識率 0.95 を達成することができた。また、再現率の点では IncA の方が優れていた。

今回の試行により、提案する CNN&SVM 設計支援ツールの有用性を確認することができたため、今後は他の工業製品の検査工程にも転移学習ベースの CNN による欠陥検出法を適用し、ユーザの視点から開発ツールの操作性、有用性および安定性を高めていきたい。

References

- [1] A. Krizhevsky, I. Sutskever, and G.E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” *Advances in Neural Information Processing Systems*, pp. 1–12, 2012.
- [2] T. Koeipensri, 保田俊行, 神代 充, “CNN を用いた画像分類に基づく電子部品の表面欠陥の検出”, 第 63 回自動制御連合講演会, 2020 .
- [3] 中島彩奈, 田中雄太, 西谷一希, 茂木和弘, 白石洋一, “製品の外観検査における畳み込みニューラルネットワークのトレーニング”, 第 32 回エレクトロニクス実装学術講演大会, pp. 348–349, 2018 .
- [4] 永田寅臣, 渡辺桂吾, “不良品検出のための畳み込みニューラルネットワークとサポートベクトルマシン設計支援ツール”, システム / 制御 / 情報, Vol. 64, No. 8, pp. 304–309, 2020.
- [5] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna “Rethinking the Inception Architecture for Computer Vision,” *Procs. of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2818–2826, 2016.
- [6] 中山英樹 “深層畳み込みニューラルネットワークによる画像特徴抽出と転移学習”, 信学技報, pp. 55–59, 2015.
- [7] I. Kandel and M. Castelli, “How Deeply to Fine-Tune a Convolutional Neural Network: A Case Study Using a Histopathology Dataset,” *Applied Science*, Vol. 10, No. 10, pp. 1–20, 2020.