

## 『特集名』特集号

## 解 説

不良品検出のための畳み込みニューラルネットワークと  
サポートベクタマシン設計支援ツール

永田 寅臣\*, 渡辺 桂吾†

## 1. はじめに

工業製品における欠陥の種類やサイズは多岐にわたり、最終的な検出作業は熟練者の目視に頼るケースがほとんどである。寸法など数値的な画像解析により欠陥を検出しようとするシステムでは、それぞれの欠陥の特徴の定量化が難しく、画像内での形状、位置、サイズ、姿勢などの違いにより検出精度が大きく劣ってしまうという欠点がある。最近、AI 技術の中でも深層学習 (Deep Learning: DL) を画像認識に特化させた深層畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) [1] を応用して不良品検出や欠陥検出を行おうとするシステム開発の取り組みがなされている。また、1963 年に Vapnik らが発表したサポートベクターマシン (Support Vector Machine: SVM) は、線形分類問題を解くことができる教師あり学習による認識モデルであったが、1990 年代になりカーネル学習法が提案され非線形分類問題へと拡張されるとともに優れた分類性能が広く知られるようになった [2-4]。しかしながら、類似した多くの画像の中から微小な欠陥を高精度に検出し、不良品として分類することは困難だけでなく、ソフトウェアに関する高度な専門知識も必要とされるため樹脂成型品など中小規模の製造メーカーが検査システムを自社開発する上での大きな課題となっている [5,6]。

筆者らは、プログラム開発や画像処理の初心者であっても高性能な不良品検出用 AI を設計できるように CNN&SVM 設計支援ツールを開発している。これにより、CNN, SVM といった分類器に対して転移学習、追加学習などの学習アルゴリズムを適用し、静止画や動画に含まれる工業製品の欠陥を検出するためのシステム構築の支援が可能になってきた。実際、地域のものづくりの現場では作業者が環境設定から運用までを容易に行えるシステムへのニーズが高いため、試用を通じた普及と利用者からのフィードバックに基づく機能改善を図っている。開発環境は MATLAB であり、Neural Network Toolbox, Parallel Computing Toolbox for GPU, Deep Learning Toolbox, Statistics and Machine Learning Toolbox [7]

などを用いている。

## 2. 開発内容


このツールは、画像オーギュメンテーションダイアログ、メインダイアログ、パラメータダイアログ、オプションダイアログから構成されている。

## 2.1 画像の編集と生成用ダイアログ

画像オーギュメンテーションダイアログは訓練用画像を効率的に生成させるために開発している。製造現場では、例えば図 1 のような不良品の画像の収集に苦慮するケースが多いようであるが、限られた数のオリジナルの良品画像と不良品画像をもとに生成させたい枚数を入力すれば、ワンクリック操作で多数の訓練画像を生成できる機能を持たせている。左右回転、上下左右反転、拡大縮小、明暗変化などの変化を与えながら、PNG, JPG, BMP など指定された画像フォーマットで自動生成させる機能である。このほか、全ての訓練画像に対して一括でテンプレートマッチングを適用し、指定された領域のみを抽出する機能や、微分係数にソーベル近似、プレウィット近似、ロバーツ近似などを適用したエッジ検出で輪郭情報を抽出する機能により、画像サイズに関するコストを大幅に軽減しながら重要な特徴を含む新たな訓練画像を効率的に生成できるようにしている。

## 2.2 CNN, SVM 構築用メインダイアログ

図 2 に示す CNN&SVM 設計ツールのメインダイアログではシリーズ型の CNN の設計と学習に加えて、有向非循環グラフ (Directed Acyclic Graph: DAG) ネットワークを含む様々な CNN を特徴抽出器として用いる SVM、既に学習済みの CNN の後半部にある全結合層部を新たな目的のクラス分類用に置き換える転移学習による CNN の設計などを可能にしている。CNN 単体の設計ではパラメータ設定用ダイアログを通じて、畳み込み




第 1 図 樹脂成型品の製造工程で発生する欠陥のイメージ。

\* 山口東京理科大学大学工学部機械工学科

† 岡山大学大学院自然科学研究科

**Key Words:** defect detection, convolutional neural network, support vector machine, design and training tool





第 3 図 オリジナルの sssNet を特徴抽出器に用いた 2 クラス分類用の SVM の例。

うに分類平面が配置される。初期値は 0.2 であるが、メインダイアログ内で変更できるようにしている。

さて、特徴抽出器として利用される sssNet にテスト画像が入力されると特徴ベクトル  $\mathbf{x} \in \mathbb{R}^{32 \times 1}$  が得られる。この  $\mathbf{x}$  を学習後の SVM に対して与えると次式で与えられるスコア  $f(\mathbf{x})$  が出力される。 $f(\mathbf{x})$  は分類の基準となる超平面からの符号付距離である。

$$f(\mathbf{x}) = \sum_{i=1}^N \alpha_i y_i G(\mathbf{x}_i^*, \mathbf{x}) + b \quad (1)$$

ここで、 $\mathbf{x}_i^* \in \mathbb{R}^{1 \times 32}$  ( $i=1, 2, \dots, N$ ) と  $N$  はそれぞれ、良品の画像データを使った学習過程で得られたサポートベクタとその数である。 $\alpha_i$  ( $i=1, 2, \dots, N$ ) と  $b$  はそれぞれ、ラグランジュ乗数とバイアスである。 $y_i$  はラベルであり、1 クラス学習の場合は常に 1 がセットされる。 $G(\mathbf{x}_i^*, \mathbf{x})$  は高次元化のためのカーネル関数であり、今回の実験では次式で与えられるガウシアン関数を用いた。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \exp\left(-\left\|\frac{\mathbf{x}_i^* - \mathbf{x}_s}{k}\right\|^2\right) \quad (2)$$

ここで、 $k$  と  $\mathbf{x}_s$  はそれぞれ、カーネルスケールと次式で与えられる標準化された入力ベクトルである。


$$\mathbf{x}_s = (\mathbf{x} - \mathbf{x}_\mu) \oslash \mathbf{x}_\sigma \quad (3)$$

ただし、

$$\mathbf{x}_\mu = \frac{\sum_{j=1}^{5100} \mathbf{x}_j}{5100} \quad (4)$$

$$\mathbf{x}_\sigma = \left[ \frac{1}{5100} \sum_{j=1}^{5100} (\mathbf{x}_j - \mathbf{x}_\mu)^{\circ 2} \right]^{\circ \frac{1}{2}} \quad (5)$$

ここで、 $\oslash$ ,  $\circ 2$ ,  $\circ \frac{1}{2}$  はそれぞれ、要素毎の商、二乗および根号を表すアダマール演算子である。今回は試行的に  $\nu=0.5$  とし、欠陥を含まない良品のみの画像 5100 枚を用いて SVM を学習させた結果、得られた  $k$ ,  $N$  および




第 4 図 1 クラスの教師なし学習による最適化後の SVM。


$b$  はそれぞれ、1.1875, 2621, -1.0639 であった。図 4 には、1 クラス学習後に得られたサポートベクタマシンを示す。不良品を含むテスト画像から得られた特徴ベクトルの 2 クラス分類は  $f(\mathbf{x})$  の符号をチェックすることで、 $f(\mathbf{x}) > 0$  の場合は良品、 $f(\mathbf{x}) < 0$  の場合は学習時に使用した良品画像と異なる特徴を持つ不良品の画像と推定できる。次式で与えられる  $n$  次多項式などもカーネル関数として利用できるが、画像や特徴ベクトルとの相性は実際の学習とテストデータによる汎化性の評価により確認する必要がある。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \left[ 1 + \frac{(\mathbf{x}_i^*)^T \mathbf{x}_s}{k} \right]^n \quad (6)$$

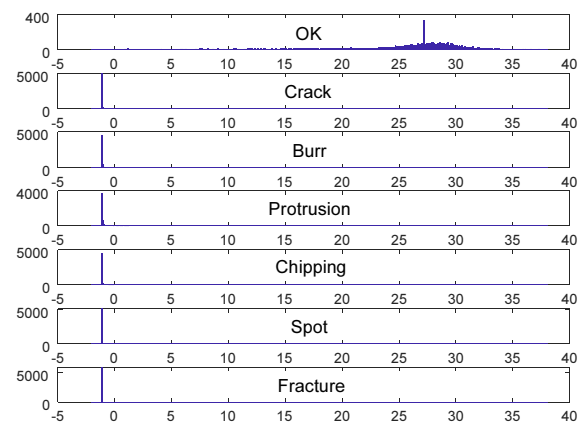
つぎに、ImageNet データベースの 100 万枚を超える画像で学習済みの畳み込みニューラル ネットワークである AlexNet を用いてもう一つの SVM を設計する。このネットワークは全 25 層から構成され、入力画像を 1000 種類のカテゴリに分類できるため、豊富な特徴を表現できる能力を獲得していると言える。ネットワークへの画像の入力サイズは  $227 \times 227$  であり、RGB の 3 チャンネルを持つ。このため、訓練およびテスト画像が異なる解像度もしくはグレースケールなど異なるチャンネル数を持つ場合には  $227 \times 227 \times 3$  に変換しなければならない。ここでは、ターゲットとなる樹脂成型品の模擬画像を用いた訓練およびテスト時、入力画像に対して第 2 全結合層



第 5 図 AlexNet を特徴抽出器に用いた 2 クラス分類用の SVM.



第 6 図 図 3 の SVM による分類結果 (ヒストグラム).



第 7 図 図 5 の SVM による分類結果 (ヒストグラム).

から出力される特徴ベクトル  $\mathbf{x} = [x_1, x_2, \dots, x_{4096}]^T$  を SVM への入力として用いる. AlexNet ではこの 4096 要素の特徴ベクトルから 1000 種類の分類を行う機能を実現している. 図 5 には AlexNet の第 20 層目にあたる第 2 全結合層からの出力である特徴ベクトルを SVM への入力として設計した SVM の例を示す. 学習には sssNet のときと同様に 5100 枚の良品の画像から得られた特徴ベクトル  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{5100} \in \mathbb{R}^{4096 \times 1}$  のみを用いて行った. カーネル関数などその他のパラメータについても sssNet を用いたときと同様である. 学習により, 得られた  $k, N$  および  $b$  はそれぞれ, 26.7690, 2667,  $-1.0635$  となった.

### 3.2 二つの SVM による分類実験

ここでは, メインダイアログを用いて良品と不良品のテスト画像からなるデータセットの分類実験を行い, 前節で設計から学習までを行った二つの SVM の汎化性を評価する. テスト画像は学習時に用いた画像のデータセットには含まれていない. 図 6 は, 図 3 で紹介した学習後の SVM による分類結果を示したヒストグラムである. 横軸と縦軸はそれぞれ, sssNet を特徴抽出器とした SVM からの出力  $f(\mathbf{x})$  と分類された画像の枚数である. この結果から SVM は良品の画像と欠陥を含む画像を良好に分類できていることが確認できる.

第 1 表 誤分類された画像枚数による比較結果.

SVM	Burr	Crack	Chip.	Knob	Spot	Frac.
sssNet	13	4	1	0	0	0
AlexNet	167	20	298	127	0	0

また, 図 7 には同じテスト画像を用いて図 5 の AlexNet を特徴抽出器とした SVM による分類結果を示す. この図から sssNet ベースの SVM と同様, 良好に分類できていることが確認できる. 実際, sssNet と AlexNet から出力された特徴ベクトルの長さはそれぞれ, 32 と 4096 と大きく異なっていたものの, ヒストグラムからは同じような傾向の分類性能が得られていたことが分かる.

今回の CNN&SVM 設計ツールの使用テストでは, 図 1 のような樹脂成型品を模擬した  $200 \times 200$  のグレースケール画像を用いているが, 要素数 4096 の特徴ベクトルは冗長であったかもしれない. 表 1 にはそれぞれの SVM を使った評価において誤分類された, すなわち欠陥を含む不良品の画像にもかかわらず良品として分別された画像の枚数を示す. この表からは, ターゲットとなる樹脂成型品の模擬画像で直接訓練していた sssNet を特徴抽出器として用いた SVM の優位性を確認できる.



### 3.3 2クラスの教師なし学習によるSVMの例

前節では、1クラスの教師なし学習で設計した2種類のSVMを紹介した。ここでは、AlexNetを特徴抽出器に用いた2クラスの教師あり学習によるSVMも試行的に設計し、評価を行う。2クラス学習では良品の画像と欠陥を含む不良品の画像を用いてSVMの学習を行う。学習後、SVMの出力であるスコア関数 $f(\mathbf{x})$ は式(1)で表されるが、ラベル $y_i$ には $i$ 番目のサポートベクトルが良品側のクラスの場合に1が、不良品側のクラスの場合には-1が設定される。カーネル関数 $G(\mathbf{x}_i^*, \mathbf{x})$ に次式で与えられる線形関数を用いた場合

$$G(\mathbf{x}_i^*, \mathbf{x}) = \frac{(\mathbf{x}_i^*)^T \mathbf{x}_s}{k} \quad (7)$$


式(1)で与えられるスコア関数は次式のように表される。

$$f(\mathbf{x}) = \frac{\mathbf{x}_s^T}{k} \boldsymbol{\beta} + b \quad (8)$$

ここで、 $k$ はカーネルスケール、 $\boldsymbol{\beta} \in \mathbb{R}^{4096 \times 1}$ は線形係数ベクトル、 $b$ はバイアスである。 $k$ 、 $\boldsymbol{\beta}$ および $b$ は学習を通じて得られるSVMのパラメータである。図8には式(8)で与えられたSVMの構造を示す。このとき、特徴ベクトル $\mathbf{x} \in \mathbb{R}^{4096 \times 1}$ はAlexNetの第2全結合層からの出力である。学習時、正の定数として与えられる正則化係数 $C$ を変更できるようにしており、ソフトマージンの程度を調整することができる。今回の学習では $C=1$ としているが、 $C$ が大きくなるにつれてハードマージンの条件に近づいていくことが知られている。

### 3.4 2クラス学習によるSVMの分類実験

図8に示すSVMを学習するために5100枚の良品の画像と、5100枚×6種類の欠陥を含む不良品画像を用意した。欠陥の種類については図1に示したとおりである。今回の学習では、 $k$ 、 $N$ および $b$ はそれぞれ、63.8168、698、4.9334のように最適化された。表2には学習後の過学習の状況を確認するために、学習で用いた画像を分類させた結果をまとめた混合行列であり、認識率 (accuracy) と精度 (precision) はそれぞれ、0.9990、0.9997であることがわかる。次に、学習後のSVMの汎化性を評価す



第8図 2クラスの教師あり学習による最適化後のSVM。

第2表 SVMの訓練状況を示す混合行列。

Actual \ Predicted	Anomaly	Normal
Anomaly	30573	27
Normal	8	5092

第3表 未学習のデータを用いたSVMの評価結果。


Actual \ Predicted	Anomaly	Normal
Anomaly	5987	13
Normal	3	997

るために1000枚の良品の画像と、1000枚×6種類の欠陥を含む不良品画像を新たに用意し分類させたところ、表3のような結果が得られた。このときの認識率と精度はそれぞれ、0.9977、0.9995である。今回は過学習を防ぐために分類境界は正則化係数を含むソフトマージンのコンセプトをもとに最適化されており、表2のように訓練データに対しても誤分類が発生していたことが分かる。誤分類に対する許容の程度については実際の検査ラインへの適用段階で検討されなければならない。


### 3.5 テンプレートマッチングによる特徴抽出

様々な課題に対する画像処理で広く利用されているテンプレートマッチングは、撮影されたワークの中で欠陥が含まれやすい領域を抽出するためにも非常に有効である。結果的に、これから設計するCNNやSVMへの入力画像のサイズを大幅に減らすことができ、計算コスト、メモリ占有コストを削減することができる。このため、メイン、オプション及びオーギュメンテーションのダイアログの中ではテンプレートマッチングの機能を利用できるようにしている。

実装したテンプレートマッチング機能により、オリジナルの3000枚の良品画像から切り出した画像を用いて図5で紹介したSVMに学習させたところ、得られたパラメータ $k$ 、 $N$ および $b$ はそれぞれ50.0116、1,526、-5.6925であった。学習後のSVMの汎用化性をチェックするために図9のような良品と不良品からなる120枚



第9図 訓練後のSVMを評価するための未学習データ。



第 10 図 120 枚のテスト画像による分類結果.

のテスト画像を用意し, 分別実験を行った結果を図 10 に示す. この評価実験では, 120 枚全ての画像が良好に良品あるいは不良品に分類され, テンプレートマッチングの有効性を確認することができた.

#### 4. おわりに

本稿では, 畳み込みニューラルネットワークとサポートベクターマシンを応用した欠陥検出システムについて紹介した. プログラム開発や画像処理の初心者であっても高性能な不良品検出用 AI を設計できるように現在開発中の CNN&SVM 設計支援ツールについては, 評価用の樹脂成型品を模倣した画像のデータセットを用いた評価実験により有用性を確認することができた. 現在, このアプリケーション内に操作方法の説明を組み込みながら, 山口県内外のものづくり企業 3 社との共同研究を通して実ラインへの適用に取り組んでいる. そこでは本稿で紹介したソフトウェアと, それぞれの製造工程が対象とするワーク, 工作機械や産業用ロボットといった機械装置, ピッキングのためのハンドなどハードウェアとの統合を考慮したシステム開発が中心となっている.

#### 参考文献

- [1] A. Krizhevsky, I. Sutskever, and G.E. Hinton: ImageNet classification with deep convolutional neural networks; *Advances in neural information processing systems*, pp. 1–12 (2012)
- [2] V. Vapnik: *The Nature of Statistical Learning Theory*, Springer, New York, (1995)
- [3] N. Cristianini, J. Shawe-Taylor, 大北 (訳): サポートベクターマシン入門, 共立出版, (2005)
- [4] 竹内, 鳥山: サポートベクトルマシン, 講談社, (2015)
- [5] 徳野, 永田, 大塚, 渡辺: 畳み込みニューラルネットワークを応用した不良品検出の基礎研究, 日本機械学会九州支部北九州講演会講演論文集, pp. 35–39, 北九州市立大学ひびきのキャンパス (2018)
- [6] 中島, 永田, 渡辺: 畳み込みニューラルネットワーク (CNN) とサポートベクターマシン (SVM) を用いた微小な欠陥を持つ不良品検出の基礎研究, ロボティクス・メ

カトロニクス講演会 2019 講演論文集, 4 pages, 広島国際会議場 (2019)

- [7] <https://jp.mathworks.com/>
- [8] J. Platt: Sequential minimal optimization: A fast algorithm for training support vector machines, *Technical Report MSR-TR-98-14*, pp. 1–24 (1998)
- [9] F. Nagata, K. Tokuno, K. Nakashima, A. Otsuka, T. Ikeda, H. Ochi, K. Watanabe, M.K. Habib: Fusion method of convolutional neural network and support vector machine for high accuracy anomaly detection; *Procs. of the 2019 IEEE International Conference on Mechatronics and Automation (ICMA 2019)*, pp. 970–975 (2019)
- [10] F. Nagata, K. Tokuno, K. Mitarai, A. Otsuka, T. Ikeda, H. Ochi, K. Watanabe, M.K. Habib, “Defect detection method using deep convolutional neural network, support vector machine and template matching techniques,” *Artificial Life and Robotics*, Vol. 24, No. 4, pp 512–519 (2019)

#### 著者略歴

永田寅臣: 1962 年 7 月 22 日生. 1985 年九州工業大学工学部電子工学科卒業. 1985 年九州松下電器株式会社, 1989 年福岡県工業試験場, 1990 年福岡県工業技術センター, 1999 年佐賀大学大学院工学系研究科博士後期課程修了, 2006 年山口東京理科大学基礎工学部電子情報工学科助教授, 2012 年同工学部機械工学科教授となり現在に至る. 様々なメーカーの産業用ロボットを応用した加工, 研磨, 仕上げ工程などの自動化システムの開発, 機械学習を応用した製品の欠陥検出システムの開発などに従事. 日本機械学会, 計測自動制御学会, 日本ロボット学会, 日本知能情報ファジィ学会, 産業応用工学会, IEEE の会員.

渡辺桂吾: 1978 年徳島市市役所嘱託研究員. 1979 年 (株) 数値解析研究所. 1980 年九州大学工学部航空工学科助手. 1985 年静岡大学工業短期大学部助教授. 1990 年佐賀大学理工学部生産機械工学科助教授. 1993 年同教授. 1997 年同機械システム工学科教授. 1998 年佐賀大学大学院工学系研究科生体機能システム制御工学専攻教授. 2009 年岡山大学大学院自然科学研究科産業創成工学専攻. ソフトコンピューティング, 生物模倣ロボット, 各種ロボット制御の研究教育に従事. 計測自動制御学会, 日本知能情報ファジィ学会, 日本機械学会, 日本航空宇宙学会, 日本ロボット学会, システム制御情報学会, 精密工学会, IEEE の会員.