

# 不良品検出のための畳み込みニューラルネットワークと サポートベクタマシン設計支援ツール

永田寅臣† 中島健斗† 三木康平† 渡辺桂吾‡

† 山口東京理科大学大学院 工学研究科

‡ 岡山大学大学院 自然科学研究科

E-mail: nagata@rs.socu.ac.jp

## 1 はじめに

工業製品における欠陥の種類やサイズは多岐にわたり、最終的な検出作業は熟練者の目視に頼るケースがほとんどである。寸法など数値的な画像解析により欠陥を検出しようとするシステムでは、それぞれの欠陥の特徴の定量化が難しく、画像内での形状、位置、サイズ、姿勢などの違いにより検出精度が大きく変わってしまうという欠点がある。最近、AI 技術の中でも深層学習 (Deep Learning: DL) を画像認識に特化させた深層畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) [1] を応用して不良品検出や欠陥検出を行おうとするシステム開発の取り組みがなされている。また、1963 年に Vapnik らが発表したサポートベクターマシン (Support Vector Machine: SVM) は、線形分類問題を解くことができる教師あり学習による認識モデルであったが、1990 年代になりカーネル学習法が提案され非線形分類問題へと拡張されるとともに優れた分類性能が広く知られるようになった [2, 3, 4]。しかしながら、類似した多くの画像の中から微小な欠陥を高精度に検出し、不良品として分類することは困難だけでなく、ソフトウェアに関する高度な専門知識も必要とされるため中小規模の製造メーカーが検査システムを自社開発する上での大きな課題となっている [5, 6]。

筆者らは、プログラム開発や画像処理の初心者であっても高性能な不良品検出用 AI を設計できるように CNN&SVM 設計支援ツールを開発している。これにより、CNN, SVM といった分類器に対して転移学習、追加学習などの学習アルゴリズムを適用し、静止画や動画に含まれる工業製品の欠陥を検出するためのシステム構築の支援が可能になってきた。実際、地域のものづくりの現場では作業者が環境設定から運用までを容易に行えるシステムへのニーズが高いため、試用を通じた普及と利用者からのフィードバックに基づく機能改善を図っている。

開発環境は MATLAB であり、Neural Network Toolbox, Parallel Computing Toolbox for GPU, Deep Learning Toolbox, Statistics and Machine Learning Toolbox [7] などを用いている。

## 2 開発内容

このツールは、画像オーギュメンテーションダイアログ、メインダイアログ、パラメータダイアログ、オプションダイアログから構成されている。現場ユーザへの分かり易い操作インタフェースとして提案するために、様々な対話型コンポーネントが提供された開発環境である App Designer を用いている。

### 2.1 画像の編集と生成用ダイアログ

図 1 には訓練用画像を効率的に生成させるために開発した画像オーギュメンテーションのためのダイアログを示す。製造現場では、例えば図 2 のような不良品の画像の収集に苦慮するケースが多いようであるが、限られた数のオリジナルの良品画像と不良品画像をもとに生成させたい枚数を入力すれば、ワンクリック操作で多数の訓練画像を生成できる機能を持たせている。左右回転、上下左右反転、拡大縮小、明暗変化などの変化を与えながら、PNG, JPG, BMP, TIF など指定された画像フォーマットで自動生成させる機能である。このほか、全ての訓練画像に対して一括でテンプレートマッチングを適用し、指定された領域のみを抽出する機能や、微分係数にソーベル近似、プレウィット近似、ロバーツ近似などを適用したエッジ検出で輪郭情報を抽出する機能により、画像サイズに関するコストを大幅に軽減しながら重要な特徴を含む新たな訓練画像を効率的に生成できるようにしている。

### 2.2 CNN と SVM 構築用のメインダイアログ

図 3 に示す CNN&SVM 設計ツールのメインダイアログではシリーズ型の CNN の設計と学習に加えて、有向非循環グラフ (Directed Acyclic Graph: DAG) ネットワークを含む様々な CNN を特徴抽出器として用いる SVM、既に学習済みの CNN の後半部にある全結合層部を新たな目的のクラス分類用に置き換える転移学習

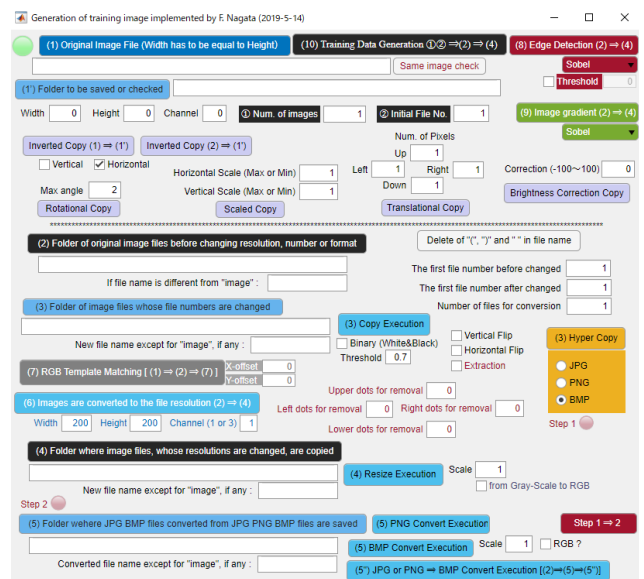


Figure 1 Image augmentation dialogue to efficiently generate several types of images.

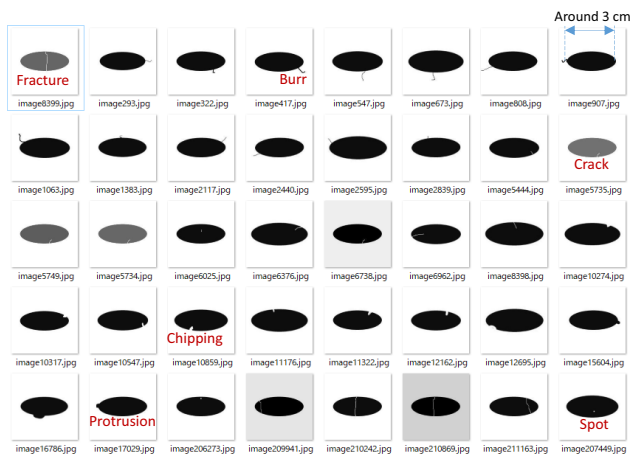


Figure 2 Examples of six kinds of defects which appear in production process of resin molded articles, whose lengths are about 30 mm.

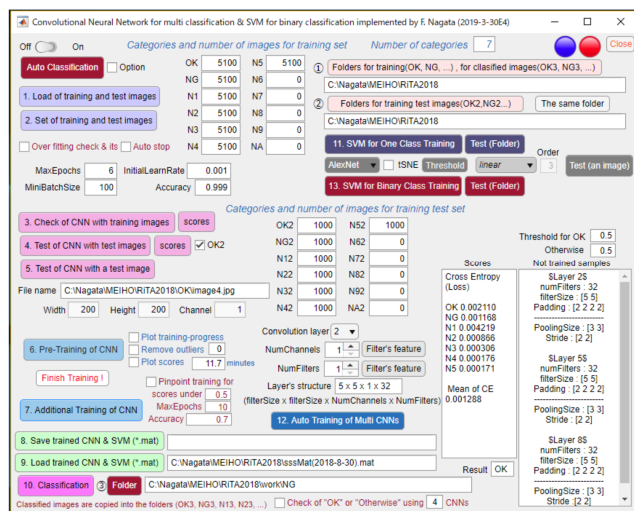


Figure 3 Main dialogue to user-friendly design and train CNNs and SVMs.

による CNN の設計などを可能にしている。

CNN 単体の設計時には図 4 に示すパラメータ設定用のサブダイアログを表示させて、畳み込み層、ReLU 層、Pooling 層などを含む層数、各畳み込み層のフィルタ数とサイズ、パディング、ストライド、Pooling 層の各パラメータなど細かな構造に加えて、バッチ正規化層、Global Average Pooling 層の使用の有無を設定できる。CNN 単体の学習では、分類するカテゴリ数、各カテゴリの訓練用及びテスト用画像のあるフォルダ、学習率、ミニバッチサイズ、マックスエポック、目標の認識精度などの設定や、初期化されたフィルタの重みで学習を始める事前学習、既に訓練されている重みを使って学習を始める追加学習を選択できるなどの機能を持つ。また、評価用の画像が入力されたとき各畳み込み層の各フィルタが活性化させた特徴マップの状況を確認できる機能を持たせている。さらに、バイナリクラスの分類を行うことができる SVM の学習では、様々なシステムでその性能が認知されているシリーズネットワークの AlexNet, VGG16, VGG19, DAG ネットワークである GoogleNet, Inception-v3, IncResNet-v2 に加えてオリジナルで設計した CNN (sssNet) を特徴抽出器として選択できる機能、良品 1 クラスのみの画像データで学習を行う教師なし学習と、良品と不良品の 2 クラスの画像データで学習を行う教師あり学習を選択できるようにしている。

### 2.3 オプションダイアログ

図 5 に示すオプションダイアログでは、カメラから入力されたオリジナル画像から対象ワークの特徴部分を抽出するためのテンプレート画像、テンプレートマッチングで得られた画像から特徴ベクトルを抽出する CNN、および得られた特徴ベクトルから良品と不良品のバイナリ分類を行う SVM から構成されるグループを複数設定できる。この機能により、異なる特徴の欠陥毎に SVM を構成できるため、一つの入力画像を複数の SVM それぞれに判断させて、例えば全ての SVM の一致であるいは多数決で最終的な決定を行うなどヒューマンライクな分別が可能となった。同様に、CNN を用いた分類についてもオリジナルで設計から訓練までを行った sssNet や、その性能が広く認知されている AlexNet, GoogleNet などの転移学習により構築した新たな CNN

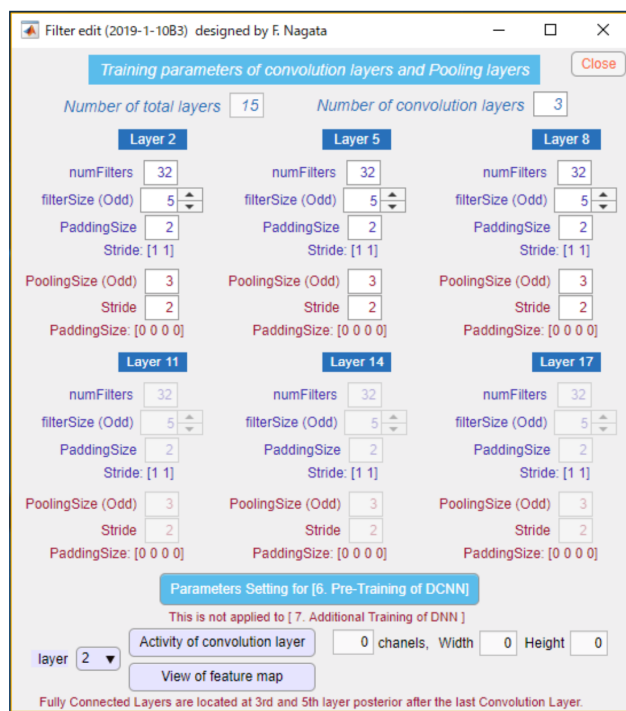


Figure 4 Parameter dialogue to give more detailed parameters for CNN structure.

など複数の CNN を自由に組み合わせて全会一致や多数決により最終的な決定を出せるようにしている。また、評価したい画像が CNN に入力された際、図 6 のように指定された畳み込み層で最も活性化した特徴マップとそのマップ内で最大活性化値を持つ領域を視覚化できるようにしている。これにより、入力画像から最終的に決定されたラベルに至ったその根拠となった特徴部分を確認できるようになった。

### 2.4 画像類似度の評価機能

CNN や SVM を訓練するための良品と不良品の画像の準備、管理には注意を要する。工業製品によっては熟練者であっても良品と不良品の分別が難しいグレー

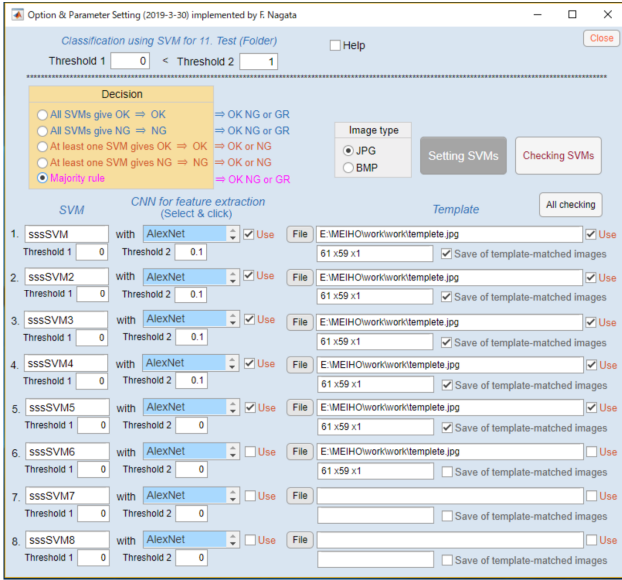


Figure 5 Option dialogue to set multiple CNNs or SVMs with unanimity or majority rule.




Figure 6 Most activated feature maps at each convolutional layer.

ゾーンのワークが存在し、このグレーゾーンのワークの分別については担当する熟練者によって、また同一熟練者であっても日時や体調などにより結果が異なることが少なくないからである。例えば、今回提案するAI分別システムが不良品を良品として誤認識した場合、すなわちシステムは良品として分別したが熟練者が最終的に不良品と判断したような場合、この不良品の画像に類似した画像が良品の訓練用画像のデータセットに含まれている可能性が危惧される。このため、このような良品と誤認識された不良品の画像と、訓練用の全ての良品画像との相関係数を一括で求め、より類似度の高い画像があれば、良品のデータセットから不良品のデータセット内に移動させる機能を持たせている。

### 3 CNN および SVM の設計と訓練

#### 3.1 1クラスの教師なし学習による SVM の例

ここでは、バリ、クラックなどの欠陥を含む樹脂成型品の画像を分別できるように訓練した CNN である sssNet を特徴抽出器として用いる。訓練後の sssNet に画像を入力した際に全結合層で得られる特徴ベクトル  $\mathbf{x} = [x_1, x_2, \dots, x_{32}]^T$  を SVM への入力として用いる。図 7 には、sssNet の第 11 層にある最初全結合層から生成される特徴ベクトルを入力に用いた 2 クラス分類用の SVM の構成方法を示しており、出力層に向かう最後部の 4 層は使用されない。訓練には 5100 枚の良品の画像のみを使用するが、SVM への入力は特徴ベクトル  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{5100} \in \mathbb{R}^{32 \times 1}$  となる。これは欠陥が含まれた不良品の画像を必要としない 1 クラスの教師なし学習である。

SVM の主問題である二次計画問題はラグランジュの未定乗数法により双対問題として得られ、MATLAB ではその解法に逐次最小問題最適化法 (Sequential Minimal Optimization algorithm: SMO [8]) を利用できる。SVM の 1 クラス学習時、正則化パラメータ  $\nu (0 < \nu < 1)$  は原点と分類平面と呼ばれる超平面の間に位置する異常とみなされた特徴ベクトルの割合の上限であり、 $\nu$  の値が大きいほど原点側に多くの割合で訓練データが存在するように分類平面が配置される。初期値は 0.2 であるが、メインダイアログ内で変更できるようにしている。

さて、特徴抽出器として利用される sssNet にテスト画像が入力されると特徴ベクトル  $\mathbf{x} \in \mathbb{R}^{32 \times 1}$  が得られる。この  $\mathbf{x}$  を学習後の SVM に対して与えると次式で与えられるスコア  $f(\mathbf{x})$  が出力される。 $f(\mathbf{x})$  は分類の基準となる超平面からの符号付距離である。

$$f(\mathbf{x}) = \sum_{i=1}^N \alpha_i y_i G(\mathbf{x}_i^*, \mathbf{x}) + b \quad (1)$$

ここで、 $\mathbf{x}_i^* \in \mathbb{R}^{1 \times 32}$  ( $i = 1, 2, \dots, N$ ) と  $N$  はそれぞれ、良品の画像データを使った学習過程で得られたサポートベクトルとその数である。 $\alpha_i$  ( $i = 1, 2, \dots, N$ ) と  $b$  はそれぞれ、ラグランジュ乗数とバイアスである。 $y_i$  はラベルであり、1 クラス学習の場合は常に 1 がセットされる。 $G(\mathbf{x}_i^*, \mathbf{x})$  は高次元化のためのカーネル関数であり、今回の実験では次式で与えられるガウシアン関数を用いた。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \exp\left(-\left\|\frac{\mathbf{x}_i^* - \mathbf{x}_s}{k}\right\|^2\right) \quad (2)$$

ここで、 $k$  と  $\mathbf{x}_s$  はそれぞれ、カーネルスケールと次式で与えられる標準化された入力ベクトルである。

$$\mathbf{x}_s = (\mathbf{x} - \mathbf{x}_\mu) \oslash \mathbf{x}_\sigma \quad (3)$$

ただし、

$$\mathbf{x}_\mu = \frac{\sum_{j=1}^{5100} \mathbf{x}_j}{5100} \quad (4)$$

$$\mathbf{x}_\sigma = \left[ \frac{1}{5100} \sum_{j=1}^{5100} (\mathbf{x}_j - \mathbf{x}_\mu)^{\circ 2} \right]^{\circ \frac{1}{2}} \quad (5)$$



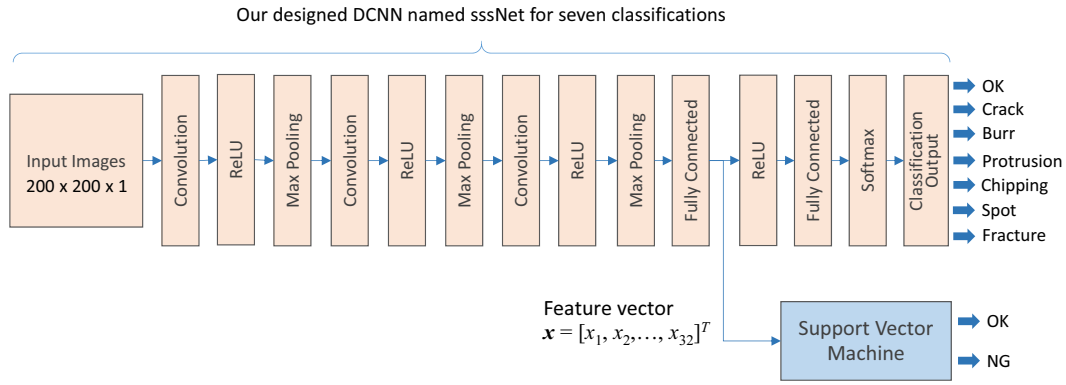


Figure 7 Binary class SVM whose input is the feature vector generated from the fully-connected layers of our designed CNN named sssNet.

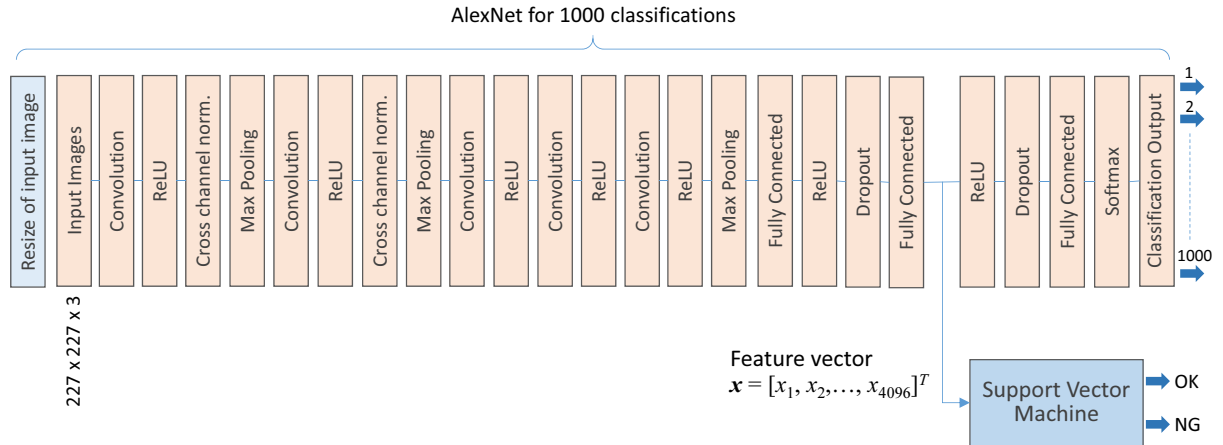


Figure 9 Another binary class SVM whose input is the feature vector generated from AlexNet.




Figure 8 Support vector machine given by Eq. (1) after optimized through one-class learning.

ここで、 $\odot$ ,  $\circ 2$ ,  $\circ \frac{1}{2}$  はそれぞれ、要素毎の商、二乗および根号を表すアダマール演算子である。今回は試行的に  $\nu = 0.5$  とし、欠陥を含まない良品のみの画像 5100 枚を用いて SVM を学習させた結果、得られた  $k$ ,  $N$  および  $b$  はそれぞれ、1.1875, 2621,  $-1.0639$  であった。図 8 には、1 クラス学習後に得られたサポートベクタマシンを示す。不良品を含むテスト画像から得られた特徴ベクトルの 2 クラス分類は  $f(\mathbf{x})$  の符号をチェックするこ

とで、 $f(\mathbf{x}) > 0$  の場合は良品、 $f(\mathbf{x}) < 0$  の場合は学習時に使用した良品画像と異なる特徴を持つ不良品の画像と推定できる。次式で与えられる  $n$  次多項式などもカーネル関数として利用できるが、画像や特徴ベクトルとの相性は実際の学習とテストデータによる汎化性の評価により確認する必要がある。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \left[ 1 + \frac{(\mathbf{x}_i^*)^T \mathbf{x}_s}{k} \frac{\mathbf{x}_s}{k} \right]^n \quad (6)$$

つぎに、ImageNet データベースの 100 万枚を超える画像で学習済みの畳み込みニューラルネットワークである AlexNet を用いて図 9 のようなもう一つの SVM を設計した。このネットワークは全 25 層から構成され、入力画像を 1000 種類のカテゴリに分類できるため、豊富な特徴を表現できる能力を獲得していると言える。ネットワークへの画像の入力サイズは  $227 \times 227$  であり、RGB の 3 チャネルを持つ。このため、訓練およびテスト画像が異なる解像度もしくはグレースケールなど異なるチャネル数を持つ場合には  $227 \times 227 \times 3$  に変換できるようにしている。

ここでは、ターゲットとなる樹脂成型品の模擬画像を用いた訓練およびテスト時、入力画像に対して第 2 全結合層から出力される特徴ベクトル  $\mathbf{x} = [x_1, x_2, \dots, x_{4096}]^T$  を SVM への入力として用いる。AlexNet ではこの 4096 要素の特徴ベクトルから 1000 カテゴリへの分類を行う機能を実現している。図 9 には AlexNet の第 20 層目にあたる第 2 全結合層からの

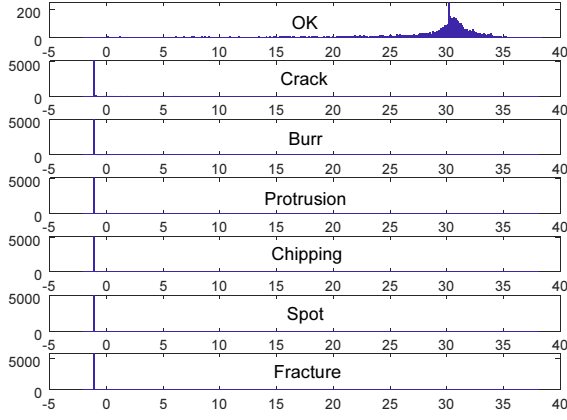


Figure 10 Classification results using the SVM shown in Fig. 7, in which horizontal and vertical axes denote the output from the SVM trained with our designed sssNet and the number of image samples, respectively.

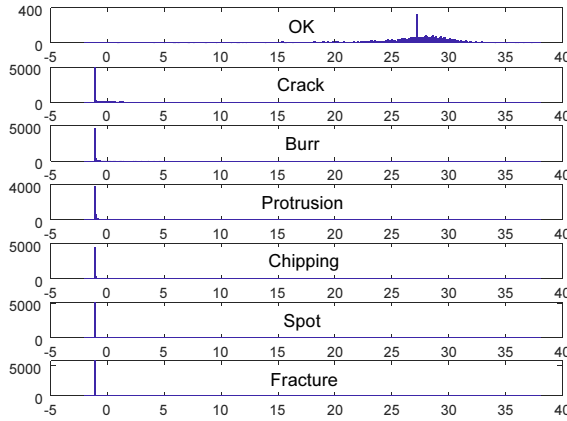


Figure 11 Classification results using the SVM shown in Fig. 9, in which horizontal and vertical axes denotes the output from the SVM trained using AlexNet and the number of image samples, respectively.

出力である特徴ベクトルを SVM への入力として設計した SVM の例を示す。学習には sssNet のときと同様に 5100 枚の良品の画像から得られた特徴ベクトル  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{5100} \in \mathbb{R}^{4096 \times 1}$  のみを用いて行った。カーネル関数などその他のパラメータについても sssNet を用いたときと同様である。学習により、得られた  $k, N$  および  $b$  はそれぞれ、26.7690, 2667, -1.0635 となった。

### 3.2 1 クラス教師なし学習により得られた二つの SVM による分類実験

ここでは、メインダイアログを用いて良品と不良品のテスト画像からなるデータセットの分類実験を行い、前節で設計から学習までを行った二つの SVM の汎化性を評価する。テスト画像は学習時に用いた画像のデータセットには含まれていない。図 10 は、図 7 で紹介した学習後の SVM による分類結果を示したヒストグラムである。横軸と縦軸はそれぞれ、sssNet を特徴抽出器とした SVM からの出力  $f(\mathbf{x})$  と分類された画像の枚数である。この結果から SVM は良品の画像と欠陥を含む画像を良好に分類できていることが確認できる。

Table 1 Detailed comparison using the number of misclassified images.

SVM	Burr	Crack	Chip.	Knob	Spot	Frac.
sssNet	13	4	1	0	0	0
AlexNet	167	20	298	127	0	0

また、図 11 には同じテスト画像を用いて図 9 の AlexNet を特徴抽出器とした SVM による分類結果を示す。この図から sssNet ベースの SVM と同様、良好に分類できていることが確認できる。実際、sssNet と AlexNet から出力された特徴ベクトルの長さはそれぞれ、32 と 4096 と大きく異なっていたものの、ヒストグラムからは同じような傾向の分類性能が得られていたことが分かる。

今回の CNN&SVM 設計ツールの使用テストでは、図 2 のような樹脂成型品を模擬した  $200 \times 200$  のグレースケール画像を用いているが、要素数 4096 の特徴ベクトルは冗長であったかもしれない。表 1 にはそれぞれの SVM を使った評価において誤分類された、すなわち欠陥を含む不良品の画像にもかかわらず良品として分別された画像の枚数を示す。この表からは、ターゲットとなる樹脂成型品の模擬画像で直接訓練していた sssNet を特徴抽出器として用いた SVM の優位性を確認できる。

### 3.3 2 クラスの教師あり学習による SVM の例

前節では、1 クラスの教師なし学習で設計した 2 種類の SVM を紹介した。ここでは、AlexNet を特徴抽出器に用いた 2 クラスの教師あり学習による SVM も試行的に設計し、評価を行う。2 クラス学習では良品の画像と欠陥を含む不良品の画像を用いて SVM の学習を行う。学習後、SVM の出力であるスコア関数  $f(\mathbf{x})$  は式 (1) で表されるが、ラベル  $y_i$  には  $i$  番目のサポートベクトルが良品側のクラスの場合に 1 が、不良品側のクラスの場合には -1 が設定される。例えば、カーネル関数  $G(\mathbf{x}_i^*, \mathbf{x})$  に次式で与えられる線形関数を用いた場合

$$G(\mathbf{x}_i^*, \mathbf{x}) = \frac{(\mathbf{x}_i^*)^T \mathbf{x}_s}{k} \quad (7)$$




Figure 12 Support vector machine given by Eq. (8) after trained through two-class learning.

Table 2 Confusion matrix to check the trained situation of the two-class learning based SVM.

Actual \ Predicted	Anomaly	Normal
Anomaly	30573	27
Normal	8	5092

Table 3 Confusion matrix to check the generalization of the two-class learning based SVM.

Actual \ Predicted	Anomaly	Normal
Anomaly	5987	13
Normal	3	997

式 (1) で与えられるスコア関数は次式のように表される [7].

$$f(\mathbf{x}) = \frac{\mathbf{x}_s^T}{k} \boldsymbol{\beta} + b \quad (8)$$

ここで,  $k$  はカーネルスケール,  $\boldsymbol{\beta} \in \mathbb{R}^{4096 \times 1}$  は線形係数ベクトル,  $b$  はバイアスである.  $k, \boldsymbol{\beta}$  および  $b$  は学習を通じて得られる SVM のパラメータである. 図 12 には式 (8) で与えられた SVM の構造を示す. このとき, 特徴ベクトル  $\mathbf{x} \in \mathbb{R}^{4096 \times 1}$  は AlexNet の第 2 全結合層からの出力である. 学習時, 正の定数として与えられる正則化係数  $C$  を変更できるようにしており, ソフトマージンの程度を調整することができる. 今回の学習では  $C = 1$  としているが,  $C$  が大きくなるにつれてハードマージンの条件に近づいていくことが知られている.

### 3.4 2 クラスの教師あり学習による SVM の分類実験

図 12 に示す SVM を学習するために 5100 枚の良品の画像と, 5100 枚  $\times 6$  種類の欠陥を含む不良品画像を用意した. 欠陥の種類については図 2 に示したとおりである. 今回の学習では,  $k, N$  および  $b$  はそれぞれ, 63.8168, 698, 4.9334 のように最適化された. 表 2 には学習後の過学習の状況を確認するために, 学習で用いた画像を分類させた結果をまとめた混合行列であり, 認識率 (accuracy) と精度 (precision) はそれぞれ, 0.9990, 0.9997 であることがわかる. つぎに, 学習後の SVM の汎化性を評価するために, 1000 枚の良品の画像と 1000 枚  $\times 6$  種類の欠陥を含む不良品画像を新たに用意し分類させたところ, 表 3 のような結果が得られた. このときの認識率と精度はそれぞれ, 0.9977, 0.9995 である. 今回は過学習を防ぐために分類境界は正則化係数を含むソフトマージンのコンセプトをもとに最適化されており, 表 2 のように訓練データに対しても誤分類が発生していたことが分かる. 誤分類に対する許容の程度については実際の検査ラインへの適用段階で検討されなければならない.

### 3.5 テンプレートマッチングによる特徴抽出

様々な課題に対する画像処理で広く利用されているテンプレートマッチングは, 撮影されたワークの中で欠陥が含まれやすい領域を抽出するためにも有効である. 特に, 製造ラインを流れてくるワークの姿勢をばらつきなく一定に保つことができる場合, 適用も容易となる. 結果的に, これから設計する CNN や SVM へ




Figure 13 Configuration among a target image, padding area and template image whose size is  $(M, N)$ .

の入力画像のサイズを大幅に減らすことができ, 計算コスト, メモリ占有コストを削減することができる. このため, メイン, オプション及びオーギュメンテーションのダイアログの中ではテンプレートマッチングの機能を利用できるようにしている.

さて,  $(M, N)$  のサイズのテンプレートをターゲット画像内でラスタスキャンさせて相関係数の高い位置を検出する場合, 周辺領域でもマッチング評価ができるように図 13 に示すようにパディング処理を行う. テンプレートとパディングにより拡張されたターゲット画像内の同面積の領域との相関係数  $\alpha(u, v)$  は, 次式から計算される [9].

$$\alpha(u, v) = \frac{s_{it}(u, v)}{s_i(u, v)s_t(u, v)} \quad (9)$$

$$s_{it}(u, v) = \sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \{f(x, y) - \bar{f}_{u,v}\} \times \{t(x-u, y-v) - \bar{t}\} \quad (10)$$

$$s_i(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \{f(x, y) - \bar{f}_{u,v}\}^2} \quad (11)$$

$$s_t(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \{t(x-u, y-v) - \bar{t}\}^2} \quad (12)$$

ここで,  $(u, v)$  は拡張されたターゲット画像内におけるテンプレート左上コーナーの座標である.  $s_t(u, v)$  と  $s_i(u, v)$  はそれぞれ, テンプレート内とターゲット内比較領域の標準偏差であり,  $s_{it}(u, v)$  は共分散である.  $f(x, y)$  は拡張された画像内の  $(x, y)$  におけるグレースケール 256 階調値を正規化した値である.  $t(x-u, y-v)$  はテンプレート内の  $(x-u, y-v)$  における同様の値である.  $M$  と  $N$  はそれぞれ, テンプレートの幅と高さである.  $\bar{t}$  と  $\bar{f}_{u,v}$  はそれぞれ, テンプレート内のグレースケール値の平均値と, ターゲット画像内のテンプレ

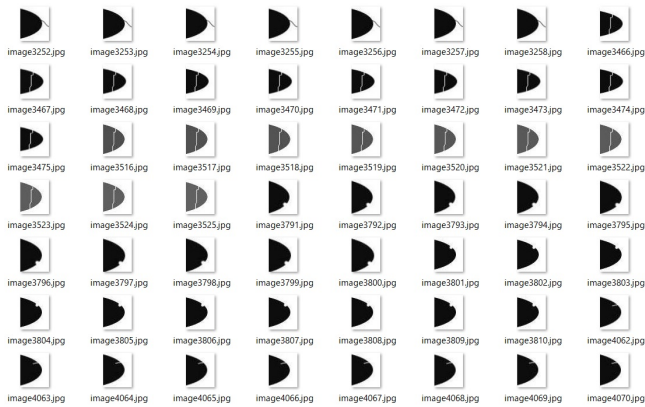


Figure 14 Some of 120 test images for evaluating the generalization of the SVM.




Figure 15 Binary classification result of 120 test images shown in Fig. 14.

レート真下の領域のそれである。式 (9) で与えられる相関係数  $\alpha(u, v)$  は、テンプレートを拡張されたターゲット画像内の左上から右下までラスタースキャンさせることで計算される。ラスタースキャン後、テンプレートと最もマッチする領域、すなわち最も大きな値  $\alpha(u, v)$  を持つ領域が抽出される。

実装したテンプレートマッチング機能により、オリジナルの 3000 枚の良品画像から切り出した画像を用いて図 9 で紹介した SVM に学習させたところ、得られたパラメータ  $k$ ,  $N$  および  $b$  はそれぞれ 50.0116, 1, 526, -5.6925 であった。学習後の SVM の汎用化性をチェックするために図 14 のような良品と不良品からなる 120 枚のテスト画像を用意し、分別実験を行った結果を図 15 に示す。この評価実験では、120 枚全ての画像が良好に良品あるいは不良品に分類され、テンプレートマッチングの有効性を確認することができた。

## 4 おわりに

本稿では、畳み込みニューラルネットワークとサポートベクターマシンを応用した欠陥検出システムについて紹介した。プログラム開発や画像処理の初心者であっても高性能な不良品検出用 AI を設計できるように現在開発中の CNN&SVM 設計支援ツールについては、評価用の樹脂成型品を模倣した画像のデータセットを用いた評価実験により有用性を確認することができた。現在、このアプリケーション内に操作方法の説明を組み込みながら、山口県内外のものづくり企業数社との共同研究を通して実ラインへの適用に取り組んでいる。ここでは本稿で紹介したソフトウェアと、それぞれの製造工程が対象とするワーク、工作機械や産業用ロボットと

いった機械装置、ピッキングのためのハンドなどハードウェアとの統合を考慮したシステム開発が中心となっている。

## References

- [1] A. Krizhevsky, I. Sutskever, and G.E. Hinton: ImageNet classification with deep convolutional neural networks; *Advances in neural information processing systems*, pp. 1–12 (2012)
- [2] V. Vapnik: *The Nature of Statistical Learning Theory*, Springer, New York, (1995)
- [3] N. Cristianini, J. Shawe-Taylor, 大北 (訳): サポートベクターマシン入門, 共立出版, (2005)
- [4] 竹内, 鳥山: サポートベクトルマシン, 講談社, (2015)
- [5] 徳野, 永田, 大塚, 渡辺: 畳み込みニューラルネットワークを応用した不良品検出の基礎研究, 日本機械学会九州支部北九州講演会講演論文集, pp. 35–39, 北九州市立大学ひびきのキャンパス (2018)
- [6] 中島, 永田, 渡辺: 畳み込みニューラルネットワーク (CNN) とサポートベクターマシン (SVM) を用いた微小な欠陥を持つ不良品検出の基礎研究, ロボティクス・メカトロニクス講演会 2019 講演論文集, 4 pages, 広島国際会議場 (2019)
- [7] <https://jp.mathworks.com/>
- [8] J. Platt: Sequential minimal optimization: A fast algorithm for training support vector machines, *Technical Report MSR-TR-98-14*, pp. 1–24 (1998)
- [9] J.P. Lewis, “Fast Normalized Cross-Correlation,” *Industrial Light & Magic*, 7 pages, 2001.
- [10] F. Nagata, K. Tokuno, K. Nakashima, A. Otsuka, T. Ikeda, H. Ochi, K. Watanabe, M.K. Habib: Fusion method of convolutional neural network and support vector machine for high accuracy anomaly detection; *Procs. of the 2019 IEEE International Conference on Mechatronics and Automation (ICMA 2019)*, pp. 970–975 (2019)
- [11] F. Nagata, K. Tokuno, K. Mitarai, A. Otsuka, T. Ikeda, H. Ochi, K. Watanabe, M.K. Habib, “Defect detection method using deep convolutional neural network, support vector machine and template matching techniques,” *Artificial Life and Robotics*, Vol. 24, No. 4, pp 512–519 (2019)