

# 学習済み CNN モデルの転移学習を用いた微小な欠陥の検出

中島 健斗 (山口東京理科大学大学院), 永田 寅臣 (山口東京理科大学大学院)

渡辺 桂吾 (岡山大学大学院)

## Detection of Minute Defects Using Transfer Learning of Trained CNN Model

Kento NAKASHIMA, Sanyo-Onoda City University

Fusaomi NAGATA, Sanyo-Onoda City University

Keigo WATANABE, Okayama University

**Abstract :** In this paper, we propose a system that can detect defects in resin molded products by transfer learning of an already trained CNN named AlexNet. AlexNet is used for the trained CNN, and its fully connected layers are replaced according to the number of classifications. Additional trainings are conducted using the training images including small defects targeted in this system. In experiments, we first design AlexNet\_6 and AlexNet\_2 that are obtained from transfer learnings corresponding to 6 and 2 class classifications, respectively. Then, our originally designed 15 layers CNNs named sssNet\_6 and sssNet\_2 are prepared. Finally, AlexNet\_6, 2 and sssNet\_6, 2 are quantitatively compared and evaluated through classification experiments.

### 1. 緒言

これまでも畳み込みニューラルネットワーク (CNN) を製品の欠陥検出に応用した研究がある。例えば、多田らは多段階型 CNN を用いた自動車用タイヤ内面部における欠陥識別の研究を行っている [1]。Young らは橋やダムなどの構造物の亀裂損傷検出に CNN を用いた研究を行っている [2]。筆者らは、CNN を応用した欠陥を含む不良品検出の基礎研究 [3, 4]、カスケードタイプ CNN の設計と欠陥検出への応用研究に取り組んでいる [5]。

本研究では学習済みの CNN モデルの転移学習により、前報 [6] より高い精度で樹脂成型品の欠陥検出を行うことができるシステムを提案する。学習済みの CNN には ILSVRC2012 で優勝した AlexNet を用い、クラス分類の数に応じて全結合層部を置き換え、追加学習を行う。図 1 には今回の欠陥検出で対象とする  $200 \times 200$  ピクセル 256 階調のグレースケールで作成した良品と、バリ、クラック、欠け、突起、スポットの 5 種類の欠陥を含む樹脂成型品の画像を示す。この画像データセットを用いて転移学習を行

う。実験では、まず、2 クラス分類と 6 クラス分類にそれぞれ対応して転移学習を行った AlexNet\_2, AlexNet\_6 と、AlexNet と同様に 2 クラス分類と 6 クラス分類に対応した 15 層から成る CNN である sssNet\_2 と sssNet\_6 [6] を設計し、性能を比較評価する。

### 2. AlexNet による欠陥検出

#### 2.1 転移学習について

転移学習はある異なるタスクに対して学習済みの CNN のモデルの重みを初期値としてセットし、目的のタスクに応じた学習データセットに合うように全結合層を置き換え、再学習を行う手法である。本研究では AlexNet を用いて転移学習を行う。AlexNet は、ImageNet データベースの 130 万もの画像を使用してトレーニングされた CNN の 1 つである [7]。図 2 に示すように AlexNet は 5 つの畳み込み層と 3 つの全結合層を含む合計 25 層から構成されている。最初の畳み込み層は、 $227 \times 227 \times 3$  のサイズの入力画像に対して、縦横サイズとチャンネル数が  $11 \times 11 \times 3$  の 96 枚のフィルタにより 96 枚の特徴マップを生成する。第 2 の畳み込み層は最初の畳み込み層の出力を受け取り、 $5 \times 5 \times 48$  の特徴マップを 256 枚生成する。第 3 の畳み込み層以降はそれぞれ、 $3 \times 3 \times 256$  のサイズのフィルタを 384 枚、 $3 \times 3 \times 192$  サイズのフィルタを 384 枚、 $3 \times 3 \times 192$  サイズのフィルタを 256 枚有し、フィルタと同数の特徴マップを生成する。全結合層は、 $4096 \times 4096 \times 1000$  個の重みを有する。AlexNet は、入力画像をキーボード、マウス、鉛筆、




Fig. 1: Samples of training images with and without defects.

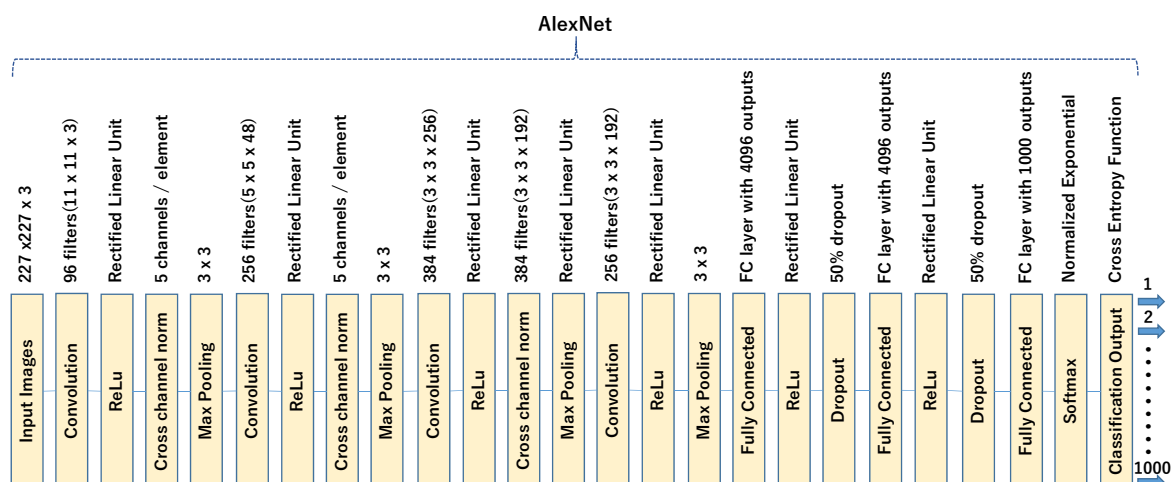


Fig. 2: Architecture of original AlexNet.

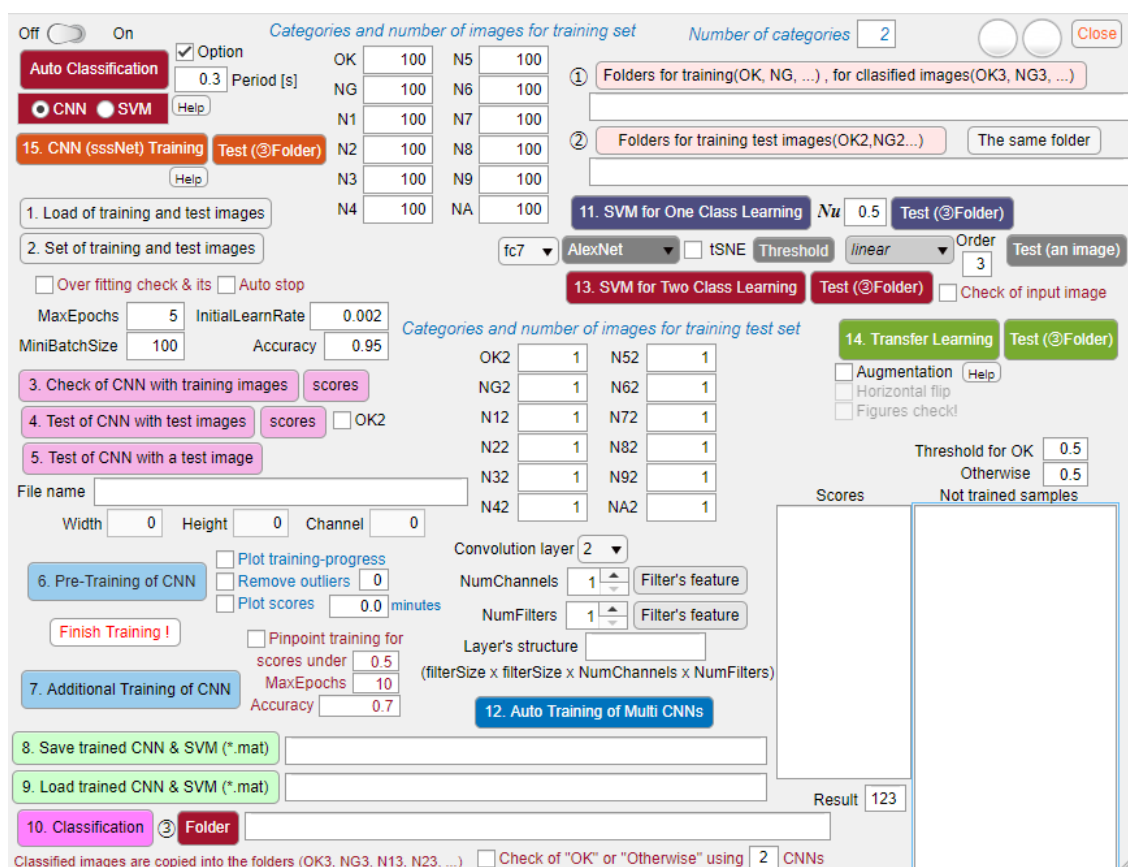


Fig. 3: Proposed software developed on MATLAB system to user-friendly design CNNs.

多くの種類の動物などを含む 1,000 種類のオブジェクトクラスに分類できるように訓練されている。

## 2.2 分類実験

図 3 には MATLAB 上で開発した CNN の設計や転移学習のためのソフトウェアを示す。本研究ではこのソフトウェアを用いて AlexNet の転移学習により 6 クラス分類用に再構成した AlexNet\_6 を設計した。図 4 には設計し

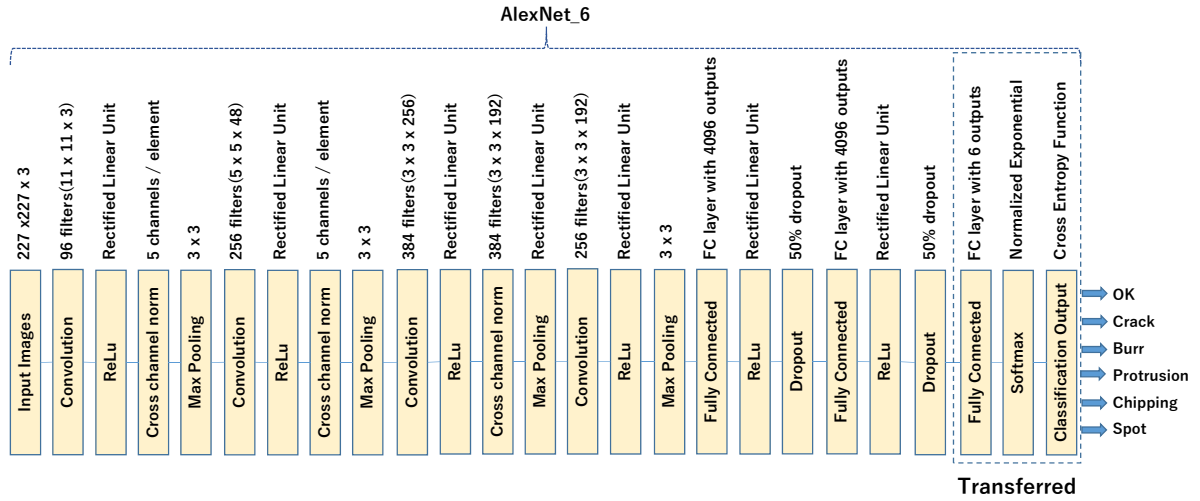


Fig. 4: AlexNet\_6 designed using the proposed application shown in Fig. 3.

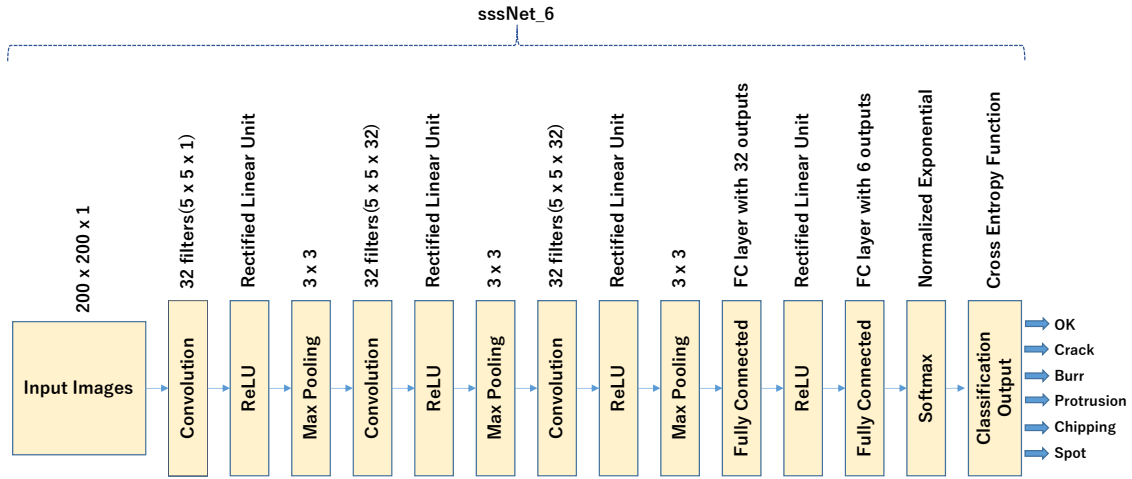


Fig. 5: Our original CNN named sssNet\_6 designed using the proposed application shown in Fig. 3.

た AlexNet\_6 の構造を示す．訓練用データセットとして良品 10,000 枚と，5 種類の不良品（バリ，クラック，欠け，突起，スポット）の画像をそれぞれ 10,000 枚，計 60,000 枚を用いた．なお，訓練中の過学習を防ぐため，1 回の訓練が終了する度に各クラスにつき未学習の検証用画像を 3,000 枚ずつ用意し，汎化性能が低下してないかを調べながら AlexNet\_6 の訓練を続け，認識率が 95 %程度で安定した段階で訓練を終了させた．同様に良品と不良品（バリ，クラック，欠け，突起，スポット）の 2 クラス分類に対応した AlexNet\_2 も設計した．

次に訓練した AlexNet\_6, 2 の汎化性能を評価するために未学習のテスト画像を各クラスにつき 1,000 枚ずつ用意し，分類実験を行った．表 1 と表 2 にはそれぞれ，AlexNet\_6 と AlexNet\_2 が誤認識した画像の枚数と，AlexNet\_6 の全体的な認識結果を表す混同行列（縦軸：実際のクラス，横軸：予測クラス）を示す．表 2 により

AlexNet\_6 を用いた場合，テスト画像に対して不良品を良品として誤認識した画像枚数は合計で 89 枚であった．また，表 1 より AlexNet\_2 を用いた場合，テスト画像に対して不良品を良品として誤認識した画像枚数は合計で 13 枚であった．

Table 1: Number of misclassified images.

CNN	OK	Burr	Crack	Chip.	Prot.	Spot
AlexNet_6	34	108	73	76	347	76
AlexNet_2	0	12	0	0	1	0

Table 2: Confusion matrix by AlexNet\_6 (row: true labels, column: predicted labels).

	OK	Burr	Crack	Chip.	Prot.	Spot
OK	966	0	0	0	0	34
Burr	36	892	0	25	21	26
Crack	11	5	927	4	0	53
Chip.	14	6	53	924	3	0
Prot.	28	215	13	91	653	0
Spot	0	0	76	0	0	924

### 3. ターゲット画像で訓練した CNN による欠陥検出

#### 3.1 比較用 CNN(sssNet) の設計

本章では比較評価のために設計した図 5 のような 6 つのクラス分けが可能な 15 層からなる sssNet\_6 を示す。また, sssNet\_6 と同様に 2 つのクラス分けが可能な sssNet\_2 を設計した。この CNN は AlexNet よりも浅い構造であるが, 図 1 に示すような実際のターゲット画像を用いて訓練していることを特徴とする。第 1 層には図 1 のような画像が入力され, 正規化される。第 2 層と第 5 層及び第 8 層はそれぞれ,  $5 \times 5 \times 1 \times 32$  および  $5 \times 5 \times 32 \times 32$  の構造を持つフィルタで構成される畳み込み層である。畳み込み層では, 入力画像や特徴マップに対してフィルタと呼ばれる特徴抽出用の素子が左上から右下にかけてストライドに指定された画素数をシフトしながら適用される。

#### 3.2 sssNet による分類実験

まず, 訓練画像やその他終了の条件などは前章の AlexNet と同一とし, 6 クラス分類用 sssNet\_6 の訓練を行った。次に, 同様に 2 クラス分類に対応した sssNet\_2 の訓練を行った。これら訓練済みの sssNet\_6, 2 の汎化性能を評価するために AlexNet と同一のテスト画像を用いて分類実験を行った。表 3 と表 4 にはそれぞれ, sssNet\_6, sssNet\_2 により誤認識された画像の枚数と, sssNet\_6 の全体的な認識結果を表す混同行列 (縦軸: 実際のクラス, 横軸: 予測クラス) を示す。例えば, 表 3 において sssNet\_2 が 1000 枚のバリを含む画像を評価した際, 61 枚は良品と誤認識されたことを示している。表 3 より sssNet\_2 を用いた場合, テスト画像に対して不良品を良品として誤認識した画像枚数は合計で 109 枚であった。また, sssNet\_6 を用いた場合, 表 4 の第 1 列目に示された OK と予測されたラベルより, 不良品を良品として誤認識した画像枚数は合計で 123 枚であった。

Table 3: Number of misclassified images [6].

CNN	OK	Burr	Crack	Chip.	Prot.	Spot
sssNet_6	0	248	378	364	485	262
sssNet_2	1	61	26	0	22	0

Table 4: Confusion matrix by sssNet\_6 (row: true labels, column: predicted labels) [6].

	OK	Burr	Crack	Chip.	Prot.	Spot
OK	1000	0	0	0	0	0
Burr	93	752	97	2	37	19
Crack	0	0	622	0	0	378
Chip.	0	25	172	636	144	23
Prot.	30	306	64	66	515	19
Spot	0	0	262	0	0	738

Table 5: Comparison results of AlexNet\_2, AlexNet\_6, sssNet\_2 and sssNet\_6.

CNN	Accuracy	Precision
AlexNet_6	0.8810	0.8869
sssNet_6	0.7105	0.7277
AlexNet_2	0.9978	0.9974
sssNet_2	0.9817	0.9782

## 4. 比較結果と考察

AlexNet の転移学習で得られた AlexNet\_6, 2 と, 新たに設計した CNN である sssNet\_6, 2 の性能を比較するために, 前章までの分類結果をもとに認識率と精度を求めた結果を表 5 に示す。

#### 4.1 6 クラス分類の場合

6 クラス分類で良品を評価した場合, 例えば良品を良品として分類したものと, 良品をバリ, クラック, 欠け, 突起, スポットの欠陥を持つ不良品として分類したものをそれぞれ  $T_{OK}$ ,  $F_{Bu}$ ,  $F_{Cr}$ ,  $F_{Ch}$ ,  $F_{Pr}$ ,  $F_{Sp}$  としたとき, 認識率は次式で与えられる。

$$Accuracy = \frac{T_{OK}}{T_{OK} + F_{Bu} + F_{Cr} + F_{Ch} + F_{Pr} + F_{Sp}} \quad (1)$$

他クラスの分類時の認識率も同様に求めることができる。なお, 表 5 中の 6 クラス分類時の認識率は 6 クラスそれぞれの認識率の平均値を示している。

次に, 例えば良品の場合, 他の 5 クラスのどれかに誤分類されたものの合計を  $F_{OK}$  としたとき, 精度は次式で表される。

$$Precision = \frac{T_{OK}}{T_{OK} + F_{OK}} \quad (2)$$

他クラスの分類時の精度も同様に求めることができる。なお, 表 5 中の 6 クラス分類時の精度は 6 クラスそれぞれの

精度の平均値を示している．表 5 より認識率と精度の両方において，sssNet\_6 よりも AlexNet\_6 の方が優れていた．

## 4.2 2 クラス分類の場合

2 クラス分類の場合，全体のデータの中で不良品を不良品として分類したものを  $T_P$ ，良品を良品として分類したものを  $T_N$ ，不良品を良品として分類したものを  $F_P$ ，さらに良品を不良品として分類したものを  $F_N$  としたとき，認識率は一般的に次式で与えられる．

$$Accuracy = \frac{T_P + T_F}{T_P + T_N + F_P + F_N} \quad (3)$$

また，精度は次式で表される．

$$Precision = \frac{T_P}{T_P + T_F} \quad (4)$$

表 5 より AlexNet\_2 の方が sssNet\_2 よりも認識率と精度の点で優れていた．

表 2 と表 4 より AlexNet\_6 の方が sssNet\_6 よりも不良品を良品と誤認識した画像の枚数は少なかった．また，表 1 と表 3 より AlexNet\_2 の方が sssNet\_2 よりも不良品を良品と誤認識した画像の枚数は少なかった．その結果，ターゲット画像で訓練した sssNet よりも AlexNet の転移学習で得られた CNN の方が不良品を良品と誤認識する画像の枚数は少なく，転移学習の効果が確認され，不良品検出システムとしての性能が高かった．

## 5. 結言

本研究では学習済みの CNN モデルの転移学習により，前報 [6] より高い精度で樹脂成型品の欠陥検出を行うことができるシステムを提案した．学習済みの CNN には ILSVRC2012 で優勝した AlexNet を用い，クラス分類の数に応じて全結合層部を置き換えた．今回の欠陥検出で対象とする  $200 \times 200$  ピクセル 256 階調のグレースケールで作成した良品と，バリ，クラック，欠け，突起，スポットの 5 種類の欠陥を含む樹脂成型品の画像データセットを用いて転移学習を行った．実験では，まず，6 クラス分類と 2 クラス分類にそれぞれ対応して転移学習を行った AlexNet\_6, AlexNet\_2 と，AlexNet と同様に 6 クラス分類と 2 クラス分類に対応した 15 層から成る CNN である sssNet\_6, sssNet\_2 を設計し，性能を比較評価した．その結果，ターゲット画像で訓練した sssNet よりも AlexNet の転移学習で得られた CNN の方が不良品を良品と誤認識する画像の枚数は少なく，分類性能が高かった．

実際の製造ラインにおいて，不良品が良品のロットに含まれることは重大なりコールにつながる恐れがあり，重要

な指標となっている．以上の結果から転移学習が不良品検出用の CNN の設計において非常に有効な手法であることが確認ができた．

## 参考文献

- [1] 多田 拓太郎, 杉浦 彰彦, “多段階型 CNN を用いた自動車用タイヤ内面における欠陥識別,” 電気学会論文誌 C (電子・情報・システム部門誌), pp. 1586–1594 2018.
- [2] Young-Jin Cha, Wooram Choi, Oral Buyukozturk, “Deep Learning-Based Crack Damage Detection Using Convolutional Neural Networks,” *Computer-Aided Civil and Infrastructure Engineering*, pp. 1–18, 2017.
- [3] 徳野 健太, 永田 寅臣, 大塚 章正, 渡辺 桂吾, “畳み込みニューラルネットワーク応用した不良品検出の基礎研究,” 日本機械学会九州支部 北九州講演会講演論文集, pp. 35–39, 北九州市立大学ひびきのキャンパス, 2018.
- [4] 徳野 健太, 永田 寅臣, 大塚 章正, 渡辺 桂吾, “Deep Learning 応用した不良品検出の基礎研究,” ロボティクス・メカトロニクス講演会 2018 講演論文集, 2A2–K14(1–3), 北九州国際会議場, 2018.
- [5] Kenta Tokuno, Fusaomi Nagata, Akimasa Otsuka, Keigo Watanabe, Maki K. Habib, “Design Tool of Convolutional Neural Network (CNN)- Design of Cascade-Type CNN and Its Application to Defect Detection,” *Procs. of 24th International Symposium on Artificial Life and Robotics*, pp. 733–737, 2019.
- [6] 中島 健斗, 永田 寅臣, 渡辺 桂吾, “畳み込みニューラルネットワーク (CNN) とサポートベクターマシン (SVM) を用いた微小な欠陥を持つ不良品検出の基礎研究,” ロボティクス・メカトロニクス講演会 2019 講演論文集, 2A1-Q05(1-4), 広島国際会議場, 2019.
- [7] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” *Neural Information Processing Systems Conference*, 2012.