

# 畳み込みニューラルネットワーク (CNN) とサポートベクターマシン (SVM) を用いた微小な欠陥を持つ不良品検出の基礎研究

Basic Research on Detection of Defective Products with Minute Defects Using Convolution Neural Network (CNN) and Support Vector Machine (SVM)

○学 中島 健斗 (山口東京理科大学大学院) 正 永田 寅臣 (山口東京理科大学大学院)

正 渡辺 桂吾 (岡山大学大学院)

Kento NAKASHIMA, Sanyo-Onoda City University, f115066@ed.socu.ac.jp

Fusaomi NAGATA, Sanyo-Onoda City University, nagata@rs.socu.ac.jp

Keigo WATANABE, Okayama University, watanabe@sys.okayama-u.ac.jp

In this paper, we propose visual inspection systems that detect defective products with minute defects seen in the production process of resin molded articles. Firstly, an application of 15-layered CNN is developed for visual inspection and is trained using a large number of images to perform effective generalization. Then, the trained CNN named sssNet is incorporated with a two-class learning based SVM to classify test images with high recognition rate into accept as OK category or reject as NG category, in which compressed feature vectors obtained from the CNN is used as the inputs for the SVM. Finally, the CNN and the SVM are compared and evaluated through classification experiments. It has been confirmed that the SVM has a higher classification ability than the CNN.

**Key Words:** Convolution neural network, Support Vector Machine, Defect inspection system

## 1 緒言

これまでも畳み込みニューラルネットワーク (CNN) やサポートベクターマシン (SVM) を製品の欠陥検出に応用した研究がある。例えば、多田らは多段階型 CNN を用いた自動車用タイヤ内面における欠陥識別の研究を行っている [1]。また、西村らは SVM を用いた電子部品検査に適用した場合の課題検討の研究を行っている [2]。著者らは、CNN での欠陥検出を中心とした CNN を応用した不良品検出の基礎研究 [3]、Deep Learning を応用した不良品検出の基礎研究 [4]、カスケードタイプ CNN の設計と欠陥検出へのその応用という研究を行っている [5]。本研究では、樹脂成形品の製造ラインで発生する微小な欠陥を持つ不良品を検出するシステムを提案する。不良品検出のための機械学習アルゴリズムとして CNN と SVM を用い、どちらが高い識別性能を示すかについて比較し、評価する。




Fig.1 Samples of training images with and without defects.

## 2 CNN による欠陥検出

### 2.1 CNN の設計

図 1 には 200 × 200 ピクセルの 256 階調のグレースケールで作成した良品と、バリ、クラック、欠け、突起、スポットの 5 種類の樹脂成型品の画像を示す。本研究では C 言語や Python などのプログラミング技術の知識がなくても CNN を簡易設計出来る

ソフトウェアを開発した。図 2 には MATLAB 上で開発したソフトウェアのユーザインタフェースを示す。図 3 には図 2 のツールを使って設計した 5 つのカテゴリ分けが可能な 15 層からなる CNN を示す。第 1 層には図 1 のような画像が入力され、正規化される。第 2 層と第 5 層はそれぞれ、5 × 5 × 1 × 32 および 5 × 5 × 32 × 32 の構造を持つフィルタ (たて×よこ×チャンネル数×フィルタ数) で構成される畳み込み層であり、第 8 層は同様に 32 個のフィルタ (5 × 5 × 32 × 32) を持つ畳み込み層である。畳み込み層では、入力画像や特徴マップに対してフィルタと呼ばれる特徴抽出器が左上から右下にストライドに指定された画素数をシフトしながら適用される。第 3, 6, 9, 12 層には次式に示す正規化線形ユニット (ReLU) と呼ばれる活性化関数を配置した。

$$f(u) = \max(0, u) \quad (1)$$

$$f'(u) = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases} \quad (2)$$

さらに第 13 層の最終的な判断を行う全結合層を経て第 14 層では正規化指数関数である softmax 関数により各カテゴリに対するスコア (確率) を出力できるようにした。

### 2.2 分類実験

訓練用データセットとして良品と 5 種類の不良品 (バリ、クラック、欠け、突起、スポット) の画像をそれぞれ 10,000 枚ずつ用意した。CNN の訓練中の過学習を防ぐため、1 回の訓練が終了する度に各カテゴリにつき未学習の画像を 3,000 枚ずつ検証用に用意し、汎化性能が低下してないか調べながら CNN の訓練を行った。得られた CNN を sssNet という名前で保存した。次に汎化性能を評価するために未学習のテスト画像を各カテゴリにつき 1,000 枚ずつ用意し、sssNet に分別させた。表 1 と表 2 にはそれぞれ、全体的な認識結果を表す混同行列と誤認識された画像の数を示す。



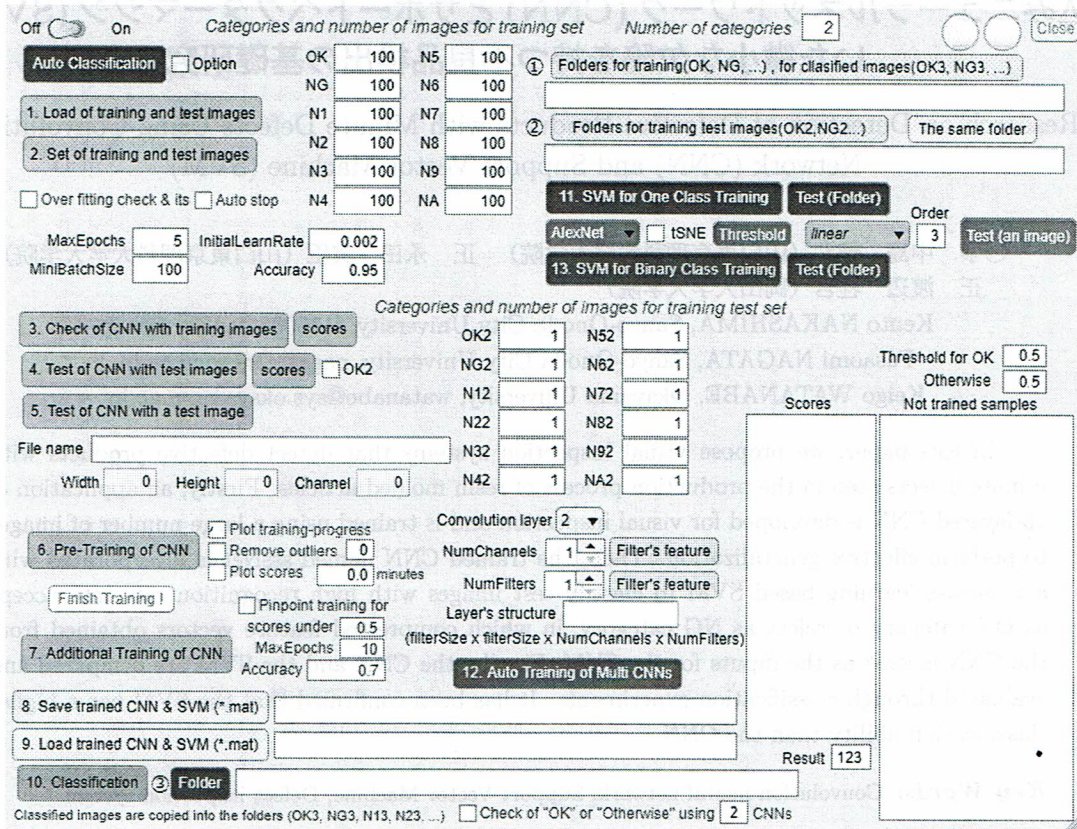


Fig.2 Developed software on MATLAB system to user-friendly design CNN and SVM.

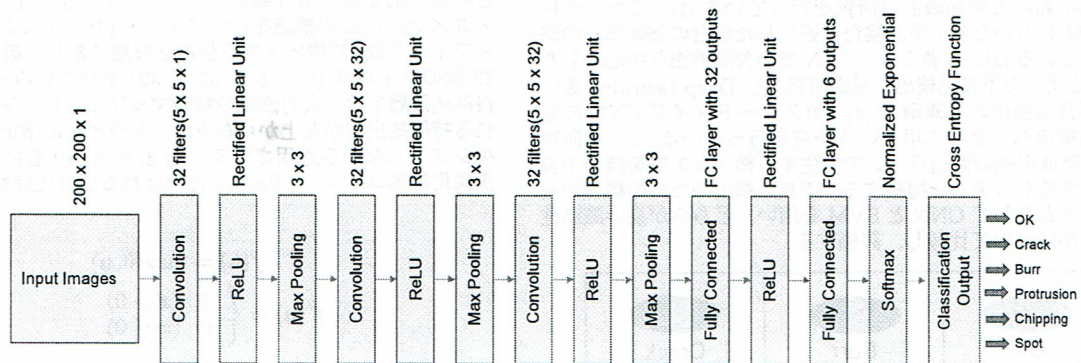


Fig.3 CNN with 15 layers which is designed using the application shown in Fig. 2.

### 3 SVM による欠陥検出

符号付き距離であり、次式で与えられる。

#### 3.1 SVM の設計

提案する SVM では、前章で設計した sssNet を使用して各入力画像から多次元特徴ベクトル  $x = [x_1, x_2, \dots, x_{32}]^T$  を抽出する。図 4 には提案する SVM の構造を示す。これは sssNet の最初の全結合層 (11 番目の層) から生成させた特徴ベクトル  $x$  を 2 クラス分類の SVM の入力として用いる設計である。学習によって  $f(x) = 0$  で与えられる超平面と呼ばれる決定境界が得られる。 $f(x)$  は、これから分類される特徴ベクトル  $x$  から超平面までの

$$f(x) = \sum_{i=1}^N \alpha_i y_i G(x_i^*, x) + b \quad (3)$$

ここで、 $G(x_i^*, x)$  はガウスカーネルなどのカーネル関数、 $x_i^* \in \mathbb{R}^{1 \times 32}$  ( $i = 1, 2, \dots, N$ ) は学習により決定されたサポートベクトル、 $N$  はサポートベクトルの数、 $\alpha_i$  ( $i = 1, 2, \dots, N$ ) と  $b$  はそれぞれラグランジュ乗数とバイアスであり、これらは学習によって推定された SVM パラメータである。また、 $y_i$  は 2 クラス学習の場合、 $x_i^*$  の陽性 (良品) あるいは陰性 (不良品) に応じて 1



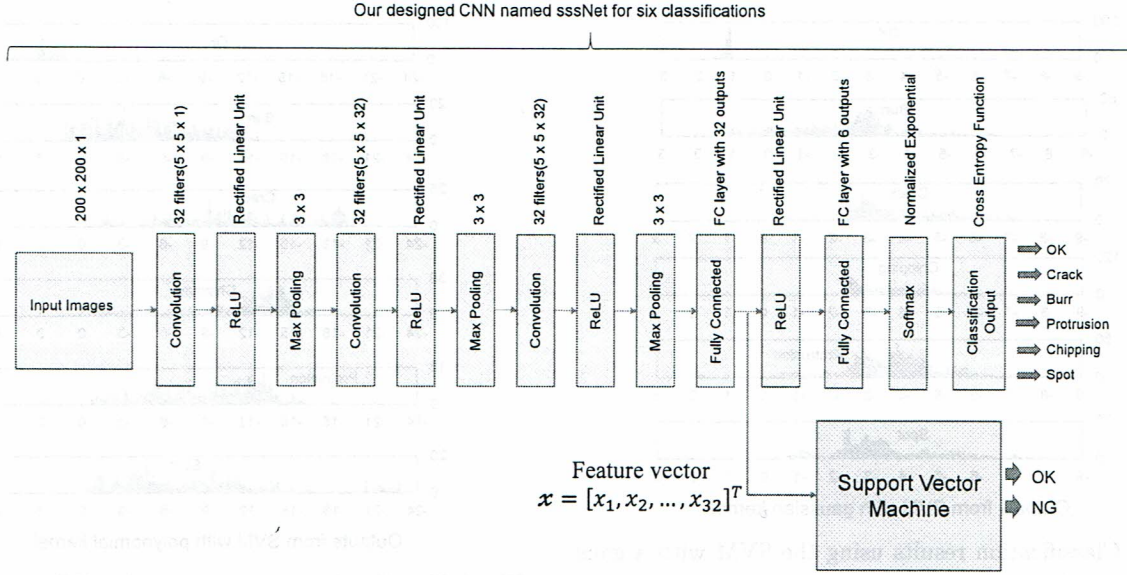


Fig.4 The proposed binary class SVM whose input is the feature vector generated from our designed DCNN named sssNet.

Table 1 Confusion matrix (row: true labels, column: predicted labels).

	OK	Burr	Crack	Chip.	Prot.	Spot
OK	1000	0	0	0	0	0
Burr	93	752	97	2	37	19
Crack	0	0	622	0	0	378
Chip.	0	25	172	636	144	23
Prot.	30	306	64	66	515	19
Spot	0	0	262	0	0	738

Table 2 Number of images misclassified by CNN.

CNN	Burr	Crack	Chip.	Prot.	Spot
sssNet	248	378	364	485	262

または  $-1$  に設定されたラベルである。分類はスコア  $f(x)$  の符号によって行われ、 $f(x) > 0$  の場合は良品、 $f(x) < 0$  の場合は欠陥が含まれている、のように判断される。例えば、ガウスクネルが適用される場合、 $G(x_i^*, x)$  は次式で与えられる。

$$G(x_i^*, x) = \exp\left(-\left\|\frac{x_i^* - x_s}{k}\right\|^2\right) \quad (4)$$

ここで、 $k$  と  $x_s$  はそれぞれのカーネルスケールと、次式で得られる標準化入力ベクトルである。

$$x_s = (x - x_\mu) \oslash x_\sigma \quad (5)$$

$$x_\mu = \frac{\sum_{j=1}^{5100} x_j}{5100} \quad (6)$$

$$x_\sigma = \left[ \frac{1}{5100} \sum_{j=1}^{5100} (x_j - x_\mu)^{\circ 2} \right]^{\circ \frac{1}{2}} \quad (7)$$

ここで、 $\oslash$ ,  $\circ 2$ ,  $\circ \frac{1}{2}$  は、それぞれ要素単位の除算、べき乗および平方根を求めるアダマール演算子である。図 5 は、2 クラス学習を通じて得られたサポートベクターマシンを示している。なお、線形カーネルと  $n$  次多項式カーネルの関数をそれぞれ次式に示す。

$$G(x_i^*, x) = \left[ 1 + \frac{(x_i^*)^T x_s}{k} \right]^n \quad (8)$$

$$G(x_i^*, x) = \frac{(x_i^*)^T x_s}{k} \quad (9)$$




Fig.5 Support vector machine given by Eq. (3) after two-class learning.

### 3.2 分類実験

訓練用データセットとして良品 10,000 枚と、5 種類の不良品の画像をそれぞれ 10,000 枚、計 60,000 枚を用意した。図 4 のように前章で保存した訓練済みの CNN である sssNet を特徴抽出器として使用し、ガウスクネル、線形カーネル、多項式カーネルのカーネル関数をそれぞれ用いて 3 種類の SVM の訓練を行った。次に、汎化性能を評価するために未学習の画像を各カテゴリにつき 1,000 枚ずつ、テスト用データセットとして用意した。分






Fig.6 Classification results using the SVM with a gaussian kernel function.

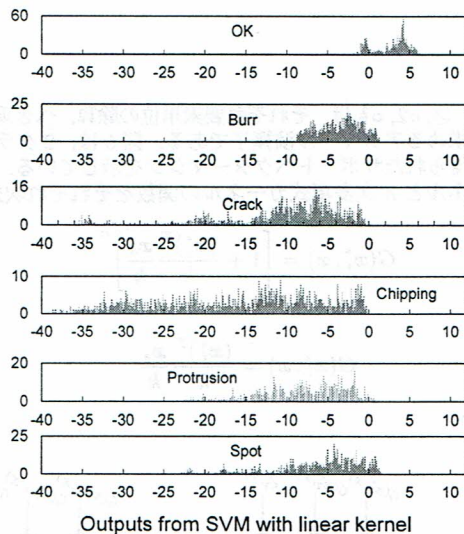


Fig.7 Classification results using the SVM with a linear kernel function.

類実験では1カテゴリずつSVMに分類させ、汎化性能の評価を行った。図6、図7、図8にはそれぞれ、ガウスカーネル、線形カーネル、多項式カーネルの各カーネル関数を用いたSVMによる分類結果を示す。横軸および縦軸はそれぞれ、SVMからの出力値と分類された画像の数を示すヒストグラムである。また、表3、表4、表5にはそれぞれ、ガウスカーネル、線形カーネル、多項式カーネルの各カーネル関数を用いたSVMによる分類の結果、誤認識となった画像の枚数を示している。

#### 4 結言

本研究では、樹脂成型品を模倣した良品と5種類の欠陥が含まれた画像をCNNとSVMにそれぞれ学習させ、どちらが高い識別性能を示すか性能を比較し、評価を行った。誤認識された画像の枚数による比較実験の結果から、CNNよりもSVMの方に高い分類能力があることが確認された。また、3種類のSVMについては、多項式カーネルをカーネル関数として用いたものが最も優れていた。

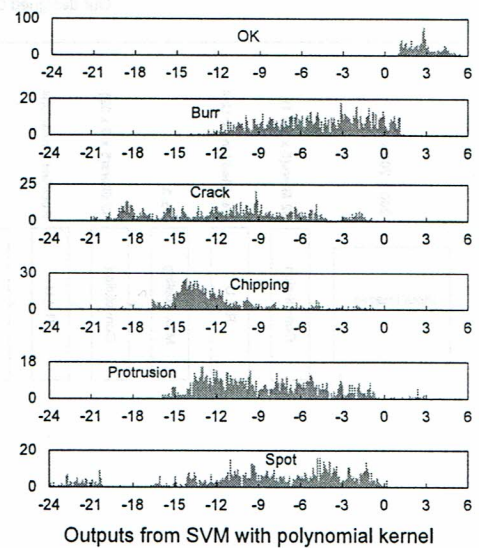


Fig.8 Classification results using the SVM with a 3rd-order polynomial kernel function.

Table 3 Number of images misclassified by SVM whose kernel function is Gaussian.

SVM	Burr	Crack	Chip.	Proto.	Spot
sssNet	100	0	0	17	0

Table 4 Number of images misclassified by SVM whose kernel function is Linear.

SVM	Burr	Crack	Chip.	Proto.	Spot
sssNet	80	0	0	13	92

Table 5 Number of images misclassified by SVM whose kernel function is Polynomial.

SVM	Burr	Crack	Chip.	Proto.	Spot
sssNet	80	0	0	17	5

#### 参考文献

- [1] 多田 拓太郎, 杉浦 彰彦, “多段階型 CNN を用いた自動車用タイヤ内面における欠陥識別,” 電気学会論文誌 C (電子・情報・システム部門誌), pp. 1586–1594 2018
- [2] 西村 晃紀, 柳部 正樹, 吉戸 勇太, 長谷 智紘, 森山 健, 前田 俊二, “HOG 特徴量を電子部品検査に適用した場合の課題検討,” 精密工学会学術講演会講演論文集, pp. 219–220, 2017
- [3] 徳野 健太, 永田 寅臣, 大塚 章正, 渡辺 桂吾, “畳み込みニューラルネットワーク応用した不良品検出の基礎研究,” 日本機械学会九州支部 北九州講演会講演論文集, pp. 35–39, 北九州市立大学ひびきのキャンパス, 2018.
- [4] 徳野 健太, 永田 寅臣, 大塚 章正, 渡辺 桂吾, “Deep Learning 応用した不良品検出の基礎研究,” ロボティクス・メカトロニクス講演会 2018 講演論文集, 2A2-K14(1-3), 北九州国際会議場, 2018.
- [5] Kenta Tokuno, Fusaomi Nagata, Akimasa Otsuka, Keigo Watanabe, Maki K. Habib, “Design Tool of Convolutional Neural Network (CNN)- Design of Cascade-Type CNN and Its Application to Defect Detection,” *Procs. of 24th International Symposium on Artificial Life and Robotics*, pp. 733–737, 2019.