

サポートベクタマシンを用いたラップフィルムの不良品検出 -畳み込みニューラルネットワークを特徴抽出器として用いた場合-

清水 竜樹 (山口東京理科大学工学部機械工学科) 中島 健斗, 三木 康平

永田 寅臣 (山口東京理科大学大学院) 渡辺 桂吾 (岡山大学大学院)

123

Tatsuki Shimizu, Department of Mechanical Engineering, Sanyo-Onoda City University

Kento NAKASHIMA, Kouhei Miki

Fusaomi NAGATA, Graduate School of Engineering Sanyo-Onoda City University, Keigo

WATANABE, Graduate School of Science and Engineering Okayama University

Abstract : This paper proposes a system processed by two-class support vector machine (TCSVM) which can detect defective products that occurs in the wrap film manufacturing. The TCSVM has a feature vector extractor based on pre-trained CNNs such as AlexNet and VGG19. The TCSVM is trained using collected images of normal products and defective products. In addition to the difference between the two CNNs used in the feature extractor, using a Gaussian function or a polynomial function as a kernel function. Furthermore, we examine the exchange regularization parameter C and search for TCSVM that can obtain more accurate results.

1. 緒言

これまでもサポートベクタマシン (SVM) を製品の欠陥検出に応用した研究がある。例えば、西村らは HOG 特徴量を用いて、SVM を電子部品の欠陥検出に使用した場合の課題についての研究を行っている。

本研究では、ラップフィルム品の欠陥検出を行うことができる SVM を提案する。SVM では特徴抽出器から取得した特徴ベクトルの一部をサポートベクタとし、不良品と良品を判別する境界面を作成する。また、境界面を作成するにあたってカーネル法を用いる。実験では、特徴抽出器のほか、カーネル関数と正則化パラメータである C を変更し、より精度の高い分類が可能となる SVM を探索する。特徴抽出器には AlexNet と VGG19 の二通りを用い、カーネル関数にはガウス関数と多項式関数の二通りをそれぞれ組み合わせて 2 クラス分類を行う SVM (TCSVM) を設計する。

図 1 のようなラップフィルム品を良品と不良品に分類した訓練用のデータセットの画像から 4096 次元の特徴ベクトルを抽出し、SVM の学習を行う。その後、未知のデータセットを分類器にかけ、どれほど画像を正しく分類することができたかを評価する。




Fig. 1: Samples of training images with and without defects.

2. 相関係数に基づくマッチング領域の抽出

本章では、治具を含むラップロール品の全体画像に対してテンプレートマッチングを適用し、ラップフィルム部分のみを抽出する画像処理を行う。

様々な課題に対する画像処理で広く利用されているテンプレートマッチングは、撮影されたワークの中で欠陥が含まれやすい領域を抽出するためにも非常に有効である。これから設計する CNN への入力画像のサイズを大幅に減らすことができ、計算コスト、メモリ占有コストを軽減することができる。このため、開発したメイン、オプション及びオーギュメンテーションのダイアログの中ではテンプレートマッチング機能を利用できるようにしている。

さて、 (M, N) のサイズのテンプレートをターゲット画像内でラスタースキャンさせて相関係数の高い位置を検出する場合、周辺領域でもマッチング評価ができるようにパディング処理を行う。テンプレートとパディングにより拡張されたターゲット画像内の同面積の領域との相関係数 $\alpha(u, v)$ は、次式から計算される。

$$\alpha(u, v) = \frac{s_{it}(u, v)}{s_i(u, v)s_t(u, v)} \quad (1)$$

$$s_{it}(u, v) = \sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \{f(x, y) - \bar{f}_{u,v}\} \{t(x-u, y-v) - \bar{t}\} \quad (2)$$

$$s_i(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \{f(x, y) - \bar{f}_{u,v}\}^2} \quad (3)$$

$$s_t(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \{t(x-u, y-v) - \bar{t}\}^2} \quad (4)$$




Fig. 2: An example of extracted image using the template matching technique.

ここで、 (u, v) はターゲット画像内におけるテンプレート左上コーナーの座標である。 $s_t(u, v)$ と $s_i(u, v)$ はそれぞれ、テンプレート内とターゲット内比較領域の標準偏差であり、 $s_{it}(u, v)$ は共分散である。 $f(x, y)$ は拡張された画像内の (x, y) におけるグレースケール 256 階調値を正規化した値である。 $t(x-u, y-v)$ はテンプレート内の $(x-u, y-v)$ における同様の値である。 M と N はそれぞれ、テンプレートの幅と高さである。 \bar{t} と $\bar{f}(u, v)$ はそれぞれ、テンプレート内のグレースケール値の平均値と、ターゲット画像内のテンプレート真下の領域のそれである。式 (1) で与えられる相関係数 $\alpha(u, v)$ は、テンプレートをターゲット画像内の左上から右下までラスタースキャンさせることで計算される。ラスタースキャン後、テンプレートと最もマッチする領域、すなわち最も大きな値 $\alpha(u, v)$ を持つ領域が抽出される。図 2 には、テンプレートで抽出されたラップロール品の画像の例を示している。今回の実験で

は、テンプレートマッチングによりラップロール製品の画像解像度を 640×480 から 347×347 にダウンサイジングした。

3. SVM による欠陥検出

3.1 SVM の設計

筆者らは、プログラミングの知識がなくとも容易に SVM をアプリケーションの開発を行っている。図 3 には、該当アプリケーションの UI の一部を示す。本研究では、このアプリケーションを用いて SVM を設計し、実験を行う。前章で抽出したラップフィルムの画像を良品と不良品に分類し、訓練用データセットを作成した。AlexNet と VGG19 を特徴抽出器として用いた SVM は、以下の図 4, 5 のような構造になる。

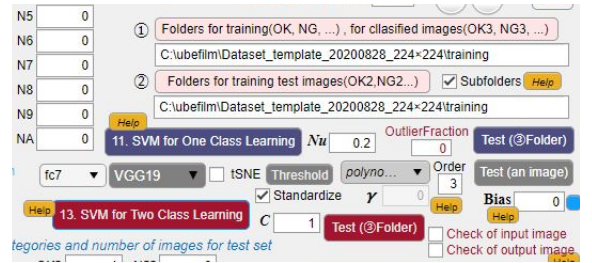


Fig. 3: The application interface for 2-class SVM.

SVM では、特徴抽出器を使用し各入力画像から多次元特徴ベクトル $\mathbf{x} = [x_1, x_2, \dots, x_{4096}]^T$ を抽出する。この特徴ベクトルが SVM の学習に使用され、学習によって $f(\mathbf{x}) = 0$ で与えられる超平面と呼ばれる決定境界が得られる。 $f(\mathbf{x})$ は、これから分類される特徴ベクトル \mathbf{x} から超平面までの符号付き距離であり、次式で与えられる。

$$f(\mathbf{x}) = \sum_{i=1}^N \alpha_i y_i G(\mathbf{x}_i^*, \mathbf{x}) + b \quad (5)$$

ここで、 $G(\mathbf{x}_i^*, \mathbf{x})$ はカーネル関数、 $\mathbf{x}_i^* \in \mathbb{R}^{1 \times N}$ ($i = 1, 2, \dots, N$) は学習により決定されたサポートベクトル、 N はサポートベクトルの数、 α_i ($i = 1, 2, \dots, N$) と b はそれぞれラグランジュ乗数とバイアスであり、これらは学習によって推定された SVM パラメータである。また、 y_i は 2 クラス学習の場合、 \mathbf{x}_i^* の陽性あるいは陰性に依拠して 1 または -1 に設定されたラベルである。分類はスコア $f(\mathbf{x})$ の符号によって行われ、 $f(\mathbf{x}) > 0$ の場合は陽性、 $f(\mathbf{x}) < 0$ の場合は陰性であるといったように判断される。例えば、ガウシアン関数が適用される場合、 $G(\mathbf{x}_i^*, \mathbf{x})$ は次式より与えられる。




Fig. 4: Architecture of TCSVM based AlexNet.

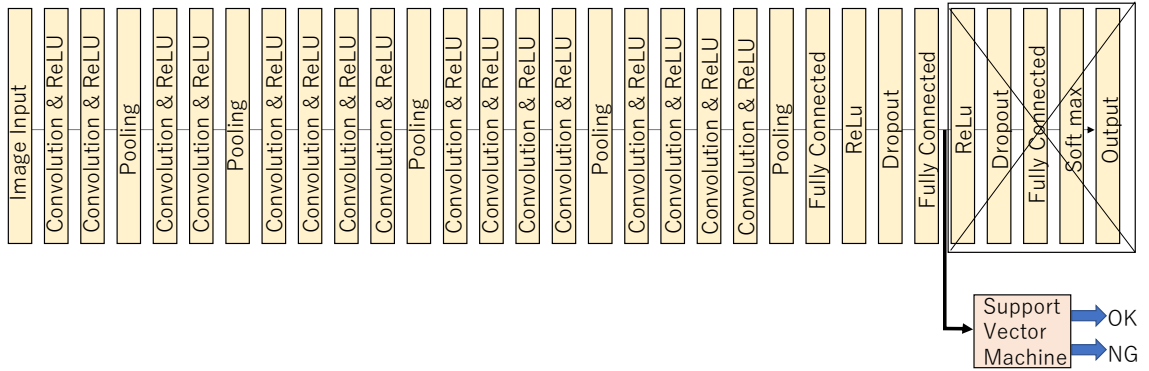


Fig. 5: Architecture of TCSVM based VGG19.

$$G(\mathbf{x}_i^*, \mathbf{x}) = \exp\left(-\left\|\frac{\mathbf{x}_i^* - \mathbf{x}_s}{k}\right\|^2\right) \quad (6)$$

ここで、 k と \mathbf{x}_s はそれぞれのカーネルスケールと、式 (8) と式 (9) を使って得られる標準化入力ベクトルである。

$$\mathbf{x}_s = (\mathbf{x} - \mathbf{x}_\mu) \oslash \mathbf{x}_\sigma \quad (7)$$

$$\mathbf{x}_\mu = \frac{\sum_{j=1}^{36715} \mathbf{x}_j}{36715} \quad (8)$$

$$\mathbf{x}_\sigma = \left[\frac{1}{36715} \sum_{j=1}^{36715} (\mathbf{x}_j - \mathbf{x}_\mu)^{\circ 2} \right]^{\circ \frac{1}{2}} \quad (9)$$

ここで、 \oslash , $\circ 2$, $\circ \frac{1}{2}$ は、それぞれ要素単位の除算、べき乗および平方根を求めるアダマール演算子である。

また、多項式関数が適用される場合は $G(\mathbf{x}_i^*, \mathbf{x})$ は次式になる。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \left[1 + \frac{\mathbf{x}_i^{*\top} \mathbf{x}_s}{k} \right]^n \quad (10)$$

訓練するデータが線形分離可能である場合、SVM は境界面でデータを完全にわけけるハードマージンを行う。しか

し、現実の問題が必ずしも線形分離可能であるとは限らない。そのため、SVM には完全にデータを分離しないことを許容するソフトマージンが適用される。ソフトマージンの最適化問題は最終的に次式のような双対問題として得られることが知られている [1, 2]。

$$\max_{\alpha} -\frac{1}{2} \sum_{i,j \in [n]} \alpha_i \alpha_j y_i y_j G(\mathbf{x}_i^*, \mathbf{x}) + \sum_{i \in [n]} \alpha_i \quad (11)$$

ここで、 α C はボックス制約と呼ばれる正則化係数、…である。実験では特徴抽出器として用いる CNN、カーネル関数、及び C の値を変化させてより優れた分類性能を持つ CNN の設計を試みた。

3.2 分類実験

実験を行うにあたり、AlexNet を特徴抽出器とし、カーネル関数にガウス関数を用いた SVM を AG、AlexNet を特徴抽出器とし、カーネル関数に多項式関数を用いた SVM を AP、VGG19 を特徴抽出器とし、カーネル関数にガウス関数を用いた SVM を VG、VGG19 を特徴抽出器とし、カーネル関数に多項式関数を用いた SVM を VP と名付ける。良品の画像 34482 枚と不良品の画像 2233 枚

を訓練データとして，ラップフィルムの画像をこれらの TCSVM に学習させる．次に汎化性能を評価するために，良品 4035 枚，不良品 21 枚の未学習の画像を用意し，学習終了後に SVM に分類させ汎化性能の評価を行った．このときの分類結果を以下の表 (1) のようにまとめる．表の縦軸が本来のラベルであり，横軸が SVM が予測したラベルである．

Table 1: confusion matrix (row: true labels, column: predicted labels).

	NG	OK
NG	TP	FP
OK	FN	TN

さらに，正則化パラメータ C を変更し訓練を行い，より汎化性能の高い SVM の探索を行った．

4. 結果および考察

以下の表 2，表 3，表 4，表 5 には，AG, AP, VG, VP それぞれの分類結果の混合行列を示す．

Table 2: confusion matrix of AG.

AGC0.5	NG	OK
NG	20	1
OK	2	4033

Table 3: confusion matrix of AP.

APC0.5	NG	OK
NG	20	1
OK	0	4035

Table 4: confusion matrix of VG.

VGC0.5	NG	OK
NG	20	1
OK	5	4030

Table 5: confusion matrix of VP.

VPC1	NG	OK
NG	21	0
OK	4	4031

一般に，学習を行った SVM の性能を検討するさいには評価指標を用いる．今回は不良品を陽性，良品を陰性とし， TP , FP , TN , FN の値を決定した．これらより，性能を比較検討する評価指標として，Accuracy(Ac), Precision(Pr), Recall(Re), F 値 (F) を算出する．各指標は式 12, 13, 14, 15 より求めることができる．

$$Ac = \frac{TP + FP}{TP + FN + FP + TN} \quad (12)$$

$$Pr = \frac{TP}{TP + FP} \quad (13)$$

$$Re = \frac{TP}{TP + FN} \quad (14)$$

$$F = \frac{2 \cdot Re \cdot Pr}{Re + Pr} \quad (15)$$

今回の実験より得られた結果をもとに各評価指標をまとめたものを次の表に示す．AG, AP, VG, VP 全てに関して，

Table 6: comparison.

	AG	AP	VG	VP
Ac	0.999	0.999	0.999	0.999
Pr	0.909	1	0.8	0.84
Re	0.952	0.952	0.952	1
F	0.930	0.976	0.870	0.913

分類実験に使用した画像の枚数が 4056 枚であることを考えると誤認識の枚数は最大が 6 と非常に少なかった．これは Accuracy にも表れており，Accuracy は全ての SVM が高い値を示した．Precision は，陽性と判断した画像が実際に陽性であった割合を示すため，これが高い値を示すということは，本実験の条件においては AlexNet を特徴抽出器とした方が良品を不良品と判断することが少ないということになる．Recall については陽性の画像を陽性と判断できた割合を表す指標である．本実験では，未知の画像として分類にかけることが可能な不良品の画像が多くないため，Recall の値は変動が起きやすく，VP 以外の SVM でも誤認識は 1 枚であるが指標に大きな差が生じた．F 値は Precision と Recall のバランスを示す指標である．

特徴抽出器ごとに指標を比較すると，Precision と F 値という 2 点で AG より AP の方が優れており，VP は VG に Precision, Recall, F 値の 3 点で優れていることがわかる．AP と VP を比較すると，AP は Recall では劣るものの，Precision と F 値では VP より優れているという点から AP の方がより良い性能を有していると結論付けられる．これらより，本実験の条件下では Precision および F 値から，特徴抽出器には VGG19 より AlexNet の方が適しており，多項式関数の方がガウス関数よりカーネル関数にふさわしいと結論付けられる．また，多くの SVM で良品と誤認識された不良品に関して，必ず同じ画像が誤認識されており，訓練のデータセットに類似する不良品が含まれていない可能性が高いと考えられる．そのため，さらに不良品の画像を収集可能になれば，より精度の高い SVM が設計できる可能性がある．

5. 結言

本研究では、ラップフィルム品の欠陥検出を行うことができる SVM について検討した。実験では、特徴抽出器として用いる CNN のほか、カーネル関数と正則化パラメータである C を変更しながら、より精度の高い分類が可能となる SVM を設計した。特徴抽出器には AlexNet と VGG19 の二通りを用い、カーネル関数にはガウス関数と多項式関数の二通りをそれぞれ組み合わせて 2 クラス分類を行う SVM (TCSVM) を設計した。評価実験の結果、本実験の条件下では特徴抽出器には AlexNet を用いた方が VGG19 を用いるより性能が高いことがわかった。また、カーネル関数には多項式関数を用いる方がガウス関数を用いるより性能が高く、正則化係数は 1 以下でソフトマージンで方がより性能を高めることができたことがわかった。

実際の製造ラインにおいて、不良品を良品と誤認識することは重大な問題につながりかねず、一方で良品を不良品と誤認識することは損失につながる。以上の結果から、学習済み CNN を特徴抽出器として SVM を設計することは有効な手段であることが確認でき、本研究では訓練用データ内の不良品の画像と良品の画像の枚数に偏りがあったことから、今後は偏りをなくすことでより高い性能が得られることが期待される。

参考文献

- [1] <https://jp.mathworks.com/>
- [2] 竹内, 鳥山: サポートベクトルマシン, 講談社 (2015)
- [3] F. Nagata, K. Tokuno, K. Mitarai, A. Otsuka, T. Ikeda, H. Ochi, K. Watanabe, M.K. Habib, “Defect detection method using deep convolutional neural network, support vector machine and template matching techniques,” *Artificial Life and Robotics*, Vol. 24, No. 4, pp. 512–519 (2019)