

# サポートベクタマシンを用いたラップフィルムの不良品検出 —畳み込みニューラルネットワークを特徴抽出器として用いた場合—

○清水 竜樹（山口東京理科大学工学部機械工学科），中島 健斗，三木 康平

永田 寅臣（山口東京理科大学大学院工学研究科），渡辺 桂吾（岡山大学大学院自然科学研究科）

## Defect Detection System Using Support Vector Machine for Wrap Film Products

-In Case of Convolutional Neural Network Based Feature Extractor-

○Tatsuki SHIMIZU, Department of Mechanical Engineering, Sanyo-Onoda City University

Kento NAKASHIMA, Kohei MIKI, Fusaomi NAGATA (Graduate School of Engineering,  
Sanyo-Onoda City University)

Keigo WATANABE (Graduate School of Natural Science and Technology, Okayama University)

**Abstract :** This paper proposes a system processed by two-class support vector machine (TCSVM) which can detect defective products occurring in the wrap film manufacturing process. The TCSVM has a feature vector extractor based on pre-trained CNN models such as AlexNet and VGG19. The TCSVM is trained using collected images of normal and defective wrap film products. In training, CNN model as AlexNet or VGG19, Kernel function as Gaussian or polynomial, and regularization parameter C are used for tuning conditions to obtain superior classification performance. Through several comparative experiments based on confusion matrix, the most desirable CNN model is considered.

### 1. 緒言

様々な工業製品の検査工程においては一部で自動化が進んでいるものの、それぞれの製品の品質管理に精通した検査員の目視検査に頼るところが大きい状況である。最近、画像認識に特化した人工知能を製品の欠陥検出に応用しようとする試みがなされており、その中にはサポートベクタマシン（SVM）も含まれている。

これまでも SVM を製品の欠陥検出に応用した研究がある。例えば、西村らは HOG 特徴量を用いて、SVM を電子部品の欠陥検出に使用した場合の課題について研究を行っている [1]。また、Yang らは SIFT 特徴量を用いた SVM により、輸送用パッケージの欠陥検出を試みている [2]。

本研究では、ラップフィルム品の欠陥検出を行うことができる SVM について検討する。SVM では特徴抽出器から取得した特徴ベクトルを用いて学習を行い、不良品と良品を判別する境界面の作成に必要なサポートベクトルを決定する。ベクトルデータの高次元化のためにカーネル法を用いること分類性能を向上できるため、実験では特徴抽出器のほか、カーネル関数と最適化関数に現れる正規化係数を変更し、より精度の高い分類が可能となる SVM を探索する。特徴抽出器には AlexNet あるいは VGG19 を用い、カーネル関数にはガウス関数と多項式関数の二通りをそれぞれ組み合わせて 2 クラス分類を行う SVM (TCSVM) を設計する。




Fig. 1: Samples of training images without and with defects (marked with orange rectangle).

図 1 のような良品と不良品からなるラップフィルム品の訓練用データセットを用意し、それぞれの画像から要素数 4096 の特徴ベクトルを抽出し、SVM の学習を行う。その後、学習後の SVM が未学習のデータセットをどの程度正しく分類できるかを評価する。

### 2. テンプレートマッチングによる目標領域の抽出

本章では、治具を含むラップフィルム品の全体画像に対してテンプレートマッチングを適用し、ラップフィルム




Fig. 2: An example of extracted image using the template matching technique.

部分のみを抽出する画像処理を行う。様々な課題に対する画像処理で広く利用されているテンプレートマッチングは、撮影されたワークの中で欠陥が含まれやすい目標領域を抽出するためにも非常に有効である。これから設計する CNN への入力画像のサイズを大幅に減らすことができ、計算コスト、メモリ占有コストを軽減することができる。このため、開発したメイン、オプション及びオーギュメンテーションのダイアログの中ではテンプレートマッチング機能を利用できるようにしている [3].

テンプレートマッチングの処理では、 $(M, N)$  のサイズのテンプレートをターゲット画像内でラスタースキャンさせて相関係数の高い位置を検出する場合、周辺領域でもマッチング評価ができるようにパディング処理を行う。テンプレートとパディングにより拡張されたターゲット画像内の同面積の領域との相関係数  $\alpha(u, v)$  は、次式から計算される。

$$\alpha(u, v) = \frac{s_{it}(u, v)}{s_i(u, v)s_t(u, v)} \quad (1)$$

$$s_{it}(u, v) =$$

$$\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \left\{ f(x, y) - \bar{f}_{u,v} \right\} \left\{ t(x-u, y-v) - \bar{t} \right\} \quad (2)$$

$$s_i(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \left\{ f(x, y) - \bar{f}_{u,v} \right\}^2} \quad (3)$$

$$s_t(u, v) = \sqrt{\sum_{y=v}^{v+N-1} \sum_{x=u}^{u+M-1} \left\{ t(x-u, y-v) - \bar{t} \right\}^2} \quad (4)$$

ここで、 $(u, v)$  はターゲット画像内におけるテンプレート左上コーナーの座標である。  $s_t(u, v)$  と  $s_i(u, v)$  はそれぞれ、テンプレート内とターゲット内比較領域の標準偏差であり、  $s_{it}(u, v)$  は共分散である。  $f(x, y)$  は拡張された画像内の  $(x, y)$  におけるグレースケール 256 階調値を正

規化した値である。  $t(x-u, y-v)$  はテンプレート内の  $(x-u, y-v)$  における同様の値である。  $M$  と  $N$  はそれぞれ、テンプレートの幅と高さである。  $\bar{t}$  と  $\bar{f}(u, v)$  はそれぞれ、テンプレート内のグレースケール値の平均値と、ターゲット画像内のテンプレート真下の領域のそれである。式 (1) で与えられる相関係数  $\alpha(u, v)$  は、テンプレートをターゲット画像内の左上から右下までラスタースキャンさせることで計算される。ラスタースキャン後、テンプレートと最もマッチする領域、すなわち最も大きな値  $\alpha(u, v)$  を持つ領域が抽出される。図 2 には、テンプレートで抽出されたラップフィルム品の画像の例を示している。今回の実験では、テンプレートマッチングによりラップフィルム品の画像解像度を特徴抽出器として用いる CNN の入力層に適合させやすいように  $640 \times 480$  から正方形の  $347 \times 347$  にダウンサイジングして用いた [4].

### 3. SVM による欠陥検出

#### 3.1 SVM の設計と学習

筆者らは、C++ や Python などのプログラミングの知識がなくとも容易に SVM を設計できるようにアプリケーションを開発している [5]. 図 3 には、アプリケーションの UI の一部を示す。本研究では、このアプリケーションを用いて SVM を設計し、分類評価の実験を行う。前章で抽出した良品と不良品からなるラップフィルムの画像をもとに訓練用データセットを作成した。AlexNet と VGG19 を特徴抽出器として用いた SVM はそれぞれ、図 4, 5 のような構造になる。

SVM では、特徴抽出器を使用し各入力画像から多次元特徴ベクトル  $\mathbf{x} = [x_1, x_2, \dots, x_{4096}]^T$  を抽出する。この特徴ベクトルが SVM の学習に使用され、学習によって  $f(\mathbf{x}) = 0$  で与えられる超平面と呼ばれる決定境界が得られる。  $f(\mathbf{x})$  は、これから分類される特徴ベクトル  $\mathbf{x}$  から

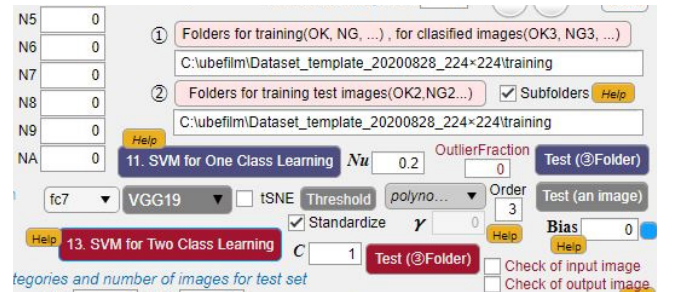


Fig. 3: The application interface for two class SVM.

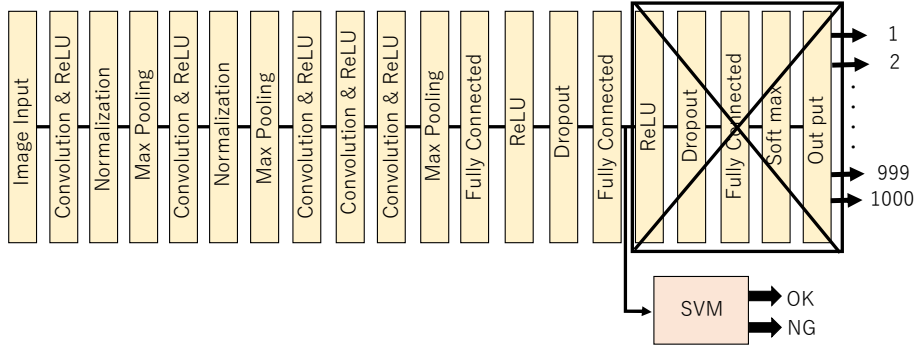


Fig. 4: Architecture of TCSVM based on AlexNet.




Fig. 5: Architecture of TCSVM based on VGG19.

超平面までの符号付き距離であり、次式で与えられる。

$$f(\mathbf{x}) = \sum_{i=1}^N \alpha_i y_i G(\mathbf{x}_i^*, \mathbf{x}) + b \quad (5)$$

ここで、 $G(\mathbf{x}_i^*, \mathbf{x})$  はカーネル関数、 $\mathbf{x}_i^* \in \mathcal{R}^{1 \times N}$  ( $i = 1, 2, \dots, N$ ) は学習により決定されたサポートベクトル、 $N$  はサポートベクトルの数、 $\alpha_i$  ( $i = 1, 2, \dots, N$ ) と  $b$  はそれぞれラグランジュ乗数とバイアスであり、これらは逐次最小最適化 (SMO) を用いた学習によって推定された SVM パラメータである。また、 $y_i$  は 2 クラス学習の場合、 $\mathbf{x}_i^*$  の陽性あるいは陰性に依じて  $-1$  または  $1$  に設定されたラベルである。分類はスコア  $f(\mathbf{x})$  の符号によって行われ、 $f(\mathbf{x}) > 0$  の場合は陰性、 $f(\mathbf{x}) < 0$  の場合は陽性であるといったように判断される。例えば、カーネル関数  $G(\mathbf{x}_i^*, \mathbf{x})$  にガウシアン関数が適用される場合は次式となる。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \exp\left(-\left\|\frac{\mathbf{x}_i^* - \mathbf{x}_s}{k}\right\|^2\right) \quad (6)$$

ここで、 $k$  と  $\mathbf{x}_s$  はそれぞれのカーネルスケールと、式 (7)、式 (8) および式 (9) を使って得られる標準化された入力ベクトルである。

$$\mathbf{x}_s = (\mathbf{x} - \mathbf{x}_\mu) \oslash \mathbf{x}_\sigma \quad (7)$$

$$\mathbf{x}_\mu = \frac{\sum_{j=1}^{36715} \mathbf{x}_j}{36715} \quad (8)$$

$$\mathbf{x}_\sigma = \left[ \frac{1}{36715} \sum_{j=1}^{36715} (\mathbf{x}_j - \mathbf{x}_\mu)^{\circ 2} \right]^{\circ \frac{1}{2}} \quad (9)$$

ここで、36715 は訓練画像の総数であり、 $\oslash$ ,  $\circ 2$ ,  $\circ \frac{1}{2}$  はそれぞれ、要素単位の除算、べき乗および平方根を求めるアダマール演算子である。また、カーネル関数に多項式関数が適用される場合、次式のようになる。

$$G(\mathbf{x}_i^*, \mathbf{x}) = \left[ 1 + \frac{(\mathbf{x}_i^*)^T \mathbf{x}_s}{k} \right]^n \quad (10)$$

訓練するデータが式 (5) の境界面で分離可能である場合、SVM の学習はデータを完全に 2 クラスに分類できるハードマージンによる最適化が可能である。しかし、現実の問題が必ずしも完全に分離可能であるとは限らない。そのため、SVM には完全にデータを分離しないことを許容するソフトマージンによる最適化が適用される。ソフトマージンの最適化問題は最終的に次式のような双対問題として得

られることが知られている [6, 7].

$$\begin{aligned} \max_{\alpha} \quad & -\frac{1}{2} \sum_{i,j \in [n]} \alpha_i \alpha_j y_i y_j G(\mathbf{x}_i^*, \mathbf{x}) + \sum_{i \in [n]} \alpha_i \\ \text{s.t.} \quad & \sum_{i \in [n]} \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i \in [n] \end{aligned} \quad (11)$$

ここで、 $C$  はボックス制約と呼ばれる正則化係数である。式 (11) で与えられる最適化問題を解くことにより、式 (5) を構成する SVM パラメータが決定される。実験では特徴抽出器として用いる CNN、カーネル関数、及び  $C$  の値を変化させてより優れた分類性能を持つ SVM の設計を試みた。

### 3.2 分類実験

評価実験を行うにあたり、AlexNet を特徴抽出器とし、カーネル関数にガウス関数を用いた SVM と多項式関数を用いた SVM をそれぞれ AG, AP, VGG19 を特徴抽出器とし、カーネル関数にガウス関数を用いた SVM と多項式関数を用いた SVM をそれぞれ VG, VP とする。ラップフィルムの良品画像 34482 枚と不良品画像 2233 枚を訓練データとしてこれらの SVM の訓練を行った。さらに、正則化係数  $C$  の値を変更しながら、より汎化性能の高い SVM の探索を行った。汎化性能を評価するために、良品 4035 枚と不良品 21 枚の未学習の画像を用意し、学習終了後の SVM に分類させた。表 1, 2, 3, および 4 には、AG, AP, VG, および VP それぞれの分類結果の混合行列を示す。なお、表内の Actual と Predicted はそれぞれ、実際のラベルと予測されたラベルを表す。AG, AP, VG, および VP 全てに関して、分類実験に使用した画像の枚数が 4056 であることを考えると誤認識の枚数が最大 6 というのは分類性能の高い結果であると言える。

## 4. 評価結果および考察

一般に、学習を行った SVM の性能を検討する際には次式のような評価指標を用いる [8].

$$Ac = \frac{TP + TN}{TP + FN + FP + TN} \quad (12)$$

$$Pr = \frac{TP}{TP + FP} \quad (13)$$

$$Re = \frac{TP}{TP + FN} \quad (14)$$

$$F = \frac{2 \cdot Re \cdot Pr}{Re + Pr} \quad (15)$$

Table 1: Confusion matrix of AG ( $C=0.5$ ).

Act. \ Pred.	Pred.	
	NG	OK
NG	20	1
OK	2	4033

Table 2: Confusion matrix of AP ( $C=0.5$ ).

Act. \ Pred.	Pred.	
	NG	OK
NG	20	1
OK	0	4035

Table 3: Confusion matrix of VG ( $C=0.5$ ).

Act. \ Pred.	Pred.	
	NG	OK
NG	20	1
OK	5	4030

Table 4: Confusion matrix of VP ( $C=1$ ).

Act. \ Pred.	Pred.	
	NG	OK
NG	21	0
OK	4	4031

ここでは不良品を陽性、良品を陰性とし、全体のデータの中で不良品を不良品として分類したものを  $TP$ 、良品を良品として分類したものを  $TN$ 、不良品を良品として分類したものを  $FN$ 、さらに良品を不良品として分類したものを  $FP$  として値を決定した。これらの値から式 (12), (13), (14), および (15) で与えられる Accuracy( $Ac$ ), Precision( $Pr$ ), Recall( $Re$ ), および F 値 ( $F$ ) をそれぞれ算出する。

今回の実験結果をもとにまとめた各評価指標を表 5 に示す。指標の Accuracy は、全ての予測のうち正しく予測できたものはどれだけかを表す指標である。Precision は、陽性と判断した画像が実際に陽性であった割合を示すため、この値が高い場合は不良品を正しく見分けることができているということになる。Recall は、陽性の画像を陽性と判断できた割合を表す指標である。さらに F 値は、Precision と Recall のバランスを示す指標である。

従来、画像認識を応用したラップフィルムの欠陥検出は難しい課題とされてきたが、表 1, 2, 3, 4 に示した SVM の分類結果はどれも性能が高く、これは表 5 の Accuracy の値に表れている。また、Precision に着目すると 0.9 以上

Table 5: Comparison of result.

	AG	AP	VG	VP
$Ac$	0.999	0.999	0.999	0.999
$Pr$	0.909	1	0.8	0.84
$Re$	0.952	0.952	0.952	1
$F$	0.930	0.976	0.870	0.913

の AG と AP の値に対し、VG, VP は 0.9 未満であり、本実験の条件においては AlexNet を特徴抽出器とした SVM の方が良品を不良品と誤判断することが少なかったということになる。さらに、Recall に関しては、未学習の画像として分類にかけることが可能な不良品のテスト画像が少なかったために、Recall の値は変動が起きやすく、VP 以外の SVM でも誤認識は 1 枚であるが指標に大きな差が生じた。

特徴抽出器ごとに指標を比較すると、Precision と F 値という 2 点で AG より AP の方が優れており、VP は VG に Precision, Recall, F 値の 3 点で優れていることがわかる。さらに AP と VP を比較すると、AP は Recall では劣るものの、Precision と F 値では VP より優れているという点から AP の方がより良い性能を有していると推測できる。本実験の条件下では Precision および F 値から、特徴抽出器としては VGG19 より AlexNet の方が適しており、カーネル関数としてはガウス関数より多項式関数の方が適していたと考えられる。また、ある不良品画像は 3 つの SVM で良品と誤認識されており、訓練のデータセットに類似する不良品が含まれていなかった可能性がある。今後、さらに不良品の画像を収集可能になれば、その不良品画像を使った追加学習を行うことでより分類性能の高い SVM を構築できるものと期待される。

## 5. 結言

本研究では、ラップフィルム品の欠陥検出を行うことができる SVM について検討した。実験では、特徴抽出器として用いる CNN、カーネル関数、分離平面の-margin 内のデータに与えるペナルティの程度である正則化係数の値を変更しながら、より分類性能の高い SVM の設計を目指した。特徴抽出器には AlexNet あるいは VGG19 を、カーネル関数にはガウス関数と多項式関数をそれぞれ組み合わせて 2 クラス分類を行う SVM (TCSVM) を設計した。評価実験の結果、今回の条件下では特徴抽出器には AlexNet を、カーネル関数には多項式関数を使用し、正則化係数を 1 以下にすることでより高い分類性能を持つ SVM を設計できた。

実際の製造ラインにおいて不良品が良品と誤認識されることはリコールなど重大な事態につながりかねない。一方、良品が不良品と誤認識されることは生産工程における大きな損失につながる。学習済みの CNN を特徴抽出器とした SVM の設計が可能となっている提案アプリケーションは、不良品検出用の AI 構築に関して有効なツールであることが確認できたため、今後はラップフィルム以外の製品の欠陥検出用 AI の構築にも適用できるのかの検証を行いたい。

## 参考文献

- [1] 西村 晃紀, 柳部 正樹, 青戸 勇太, 長谷 智紘, 森山 健, 前田 俊二, “HOG 特徴量を電子部品検査に適用した場合の課題検討,” 2017 年度精密工学会秋季大会学術講演会講演論文集, pp. 219–220, 2017.
- [2] X. Yang, M. Han, H. Tang, Q. Li, X. Luo, “Detecting Defects With Support Vector Machine in Logistics Packaging Boxes for Edge Computing,” IEEE Access, Vol. 8, pp. 64002–64010, 2020.
- [3] F. Nagata, K. Tokuno, K. Mitarai, A. Otsuka, T. Ikeda, H. Ochi, K. Watanabe, M.K. Habib, “Defect detection method using deep convolutional neural network, support vector machine and template matching techniques,” *Artificial Life and Robotics*, Vol. 24, No. 4, pp. 512–519, 2019.
- [4] 中島 健斗, 永田 寅臣, 渡辺 桂吾, “畳み込みニューラルネットワークを用いたラップロール製品の不良品検出,” 第 36 回ファジィシステムシンポジウム 論文集, MC2-4, 5 pages, 2020.
- [5] 中島 健斗, 永田 寅臣, 渡辺 桂吾, “畳み込みニューラルネットワーク (CNN) とサポートベクターマシン (SVM) を用いた微小な欠陥を持つ不良品検出の基礎研究,” ロボティクス・メカトロニクス講演会 2019 講演論文集, 2A1-Q05, 4 pages, 広島国際会議場, 2019.
- [6] MATLAB, “<https://jp.mathworks.com/>”
- [7] 竹内 一郎, 鳥山 昌幸, “サポートベクトルマシン,” 講談社, 2015.
- [8] 中川 裕志, “東京大学工学教程 情報工学 機械学習,” 丸善出版, 2015