

欠陥検出のための CNN & SVM 設計支援ツールの開発と適用実験 - 2 クラス分類用の SVM の場合 -

清水 竜樹† 三木 康平† 中島 健斗† 永田 寅臣† 渡辺 桂吾‡

† 山口東京理科大学大学院 工学研究科 ‡ 岡山大学学術研究院 自然科学学域

E-mail: nagata@rs.socu.ac.jp

1 はじめに

筆者らは、プログラム開発や画像処理の初心者であっても高性能な不良品検出用 AI をカスタマイズしながら設計できるように CNN&SVM 設計支援ツールを開発している。これにより、CNN, SVM といった分類器に対して転移学習、追加学習などの学習アルゴリズムを適用し、静止画や動画に含まれる工業製品の欠陥を検出するためのシステム構築の支援が可能になってきた [1]。本報では、2 クラス分類用の SVM の設計と、ラップフィルム製品の欠陥検出への適用実験の結果について報告する。

2 CNN & SVM 設計支援ツール

開発は機械学習関連の安定した関数群が提供されている MATLAB 上で行った。このツールは、画像オーギュメンテーションダイアログ、メインダイアログ、パラメータダイアログ、オプションダイアログ、カメラ設定ダイアログ、TCP/IP 通信ダイアログなどから構成されている。ここでは例として、2 クラス学習による SVM の設計とラップフィルム製品の欠陥検出への応用例を紹介する。

図 1 に示す CNN&SVM 設計ツールのメインダイアログでは、様々な CNN を特徴抽出器として用いる SVM の設計を可能にしている。また、良品 1 クラスのみの画像データで学習を行う教師なし学習と、良品と不良品の 2 クラスの画像データで学習を行う教師あり学習を選択できるようにしている。本研究では、2 クラスの画像データで学習を行う 2 クラス分類 SVM の訓練を行い、その分類性能を評価する。2 クラス分類 SVM を設計するにあたり、本アプリケーションでは特徴抽出器とする CNN、カーネル関数、正則化係数などの変更が可能となっている。2 クラスの分類を行うことができる SVM の学習では、様々なシステムでその性能が認知されているシリーズネットワークの AlexNet[2], VGG16, VGG19[3], DAG ネットワークである GoogLeNet, Inception-V3, IncResNet-V2 に加えて、具体的な分類対象である製品の画像をもとにオリジナルで設計した CNN (sssNet) を

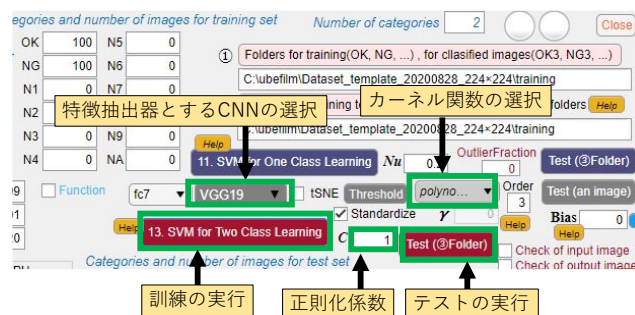


図 1 2 クラス分類 SVM の設計及び訓練用メインダイアログ

特徴抽出器として選択できるようにしている。すなわち、公開されているパワフルな学習済み CNN を特徴抽出器として選択できるだけでなく、分類の対象となる製品画像をもとに事前に学習を行わせた CNN モデルも特徴抽出器として選択できることで、より分類性能の高い 2 クラス分類用 SVM の設計を可能としている。

3 ラップフィルムの欠陥検出のための 2 クラス分類用 SVM の設計例

3.1 SVM の設計と訓練

ここでは例として、ImageNet の画像を使って 1000 カテゴリの分類に特化した学習済み CNN モデルである AlexNet と VGG19 を特徴抽出器とし、ラップフィルム製品の良品と不良品を分類可能な SVM の構築を目標とする。特徴抽出器として用いた AlexNet, VGG19 と SVM の構成は、図 2 および 3 のようになる。また、学習後の SVM は次式で与えられ、図 4 にはその構造を示す。

$$f(x) = \sum_{i=1}^N \alpha_i y_i G(x_i^*, x) + b \quad (1)$$

ここで、 $x \in \mathbb{R}^{4096}$ は特徴抽出器である CNN から出力された特徴ベクトルであり SVM への入力となる。 $x_i^* \in \mathbb{R}^{4096}$ ($i = 1, 2, \dots, N$) と N はそれぞれ、学習過程で

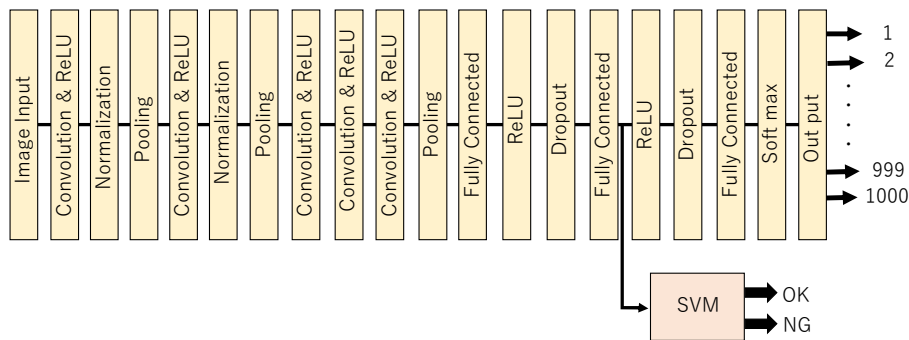


図 2 AlexNet を特徴抽出器とした 2 クラス分類 SVM の構造

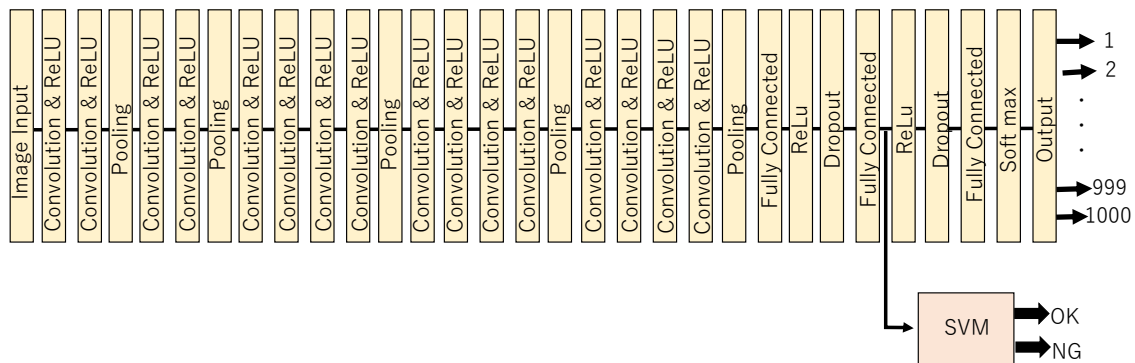


図 3 VGG19 を特徴抽出器とした 2 クラス分類 SVM の構造




図 4 学習後の SVM の構造 [4].

得られたサポートベクトルとその数である． α_i ($i = 1, 2, \dots, N$) と b はそれぞれ，ラグランジュ乗数とバイアスである [5]． y_i はラベルであり，2 クラス学習の場合は 1 あるいは -1 がセットされる． $G(x_i^*, x)$ は高次元化のためのカーネル関数であり，今回はガウス関数と多項式関数を用いた [6]．

式 (1) は次式で与えられる 2 クラス学習による SVM の双対問題を解くことで得られる．

$$\min_{\alpha_1, \dots, \alpha_n} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j G(x_i, x_j) - \sum_{i=1}^n \alpha_i \quad (2)$$

$$\text{s.t. } 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^n y_i \alpha_i = 0 \quad (3)$$

ただし， n は訓練データ数である．なお，式 (3) の不等号制約は矩形制約 (box constraint) と呼ばれる．SVM の訓練で生じる式 (2) のような 2 次計画問題 (QP) を解くためのアルゴリズムとして MATLAB では逐次最小問題最適化法 (Sequential Minimal Optimization, SMO) を用いることができる [7]．

図 5 のような良品と不良品からなる画像データセットを用意し，AlexNet あるいは VGG19 を用いて訓練画像から特徴ベクトルを抽出し，二つの SVM の学習を行う．その後，学習後の SVM が未学習のデータセットをどの程度正しく分類することができるかを評価する．また，メインダイアログを通じて特徴抽出器として使用する CNN のほか，カーネル関数，正則化係数 C を簡単に選択，調整できるようにしているため，正則化係数を変化させるなど，より分類性能の高い SVM の作成を試みる．なお，評価実験では AlexNet を特徴抽出器とし，カーネル関数にガウス関数を用いた SVM と多項式関数を用いた SVM をそれぞれ AG, AP とし，VGG19 を特徴抽出器とし，カーネル関数にガウス関数を用いた SVM と多項式関数を用いた SVM をそれぞれ VG, VP とする．

訓練画像のデータセットとして，良品画像 34,482 枚




図5 良品画像と不良品画像の一例（長方形で囲まれた箇所が欠陥部分）

を用意した。しかしながら、不良品画像は良品と比較して採集することが困難であったため、画像オーギュメントダイアログを使って不良品画像のみ水平反転により拡張を行った。画像オーギュメンテーションには様々な方法が考えられるが、今回の製品は生産ライン上に固定したカメラである程度規則正しく撮影されるため、上下が反転した状態でライン上に存在することはなく、また治具に固定されているためワークの姿勢が変化（回転）することもあり得ない。以上の理由から水平反転のみを行い、不良品画像を2,233枚に増やして訓練画像とした。AG, AP, VG および VP の学習はそれぞれ、正則化係数の値を変化させながら行った。

3.2 分類実験と考察

学習後の SVM の汎化性能を評価するために、良品4,035枚と不良品42枚の未学習の画像を用意し、分類させた。不良品のテスト用画像は訓練用画像と同様に採集が困難であり、製品メーカーからの提供が21枚しかなかったため、左右反転を行うことで画像枚数を増加させている。AG, AP, VG, VP についてそれぞれ、複数の正則化係数を試行しながら学習させた結果、テスト画像に対して最も高い分類性能を示した評価結果を表1, 2, 3 および 4 に示す。これらの結果から表2のように特徴抽出器に AlexNet, カーネル関数に多項式関数, 正則化係数0.5 のときに最も誤分類枚数が少ない結果が得られた。

一般に、学習後の SVM の性能を評価する際には次式のような評価指標が用いられる [8]。

$$Ac = \frac{TP + TN}{TP + FN + FP + TN} \quad (4)$$

$$Pr = \frac{TP}{TP + FP} \quad (5)$$

$$Re = \frac{TP}{TP + FN} \quad (6)$$

表1 AG による分類結果 ($C = 0.5$)

Pred. \ Act.	NG	OK
NG	40	2
OK	2	4033

表2 AP による分類結果 ($C = 0.5$)

Pred. \ Act.	NG	OK
NG	40	0
OK	2	4035

表3 VG による分類結果 ($C = 0.5$)

Pred. \ Act.	NG	OK
NG	39	5
OK	3	4030

表4 VP による分類結果 ($C = 1$)

Pred. \ Act.	NG	OK
NG	41	4
OK	1	4031

表5 評価指標の算出結果と比較。

	AG	AP	VG	VP
Ac	0.9990	0.9995	0.9980	0.9988
Pr	0.9524	1.0000	0.8864	0.9111
Re	0.9524	0.9524	0.9286	0.9762

ここでは不良品を陽性、良品を陰性とし、全体のデータの中で不良品を不良品として分類したものを TP 、良品を良品として分類したものを TN 、不良品を良品として分類したものを FN 、さらに良品を不良品として分類したものを FP として値を決定した。これらの値から式 (4), (5) および (6) で与えられる Accuracy(Ac), Precision(Pr), Recall(Re) をそれぞれ算出する。表1, 2, 3 および 4 の分類結果をもとに算出した各評価指標を表5に示す。表5より、全ての SVM で製品メーカーが要求する目標認識率0.95以上を達成できていたことが確認できる。なお、不良品を良品として市場に誤出荷することは大きな問題となるため、Recall(Re) の数値が重要視されることとなり、 Re の値からは VP が最も優れていたといえる。

以上の評価結果から、Accuracy(Ac) では AP が、また、Recall(Re) では VP が最も優れていたことが分かる。

3.3 前向き計算に要する時間

ところで、設計した SVM に関して実際の生産ラインでの使用を考慮すれば、分類の実行にかかる時間がより少ないことが望まれる。そこで、図2と図3に示した構造を持つ訓練後の二つの SVM (AP および VP) に対して、CNN への画像入力から SVM からの分類結果出力までに要した時間を計測し、表6に示した。使用し

表 6 分類に要した時間 .

	AG	VP
1 回目	0.0445	0.0682
2 回目	0.0580	0.0713
3 回目	0.0596	0.0714
4 回目	0.0552	0.0719
5 回目	0.0611	0.0675
平均	0.0557	0.0701

たコンピュータは、CPU: Intel Core i9-10980XE 3.00 GHz、メモリ: 64 GB、GPU: NVIDIA TITAN RTX 24 GB である。以上の結果から、AlexNet を特徴抽出器とした SVM で 56 ms 程度、VGG を特徴抽出器とした SVM で 70 ms 程度を要していたことが確認できた。これらの値は、現状の生産ラインへの適用を図る上でも十分な速度であると推測される。

4 おわりに

本稿では開発中の CNN&SVM 設計支援ツールについてメインダイアログを中心に、製品に応じた画像オーギュメンテーション、特徴抽出器として使用する CNN の選択、汎化性を高めるための正則化係数の調整などを簡単に実行できることを確認し、実際のラップフィルム製品の画像を使用した SVM の訓練と分類実験によりその有用性を確認した。今後は、自動車エンジン部品とバッテリー電極材料の欠陥検出、鋼種鑑別のための火花試験の評価への応用についても CNN&SVM 設計支援ツールの適用を検討していく予定である。

また、今回設計した SVM はどれも高い認識精度を得ることができたものの、一つの閾値による完全な 2 クラス分類が可能ではないことがわかった。そこで、実ラインへの適用段階では複数の SVM の判定結果を融合させて良でも不良でもない中間的なグレーな状態を出力させることも有効と思われるため、今後はそういった SVM の構築と性能評価も行いたい。

参考文献

[1] 永田 寅臣, 渡辺 桂吾, “不良品検出のための畳み込みニューラルネットワークとサポートベクトルマシン設計支援ツール”, システム / 制御 / 情報, Vol. 64, No. 8, pp. 304–309, 2020.

[2] Krizhevsky A, Sutskever I, Hinton GE, “Imagenet Classification with Deep Convolutionalneural Networks.” *Procs. of Advances in Neural Information Processing Systems*, pp. 1097–1105, 2012.

[3] Simonyan K, Zisserman A, “Very Deep Convolutional Networks for Large-scale Image Recognition,” *Procs. of International Conference on*

Learning Representations 2015 (ICLR2015), 14 pages, 2015.

[4] 中島 健斗, 永田 寅臣, 渡辺 桂吾, “畳み込みニューラルネットワーク (CNN) とサポートベクトルマシン (SVM) を用いた微小な欠陥を持つ不良品検出の基礎研究”, ロボティクス・メカトロニクス講演会 2019 講演論文集, 2A1-Q05, 4 pages, 広島国際会議場, 2019.

[5] 竹内 一郎, 鳥山 昌幸, “サポートベクトルマシン”, 講談社, 2015.

[6] Christianini, N., and J. C. Shawe-Taylor, “An Introduction to Support Vector Machines and Other Kernel-Based Learning Methods,” Cambridge, UK: Cambridge University Press, 2000.

[7] J. Platt, “Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines,” *Technical Report MSR-TR-98-14*, pp. 1–24, 1998.

[8] 中川 裕志, “東京大学工学教程 情報工学 機械学習”, 丸善出版, 2015.