

CNN, CAE および SVM の設計と評価のための支援ツールの開発 - Grad-CAM による機械部品の欠陥部分の可視化を改善する一手法 -

Development of Design and Evaluation Tool for CNN, CAE and SVM

- Image Processing to Improve Visualization Function of Defect Areas Included in Mechanical Parts Using Grad-CAM -

○¹ 清水 竜樹 ¹ 永田 寅臣 ¹ 有馬 滉宜 ¹ 三木 康平
² 阿部 凌真 ² 吉岡 琢人 ² 加藤 博久 ³ 渡辺 桂吾
 ○¹ Tatsuki SHIMIZU ¹ Fusaomi NAGATA ¹ Koki ARIMA ¹ Kohei MIKI
² Ryoma ABE ² Takuto YOSHIOKA ² Hirohisa KATO ³ Keigo WATANABE
¹ 山口東京理科大学大学院工学研究科
² 山口東京理科大学工学部機械工学科
³ 岡山大学大学院自然科学研究科

¹ Graduate School of Science and Engineering, Sanyo-Onoda City University

² Department of Mechanical Engineering, Faculty of Engineering, Sanyo-Onoda City University

³ Graduate School of Natural Science and Technology, Okayama University

Abstract: The authors have been developing a design, training and evaluation application with a user-friendly operation interface for CNN (Convolutional Neural Network), CAE (Convolutional Auto Encoder) and SVM (Support Vector Machine), which can be used for the defect detection of various kinds of industrial products even without deep skills and knowledges concerning information technology. When the Grad-CAM is applied to visualizing interested areas affecting the classification results, different areas not relating to target defects are sometimes mapped majestically. In this presentation, the visualization performance of defect areas using the Grad-CAM is tried to be improved. Before learning process, all images in training data set are preprocessed by a proposed masking method, in which not-interested areas in each image are replaced with randomly generated mask patterns. The effectiveness and promise are observed through visualization tests of defect areas using the Grad-CAM.

1 緒言

様々な工業製品の検査工程においては一部で自動化が進んでいるものの、それぞれの製品の品質管理に精通した検査員の目視検査に頼るところが大きい状況である。最近、深層学習の技術を画像認識に特化させた CNN(Convolutional Neural Network) を製品の欠陥検出に応用しようとする試みが活発に行われている。筆者らは製造業が抱える目視による品質検査に関する課題を解決するために、熟練した検査作業者と同等以上の不良品の識別能力を有する CNN, CAE(Convolutional Auto Encoder), SVM(Support Vector Machine) などの設計、訓練および評価を効率的に支援できるアプリケーションの開発を行っている [1]。

地元の製造メーカーからの要望として、不良品の根拠となった部分の可視化機能があったため、訓練後の CNN にテスト画像が入力された際に生成される特徴マップの中からより活性度の高いものを選択し、それらを重ねて表示させた後に元画像と比較表示できるようにしていたが、ラッピングフィルムなど工業製品の種類によっては不鮮明な可視化しかできていなかった [2]。最近では MATLAB 環境においても勾配加重クラス活性化マッピング (Gradient-weighted Class Activation Mapping: Grad-CAM) [3] の

機能が提供されており、不良品と判定された場合の欠陥部分の可視化への応用が期待されているが、例えば製品によって生じた影など、欠陥以外のところもマッピングされてしまうことがあった。

自動化ラインで安定的に製造される工業製品の場合は不良品の発生頻度が非常に低いことが多いため、欠陥が含まれた画像を蓄積していくことが容易ではなく、結果的に学習に必要な十分な量のデータセットを準備できないことがある。このため、画像オーギュメンテーションにより画像データを増やすことが必要となる。物体検出に関する研究では、例えば、Hao らがコピー&ペーストを使用して訓練データセットを増やすことで検出の精度を高める方法を提案している [4]。また、Dvornik らは複数の物体の背景を適切に合成するモデリング法を用いて、各物体の検出とラベル化の精度を高める方法を提案している [5]。

本研究では大量生産されている一つの機械部品を例として取り上げ、欠陥が含まれることのない領域に対してランダムなマスク画像を埋め込む画像処理を施すことで Grad-CAM による可視化機能の改善を試みたので報告する。

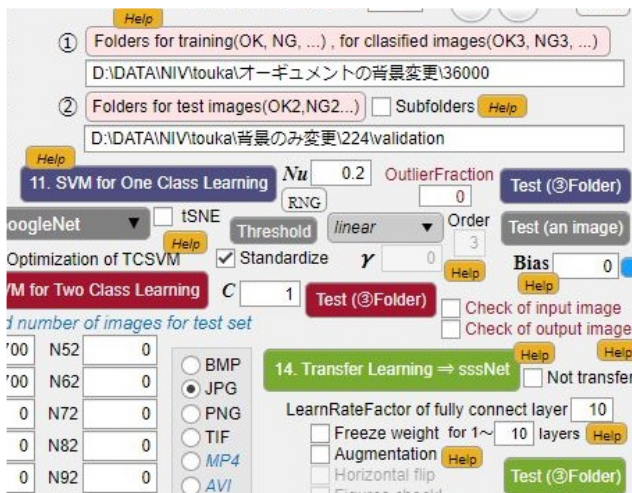


Fig. 1: A part of main dialogue developed on MATLAB system to user-friendly design artificial intelligence systems.

2 CNN, CAE & SVM 設計支援ツール

CNN, CAE & SVM 設計支援ツールの開発は、機械学習や画像処理に関する最新の関数群が安定的に提供されている MATLAB 上で行った。図 1 には開発したツールのメイン画面の一部を示す。このツールは、画像オーギュメンテーションダイアログ、メインダイアログ、パラメータダイアログ、オプションダイアログ、カメラ設定ダイアログ、TCP/IP 通信設定ダイアログなどから構成されている。開発したツールは、これまでに公開されその性能が認知されている様々な学習済みの CNN を転移学習させることが可能となっていることに加えて、オリジナルで設計した CNN(sssNet) の学習機能も選択できるようにしている。さらに、1 クラス学習による CAE, SVM の設計も可能になっている。

3 CNN を用いた工業製品の欠陥検出の例

本研究では図 2 のような工業製品の良品および不良品画像をそれぞれ 100 枚ずつ準備し、実験に用いる。まず、この 200 枚の画像を訓練データセット A とする。次に、これらを一般的なオーギュメンテーションによって増やした、良品と不良品の画像それぞれ 600 枚からなる計 1200 枚の画像を訓練データセット B とする。データセット A に対して行ったオーギュメンテーションは、水平反転、垂直反転、90 度回転、270 度回転、180 度回転の 6 つの処理である。また、訓練後の CNN の性能評価には、データセット A, B には含まれていなかった良品 20 枚、不良品 10 枚の画像を用いる。なお、本研究で取り扱う工業製




Fig. 2: Samples of training images without and with defects marked with red rectangles. Note that the centers are hidden due to the obligation of confidentiality of a cooperative company

品の画像の中央部には企業との守秘義務により公開できない情報が含まれているため、本稿中では図 2 のようなオレンジ色でハイディング処理をした上で紹介している。

転移学習には 2014 年の ILSVRC で優勝した有向非循環グラフ (DAG) 構造を持つ CNN である GoogLeNet [6] を用い、以降、訓練データセット A, B をそれぞれ用いて訓練した CNN を GNA, および GNB とする。

3.1 オリジナル画像による転移学習と評価

オリジナル画像 200 枚を用いた GNA の学習では、最大エポックを 1000、ミニバッチサイズを 40、学習率を 0.0001 などの条件に設定して訓練を開始したところ、111 エポックで訓練データセットに対する認識率が 100% に達したため、そこで学習を終了させた。表 1 には、訓練後の GNA に 30 枚のテスト画像の分類を行わせた結果を示す。GNA が良品画像を不良品画像として誤認識した枚数は 3 であり、オリジナル画像のみを用いた学習でもある程度の汎化性能を獲得できていることがわかる。

Table 1: Confusion matrix classified by GNA (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	17	0
Anomaly	3	10

3.2 オーギュメント画像による転移学習と評価

データセット A に対し一般的な画像オーギュメンテーションを行い、1200 枚まで画像を増やしたデータセット B を使用して GNB を訓練した。表 2 には訓練後の GNB による

Table 2: Confusion matrix classified by GNB (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	20	0
Anomaly	0	10

前節と同じ未学習画像 30 枚の分類結果を示す. GNB はテストに使用した画像を全て正しく分類できており, GNA と比較して分類性能を改善できていることがわかる. 以上の結果から今回取り上げた機械部品の欠陥検出においても画像オーギュメンテーションの有効性が確認された. 次節では, これら GNA と GNB に対して Grad-CAM を適用し, 欠陥部分の可視化と評価を行う.

3.3 Grad-CAM による欠陥箇所の可視化

次に, GNA や GNB のような CNN を欠陥検出システムに応用した場合, 欠陥が含まれている画像と判定された根拠となる箇所の可視化機能について検討した. 今回は, MATLAB 上で開発するアプリケーションにも実装が可能な Grad-CAM を適用することとした. Grad-CAM を用いて CNN が分類のために注視している箇所をカラーマップで表示させ, 欠陥と判定した根拠となった領域の可視化を試みる. Grad-CAM は, 勾配を用いてクラス分類を行う際に重要なピクセルを可視化する技術である. まず CNN を通してクラス分類を行い, その際に得られる畳み込み層の出力とクラス分類の結果を得る. このクラス分類の後に誤差逆伝搬を行い, 畳み込み層の各要素に対する出力の勾配を計算する. 次にそれぞれの畳み込み層の勾配の平均を求め, 全ての畳み込み層を加算することで畳み込み層の活性化を可視化することが可能になっている [3]. Grad-CAM を用いることでラベル判定の根拠となった領域がカラーマップで表示されるようになっており, 予測に強い影響を与えた領域ほど赤くマッピングされる.

図 3 と図 4 にはそれぞれ, GNA と GNB を使って不良品のテスト画像を分類した際, その根拠となった領域を Grad-CAM により可視化したものである. 図 3 では欠陥を含まない領域が赤くマッピングされており, また, 図 4 では全体が同じ色で染まっており, 不良品の画像として正しく判定されていてもその根拠となる箇所を可視化しているとは言えなかった. 以上の結果から, GNA と GNB はどちらも不良品と正しく分類できてはいるものの, 欠陥箇所を明確に特定できておらず, 本来注目すべき欠陥以外の要素を基に不良品と分類していたものと思われる.




Fig. 3: Visualization result of defect area obtained by applying Grad-CAM to GNA.




Fig. 4: Visualization result of defect area obtained by applying Grad-CAM to GNB.

4 ランダムマスキングによる画像オーギュメンテーション

4.1 ランダムマスキングによる画像拡張の一提案

前章の結果から, 今回取り上げた機械部品の場合, 従来のオーギュメンテーションにより拡張した画像データセットを用いた訓練で得られた CNN は, 未学習データに対する分類性能を改善できたものの, 欠陥箇所の可視化の機能は不十分であった. そこで本章では, オリジナル画像を 1 度ずつ 360 度まで回転させ, さらに対象となる機械部品の背景をランダムに合成する新たな拡張法を適用し, 画像データセット C として準備後, 訓練に用いる.

具体的な画像処理の方法は次のとおりである. まず, 本研究で対象としている製品は円形であり, それぞれの形状に変化はない. また欠陥は傷や抉れなどであり, 製品の表面にのみ表れていることが観察できる. これらの特徴から, 細かな角度で回転させながらオーギュメントできると考えた. オリジナル画像であるデータセット A にマスク処理を行い, 製品以外の背景部分を黒く塗りつぶした後に画像を 1 度ずつ回転させることで, 1 枚のオリジナル画像から 360 枚の画像を新たに生成させた. また, 物体検出の精度向上に関する研究では, 同じ物体に対して




Fig. 5: Examples of training images without and with defects marked with red rectangles, in which proposed image augmentation using random masking method is applied.

背景を変更したデータセットを訓練に用いることで精度を向上させた報告がある [7]. 本研究でも画像内の機械部品以外の背景を変更し、背景に多様性を持たせたデータセットを訓練に用いることで欠陥検出の精度向上が図れるのではないかと考えた. 以上のことから, 360 倍の枚数に増やした画像データセットに対し, さらに背景をランダムに合成して多様性を持たせる方法も採用した. これらの処理をデータセット A 全ての画像に施すことにより, 良品と不良品をそれぞれ 36,000 枚にまで増やすことができた. 図 5 には提案する画像拡張後のデータセット C に含まれる画像の一例を示す. 以降, データセット C を使用し, GNA, GNB と同様の条件で訓練を行った GoogLeNet ベースの CNN を GNC とする.

4.2 ランダムマスキング画像で訓練を行った CNN の性能評価

表 3 に GNC でテストデータセットを分類した結果の混同行列を示す. なお, このテストデータセットは GNA, GNB と同様であり, データセット C には含まれていない画像で構成されている. 表 3 から, GNC はテストデータセットを完全に分類できていることがわかる. これは, GNC が製品部分のみを捉えて分類を行っていることを示唆しており, GNC は高い汎化性を得られたと考えられる.

4.3 Grad-CAM による欠陥箇所の可視化

GNA, GNB と同様, GNC に Grad-CAM を適用し, 欠陥箇所を可視化した結果を図 6 に示す. 図 6 より, GNA, GNB に適用した場合に比べて欠陥を含む領域を赤くマッピングできており, 製品以外の箇所は活性化していない

Table 3: Confusion matrix classified by GNC (row: predicted labels, column: true labels).

	Normal	Anomaly
Normal	20	0
Anomaly	0	10




Fig. 6: An example of visualization result obtained by applying Grad-CAM to GNC.

ことがわかる. 以上の結果から, GNC は GNA, GNB と比較してより製品のみを捉え, さらに欠陥箇所を認識したうえで不良品と判定できていたことが確認できる.

5 結言

本研究では, 開発中の CNN, CAE&SVM 設計アプリケーションを用いて GoogLeNet の転移学習による新たな CNN を設計し, 機械部品の欠陥検出に応用した. また, Grad-CAM を用いて欠陥箇所の可視化性能を評価した. オリジナル画像, あるいは従来の画像オーギュメンテーションにより拡張した画像を用いた訓練で得られた CNN の場合, テスト画像の分類性能は十分であったが, Grad-CAM による欠陥箇所の特定には問題があった.

本研究で取り上げた工業製品の場合, 円形の検査対象部分を細かな分解能で 360 度まで回転させながら, 同時に背景を任意画像でランダムにマスキングすることで多様性を持ったデータセットの構築を試みた. このデータセットを用いた訓練で得られた CNN によりテスト画像を評価したところ, 高い分類性能を維持しながら, Grad-CAM による欠陥部分の可視化性能を改善することができた.

今後は, 提案手法を他の工業製品の検査工程にも適用しながら, 高い分類性能と欠陥部分の可視化機能を持った AI システムの検討を行っていきたい.

参考文献

- [1] 永田, 渡辺, 不良品検出のための畳み込みニューラルネットワークとサポートベクタマシン設計支援ツ

- ル, システム/制御/情報, Vol. 64, No. 8, pp. 304–309, 2020.
- [2] 中島, 永田, 渡辺, 畳み込みニューラルネットワークを用いたラップロール製品の不良品検出, 第 36 回ファジィシステムシンポジウム FSS2020 講演論文集, pp. 111–115, 2020.
- [3] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,” *Procs. of the IEEE Conference on International Conference on Computer Vision (ICCV)*, pp. 618–626, 2017.
- [4] H. Fang, J. Sun, R. Wang, MinghaoGou, Y. Li, and C. Lu, “Instaboost: Boosting Instance Segmentation via Probability Map Guided Copy-pasting,” *Procs. of the IEEE Conference on International Conference on Computer Vision (ICCV)*, pp. 682–691, 2019.
- [5] N. Dvornik, J. Mairal, and C. Schmid, “Modeling Visual Context is Key to Augmenting Object Detection Datasets,” *Procs. of the IEEE Conference on IEEE European Conference on Computer Vision (ECCV)*, pp. 375–391, 2018.
- [6] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, “Going Deeper With Convolutions,” *Procs. of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1–9, 2015.
- [7] D. Dwibedi, I. Misra, and M. Hebert, “Cut, Paste and Learn: Surprisingly Easy Synthesis for Instance Detection,” *Procs. of the IEEE Conference on International Conference on Computer Vision (ICCV)*, pp. 1301–1310, 2017.